LIVE • 90 MIN

Distributions → décisions → pipeline

Lire la forme, questionner les données, suivre chaque transformation

---

Observer → questionner → coder → expliquer

Aujourd'hui : six pauses pour raisonner

Un rythme de séance visible : notions courtes, pauses, mise en commun

01

Comparer

centre et dispersion

02

Modéliser

forme et mécanisme

03

Échantillonner

size et seed

04

Tracer

pipeline et décisions

PAUSE • EXERCICE 1

3 MIN

Même moyenne : même histoire ?

A = [3, 3, 5, 5] • B = [1, 1, 7, 7] • mean = 4

1

Dessinez les deux lots sur une ligne.

2

Nommez une différence que la moyenne cache.

3

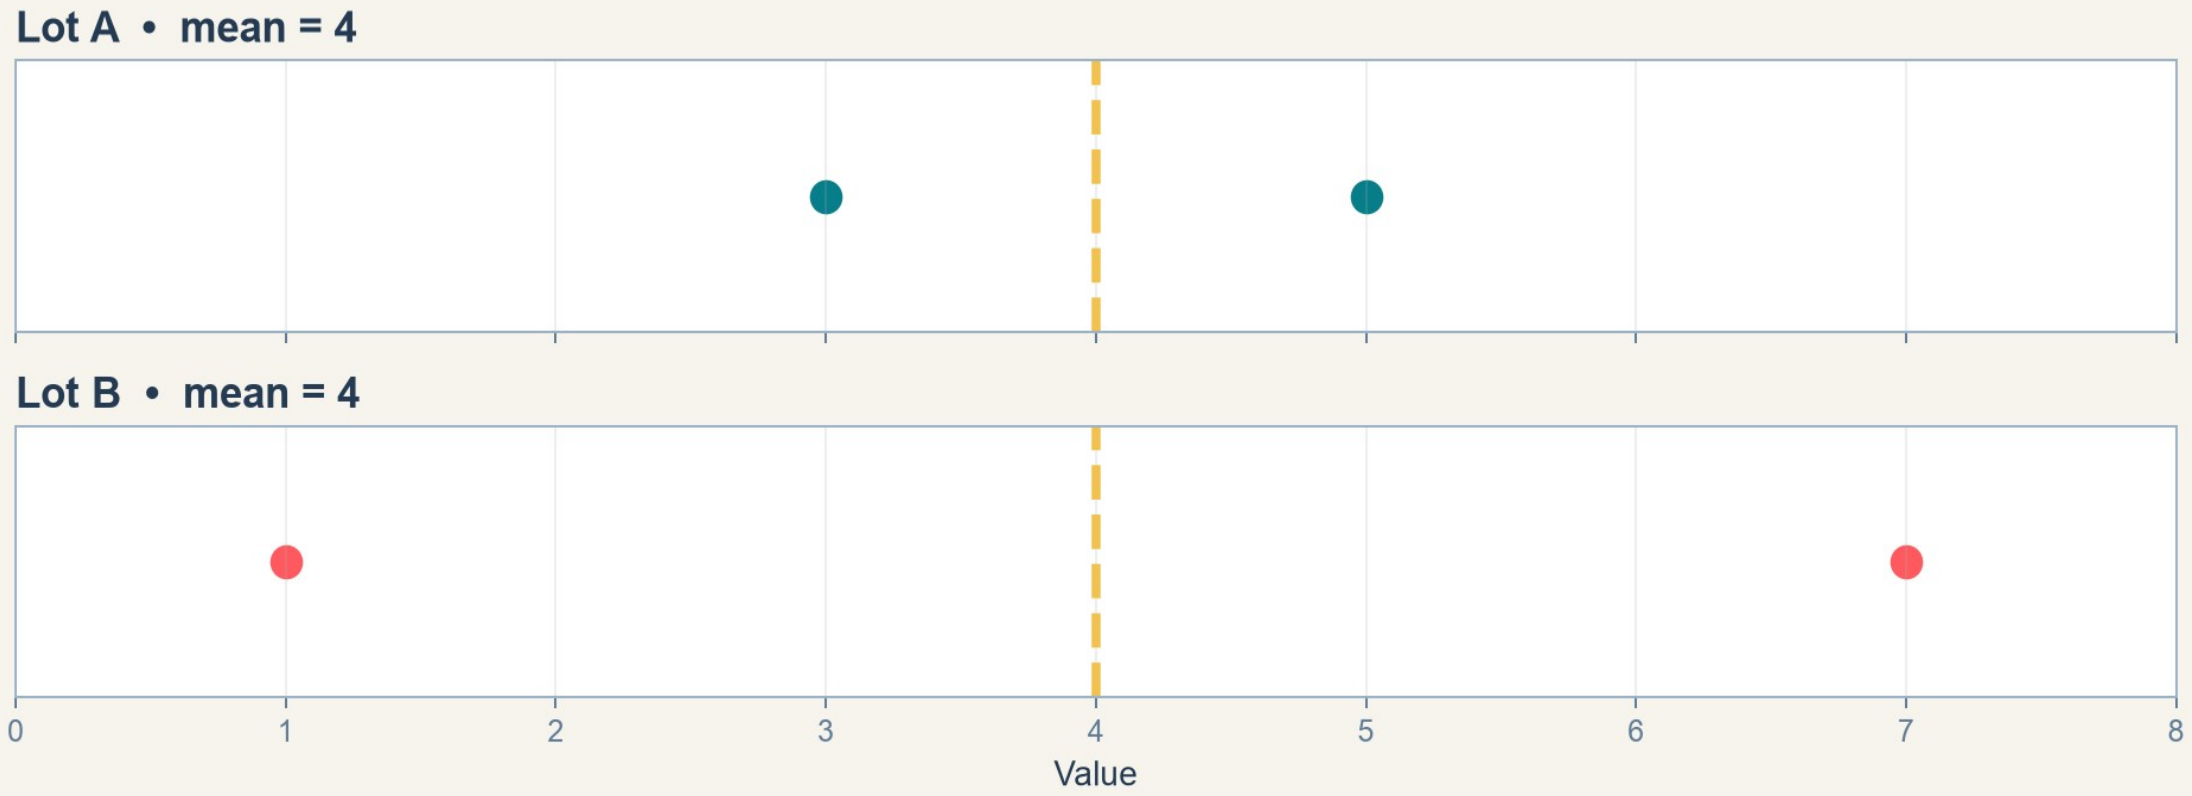
Choisissez le lot le plus dispersé et justifiez.

Réponse au prochain écran — gardez une trace de votre raisonnement.

Le centre ne décrit pas la dispersion

DEBRIEF

Même mean = 4 ; les distances autour de 4 ne racontent pas la même chose.



Une distribution répond à trois questions

Où ? Combien ? Quelle forme ?

- Centre : où se situent les valeurs ?
- Spread : à quel point sont-elles dispersées ?
- Shape : symétrie, queues, groupes, trous ?

PAUSE • EXERCICE 2

4 MIN

Combien de `bins` faut-il ?

Même jeu de 600 visites. Avant de voir le résultat, prédisez l'effet de 10 puis 55 `bins`.

1

Dessinez une version très grossière.

2

Dessinez une version très détaillée.

3

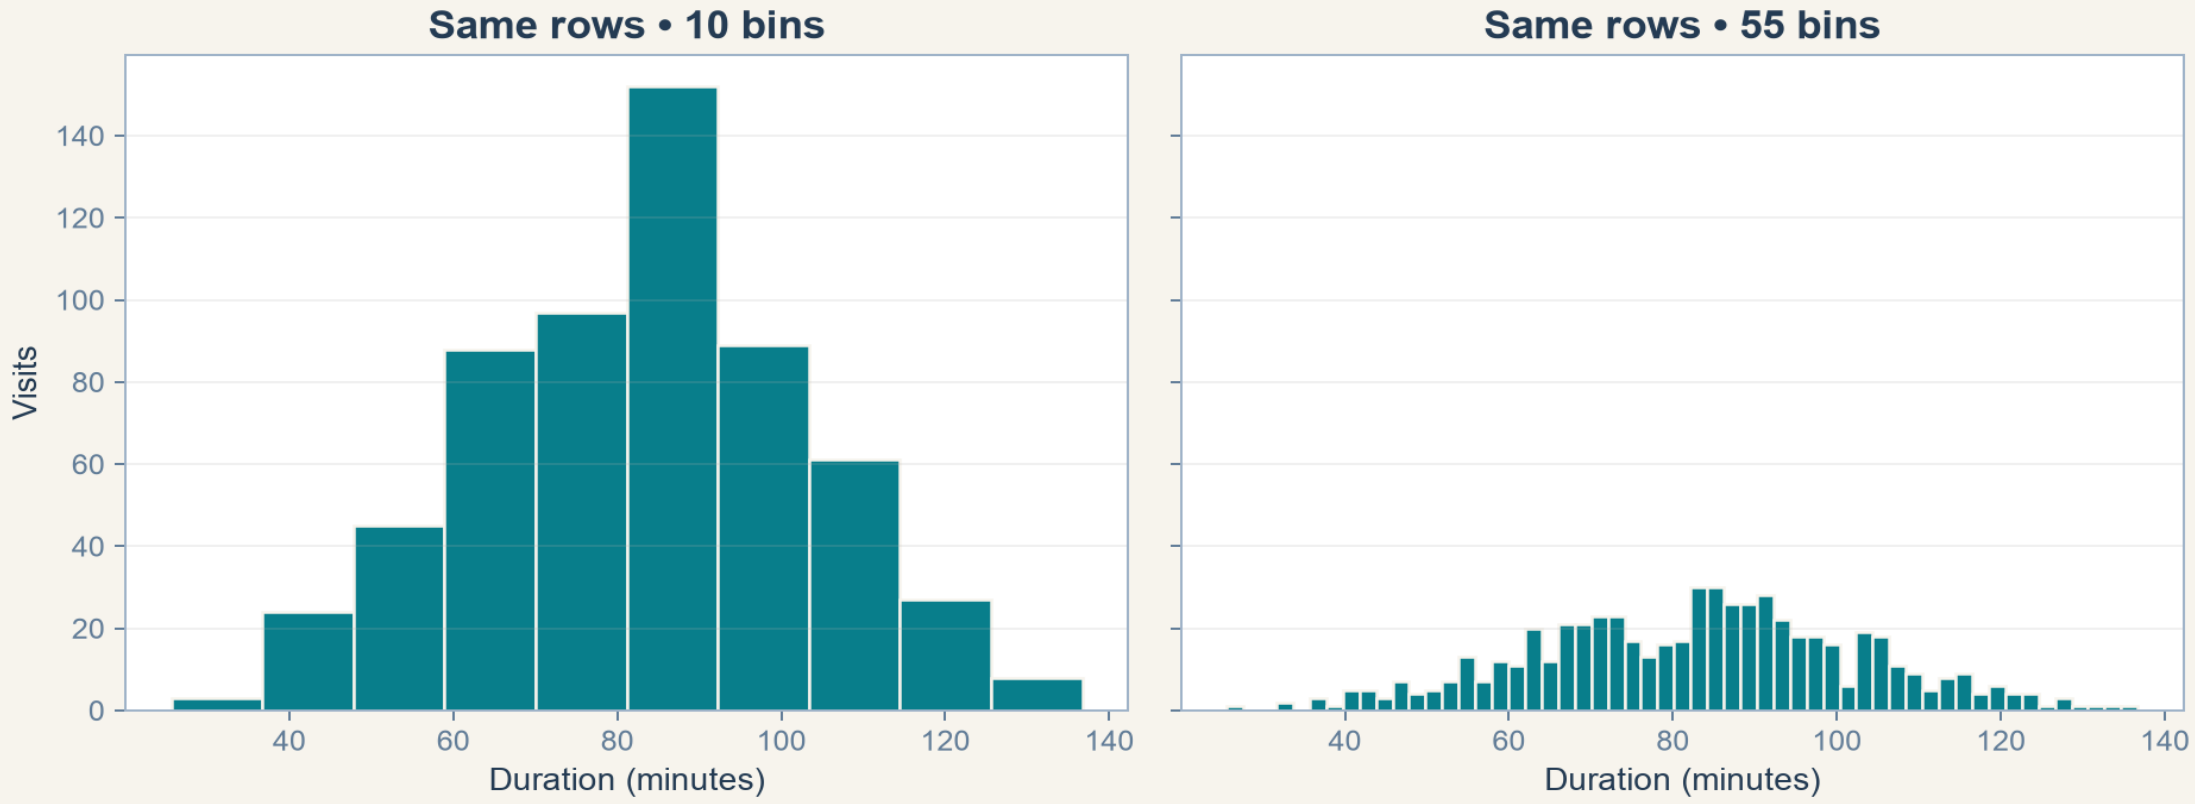
Listez ce qui ne change pas dans les données.

Réponse au prochain écran — gardez une trace de votre raisonnement.

Les `bins` changent le dessin, pas les lignes

DEBRIEF

Une forme robuste reste visible sous plusieurs découpages raisonnables.



Effectif, fréquence, densité : trois axes

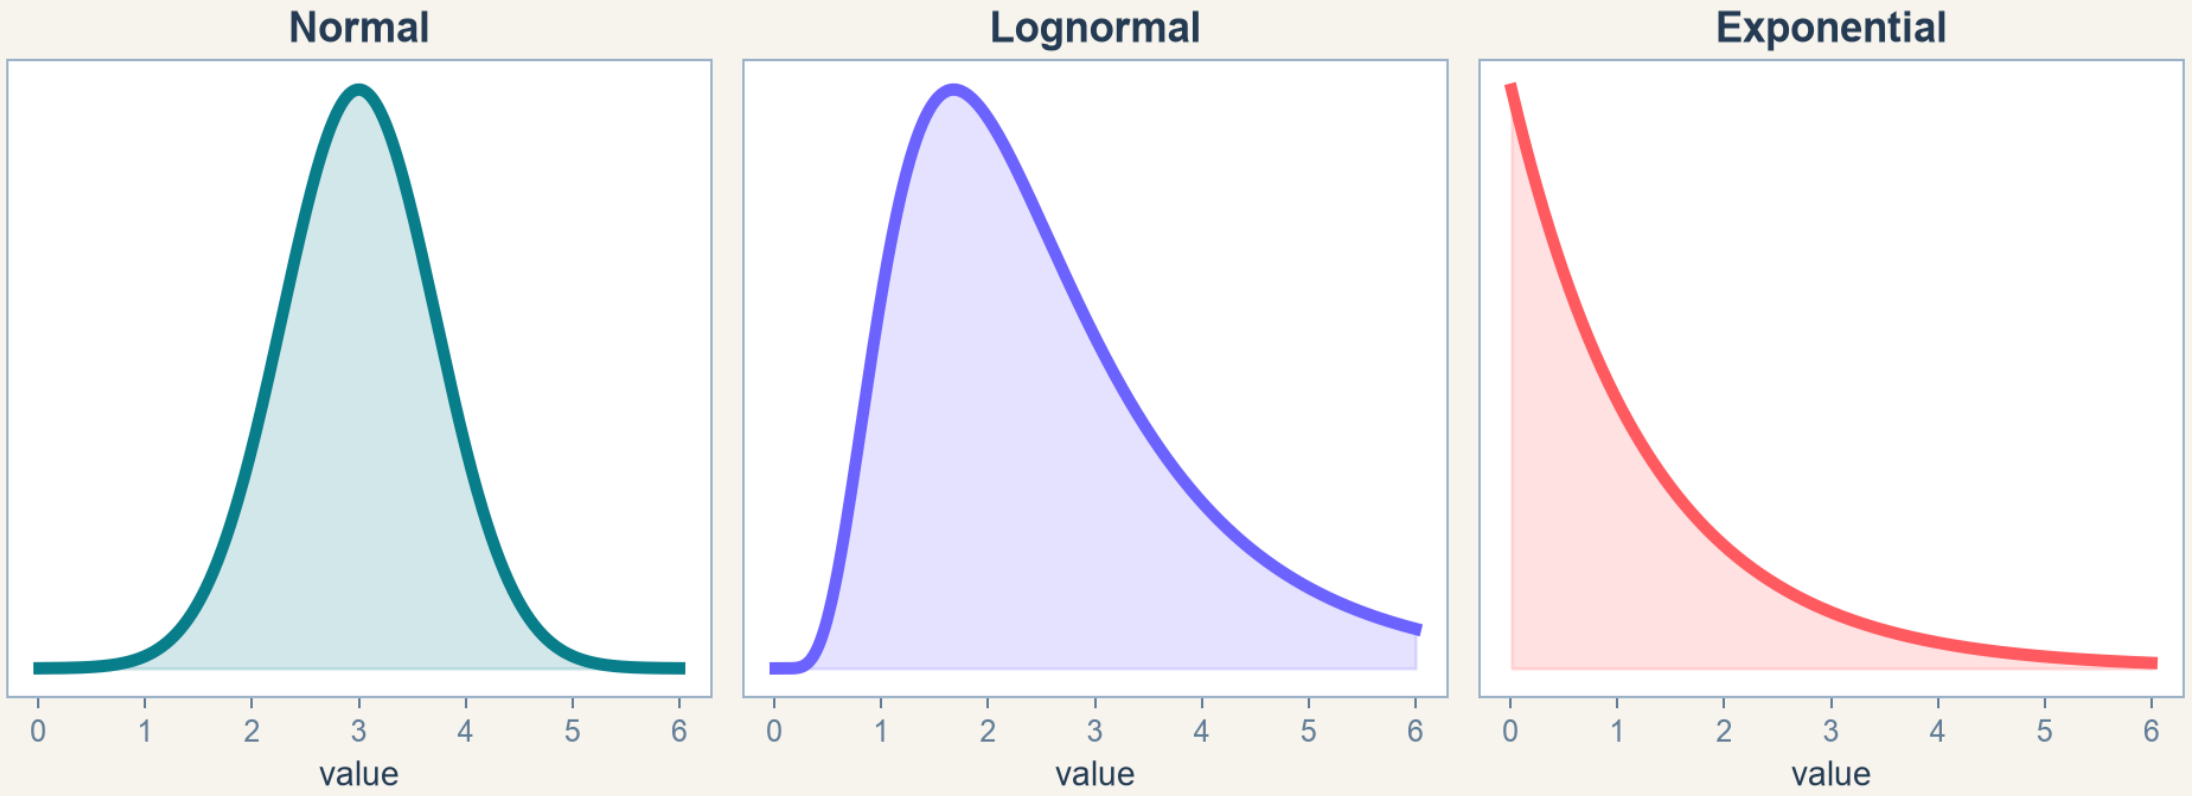
Lire l'axe vertical avant d'interpréter

- Count : nombre d'observations dans l'intervalle.
- Frequency : part des observations.
- Density : hauteur par unité ; la probabilité est une aire.
- La hauteur seule n'est pas une probabilité.

Trois familles, trois mécanismes possibles

REPÈRE

Une silhouette suggère une question ; elle ne prouve jamais le processus.



PAUSE • EXERCICE 3

5 MIN

Reliez mécanisme et modèle

Travaillez par binôme. Chaque proposition suppose des conditions à expliciter.

1

Effets additifs indépendants → ?

2

Croissance par facteurs positifs → ?

3

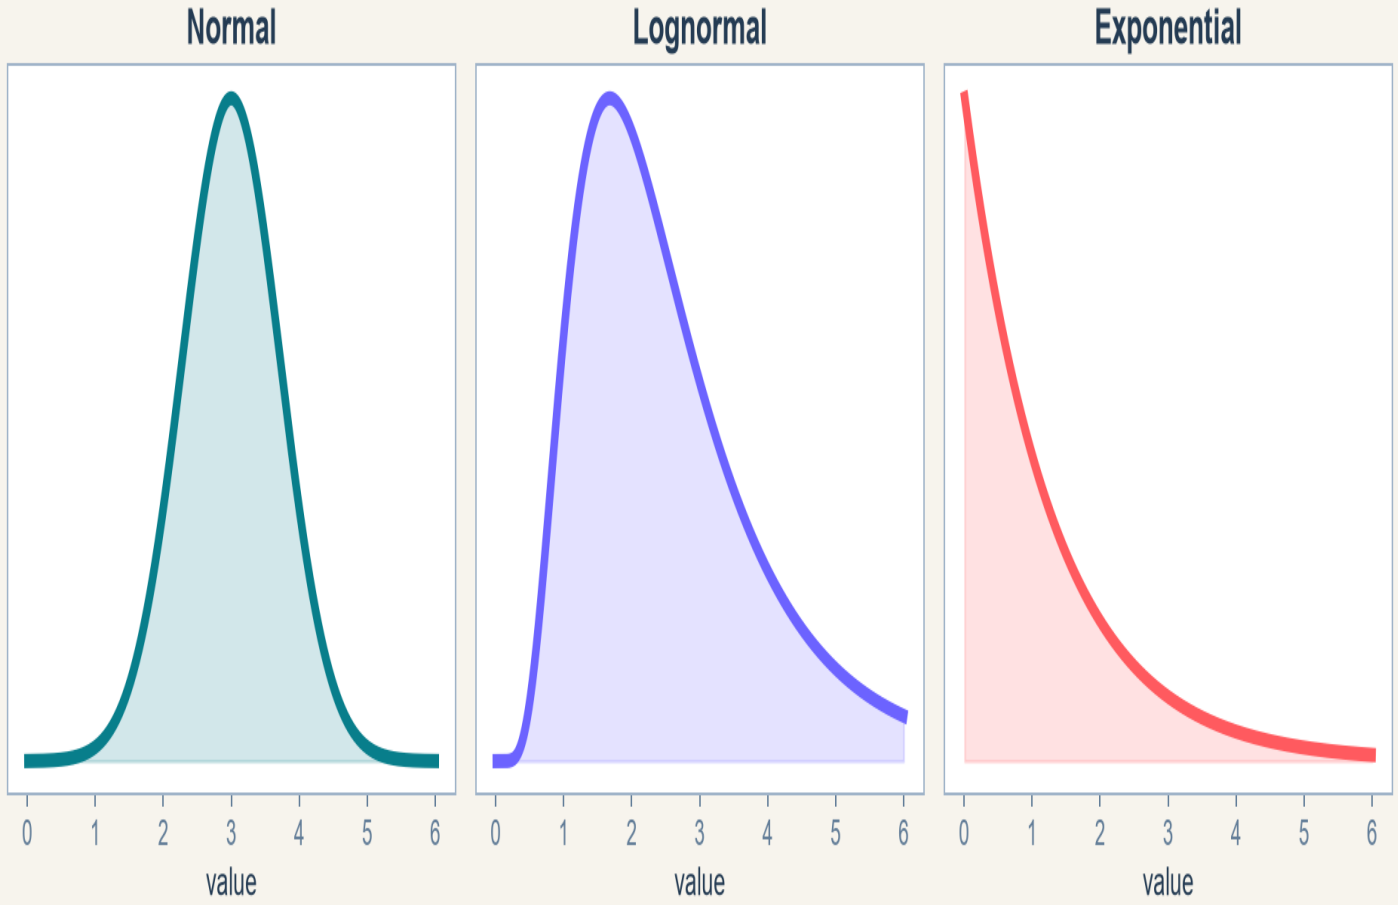
Attente avec rate constant → ?

Réponse au prochain écran — gardez une trace de votre raisonnement.

Le mécanisme vient avant la silhouette

Sous hypothèses explicites

- Additive → normal peut être plausible.
- Multiplicative → lognormal peut être plausible.
- Constant rate → exponential peut être plausible.
- Contrôler domaine, collecte et groupes.



PAUSE • EXERCICE 4

7 MIN

`sample size` et `seed`

Dans `distribution_lab.ipynb`, comparez n = 20, 100, 400 pour quatre seeds.

1

Prédisez quelle taille varie le plus.

2

Exécutez et repérez un contre-exemple local.

3

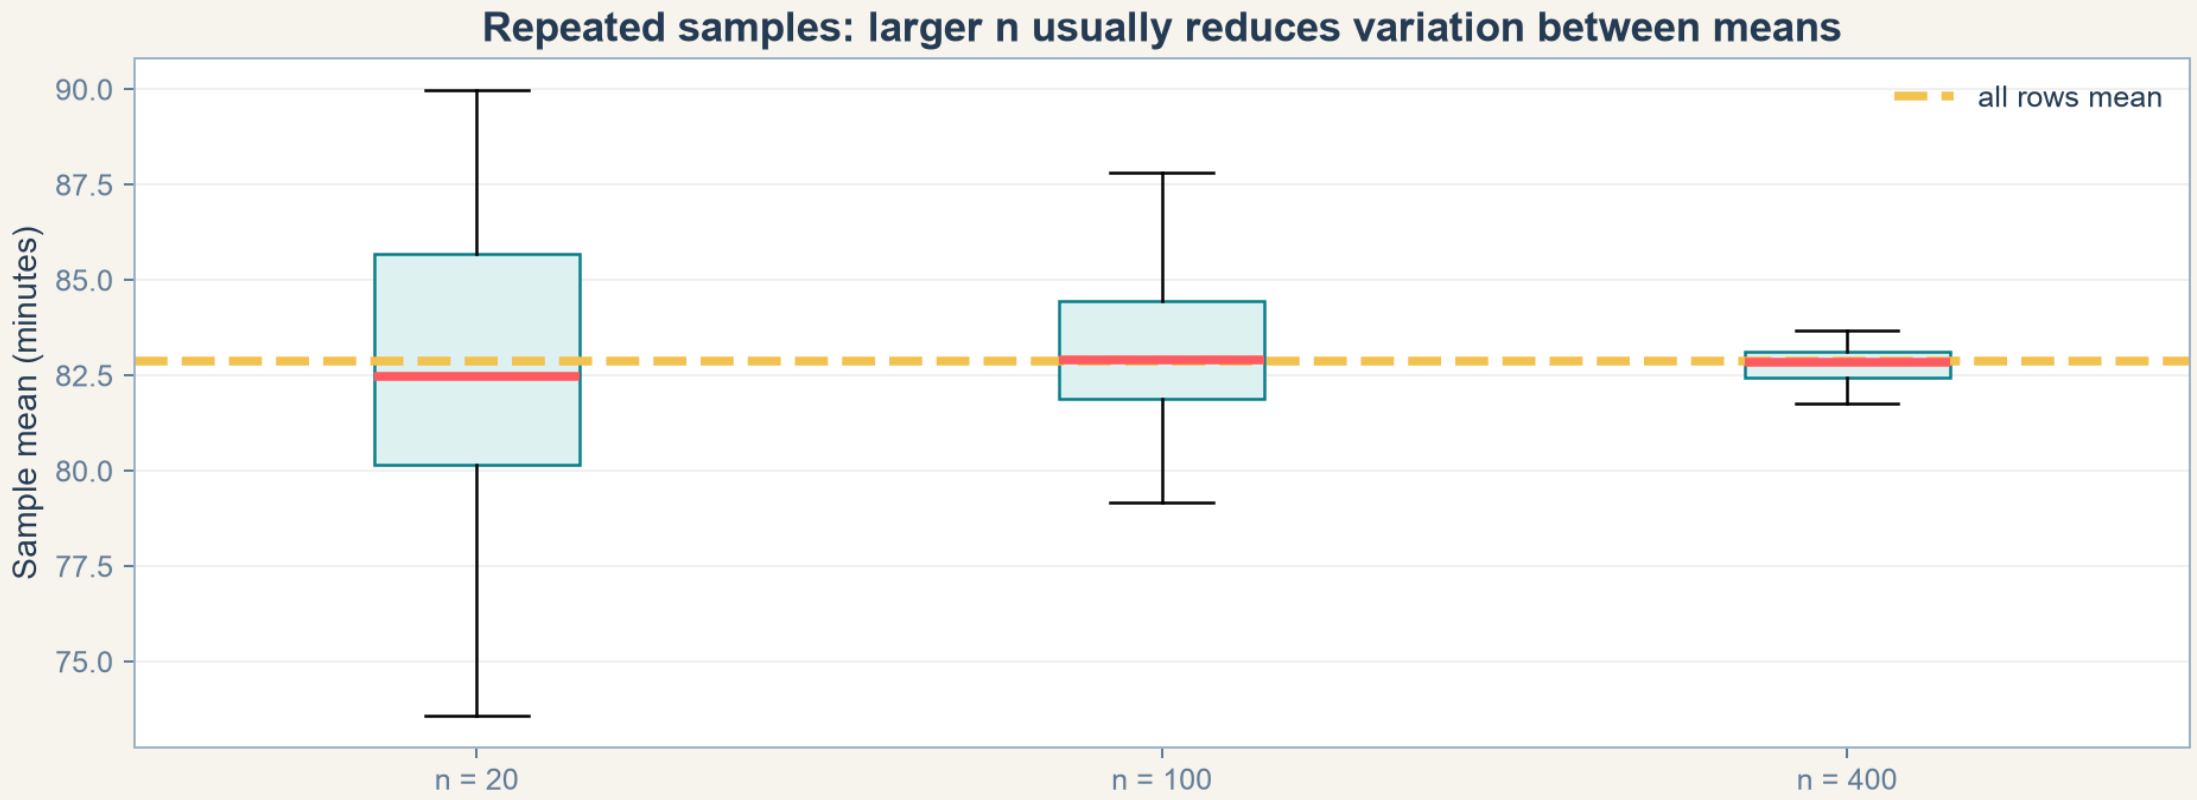
Formulez une tendance sans dire “toujours”.

Réponse au prochain écran — gardez une trace de votre raisonnement.

Plus de lignes stabilisent le résumé… en tendance

DEBRIEF

Une nouvelle seed change le tirage ; elle ne change pas la population simulée.



Un pipeline rend chaque transformation vérifiable

Chaque sortie devient l'entrée contrôlée de l'étape suivante



Checkpoint : ouvrir la sortie, vérifier les lignes et les unités, puis seulement continuer.

Les quatre fichiers ont quatre responsabilités

Un stage = une entrée, une action, une sortie

- 01_generate_visits.py : créer le raw CSV reproductible.
- 02_prepare_visits.py : valider, enrichir, signaler.
- 03_describe_visits.py : résumer globalement et par groupe.
- 04_visualize_visits.py : écrire le HTML interactif.

PAUSE • EXERCICE 5

6 MIN

Tracez une modification de bout en bout

La durée de V0042 passe de x à x + 20 minutes. Sans exécuter, prédisez les effets.

1

Quels outputs doivent changer ?

2

Quels résumés restent identiques ?

3

Quel checkpoint révèle un fichier périmé ?

Réponse au prochain écran — gardez une trace de votre raisonnement.

Une transformation doit laisser une piste

Input → code → output → contrôle

- Le raw reste la source observable.
- Le prepared ajoute des colonnes sans cacher de suppression.
- Le résumé concerné change ; les groupes non concernés restent identiques.
- Un timestamp ne prouve pas qu'un stage a réussi : ouvrir la sortie.

PAUSE • EXERCICE 6

5 MIN

Valeur inhabituelle : supprimer ?

Six visites sont marquées `needs_review`. Vous devez conseiller une action.

1

Comparez with / without sans écraser les données.

2

Listez les vérifications source nécessaires.

3

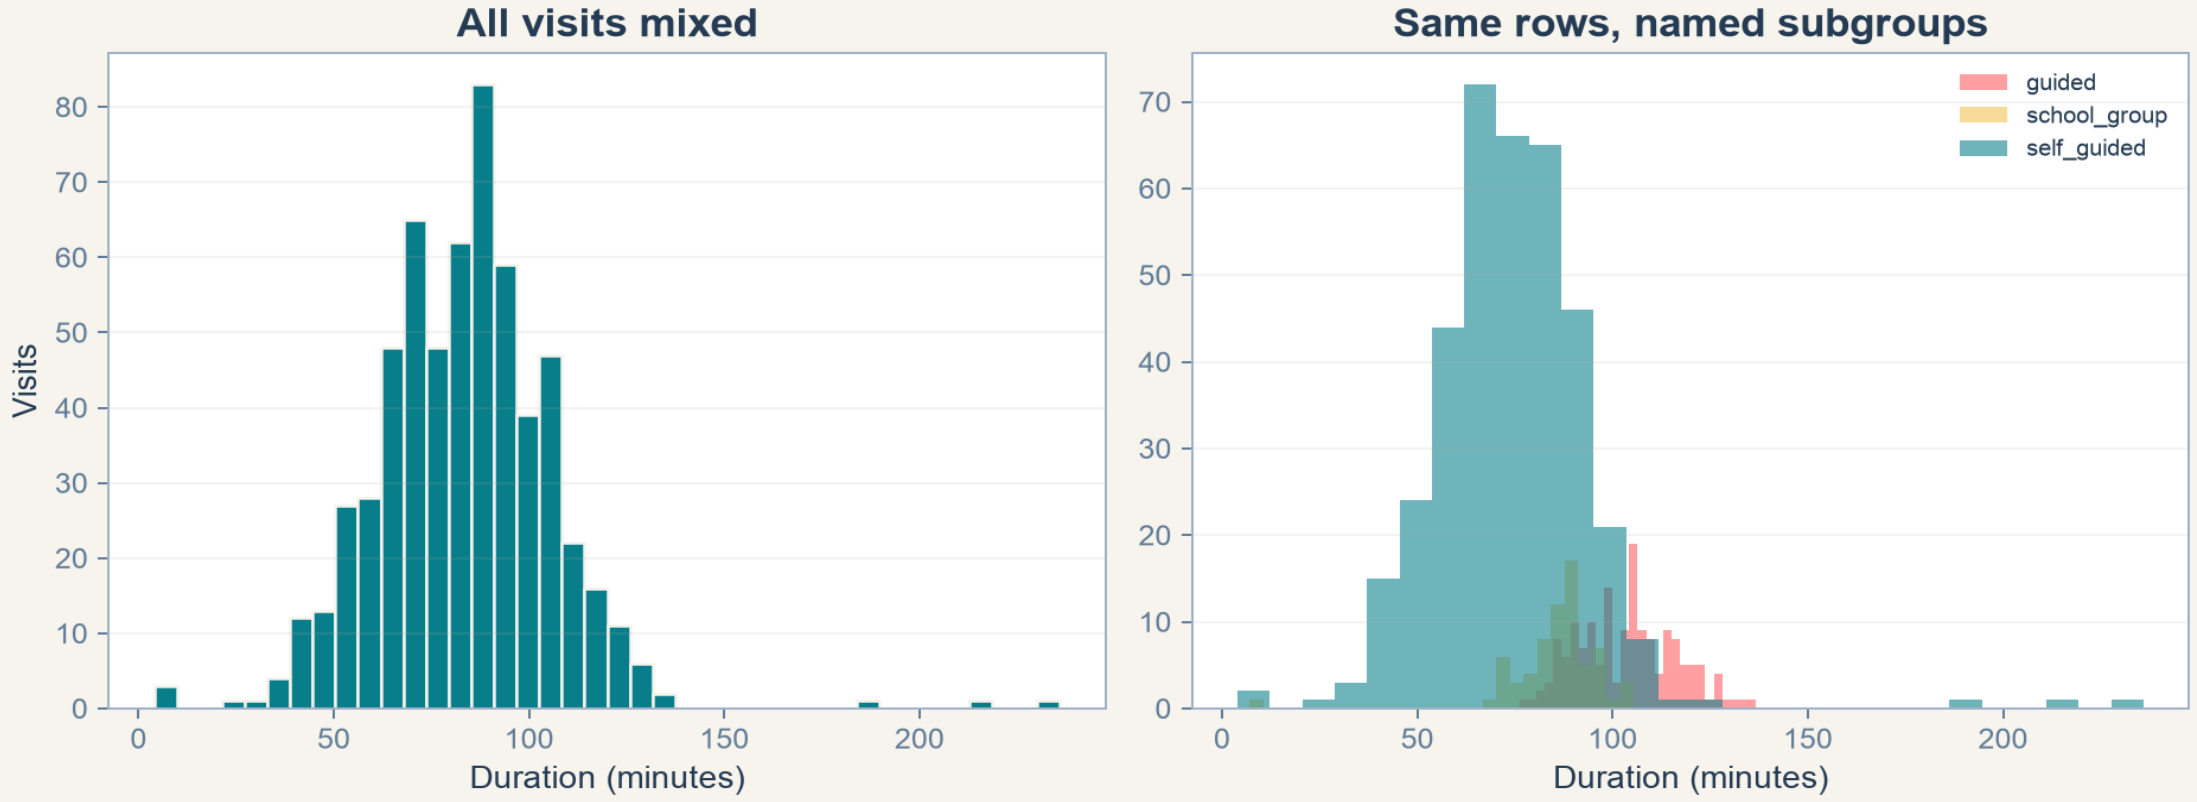
Décidez : garder, corriger ou exclure — avec condition.

Réponse au prochain écran — gardez une trace de votre raisonnement.

Avant d'effacer, regardez les groupes

DEBRIEF

Le mélange global cache des populations de visites différentes ; un point extrême peut aussi être valide.



EXIT TICKET • 3 MIN

Une conclusion explicable tient en quatre lignes

1. Observation : ce que montrent les données.
2. Evidence : résumé ou graphique utilisé.
3. Limit : ce que cette simulation ne prouve pas.
4. Next check : prochaine vérification dans un projet réel.