Formation Data Analyst

Introduction à l'analyse de données : décrire et comprendre ses données

À l'issue de ce cours, vous saurez décrire n'importe quel jeu de données avec les bons indicateurs statistiques — et justifier vos choix.

Cours 1

Novembre 2026

Sommaire

1. Objectifs d'apprentissage **3**

2. Prérequis et rappels **4**

3. Pourquoi c'est important **5**

4. Corps du cours **6**

4.1 C'est quoi, une donnée ? Observation, variable, jeu de données 6

4.2 Décrire ou prédire : statistique descriptive et statistique inférentielle 7

4.3 Population et échantillon 8

4.4 Les variables qualitatives : nominales et ordinales 9

4.5 Les variables quantitatives : discrètes et continues 9

4.6 La démarche d'analyse de données 10

4.7 Mesurer le centre : la moyenne 11

4.8 La médiane, ou le centre qui résiste aux extrêmes 12

4.9 Le mode et la classe modale 13

4.10 Mesurer la dispersion : l'étendue 15

4.11 La variance et l'écart-type 16

4.12 Population ou échantillon : le fameux « n − 1 » 17

4.13 La règle des 68-95-99,7 18

4.14 Quartiles, écart interquartile et valeurs aberrantes 19

4.15 Dispersions robustes : écart absolu moyen et MAD 20

4.16 Comparer des dispersions : le coefficient de variation 22

4.17 La forme d'une distribution : l'asymétrie 23

4.18 Deux variables ensemble : la covariance 24

4.19 Le coefficient de corrélation de Pearson 25

5. Erreurs fréquentes et pièges **27**

6. Exercices **28**

7. Fiche récapitulative **30**

8. Pour aller plus loin **31**

Corrigé détaillé des exercices **32**

1. Objectifs d'apprentissage

À l'issue de ce cours, vous saurez :

- **Identifier** le type d'une variable (qualitative nominale ou ordinale, quantitative discrète ou continue) dans un jeu de données réel ;
- **Calculer** et **interpréter** les mesures de tendance centrale : moyenne, médiane, mode ;
- **Calculer** et **interpréter** les mesures de dispersion : étendue, variance, écart-type, écart interquartile ;
- **Choisir** l'indicateur adapté à une situation métier (présence de valeurs aberrantes, comparaison de séries, distribution asymétrique) ;
- **Distinguer** population et échantillon, statistique descriptive et statistique inférentielle, et mesurer le lien linéaire entre deux variables avec la corrélation de Pearson.

2. Prérequis et rappels

Prérequis. Ce cours est le premier de la formation : il ne demande aucune connaissance en analyse de données. Vous avez seulement besoin de calculs de niveau lycée : additions, fractions, puissances et racines carrées.

Rappels de cours précédents. Il n'y a pas de cours antérieur : tout part d'ici. En revanche, les notions de ce cours seront reprises et approfondies dans toute la suite de la formation — prenez le temps de bien les ancrer, et utilisez la fiche récapitulative (section 7) pour réviser régulièrement.

3. Pourquoi c'est important

Imaginez votre premier jour comme data analyst dans une boutique en ligne française. On vous envoie un fichier de 50 000 commandes et une question en apparence simple : « Alors, nos clients dépensent combien, en moyenne ? » Pour y répondre correctement, vous devez déjà savoir ce qu'est une variable, si la moyenne est le bon indicateur, et si quelques commandes géantes ne vont pas fausser votre réponse. Tout cela, c'est la statistique descriptive — et c'est le sujet de ce cours.

Ces notions ne sont pas un formalisme scolaire. Si vous calculez une moyenne sur des données où se cachent des valeurs extrêmes, vous pouvez annoncer à votre direction un « panier moyen » que presque aucun client ne paie réellement. Si vous généralisez à tous vos clients ce que vous avez mesuré sur 200 personnes sans comprendre la différence entre population et échantillon, vous prenez des décisions sur du sable. Les erreurs de débutant les plus coûteuses en analyse de données viennent presque toujours de ces bases mal comprises.

Enfin, chaque outil que vous apprendrez ensuite — pandas, Excel, SQL, les tests statistiques, la régression — repose sur le vocabulaire et les indicateurs de ce cours. La moyenne, l'écart-type, la corrélation : vous les rencontrerez dans chaque analyse, chaque rapport, chaque graphique. Autant les comprendre une fois, correctement, maintenant.

4. Corps du cours

Dans tout ce cours, vous suivrez un fil rouge : vous êtes data analyst pour **« Maison Léa »**, une petite boutique en ligne française qui vend des articles de décoration. Chaque concept sera d'abord expliqué simplement, puis démontré pas à pas sur ses données. Un seul concept par section : prenez-les dans l'ordre, ils sont du plus simple au plus complexe.

4.1 C'est quoi, une donnée ? Observation, variable, jeu de données

Avant de calculer quoi que ce soit, il faut parler la même langue. En analyse de données, trois mots reviennent sans cesse : **observation**, **variable** et **jeu de données**. Ils semblent évidents, mais les confondre est la première source de malentendus entre analystes et équipes métier.

Une **observation** est une ligne de votre tableau : une entité précise que vous avez mesurée (une commande, un client, un produit). Une **variable** est une colonne : une caractéristique mesurée sur chaque observation (le montant, la ville, la date). Le **jeu de données** est le tableau complet : des observations en lignes, des variables en colonnes.

> **Définition**
>
> Un **jeu de données** (*dataset*) est un ensemble structuré de données, organisé en **observations** (*observations* ou *rows*, les lignes) et en **variables** (*variables* ou *features*, les colonnes). Une **donnée** (*data point*) est la valeur d'une variable pour une observation donnée — une case du tableau.

> **Analogie.** *Pensez à un carnet de notes de professeur : chaque ligne est un élève (une observation), chaque colonne est un devoir (une variable), et chaque note écrite à l'intersection est une donnée. Le carnet entier est le jeu de données.*

Tableau 1 — Extrait du jeu de données des commandes de Maison Léa : 4 observations, 5 variables.

id_commande	date	ville	nb_articles	montant (€)
C-1021	2026-09-02	Lyon	3	45,90
C-1022	2026-09-02	Nantes	1	12,50
C-1023	2026-09-03	Lyon	5	89,00
C-1024	2026-09-03	Bordeaux	2	31,20

Dans ce tableau, « Lyon » (ligne C-1021) est une donnée : c'est la valeur de la variable *ville* pour l'observation C-1021. La colonne *montant* est une variable ; la ligne C-1023 est une observation.

Exemple guidé — lire un tableau comme un analyste

Vous recevez le tableau ci-dessus. Voici comment le décrire, étape par étape.

1. **On compte les lignes** : 4 observations, donc 4 commandes. On fait cela parce que la taille du jeu de données conditionne tout ce qu'on pourra en dire.
2. **On liste les colonnes** : 5 variables. On fait cela pour savoir quelles questions on pourra traiter.
3. **On identifie l'unité d'observation** : une ligne = une commande (pas un client, pas un produit). On fait cela parce que tout indicateur calculé ensuite parlera « par commande » — jamais « par client ».

À retenir

- Ligne = **observation** ; colonne = **variable** ; case = **donnée** ; tableau = **jeu de données**.
- Toujours identifier d'abord ce que représente une ligne : cela fixe le sens de tous les calculs suivants.

4.2 Décrire ou prédire : statistique descriptive et statistique inférentielle

Les statistiques ont deux grandes missions, et les confondre est dangereux. La première consiste à **décrire** des données que vous possédez déjà : les simplifier, les organiser, les résumer. La seconde consiste à **généraliser** : tirer des conclusions sur un grand ensemble à partir d'une petite partie observée.

> **Définition**
>
> La **statistique descriptive** (*descriptive statistics*) résume et décrit des données disponibles, à l'aide d'indicateurs (moyenne, médiane…) et de graphiques. La **statistique inférentielle** (*inferential statistics*) généralise à une population entière des résultats obtenus sur un échantillon, en quantifiant l'incertitude (intervalles de confiance, tests d'hypothèses).

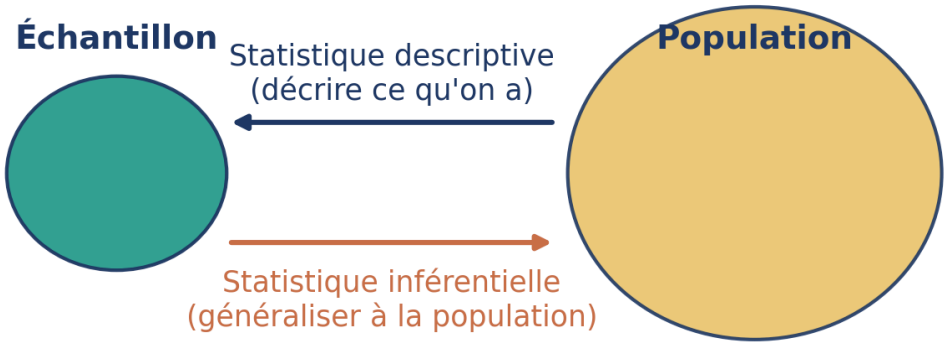


Figure 1 — La statistique descriptive part des données vers leur résumé ; la statistique inférentielle remonte de l'échantillon vers la population.

Ce cours est entièrement consacré à la statistique descriptive. Mais retenez dès maintenant la frontière : dire « la moyenne des notes de la classe est de 12/20 », c'est décrire. Dire « avec 95 % de confiance, la moyenne de toutes les classes de l'école se situe entre 11,5 et 12,5 », c'est inférer : vous parlez de données que vous n'avez pas mesurées.

Exemple guidé — décrire ou inférer ?

Trois affirmations arrivent sur votre bureau. Pour chacune, on se demande : de quelles données parle-t-on ?

1. « En septembre, le panier moyen de Maison Léa était de 42 €. » Les 50 000 commandes de septembre sont toutes dans la base : c'est de la statistique **descriptive**.
2. « D'après un sondage de 400 clients, nous estimons que 70 % de nos clients seraient prêts à payer la livraison express. » On généralise de 400 clients à tous les clients : c'est de la statistique **inférentielle**.
3. « Les ventes de décembre devraient dépasser celles de novembre. » Une prédiction sur des données futures : inférentielle à nouveau.

À retenir

- Décrire ce qu'on **a** : statistique descriptive. Généraliser à ce qu'on **n'a pas** : statistique inférentielle.
- L'inférence quantifie toujours son incertitude (ex. « avec 95 % de confiance ») — jamais de généralisation gratuite.

4.3 Population et échantillon

Pourquoi la statistique inférentielle existe-t-elle ? Parce qu'on ne peut presque jamais tout mesurer. La **population** est l'ensemble complet qui vous intéresse ; l'**échantillon** est la partie que vous observez réellement.

> **Définition**
>
> La **population** (*population*) est l'ensemble exhaustif des individus ou objets sur lesquels porte une étude. Un **échantillon** (*sample*) est un sous-ensemble de la population, effectivement observé, choisi pour la représenter. L'**échantillonnage** (*sampling*) est la méthode utilisée pour constituer ce sous-ensemble.

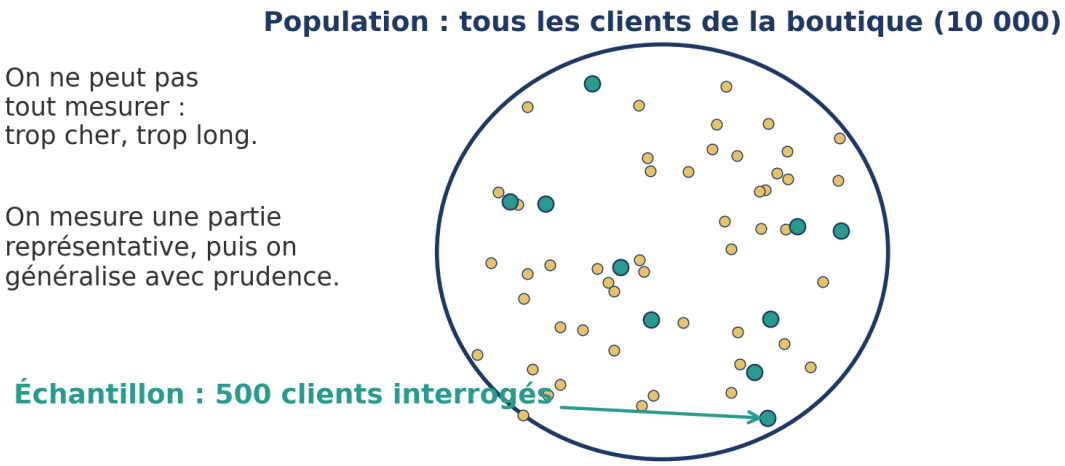


Figure 2 — On mesure un échantillon représentatif quand mesurer toute la population coûterait trop cher ou trop longtemps.

> **Analogie.** *Goûter une cuillère de soupe pour savoir si le plat est assez salé : la cuillère est l'échantillon, la casserole la population. Si la soupe est bien mélangée — échantillon représentatif — une cuillère suffit. Si le sel est resté au fond, votre cuillère vous ment.*

La distinction a une conséquence pratique majeure : les formules de certains indicateurs changent selon que vos données sont une population entière ou un échantillon. Vous verrez le cas concret de la variance et de l'écart-type en section 4.12.

Exemple guidé — population ou échantillon ?

1. Maison Léa exporte **toutes** ses commandes de septembre. Population ou échantillon ? **Population** — si la question porte sur septembre. Mais si la question est « comment achètent nos clients en général ? », ce même fichier devient un **échantillon** (un mois parmi douze).
2. On interroge 500 clients sur leur satisfaction. Échantillon : la population est l'ensemble des clients.

Le réflexe à acquérir : demandez-vous toujours « ces données sont-elles tout ce qui existe, ou une partie d'un tout plus grand ? »

À retenir

- Population = le tout ; échantillon = la partie observée.
- Un même fichier peut être une population pour une question et un échantillon pour une autre.
- Certaines formules changent selon le cas (voir section 4.12).

4.4 Les variables qualitatives : nominales et ordinales

Toutes les colonnes ne se traitent pas pareil. Avant tout calcul, un analyste classe ses variables : c'est ce classement qui décide des indicateurs et graphiques autorisés. On commence par les variables qui décrivent des **catégories**, pas des nombres.

> **Définition**
>
> Une **variable qualitative** (*categorical variable*) décrit une qualité, une catégorie ou un attribut, et non une quantité mesurable. Elle est **nominale** (*nominal*) si ses catégories n'ont pas d'ordre naturel (couleur des yeux, ville, genre) ; elle est **ordinale** (*ordinal*) si ses catégories ont un ordre naturel sans que l'écart entre elles soit mesurable (satisfaction : faible, moyen, élevé).

Tableau 2 — Qualitative nominale ou ordinale : l'ordre des catégories fait toute la différence.

Type	Ordre naturel ?	Exemples	Calculs autorisés
Nominale	Non	Ville, couleur, catégorie de produit	Effectifs, proportions, mode
Ordinale	Oui	Satisfaction (faible < moyen < élevé), taille de vêtement (S < M < L)	+ médiane, classement

Le test est simple : pour une nominale, demandez-vous « puis-je ranger les catégories de la "plus petite" à la "plus grande" ? » Si la question n'a pas de sens (une ville n'est pas « plus grande » qu'une autre en tant que catégorie), c'est une nominale. Pour une ordinale, l'ordre existe mais pas les distances : « très satisfait » est au-dessus de « satisfait », mais on ne peut pas dire « de combien ».

Exemple guidé — classer les variables de Maison Léa

1. **ville** : des catégories sans ordre → qualitative **nominale**.
2. **avis_client** (« déçu », « neutre », « ravi ») : un ordre existe → qualitative **ordinale**.
3. Pourquoi on fait ce classement : parce que calculer la « moyenne des villes » n'a aucun sens, alors que trouver la ville la plus fréquente (le mode) en a un. Le type de variable décide de l'outil.

> **À retenir**
>
> - Qualitative = catégories. Nominale = sans ordre ; ordinale = avec ordre mais sans distance mesurable.
> - Sur une qualitative, pas de moyenne : effectifs, proportions et mode uniquement.

4.5 Les variables quantitatives : discrètes et continues

Deuxième grande famille : les variables qui mesurent des **quantités**, sur lesquelles les calculs ont un sens. Là encore, deux sous-types à distinguer — et le critère est : compte-t-on ou mesure-t-on ?

> **Définition**
>
> Une **variable quantitative** (*numerical variable*) prend des valeurs numériques sur lesquelles les opérations arithmétiques ont un sens. Elle est **discrète** (*discrete*) si elle ne prend que des valeurs isolées, généralement entières, qu'on *compte* (nombre d'enfants, résultat d'un dé, nombre d'articles). Elle est **continue** (*continuous*) si elle peut prendre une infinité de valeurs entre deux valeurs, qu'on *mesure* (taille, poids, durée, montant).

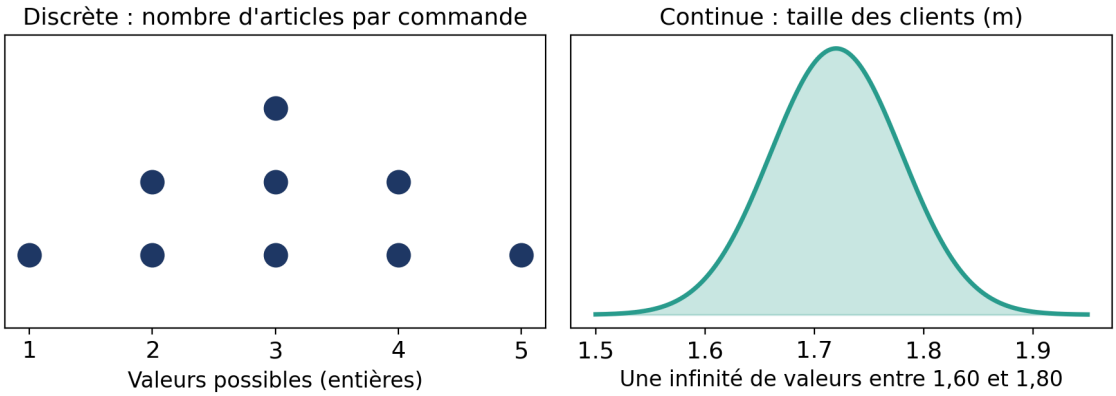


Figure 3 — À gauche, une variable discrète : des valeurs entières isolées. À droite, une variable continue : toutes les valeurs intermédiaires sont possibles.

> **Analogie.** *Une variable discrète est un escalier : on est sur une marche ou sur une autre, jamais entre deux. Une variable continue est une rampe : on peut se placer n'importe où.*

Attention à un cas classique : les montants en euros. Ils sont arrondis au centime, donc techniquement dénombrables — mais entre 10 € et 11 € il y a 100 valeurs possibles, et on les traite en pratique comme des variables **continues**. Ce qui compte, c'est la finesse de la mesure par rapport à l'analyse.

Exemple guidé — discrète ou continue ?

1. **nb_articles** : on compte des articles (1, 2, 3…), jamais 2,4 articles → **discrète**.
2. **poids_colis** (2,413 kg) : une mesure, une infinité de valeurs → **continue**.
3. **montant** : arrondi au centime, mais traité comme **continu** en analyse.
4. Pourquoi on fait cette distinction : elle oriente le choix des graphiques (diagramme en bâtons pour une discrète, histogramme pour une continue) et des résumés.

À retenir

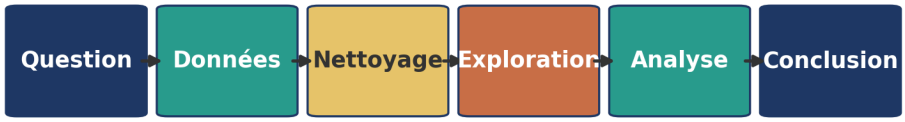
- Quantitative = nombres avec lesquels calculer. Discrète = on compte ; continue = on mesure.
- Le type de variable décide des indicateurs et graphiques pertinents : c'est le premier tri de toute analyse.

4.6 La démarche d'analyse de données

Vous savez maintenant nommer vos données. Voyons comment un analyste les met au travail. Une analyse n'est pas un calcul isolé : c'est une **démarche**, une suite d'étapes qui se répondent. La connaître vous évitera l'erreur la plus fréquente des débutants : foncer sur les chiffres avant de comprendre la question.

Définition

La **démarche d'analyse de données** (*data analysis workflow*) est la séquence d'étapes qui mène d'une question métier à une conclusion argumentée : **question → données → nettoyage → exploration → analyse → conclusion**. Ce cours se situe aux étapes d'exploration et d'analyse : résumer les données par des indicateurs.



Ce cours vous place aux étapes « Exploration » et « Analyse » : décrire les données avant tout modèle.

Figure 4 — Les six étapes de la démarche d'analyse. Les indicateurs de ce cours servent aux étapes « Exploration » et « Analyse ».

Exemple guidé — la démarche en action chez Maison Léa

La direction demande : « nos délais de livraison sont-ils acceptables ? » Voici la démarche complète.

1. **Question** : on reformule précisément — « quelle proportion de commandes dépasse 5 jours de délai, et quel est le délai typique ? ». On fait cela parce qu'une question floue produit une analyse inutile.
2. **Données** : on extrait les commandes de septembre, variables `date_commande` et `date_livraison`.
3. **Nettoyage** : on retire 212 lignes sans date de livraison et on corrige 3 dates aberrantes (livraison avant la commande).
4. **Exploration** : on calcule moyenne, médiane et étendue des délais — c'est là que ce cours intervient.
5. **Analyse** : la médiane est de 3 jours, mais 8 % des commandes dépassent 5 jours — la moyenne seule aurait masqué ce problème.
6. **Conclusion** : on recommande de surveiller le « percentile 92 » plutôt que la moyenne, et on justifie le choix auprès de la direction.

À retenir

- Six étapes : question → données → nettoyage → exploration → analyse → conclusion.
- Les indicateurs statistiques ne sont que des étapes intermédiaires : ils servent une question métier, jamais l'inverse.

4.7 Mesurer le centre : la moyenne

« C'est combien, en moyenne ? » C'est probablement la question que vous entendrez le plus souvent. Une **mesure de tendance centrale** résume toute une série de valeurs par un seul nombre « typique ». La plus connue est la moyenne — mais vous verrez dès la section suivante qu'elle n'est pas toujours la meilleure candidate.

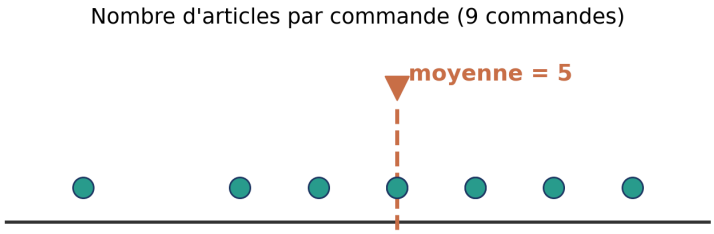
> **Définition**
>
> La **moyenne arithmétique** (*mean*) d'une série de valeurs est la somme de toutes les valeurs, divisée par le nombre de valeurs. Elle se note $\bar{x}$ (« x barre ») pour un échantillon, et μ (« mu ») pour une population.

$$\bar{x} = \frac{1}{n} \sum_{i=1}^{n} x_i$$

$\bar{x}$: moyenne de la série
n : nombre de valeurs
x_i : la i-ème valeur de la série
$\sum_{i=1}^{n}$: « somme de toutes les valeurs, de la 1re à la n-ième »

Lecture : on additionne toutes les valeurs ($\sum_{i=1}^{n} x_i$), puis on divise par leur nombre (n). La moyenne est la valeur que chaque observation aurait si on répartissait le total équitablement entre toutes.

> **Analogie.** *La moyenne est le point d'équilibre d'une balançoire : si chaque valeur posait un poids sur une règle, la moyenne serait l'endroit où poser le pivot pour que la règle reste horizontale. Un poids très lourd éloigné du centre suffit à tout faire basculer — c'est la grande faiblesse de la moyenne.*



La moyenne est le « point d'équilibre » des données : la somme des écarts à gauche compense celle des écarts à droite.

Figure 5 — La moyenne comme point d'équilibre : la somme des écarts à gauche compense exactement celle des écarts à droite.

Exemple guidé — panier de 9 commandes

Neuf commandes de septembre contiennent respectivement 1, 3, 4, 5, 5, 6, 6, 7 et 8 articles. On cherche le nombre moyen d'articles par commande.

1. **On additionne** : 1 + 3 + 4 + 5 + 5 + 6 + 6 + 7 + 8 = 45. On fait cela pour obtenir le « total d'articles vendus » sur ces 9 commandes.
2. **On divise par le nombre de commandes** : $\bar{x} = 45/9 = 5$. On fait cela pour répartir ce total également entre les commandes.
3. **On interprète** : « en moyenne, une commande contient 5 articles ». Attention : aucune commande ne contient forcément exactement 5 articles — la moyenne est un résumé, pas une observation.

En pratique dans le code

```
df["nb_articles"].mean()   # pandas : moyenne de la colonne
np.mean(x)                 # numpy : equivalent
```

À retenir

- Moyenne = somme des valeurs ÷ nombre de valeurs.
- La moyenne utilise **toutes** les valeurs : c'est sa force (rien n'est ignoré) et sa faiblesse (une valeur extrême la tire à elle).
- La moyenne n'a de sens que sur une variable quantitative — jamais sur des catégories.

4.8 La médiane, ou le centre qui résiste aux extrêmes

Une seule commande de 55 articles dans notre série de 9 commandes, et la moyenne passe de 5 à 10 : elle ne ressemble plus à aucune commande réelle. Il faut un indicateur de centre qui ne se laisse pas impressionner : la médiane.

Définition

La **médiane** (*median*) est la valeur qui partage une série ordonnée en deux parties contenant chacune 50 % des observations : la moitié des valeurs est en dessous, l'autre moitié au-dessus. Si le nombre de valeurs est impair, c'est la valeur centrale ; s'il est pair, c'est la moyenne des deux valeurs centrales.

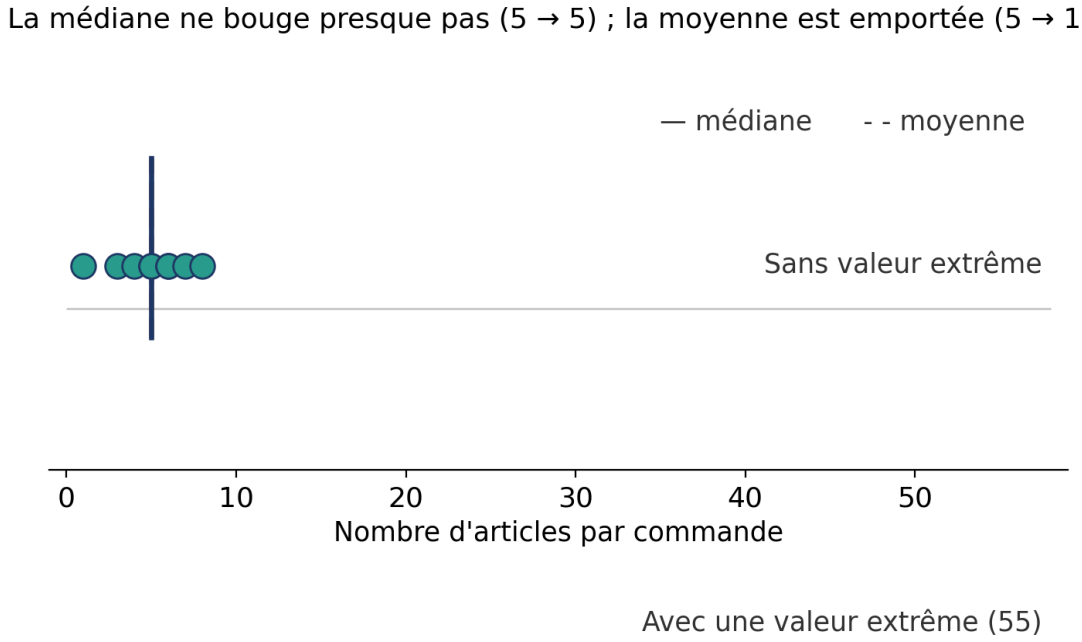


Figure 6 — Ajouter une valeur extrême (55) déplace fortement la moyenne (5 → 10) mais laisse la médiane quasi inchangée (5 → 5,5).

Exemple guidé — trouver la médiane, cas impair puis cas pair

Cas impair. Nos 9 commandes : on commence par **ordonner** les valeurs : 1, 3, 4, 5, 5, 6, 6, 7, 8. On fait cela parce que la médiane est définie par la position, pas par la grandeur.

1. 9 valeurs → la position centrale est la 5e (4 valeurs de part et d'autre).
2. La 5e valeur est 5 : **médiane = 5** articles.

Cas pair. Ajoutons une commande de 55 articles : 1, 3, 4, 5, 5, 6, 6, 7, 8, 55.

1. 10 valeurs → les deux positions centrales sont la 5e (5) et la 6e (6).
2. Médiane = (5 + 6) / 2 = **5,5**. Pendant ce temps, la moyenne est passée de 5 à 10 : c'est la médiane qui décrit encore une commande « typique ».

Analogie. *Dans une file d'attente classée par taille, la médiane est la personne du milieu. Qu'un géant ou un enfant rejoigne la fin de la file : la personne du milieu change à peine. Le « poids moyen » de la file, lui, peut changer beaucoup.*

En pratique dans le code

```
df["nb_articles"].median()   # pandas : mediane de la colonne
```

À retenir

- Médiane = valeur centrale d'une série **ordonnée** (50 % en dessous, 50 % au-dessus).
- Nombre pair de valeurs : moyenne des deux valeurs centrales.
- Robuste aux valeurs extrêmes : c'est l'indicateur à privilégier dès que la série en contient (revenus, prix de l'immobilier, paniers clients).

4.9 Le mode et la classe modale

Définition

Le **mode** (*mode*) est la valeur la plus fréquente d'une série. Une série peut n'avoir aucun mode (aucune valeur répétée), un seul (*unimodale*) ou plusieurs (*bimodale*, *multimodale*). Pour des données regroupées en classes, on parle de **classe modale** (*modal class*) : la classe de plus fort effectif. Le **mode interpolé** (*interpolated mode*) estime la position du mode à l'intérieur de la classe modale.

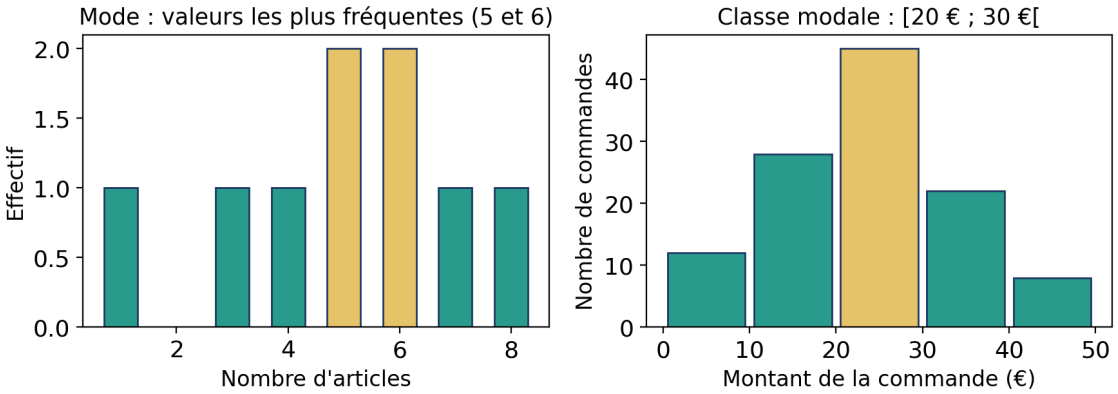


Figure 7 — À gauche, une série bimodale (5 et 6 articles, 2 fois chacune). À droite, des montants regroupés en classes : la classe modale est [20 € ; 30 €[.

Dans notre série de 9 commandes (1, 3, 4, 5, 5, 6, 6, 7, 8), les valeurs 5 et 6 apparaissent chacune deux fois : la série est **bimodale**, de modes 5 et 6.

$$M_o = L + h \times \frac{f_1 - f_0}{(f_1 - f_0) + (f_1 - f_2)}$$

M_o : mode interpolé, dans l'unité de la variable

L : borne inférieure de la classe modale

h : largeur de la classe modale

f_1 : effectif de la classe modale

f_0 : effectif de la classe précédente

f_2 : effectif de la classe suivante

Lecture : on part du bas de la classe modale (L) et on avance d'une fraction de sa largeur (h). Cette fraction compare le « dépassement » de la classe modale sur ses voisines : plus elle domine la classe précédente ($f_1 - f_0$ grand) par rapport à la suivante ($f_1 - f_2$), plus le mode se situe haut dans la classe. **Attention** : si la classe modale est la première ou la dernière, la classe précédente ou suivante n'existe pas et le calcul est impossible — on se contente alors de la classe modale. Quand les données sont groupées mais qu'on connaît moyenne et médiane, on peut aussi estimer le mode par la relation empirique de Pearson : $M_o \approx 3 \times \text{médiane} - 2 \times \text{moyenne}$.

Exemple guidé — mode interpolé sur les montants de commandes

Les commandes de septembre sont regroupées : [0 ; 10[: 12 commandes, [10 ; 20[: 28, [20 ; 30[: 45, [30 ; 40[: 22, [40 ; 50] : 8. On cherche le montant « le plus typique ».

1. **On repère la classe modale** : [20 ; 30[avec 45 commandes — le plus fort effectif.
2. **On identifie les ingrédients** : $L = 20$, $h = 10$, $f_1 = 45$, $f_0 = 28$, $f_2 = 22$.
3. **On applique la formule** : $M_o = 20 + 10 \times \frac{45-28}{(45-28)+(45-22)} = 20 + 10 \times \frac{17}{40} = 24{,}25$ €.
4. **On interprète** : le montant de commande le plus fréquent se situe autour de 24 €, légèrement à gauche du centre de la classe (25 €), car la classe précédente (28 commandes) est plus forte que la suivante (22) : le « sommet » penche du côté de la voisine la plus peuplée. On vérifie : comme f_0 et f_2 existent, le calcul était licite.

En pratique dans le code

```
df["ville"].mode()   # pandas : valeur(s) la(s) plus frequente(s)
```

À retenir

- Mode = valeur la plus fréquente ; il peut ne pas exister ou être multiple.
- Seul indicateur de centre utilisable sur une variable qualitative.
- Données groupées : on cite la classe modale, ou on interpole si les classes voisines existent.

4.10 Mesurer la dispersion : l'étendue

Deux villes peuvent avoir le même panier moyen et des clients pourtant très différents. La tendance centrale ne suffit pas : il faut mesurer à quel point les valeurs **s'étalent** autour du centre. C'est le rôle des mesures de dispersion, et la plus simple est l'étendue.

Définition

L'**étendue** (*range*) d'une série est la différence entre sa valeur maximale et sa valeur minimale : $\text{étendue} = \max(X) - \min(X)$. Elle mesure l'écart total couvert par les données.

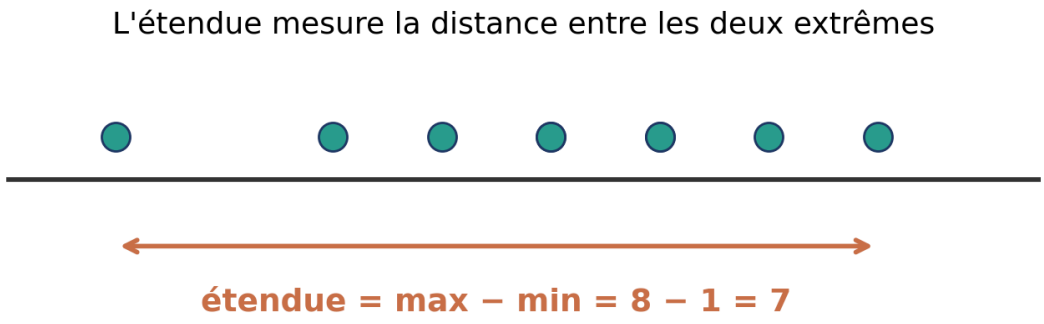


Figure 8 — L'étendue de nos 9 commandes : 8 − 1 = 7 articles.

Exemple guidé — étendue des 9 commandes

1. **On repère le minimum** : 1 article. **On repère le maximum** : 8 articles.
2. **On soustrait** : étendue = 8 − 1 = 7. On fait cela pour mesurer l'écart total couvert par les données.
3. **On constate la limite** : deux séries peuvent avoir la même étendue et des répartitions très différentes (valeurs concentrées au centre, ou collées aux extrêmes). L'étendue ne voit que les deux extrémités : elle est donc très sensible aux valeurs aberrantes.

En pratique dans le code

```
df["nb_articles"].max() - df["nb_articles"].min()   # etendue
```

À retenir

- Étendue = max − min : la dispersion en un coup d'œil.
- Elle ne regarde que les deux extrêmes : rapide mais fragile face aux valeurs aberrantes.

4.11 La variance et l'écart-type

Pour aller plus loin que l'étendue, on veut utiliser **toutes** les valeurs, pas seulement les extrêmes. L'idée : mesurer l'écart de chaque valeur à la moyenne, puis résumer ces écarts. C'est exactement ce que font la variance et sa racine carrée, l'écart-type — les deux mesures de dispersion les plus utilisées du métier.

Définition

La **variance** (*variance*) est la moyenne des carrés des écarts à la moyenne. L'**écart-type** (*standard deviation*, noté σ pour une population, s pour un échantillon) est la racine carrée de la variance : il ramène la dispersion dans l'unité des données d'origine.

$$\sigma^2 = \frac{1}{N}\sum_{i=1}^{N}(x_i - \mu)^2 \qquad \sigma = \sqrt{\sigma^2}$$

σ^2 : variance de la population, en unité au carré
σ : écart-type, dans l'unité des données
N : nombre de valeurs de la population
x_i : la i-ème valeur ; μ : moyenne de la population

Lecture : pour chaque valeur, on calcule son écart à la moyenne ($x_i - \mu$), on l'élève au carré — pour éliminer les signes et amplifier les grands écarts — puis on fait la moyenne de ces carrés. La variance s'exprime en unités au carré (des « articles² », difficiles à interpréter) ; en prenant sa racine carrée, l'écart-type revient dans l'unité des données : « les commandes s'écartent typiquement de 2 articles autour de la moyenne ».

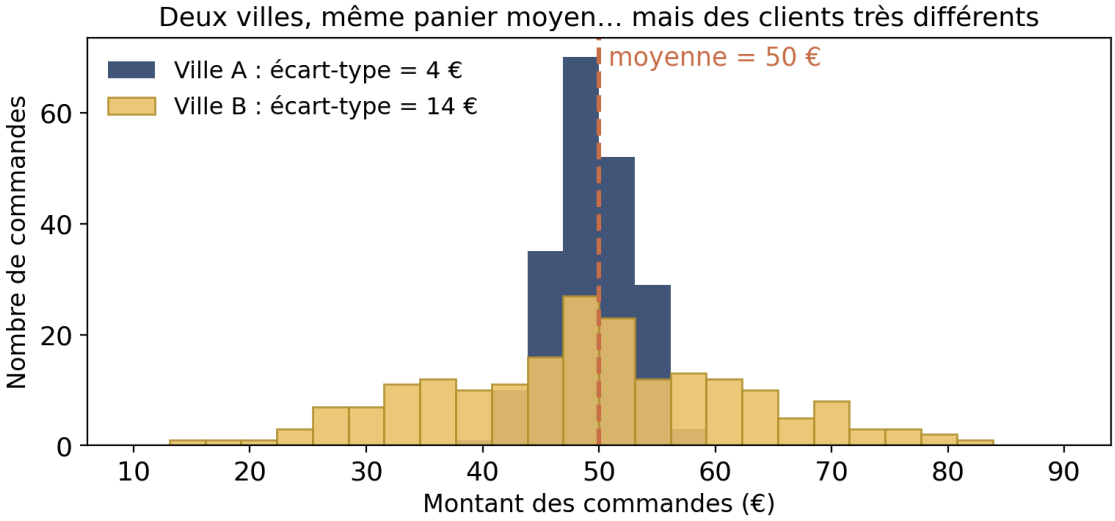


Figure 9 — Même moyenne (50 €), dispersions très différentes : seul l'écart-type permet de distinguer ces deux villes.

Exemple guidé — variance et écart-type des 9 commandes

Série : 1, 3, 4, 5, 5, 6, 6, 7, 8 (moyenne $\bar{x} = 5$, calculée en 4.7). Traitée ici comme une population.

1. **On calcule chaque écart à la moyenne** : -4, -2, -1, 0, 0, +1, +1, +2, +3. On fait cela pour mesurer la distance de chaque commande au centre.
2. **On élève au carré** : 16, 4, 1, 0, 0, 1, 1, 4, 9. On fait cela pour que les écarts négatifs ne compensent pas les positifs — sans les carrés, la somme des écarts vaut toujours 0.
3. **On fait la moyenne des carrés** : $\sigma^2 = (16 + 4 + 1 + 0 + 0 + 1 + 1 + 4 + 9)/9 = 36/9 = 4$ articles².
4. **On prend la racine** : $\sigma = \sqrt{4} = 2$ articles. Interprétation : une commande s'écarte typiquement d'environ 2 articles de la moyenne de 5.

En pratique dans le code

```
df["nb_articles"].var()    # variance (par defaut : echantillon, n-1)
df["nb_articles"].std()    # ecart-type (par defaut : echantillon, n-1)
np.var(x, ddof=0)          # variance d'une POPULATION (division par N)
```

À retenir

- Variance = moyenne des carrés des écarts à la moyenne ; écart-type = racine carrée de la variance.
- L'écart-type s'exprime dans l'unité des données : c'est lui qu'on interprète et qu'on communique.
- Comme la moyenne, ils sont sensibles aux valeurs extrêmes (les carrés amplifient les grands écarts).

4.12 Population ou échantillon : le fameux « n − 1 »

Vous avez calculé la variance en divisant par N — parce que nos 9 commandes étaient toute la population étudiée. Mais si ces 9 commandes n'étaient qu'un **échantillon** des 50 000 commandes de la boutique, il faudrait diviser par $n - 1$ au lieu de n. Ce détail change le résultat, et il est au cœur de la pratique quotidienne.

Définition

La **variance d'échantillon** (*sample variance*) se calcule en divisant par $n-1$ (et non n) ; cette correction porte le nom de **correction de Bessel** (*Bessel's correction*). Elle compense la sous-estimation systématique de la dispersion quand on utilise la moyenne de l'échantillon à la place de la vraie moyenne de la population.

$$s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2 \qquad s = \sqrt{s^2}$$

s^2 : variance de l'échantillon ; s : écart-type de l'échantillon
n : nombre de valeurs de l'échantillon
x_i : la i-ème valeur ; $\bar{x}$: moyenne de l'échantillon

Pourquoi $n-1$? On a déjà « dépensé » l'information des données pour calculer la moyenne $\bar{x}$: les écarts à $\bar{x}$ sont en moyenne un peu plus petits que les écarts à la vraie moyenne μ de la population. En divisant par n, on sous-estimerait donc systématiquement la dispersion réelle. Diviser par $n-1$ corrige ce biais. C'est pourquoi la plupart des logiciels statistiques — pandas et Excel compris — utilisent $n-1$ **par défaut**.

Tableau 3 — Population ou échantillon : deux formules, deux usages. En pratique, vos données sont presque toujours un échantillon.

Cas	Variance	Diviseur	Quand l'utiliser
Population	σ^2	N	Vous avez TOUTES les données de l'ensemble étudié
Échantillon	s^2	$n-1$	Vous généralisez à une population plus grande (cas le plus fréquent)

Exemple guidé — les mêmes 9 commandes, vues comme un échantillon

1. On reprend la somme des carrés des écarts : 36 (calculée en 4.11).
2. Traitées comme une **population** : $\sigma^2 = 36/9 = 4$ et $\sigma = 2$.
3. Traitées comme un **échantillon** : $s^2 = 36/8 = 4{,}5$ et $s = \sqrt{4{,}5} \approx 2{,}12$. La dispersion estimée est un peu plus grande : c'est le prix de l'incertitude.
4. **On choisit selon la question** : décrire ces 9 commandes → population ; estimer la dispersion de toutes les commandes de la boutique → échantillon.

À retenir

- Population : on divise par N. Échantillon : on divise par $n-1$ (correction de Bessel).
- Diviser par n sur un échantillon sous-estime la dispersion.
- Par défaut, les logiciels supposent un échantillon : vérifiez toujours quelle convention votre outil utilise.

4.13 La règle des 68-95-99,7

À quoi ressemble concrètement « un écart-type de 2 » ? Quand les données suivent une distribution en cloche — très fréquente en pratique — l'écart-type devient une véritable graduation de la réalité : des proportions connues de valeurs se situent à une, deux, trois fois l'écart-type de la moyenne.

Définition

La **règle des 68-95-99,7** (*empirical rule*) énonce que, pour une distribution en cloche (*distribution normale*, *normal distribution*), environ **68 %** des valeurs se situent à moins d'un écart-type de la moyenne, **95 %** à moins de deux, et **99,7 %** à moins de trois.

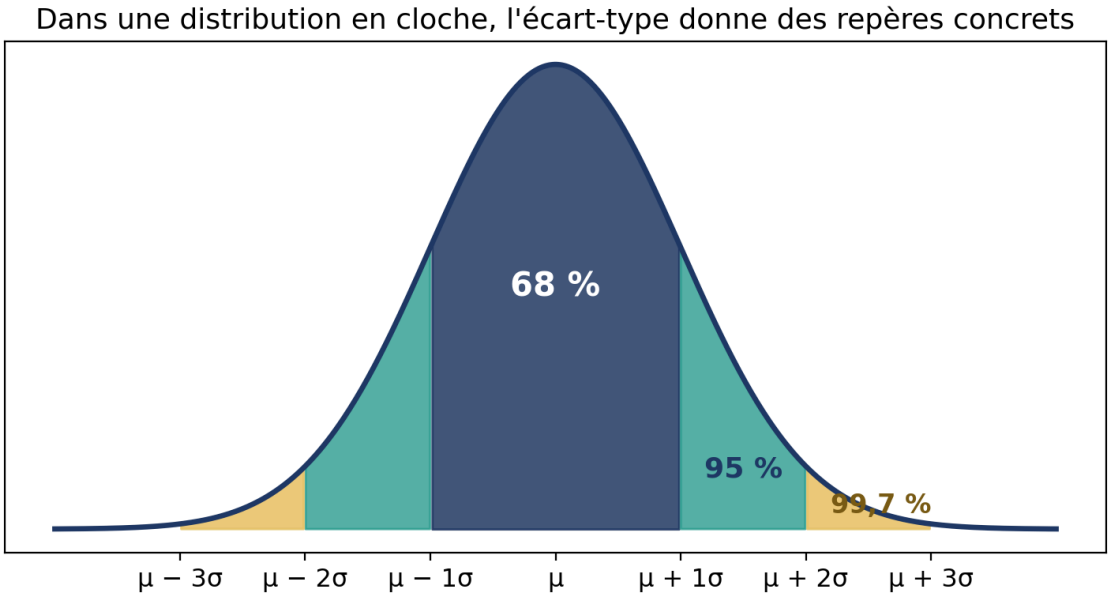


Figure 10 — La règle des 68-95-99,7 : chaque écart-type supplémentaire autour de la moyenne capture une part connue des données.

> **Analogie.** *L'écart-type est le « pas » de la distribution, comme le mètre est le pas du ruban d'un géomètre. La règle des 68-95-99,7 vous dit ce que couvre un, deux ou trois pas de part et d'autre du centre.*

Exemple guidé — délais de livraison en cloche

Les délais de livraison de Maison Léa suivent une distribution en cloche, de moyenne 3 jours et d'écart-type 1 jour.

1. **À ±1 σ** : environ 68 % des colis arrivent entre 2 et 4 jours.
2. **À ±2 σ** : environ 95 % arrivent entre 1 et 5 jours.
3. **Au-delà** : un délai de 8 jours est à 5 σ de la moyenne — extrêmement improbable. Si plusieurs colis affichent 8 jours, ce n'est pas « la faute du hasard » : il y a un incident à investiguer. C'est ainsi que l'écart-type sert de détecteur d'anomalies.

À retenir

- Distribution en cloche : ≈ 68 % des valeurs à ±1 σ, ≈ 95 % à ±2 σ, ≈ 99,7 % à ±3 σ.
- Une valeur à plus de 2-3 σ de la moyenne est rare : elle mérite votre attention.
- La règle suppose une distribution en cloche ; elle ne s'applique pas aux distributions très asymétriques (section 4.17).

4.14 Quartiles, écart interquartile et valeurs aberrantes

L'écart-type souffre du même défaut que la moyenne : les valeurs extrêmes le gonflent. Il existe une famille d'indicateurs qui les ignorent délibérément, en raisonnant sur les **positions** plutôt que sur les grandeurs : les quartiles.

Définition

Les **quartiles** (*quartiles*) découpent une série ordonnée en quatre parts de 25 % : **Q1** est la médiane de la moitié basse, **Q2** est la médiane, **Q3** la médiane de la moitié haute. L'**écart interquartile** (*interquartile range*, IQR) vaut $Q_3 - Q_1$: il contient les 50 % centraux des données. Une **valeur aberrante** (*outlier*) est une observation située très loin de la masse des données ; en pratique, on considère souvent comme aberrante toute valeur inférieure à $Q_1 - 1{,}5 \times \mathrm{IQR}$ ou supérieure à $Q_3 + 1{,}5 \times \mathrm{IQR}$.

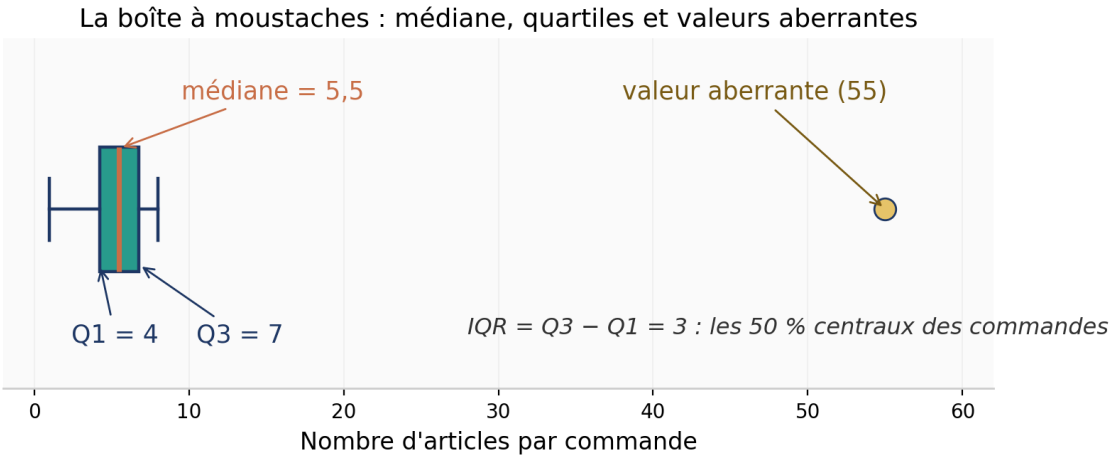


Figure 11 — La boîte à moustaches (*boxplot*) : la boîte contient les 50 % centraux, entre Q1 et Q3 ; le point isolé est une valeur aberrante.

Exemple guidé — quartiles des 10 commandes (avec la commande de 55 articles)

Série ordonnée : 1, 3, 4, 5, 5, 6, 6, 7, 8, 55.

1. **Médiane (Q2)** : moyenne des 5e et 6e valeurs : (5 + 6)/2 = 5,5.
2. **Q1** : médiane de la moitié basse (1, 3, 4, 5, 5) → 4. **Q3** : médiane de la moitié haute (6, 6, 7, 8, 55) → 7.
3. **IQR** = 7 − 4 = 3 : la moitié des commandes contient entre 4 et 7 articles — un résumé fidèle, insensible au « 55 ».
4. **Détection d'aberration** : seuil haut = Q3 + 1,5 × IQR = 7 + 4,5 = 11,5. La commande de 55 articles dépasse 11,5 : elle est **aberrante**, à traiter à part (erreur de saisie ? commande d'un grossiste ?).

En pratique dans le code

```
df["nb_articles"].quantile([0.25, 0.5, 0.75])   # Q1, mediane, Q3
df["nb_articles"].describe()                     # min, quartiles, moyenne, max d'un coup
```

À retenir

- Q1, médiane, Q3 partagent la série en quarts ; IQR = Q3 − Q1 = les 50 % centraux.
- L'IQR n'est pas sensible aux valeurs extrêmes : il représente mieux la dispersion « ordinaire » des données.
- Règle pratique : aberrant = en dehors de $[Q_1 - 1{,}5 \times \mathrm{IQR}\,;\, Q_3 + 1{,}5 \times \mathrm{IQR}]$.

4.15 Dispersions robustes : écart absolu moyen et MAD

Entre l'écart-type (sensible aux extrêmes) et l'IQR (qui ignore la moitié des données), il existe des mesures intermédiaires, dites **robustes** : elles tiennent compte de toutes les valeurs sans laisser les extrêmes prendre le pouvoir.

Définition

L'**écart absolu moyen** (*mean absolute deviation*) est la moyenne des distances absolues entre chaque valeur et la moyenne de la série. Le **MAD** (*median absolute deviation*) est la médiane des distances absolues à la médiane : c'est une mesure de dispersion robuste, insensible aux valeurs aberrantes. Attention : ce ne sont **pas** des variantes de l'écart-type — ils ne mettent pas les écarts au carré.

$$\text{EAM} = \frac{1}{n}\sum_{i=1}^{n}|x_i - \bar{x}|$$

EAM : écart absolu moyen, dans l'unité des données
n : nombre de valeurs ; x_i : la i-ème valeur
$\bar{x}$: moyenne de la série ; $|\,|$: valeur absolue

Lecture : comme pour la variance, on mesure l'écart de chaque valeur à la moyenne — mais au lieu de l'élever au carré, on prend sa valeur absolue (sa distance, sans le signe), puis on fait la moyenne de ces distances. Pas de carré : les grandes valeurs ne pèsent donc pas démesurément, et le résultat reste dans l'unité des données.

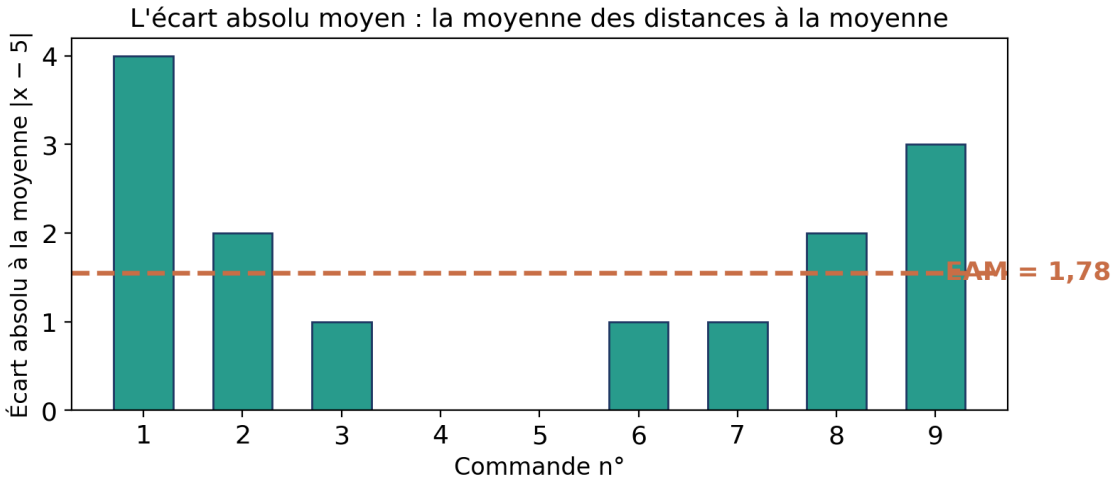


Figure 12 — L'écart absolu moyen de nos 9 commandes : les distances à la moyenne (barres) valent en moyenne 1,78 article.

Exemple guidé — EAM des 9 commandes

1. **Écarts à la moyenne (5)** : −4, −2, −1, 0, 0, +1, +1, +2, +3.
2. **Valeurs absolues** : 4, 2, 1, 0, 0, 1, 1, 2, 3. On fait cela pour compter une distance comme une distance, quel que soit le côté.
3. **Moyenne** : $(4+2+1+0+0+1+1+2+3)/9 = 14/9 \approx 1{,}78$ article. Comparez à l'écart-type (2) : l'EAM est toujours inférieur ou égal à l'écart-type, car il n'amplifie pas les grands écarts.

Et le MAD ? Même logique, tout en médianes : écarts absolus à la médiane (5) : 4, 2, 1, 0, 0, 1, 1, 2, 3 → triés : 0, 0, 1, 1, 1, 2, 2, 3, 4 → MAD = 1. Ajoutez la commande de 55 articles : le MAD ne bouge presque pas, l'écart-type explose. C'est toute la différence entre robuste et non robuste.

À retenir

- EAM : moyenne des distances absolues à la moyenne. MAD : médiane des distances absolues à la médiane.
- Pas de carrés → moins sensibles aux valeurs aberrantes que la variance et l'écart-type.
- EAM ≠ écart-type : deux mesures de dispersion, deux philosophies (carrés vs distances).

4.16 Comparer des dispersions : le coefficient de variation

Un écart-type de 200 g sur des colis de 2 kg, et un écart-type de 10 € sur des commandes de 20 € : quelle série est la plus dispersée ? Impossible à dire tel quel — les unités et les ordres de grandeur diffèrent. Il faut une mesure de dispersion **relative**, sans unité.

> **Définition**
>
> Le **coefficient de variation** (*coefficient of variation*, CV) est le rapport de l'écart-type à la moyenne, exprimé en pourcentage. Il mesure la dispersion *relative* et permet de comparer la variabilité de séries d'unités ou d'ordres de grandeur différents.

$$CV = \frac{\sigma}{\mu} \times 100$$

CV : coefficient de variation, en %
σ : écart-type de la série
μ : moyenne de la série (dans la même unité que σ)

Lecture : on divise la dispersion (σ) par le niveau moyen (μ), puis on multiplie par 100 pour obtenir un pourcentage. Le CV répond à la question : « la dispersion représente quelle part du niveau moyen ? » Un CV de 10 % signifie que les valeurs s'écartent typiquement de 10 % de la moyenne.

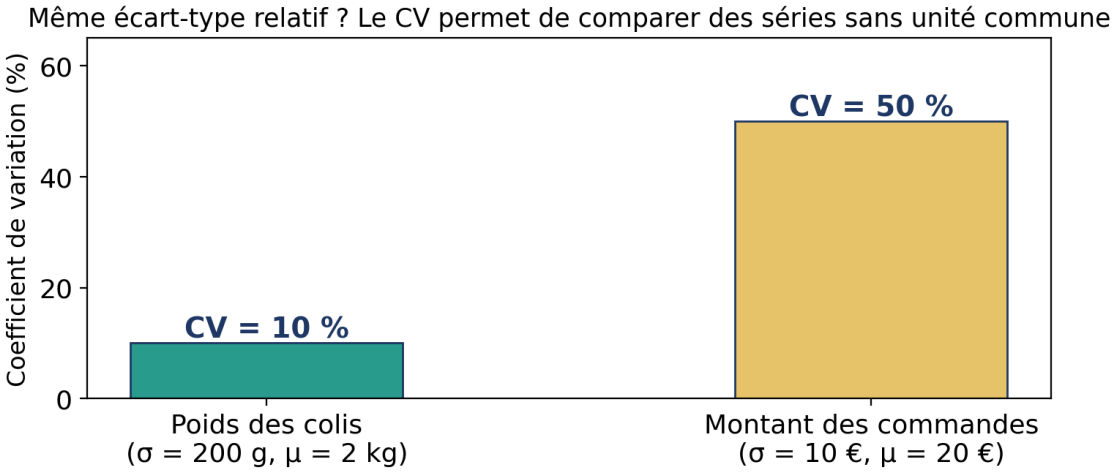


Figure 13 — Le poids des colis varie proportionnellement moins (CV = 10 %) que le montant des commandes (CV = 50 %).

Exemple guidé — colis réguliers ou paniers réguliers ?

1. **Poids des colis** : $\sigma = 200$ g, $\mu = 2\,000$ g → $CV = 200/2\,000 \times 100 = 10\,\%$. On met d'abord les deux nombres dans la même unité (grammes) : c'est indispensable.
2. **Montants des commandes** : $\sigma = 10$ €, $\mu = 20$ € → $CV = 10/20 \times 100 = 50\,\%$.
3. **Conclusion** : les montants sont cinq fois plus dispersés *relativement à leur niveau*. Sans le CV, comparer « 200 » et « 10 » n'aurait eu aucun sens.

À retenir

- CV = (écart-type ÷ moyenne) × 100, en % : la dispersion ramenée au niveau de la série.
- Il sert à comparer la variabilité de séries aux unités ou ordres de grandeur différents.
- Il perd son sens si la moyenne est proche de zéro (on diviserait par presque rien).

4.17 La forme d'une distribution : l'asymétrie

Jusqu'ici, vous savez localiser le centre et mesurer l'étalement. Reste une question : la distribution est-elle **symétrique**, ou s'étale-t-elle davantage d'un côté ? Pour un data analyst, c'est crucial : sur une distribution asymétrique, moyenne et médiane se séparent — et la « moyenne » peut devenir trompeuse.

Définition

L'**asymétrie** (*skewness*) d'une distribution mesure si les données se répartissent symétriquement autour du centre ou s'étalent davantage d'un côté. Les **coefficients d'asymétrie de Pearson** la quantifient à partir de la moyenne, du mode (ou de la médiane) et de l'écart-type : $Sk = \frac{\bar{x} - M_o}{\sigma}$ (basé sur le mode) ou $Sk = \frac{3(\bar{x} - \text{médiane})}{\sigma}$ (basé sur la médiane). Si $Sk > 0$: asymétrie positive, étalée vers la droite. Si $Sk = 0$: distribution symétrique. Si $Sk < 0$: asymétrie négative, étalée vers la gauche.

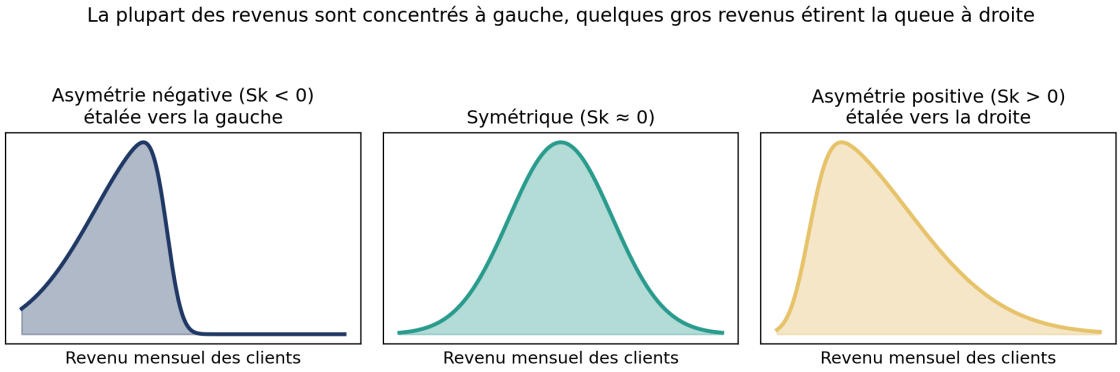


Figure 14 — Trois formes de distribution. Les revenus des clients ressemblent typiquement à la courbe de droite : une masse à gauche, quelques très gros revenus qui étirent la queue à droite.

Analogie. *Imaginez un château de sable : la symétrie, c'est un monticule parfait. L'asymétrie positive, c'est quand le sable « coule » en une longue traînée vers la droite — le sommet (le mode) reste à gauche, mais quelques pellets lointains tirent le centre de gravité (la moyenne) vers la droite.*

Exemple guidé — lire l'asymétrie des revenus clients

Sur les revenus mensuels des clients de Maison Léa : moyenne = 2 400 €, médiane = 2 100 €, écart-type = 900 €.

1. **On compare moyenne et médiane** : la moyenne (2 400) dépasse la médiane (2 100) → des valeurs élevées tirent la moyenne vers le haut → asymétrie **positive**.
2. **On calcule le coefficient de Pearson** : $Sk = 3 \times (2\,400 - 2\,100)/900 = 3 \times 300/900 = 1$. Nettement positif : distribution étalée vers la droite.
3. **On adapte la communication** : pour décrire le client « typique », on citera la médiane (2 100 €), plus représentative que la moyenne gonflée par quelques très gros revenus.

À retenir

- $Sk > 0$: queue à droite, moyenne > médiane > mode. $Sk < 0$: queue à gauche, ordre inversé. $Sk = 0$: symétrie.
- Distribution asymétrique → privilégier la médiane pour décrire le centre.
- Repérer l'asymétrie avant de choisir ses indicateurs fait partie de l'exploration systématique.

4.18 Deux variables ensemble : la covariance

Une analyse rarement porte sur une seule colonne. La vraie richesse commence quand on croise deux variables : le temps passé sur le site influence-t-il le montant du panier ? La première mesure du lien entre deux variables quantitatives est la covariance.

> **Définition**
>
> La **covariance** (*covariance*) mesure le sens dans lequel deux variables quantitatives évoluent conjointement : positive si elles augmentent ensemble, négative si l'une augmente quand l'autre diminue, proche de zéro s'il n'y a pas de tendance d'ensemble.

$$\mathrm{Cov}(X,Y) = \frac{1}{n}\sum_{i=1}^{n}(x_i - \mu_X)(y_i - \mu_Y)$$

$\mathrm{Cov}(X,Y)$: covariance de X et Y, en unité de X × unité de Y
x_i, y_i : i-èmes valeurs de X et Y, mesurées sur la même observation
μ_X, μ_Y : moyennes de X et Y
n : nombre d'observations

Lecture : pour chaque observation, on multiplie son écart à la moyenne de X par son écart à la moyenne de Y. Quand les deux écarts ont le même signe (valeurs au-dessus ou en dessous de leur moyenne en même temps), le produit est positif ; quand ils sont de signes opposés, il est négatif. La covariance est la moyenne de ces produits : son **signe** dit le sens du lien, mais sa **grandeur** dépend des unités — c'est sa limite, que la corrélation (section suivante) va corriger.

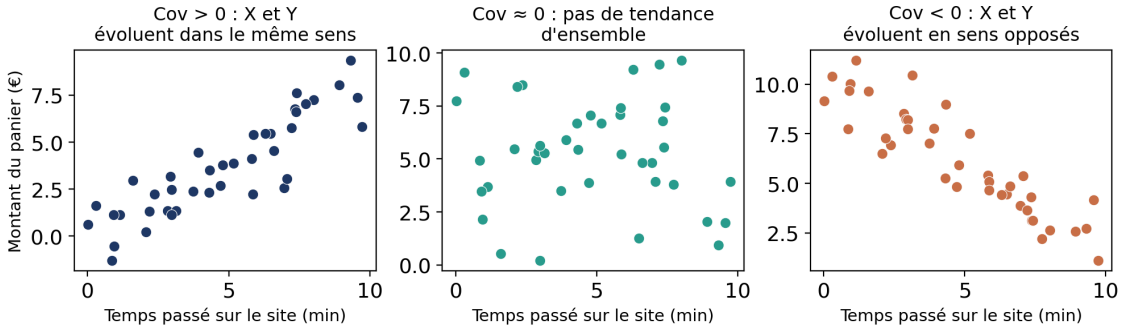


Figure 15 — Le signe de la covariance se lit dans la pente d'ensemble du nuage de points.

Exemple guidé — temps sur le site et montant du panier (5 commandes)

Temps (min) : 2, 4, 5, 7, 8 — Montant (€) : 20, 35, 25, 45, 40.

1. **Moyennes** : $\mu_X = 26/5 = 5{,}2$ min ; $\mu_Y = 165/5 = 33$ €.
2. **Écarts et produits** : $(2-5{,}2)(20-33) = (-3{,}2)(-13) = +41{,}6$; $(-1{,}2)(+2) = -2{,}4$; $(-0{,}2)(-8) = +1{,}6$; $(+1{,}8)(+12) = +21{,}6$; $(+2{,}8)(+7) = +19{,}6$. Notez le produit négatif : le deuxième client a dépensé plus que la moyenne en restant moins longtemps — son produit « tire » la covariance vers le bas.
3. **Covariance** : $(41{,}6 - 2{,}4 + 1{,}6 + 21{,}6 + 19{,}6)/5 = 82/5 = +16{,}4$. **Positive** : plus un client reste, plus il a tendance à dépenser. Mais « 16,4 min·€ » n'a pas d'interprétation directe : il nous faudra la corrélation pour mesurer la force du lien.

En pratique dans le code

```
df["temps_site"].cov(df["montant"])   # covariance (par defaut : n-1)
```

À retenir

- Covariance positive : les variables évoluent dans le même sens ; négative : en sens opposés ; ≈ 0 : pas de tendance d'ensemble.
- Son signe s'interprète ; sa grandeur, non (elle dépend des unités).
- Les deux variables doivent être mesurées sur les **mêmes** observations.

4.19 Le coefficient de corrélation de Pearson

La covariance dit « dans quel sens », mais pas « à quel point ». Pour mesurer la force du lien, on la normalise : on la ramène dans l'intervalle $[-1 ; 1]$, quelles que soient les unités. C'est le coefficient de corrélation de Pearson — probablement l'indicateur le plus cité de toute la data analyse.

Définition

Le **coefficient de corrélation de Pearson** (*Pearson correlation coefficient*, noté r) est la covariance normalisée par le produit des écarts-types de X et Y. Compris entre -1 et 1, il mesure la **force et le sens de la relation linéaire** entre deux variables quantitatives : $r = 1$ relation linéaire positive parfaite ; $r = -1$ relation linéaire négative parfaite ; $r = 0$ absence de relation *linéaire*.

$$r = \frac{\mathrm{Cov}(X, Y)}{\sigma_X \times \sigma_Y}$$

r : coefficient de corrélation de Pearson, sans unité, dans $[-1 ; 1]$
$\mathrm{Cov}(X, Y)$: covariance de X et Y
σ_X, σ_Y : écarts-types de X et Y

Lecture : en divisant la covariance par les deux écarts-types, on retire l'effet des unités et des dispersions propres à chaque variable. Il ne reste que la « pureté » de la relation linéaire. Plus $|r|$ est proche de 1, plus les points s'alignent sur une droite ; plus il est proche de 0, plus le nuage est informe.

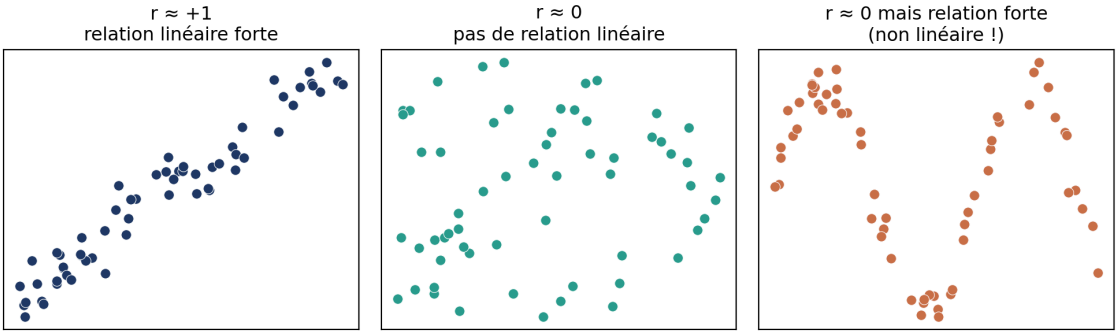


Figure 16 — Attention au troisième cas : $r \approx 0$ alors qu'une relation forte existe — mais elle n'est pas linéaire. La corrélation de Pearson ne voit que les relations en ligne droite.

Exemple guidé — quantifier le lien temps / panier

On reprend les 5 commandes de la section 4.18 : $\mathrm{Cov}(X, Y) = 16{,}4$ (en version population).

1. **Écarts-types** : $\sigma_X = \sqrt{4{,}56} \approx 2{,}14$ min et $\sigma_Y = \sqrt{86} \approx 9{,}27$ € (calculés comme en 4.11, division par n).
2. **Corrélation** : $r = 16{,}4 / (2{,}14 \times 9{,}27) \approx 16{,}4 / 19{,}8 \approx 0{,}83$.
3. **Interprétation** : $r \approx 0{,}83$ est une corrélation positive forte : le temps passé sur le site et le montant du panier sont nettement liés. **Mais** — et c'est le réflexe le plus important du cours — cela ne prouve pas que rester plus longtemps *fait dépenser* plus : corrélation n'est pas causalité (section 5).

En pratique dans le code

```
df["temps_site"].corr(df["montant"])   # correlation de Pearson
df.corr(numeric_only=True)             # matrice de correlation de toutes les colonnes
```

À retenir

- $r \in [-1\,;\,1]$: le signe donne le sens, la valeur absolue donne la force de la relation linéaire.
- $r \approx 0$ n'exclut pas une relation non linéaire : regardez toujours le nuage de points.
- Corrélation ≠ causalité : un lien mesuré n'est pas une preuve d'influence.

5. Erreurs fréquentes et pièges

Voici les cinq pièges dans lesquels tombent presque tous les débutants — et le réflexe qui permet de les éviter.

Piège 1 — Décrire avec la moyenne une série pleine de valeurs extrêmes

Erreur. Annoncer « panier moyen : 30 € » alors que la moitié des clients dépense moins de 23,50 € et qu'une commande géante a gonflé la moyenne.

Pourquoi c'est faux. La moyenne utilise toutes les valeurs : une valeur extrême la tire à elle et la déconnecte de la réalité vécue par la majorité.

Réflexe correct. Comparer systématiquement moyenne et médiane. Si elles divergent fortement, citer la médiane et signaler la présence de valeurs extrêmes.

Piège 2 — Calculer une moyenne sur une variable qualitative

Erreur. Calculer la « moyenne des villes » ou la « moyenne des codes postaux ».

Pourquoi c'est faux. Les catégories ne sont pas des quantités ; le code postal est un numéro d'étiquette, pas une mesure — sa « moyenne » ne veut rien dire.

Réflexe correct. Avant tout calcul, identifier le type de la variable. Sur une qualitative : effectifs, proportions, mode — rien d'autre.

Piège 3 — Diviser par n sur un échantillon

Erreur. Calculer la variance d'un échantillon en divisant par n, parce que « c'est la formule de la moyenne ».

Pourquoi c'est faux. Sur un échantillon, diviser par n sous-estime systématiquement la dispersion de la population : on a déjà utilisé les données pour calculer $\bar{x}$, ce qui réduit artificiellement les écarts.

Réflexe correct. Échantillon → diviser par $n - 1$ (correction de Bessel). Vérifier la convention par défaut de l'outil utilisé.

Piège 4 — Conclure « corrélation = causalité »

Erreur. « $r = 0{,}8$ entre temps passé sur le site et montant du panier, donc faire rester les clients plus longtemps les fera dépenser plus. »

Pourquoi c'est faux. Deux variables peuvent évoluer ensemble parce qu'une troisième variable les influence toutes les deux (un client déjà décidé à acheter reste plus longtemps *et* dépense plus), ou par pur hasard.

Réflexe correct. Dire « les variables sont liées », jamais « l'une cause l'autre ». La causalité demande d'autres méthodes (expérimentations, tests A/B).

Piège 5 — Croire qu'un écart-type faible garantit l'absence de valeurs aberrantes

Erreur. « L'écart-type est petit, donc toutes les données sont propres et proches de la moyenne. »

Pourquoi c'est faux. L'écart-type résume une dispersion globale : une série peut être concentrée *et* contenir une valeur aberrante isolée. De plus, un r ou un écart-type seul ne dit rien de la forme de la distribution.

Réflexe correct. Compléter les indicateurs par l'IQR, la règle des 1,5 × IQR pour traquer les aberrations, et toujours regarder un graphique des données.

6. Exercices

Faites ces exercices **sans relire le cours** : c'est en vous testant que vous ancrerez les notions. Le corrigé détaillé se trouve en toute fin de document.

6.1 Auto-évaluation

Question 1 (QCM). La variable « taille de vêtement » (S, M, L, XL) est : a) quantitative discrète ; b) qualitative nominale ; c) qualitative ordinale ; d) quantitative continue.

Question 2 (Vrai/Faux). La moyenne est moins sensible aux valeurs aberrantes que la médiane.

Question 3 (réponse courte). En une phrase, quelle différence entre statistique descriptive et statistique inférentielle ?

Question 4 (QCM). On divise la somme des carrés des écarts par $n - 1$ plutôt que n quand : a) les données sont une population ; b) les données sont un échantillon ; c) la série a un nombre pair de valeurs ; d) la moyenne est négative.

Question 5 (Vrai/Faux). Un coefficient de corrélation $r = 0$ prouve qu'il n'existe aucune relation entre les deux variables.

Question 6 (réponse courte). Citez deux mesures de dispersion peu sensibles aux valeurs aberrantes.

Question 7 (QCM). Si le coefficient d'asymétrie vaut $Sk > 0$, alors : a) la distribution est symétrique ; b) la queue s'étale vers la gauche et la moyenne est inférieure à la médiane ; c) la queue s'étale vers la droite et la moyenne dépasse généralement la médiane ; d) il n'y a pas de mode.

Question 8 (réponse courte). Dans une distribution en cloche, quelle proportion approximative des valeurs se situe à moins de deux écarts-types de la moyenne ?

6.2 Application guidée

Exercice 1 — Bilan complet d'une série (avec étapes)

Voici les montants (en €) de 10 commandes passées un lundi chez Maison Léa : 12, 15, 18, 20, 22, 25, 28, 30, 35, 95.

Étape 1. Vérifiez que la série est ordonnée, puis calculez la moyenne.

Étape 2. La série compte 10 valeurs : déterminez la médiane (moyenne des deux valeurs centrales).

Étape 3. Calculez l'étendue.

Étape 4. Calculez la variance *en traitant ces commandes comme un échantillon*, puis l'écart-type.

Étape 5. Calculez Q1, Q3 et l'IQR, puis testez si la commande de 95 € est aberrante avec la règle des 1,5 × IQR.

Étape 6. Moyenne et médiane divergent-elles ? Quel indicateur citeriez-vous à la direction, et pourquoi ?

Exercice 2 — Trier les variables (avec étapes)

Pour chaque variable du fichier clients : *ville*, *satisfaction* (déçu / neutre / ravi), *code_postal*, *nb_commandes*, *poids_colis_moyen*, *montant_total*.

Étape 1. Pour chaque variable, demandez-vous : « les valeurs sont-elles des quantités sur lesquelles calculer a un sens ? » Sinon : qualitative.

Étape 2. Pour les qualitatives, demandez-vous : « les catégories ont-elles un ordre naturel ? »

Étape 3. Pour les quantitatives, demandez-vous : « compte-t-on (discrète) ou mesure-t-on (continue) ? »

Étape 4. Attention au *code_postal* : il est écrit en chiffres… mais est-ce une quantité ?

6.3 Application autonome

Exercice 3 — Comparer deux campagnes marketing

Maison Léa compare les paniers issus de deux campagnes. Campagne A : moyenne 45 €, écart-type 15 €. Campagne B : moyenne 120 €, écart-type 30 €, médiane 100 €.

a) Quelle campagne produit les paniers les plus réguliers *relativement à leur niveau* ? Justifiez avec le bon indicateur.

b) Pour la campagne B, comparez moyenne et médiane : que déduisez-vous sur la forme de la distribution ? Calculez le coefficient d'asymétrie de Pearson basé sur la médiane.

c) Quel indicateur de centre citeriez-vous pour décrire le panier « typique » de la campagne B ?

Exercice 4 — Exercice entrelacé : audit express d'un fichier de commandes

On vous confie un extrait de 8 commandes. Variables : *ville*, *avis* (déçu / neutre / ravi), *nb_articles* : 2, 3, 3, 4, 5, 5, 6, 40 ; *temps_site* (min) ; *montant* (€). On vous indique que la corrélation de Pearson entre *temps_site* et *montant* vaut 0,85.

a) Classez les cinq variables (type et sous-type).

b) Pour *nb_articles* : calculez la moyenne, la médiane et l'étendue. Que remarquez-vous ?

c) La commande de 40 articles est-elle aberrante selon la règle des 1,5 × IQR ?

d) Interprétez $r = 0{,}85$. Peut-on affirmer que « rester plus longtemps sur le site fait dépenser plus » ?

e) Rédigez en deux phrases la synthèse que vous enverriez à la direction.

7. Fiche récapitulative

Le cours condensé en une page, à réviser seul et régulièrement.

Vocabulaire et types de données

- **Jeu de données** = observations (lignes) × variables (colonnes). Toujours identifier ce que représente une ligne.
- **Descriptive** : décrire les données qu'on a. **Inférentielle** : généraliser d'un échantillon à la population, avec incertitude.
- **Population** = le tout ; **échantillon** = la partie observée. Échantillon → variance divisée par $n-1$.
- **Qualitative** : nominale (sans ordre) ou ordinale (ordonnée). **Quantitative** : discrète (on compte) ou continue (on mesure).

Indicateurs et formules

Tableau 4 — Les indicateurs du cours, leur usage et leur point de vigilance.

Indicateur	Formule	Usage	Vigilance
Moyenne $\bar{x}$	$\frac{1}{n}\sum x_i$	Centre « équitable »	Sensible aux extrêmes
Médiane	valeur centrale (série ordonnée)	Centre robuste	50 % / 50 %, pas de grandeur
Mode	valeur la plus fréquente	Centre, même sur qualitatif	Peut ne pas exister / être multiple
Étendue	$\max - \min$	Dispersion rapide	Ne voit que les extrêmes
Variance σ^2 / s^2	$\frac{1}{N}\sum(x_i-\mu)^2$; échantillon : $\div(n-1)$	Dispersion (calcul)	Unité au carré
Écart-type σ / s	$\sqrt{\text{variance}}$	Dispersion interprétable	Sensible aux extrêmes
IQR	$Q_3 - Q_1$	Dispersion robuste (50 % centraux)	Ignore la moitié des données
Aberrant si	hors $[Q_1 - 1{,}5\,\text{IQR} ; Q_3 + 1{,}5\,\text{IQR}]$	Détection d'anomalies	Règle pratique, pas une loi
EAM / MAD	moyenne / médiane des distances (abs.)	Dispersions robustes	≠ écart-type
CV	$\sigma/\mu \times 100$	Comparer des dispersions (en %)	Moyenne proche de 0 → inutilisable
Asymétrie Sk	$3(\bar{x} - \text{médiane})/\sigma$	Forme de la distribution	$Sk > 0$: queue à droite
Corrélation r	$\text{Cov}(X,Y)/(\sigma_X\sigma_Y)$	Force du lien linéaire, dans [−1 ; 1]	≠ causalité ; aveugle au non-linéaire

Repères et fonctions

- Règle 68-95-99,7 (distribution en cloche) : ≈ 68 % à ±1 σ, 95 % à ±2 σ, 99,7 % à ±3 σ.
- Ordre sous asymétrie positive : mode < médiane < moyenne.
- Code : `df.mean()`, `df.median()`, `df.mode()`, `df.std()` ($n-1$ par défaut), `df.quantile()`, `df.describe()`, `df.corr()`.

8. Pour aller plus loin *(optionnel)*

- **Les distributions de probabilité** : la règle des 68-95-99,7 vient de la « loi normale ». Le prochain cours formalisera distributions et probabilités, qui ouvrent la porte à la statistique inférentielle.
- **Visualiser les distributions** : histogrammes et boîtes à moustaches sont les compagnons visuels des indicateurs de ce cours — un indicateur ne remplace jamais un graphique.
- **Question ouverte** : dans l'exercice 3, la campagne B a un panier moyen plus élevé mais plus irrégulier. Si vous étiez directeur marketing, laquelle choisiriez-vous — et quel rôle joue le risque dans votre choix ?
- **Corrélation et causalité** : le site *spurious correlations* (tylervigen.com) collectionne des corrélations parfaites et absurdes — un excellent détox contre le piège n° 4.

Corrigé détaillé des exercices

Auto-évaluation

1. c) Qualitative ordinale : ce sont des catégories (pas des quantités) dotées d'un ordre naturel (S < M < L < XL), mais l'écart entre deux tailles n'est pas mesurable.

2. Faux. C'est la médiane qui est peu sensible aux valeurs aberrantes : elle ne dépend que des positions. La moyenne, qui intègre toutes les grandeurs, est emportée par les extrêmes.

3. La statistique descriptive résume les données qu'on possède ; la statistique inférentielle généralise à une population entière à partir d'un échantillon, en quantifiant l'incertitude.

4. b) Quand les données sont un échantillon : la correction de Bessel ($n - 1$) compense la sous-estimation de la dispersion due à l'utilisation de la moyenne de l'échantillon.

5. Faux. $r = 0$ signifie seulement l'absence de relation *linéaire*. Une relation forte mais non linéaire (par exemple en U ou en cloche) peut donner $r \approx 0$.

6. L'écart interquartile (IQR) et le MAD (écart absolu à la médiane). L'EAM, lui, reste plus sensible aux extrêmes que ces deux-là car il s'appuie sur la moyenne.

7. c) $Sk > 0$: asymétrie positive — la queue s'étale vers la droite et la moyenne dépasse généralement la médiane, elle-même au-dessus du mode.

8. Environ 95 %.

Application guidée

Exercice 1. Série déjà ordonnée : 12, 15, 18, 20, 22, 25, 28, 30, 35, 95.

- **Étape 1.** Somme = 300 → moyenne $\bar{x} = 300/10 = 30$ €.
- **Étape 2.** Valeurs centrales : 5e = 22 et 6e = 25 → médiane = 23,50 €.
- **Étape 3.** Étendue = 95 − 12 = 83 €.
- **Étape 4.** Écarts à 30 : −18, −15, −12, −10, −8, −5, −2, 0, +5, +65. Carrés : 324, 225, 144, 100, 64, 25, 4, 0, 25, 4 225 → somme = 5 136. Échantillon : $s^2 = 5\,136/9 \approx 570{,}7$ €² ; $s = \sqrt{570{,}7} \approx 23{,}9$ €.
- **Étape 5.** Moitié basse (12, 15, 18, 20, 22) → Q1 = 18. Moitié haute (25, 28, 30, 35, 95) → Q3 = 30. IQR = 12. Seuil haut = 30 + 1,5 × 12 = 48. Or 95 > 48 : la commande de 95 € est **aberrante**.
- **Étape 6.** Moyenne (30 €) > médiane (23,50 €) : la commande aberrante gonfle la moyenne. On citera la **médiane** à la direction, en signalant la présence d'une commande atypique à investiguer.

Exercice 2.

- *ville* : qualitative nominale (catégories sans ordre).
- *satisfaction* : qualitative ordinale (ordre déçu < neutre < ravi, écarts non mesurables).
- *code_postal* : qualitative nominale — c'est une étiquette écrite en chiffres ; une « moyenne de codes postaux » ne veut rien dire.
- *nb_commandes* : quantitative discrète (on compte).
- *poids_colis_moyen* : quantitative continue (on mesure).
- *montant_total* : quantitative continue (mesure arrondie au centime, traitée comme continue).

Application autonome

Exercice 3.

- a) CV(A) = 15/45 × 100 ≈ 33 % ; CV(B) = 30/120 × 100 = 25 %. La campagne B est plus régulière *relativement à son niveau*, malgré un écart-type plus grand en valeur absolue.
- b) Moyenne (120 €) > médiane (100 €) : des paniers élevés tirent la moyenne vers le haut → asymétrie positive. $Sk = 3 \times (120 - 100)/30 = 2$: asymétrie marquée.
- c) La médiane (100 €), plus représentative du panier typique sur une distribution asymétrique.

Exercice 4.

- a) *ville* : qualitative nominale ; *avis* : qualitative ordinale ; *nb_articles* : quantitative discrète ; *temps_site* : quantitative continue ; *montant* : quantitative continue.
- b) Série ordonnée : 2, 3, 3, 4, 5, 5, 6, 40. Moyenne = 68/8 = 8,5 articles ; médiane = (4 + 5)/2 = 4,5 ; étendue = 40 − 2 = 38. La moyenne (8,5) est très au-dessus de la médiane (4,5) : la commande de 40 articles gonfle tout — moyenne et étendue.
- c) Moitié basse (2, 3, 3, 4) → Q1 = 3 ; moitié haute (5, 5, 6, 40) → Q3 = 5,5 ; IQR = 2,5. Seuil haut = 5,5 + 1,5 × 2,5 = 9,25. Or 40 > 9,25 : la commande est **aberrante**.
- d) $r = 0{,}85$: forte relation linéaire positive — clients qui restent longtemps ont tendance à dépenser plus. Mais on ne peut pas conclure à la causalité : une variable cachée (intention d'achat préalable) peut expliquer les deux.
- e) Exemple de synthèse : « Une commande typique contient 4 à 5 articles (médiane 4,5) ; une commande exceptionnelle de 40 articles fausse la moyenne et doit être vérifiée. Le temps passé sur le site est fortement lié au montant dépensé ($r = 0{,}85$), ce qui en fait un signal à suivre — sans prouver pour autant un lien de cause à effet. »