FORMATION DATA ANALYST

Lire les distributions : familles de lois, simulation et hasard d'échantillonnage

À l'issue de ce cours, vous saurez lire une distribution en entier, reconnaître les grandes familles de lois et comprendre pourquoi deux échantillons d'une même population ne se ressemblent jamais tout à fait.

Cours 2

Novembre 2026

Sommaire

1. Objectifs d'apprentissage 3
2. Prérequis et rappels 3
3. Pourquoi c'est important 3
4. Corps du cours 3
    4.1 La grille de lecture : quatre questions 4
    4.2 L'histogramme et le choix des classes 5
    4.3 Effectif, fréquence, densité : l'aire comme proportion 6
    4.4 La famille normale : la somme des petites causes 7
    4.5 La famille lognormale : les facteurs qui se multiplient 8
    4.6 La famille exponentielle : les temps d'attente 10
    4.7 Les mélanges de distributions 11
    4.8 De la forme au mécanisme : une hypothèse, pas une preuve 12
    4.9 La loi binomiale : compter des succès 13
    4.10 La loi de Poisson : compter des événements 14
    4.11 Échantillon observé et modèle théorique 15
    4.12 La probabilité de queue : une fréquence au-delà d'un seuil 16
    4.13 Valeur inhabituelle ou erreur : décider avec une règle 17
    4.14 La variation d'échantillonnage 18
    4.15 La graine aléatoire et la reproductibilité 19
    4.16 La stabilisation avec l'effectif 20
    4.17 Le théorème central limite 21
5. Erreurs fréquentes et pièges 23
6. Exercices 23
7. Fiche récapitulative 24
8. Pour aller plus loin 26
Corrigé détaillé des exercices 26

1. Objectifs d'apprentissage

À l'issue de ce cours, vous saurez :

- **Lire** une distribution complète — effectif, centre, dispersion, forme, valeurs extrêmes — en nommant toujours le groupe et l'unité d'observation ;
- **Identifier** la famille de distribution plausible d'une variable (normale, lognormale, exponentielle, binomiale, Poisson, mélange) et la relier au mécanisme qui a produit les données ;
- **Distinguer** l'échantillon observé du modèle théorique, et **calculer** une probabilité de queue comme fréquence observée avec le bon dénominateur ;
- **Expliquer** la variation d'échantillonnage, **garantir** la reproductibilité d'une simulation par la graine aléatoire, et **énoncer** le théorème central limite.

2. Prérequis et rappels

Prérequis. Ce cours suppose que vous avez validé le cours 1 : savoir typer une variable, calculer et interpréter moyenne, médiane, écart-type et écart interquartile, et distinguer population et échantillon.

Rappels utiles ici. La moyenne est sensible aux valeurs extrêmes, la médiane y résiste : quand elles s'écartent, la distribution est probablement asymétrique. L'écart-type mesure la dispersion autour de la moyenne, dans l'unité des données ; l'écart interquartile (IQR) donne la largeur des 50 % centraux, sans être influencé par les extrêmes. Sur une distribution en cloche, la règle des 68-95-99,7 situe l'essentiel des valeurs à une ou deux unités d'écart-type du centre. Enfin, un même fichier peut être une population entière ou un échantillon : tout dépend de la question posée.

3. Pourquoi c'est important

Imaginez : vous êtes analyste dans un musée. La direction vous demande si les visites « durent en moyenne plus longtemps cette année ». Vous ouvrez le fichier des durées de visite et vous calculez une moyenne : 78 minutes. Réponse expédiée ? Pas si vite. En traçant l'histogramme, vous découvrez une bosse étrange vers 105 minutes — qui s'explique par les visites guidées, mélangées aux visites autonomes. La « distribution » que vous décriviez n'existait pas : c'étaient deux distributions superposées. Sans lecture de la forme, votre réponse à la direction aurait été à la fois exacte et trompeuse.

L'inverse est tout aussi dangereux. Un service support compare ses canaux : les durées de résolution ont l'air « différentes » entre téléphone et chat. Différence réelle, ou simple hasard du tirage ? Deux échantillons d'une même population ne se ressemblent jamais exactement — savoir combien ils peuvent différer par pur hasard est la compétence qui sépare une découverte d'une illusion. Toute la statistique inférentielle, que vous aborderez au cours 4, repose sur ce que vous allez construire ici.

Enfin, les données réelles suivent souvent des « familles » reconnaissables. Reconnaître qu'une durée ressemble à une loi lognormale, qu'un nombre de tickets par heure ressemble à une loi de Poisson, ce n'est pas un exercice de style : cela vous dit quels indicateurs oser présenter, quelles valeurs extrêmes attendre, et quelles questions poser au métier. Ce cours vous apprend à lire ces silhouettes — avec la discipline de ne jamais les prendre pour des preuves.

4. Corps du cours

Tout au long de ce cours, vous suivrez deux fils conducteurs, inspirés de situations réelles : les **durées de visite d'un musée** (600 visites chronométrées, en minutes) et les **tickets d'un service support** (environ 600 tickets par canal — téléphone, chat, e-mail — avec leur durée de résolution). Chaque concept sera d'abord démontré sur ces données, puis généralisé.

CHAPITRE A — LIRE UNE DISTRIBUTION

4.1 La grille de lecture : quatre questions

Au cours 1, vous avez appris à calculer un centre, une dispersion, une forme. Ces outils ne sont efficaces que si vous les utilisez dans un ordre stable, sans jamais oublier de quoi vous parlez. Face à n'importe quelle distribution, posez-vous quatre questions, toujours les mêmes :

1. **Combien ?** Quel est l'effectif analysable — et de quel groupe, de quelle unité d'observation s'agit-il ?
2. **Où ?** Où se situe le centre (moyenne, médiane) ?
3. **Combien ça varie ?** Quelle dispersion (écart-type, IQR, étendue) ?
4. **Quelle silhouette ?** Symétrie, asymétrie, queues, pics, trous, valeurs isolées ?

> **Définition — la grille de lecture d'une distribution.** On appelle **grille de lecture** l'examen ordonné d'une distribution selon quatre dimensions : l'**effectif** (combien de lignes, dans quel groupe), le **centre**, la **dispersion** et la **forme**. Toute comparaison entre distributions doit garder visibles le **groupe** comparé et l'**unité d'observation** (*unit of observation*) : « la durée médiane des tickets résolus par le canal chat », pas « la médiane » tout court.

Pourquoi tant de discipline ? Parce que le centre seul raconte une histoire incomplète. Regardez les deux lots de la figure 1 : quatre valeurs chacun, même moyenne de 4. Pourtant personne ne dirait que ces lots « se ressemblent ».

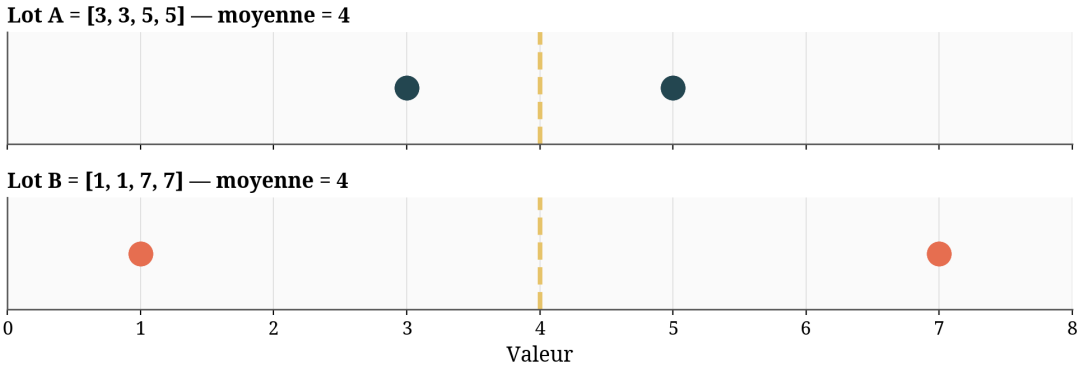


Figure 1 : Les lots A et B ont la même moyenne (4), mais pas la même dispersion : la moyenne seule ne décrit pas une distribution.

> **Analogie — le bilan de santé.** Un médecin ne conclut jamais sur un seul chiffre. Il regroupe plusieurs « constantes » : température, tension, rythme cardiaque. Votre grille de lecture fait la même chose pour une distribution : quatre mesures simples qui, ensemble, brossent un portrait fidèle.

Exemple guidé — lire le résumé du canal « phone ».

La responsable support vous transmet le résumé du canal téléphone : n = 599 tickets, moyenne 89,7 min, médiane 90,2 min, écart-type 18,0 min, Q1 = 78,6 min, Q3 = 101,1 min, maximum 147,2 min.

1. **Combien ?** 599 tickets résolus par téléphone — l'unité est le ticket, le groupe est le canal « phone ».
2. **Où ?** Centre autour de 90 min. Moyenne et médiane sont presque égales (89,7 contre 90,2) : pas d'asymétrie marquée, parce qu'aucune valeur extrême ne tire la moyenne.
3. **Combien ça varie ?** Écart-type de 18 min : la plupart des tickets se résolvent entre 72 et 108 min (le centre ± 1 écart-type). L'IQR de 22,5 min confirme un cœur resserré.
4. **Quelle silhouette ?** Le maximum (147 min) reste à moins de 3,2 écarts-types du centre : rien de choquant, mais on le vérifiera sur l'histogramme.

Conclusion rédigée pour la responsable : « Sur 599 tickets téléphone, la résolution dure typiquement 90 minutes, le plus souvent entre 79 et 101 minutes, sans valeur vraiment inhabituelle. »

À retenir

- Quatre questions, dans l'ordre : effectif, centre, dispersion, forme.
- Le centre seul ne suffit jamais : deux distributions de même moyenne peuvent être très différentes.
- Toute phrase de synthèse nomme le groupe, l'unité et l'indicateur.

4.2 L'histogramme et le choix des classes

L'histogramme est votre premier regard sur une variable quantitative. On découpe l'étendue des valeurs en intervalles — les **classes** (*bins*) — et on compte combien d'observations tombent dans chacune. Ce découpage est un choix, pas une propriété des données.

Définition — la classe d'un histogramme. Une **classe** (*bin*) est un intervalle de valeurs dans lequel on regroupe les observations pour les compter. La **largeur de classe** (*bin width*) fixe la finesse du découpage : des classes larges lissent, des classes étroites détaillent.

La figure 2 montre les mêmes 600 visites du musée, dessinées deux fois. À gauche, 10 classes : la silhouette en cloche apparaît nettement. À droite, 55 classes : le dessin devient dentelé, le bruit de détail prend le dessus. Les lignes du fichier n'ont pas changé d'un micron — seul le découpage a changé.

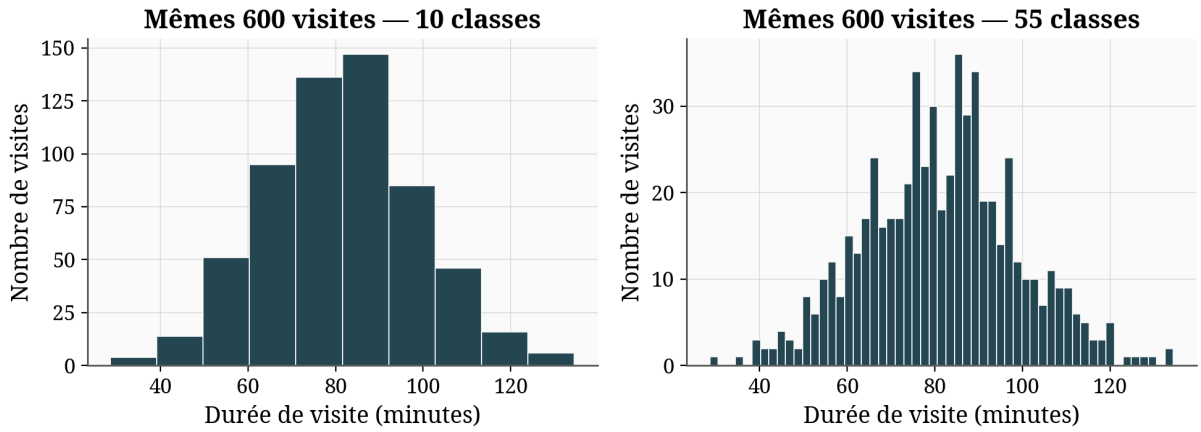


Figure 2 : Les classes changent le dessin, pas les données. Une forme robuste reste visible sous plusieurs découpages raisonnables.

Analogie — le zoom d'une photo. Choisir la largeur des classes, c'est comme régler le zoom d'une carte. Trop loin, vous ne voyez qu'une tache uniforme ; trop près, vous comptez les pavés et vous perdez le plan de la ville. Le bon réglage est celui qui laisse voir la structure.

Exemple guidé — prédire avant de tracer.

Avant même d'exécuter le code, entraînez-vous à prédire. On vous annonce : « 600 durées de visite, moyenne 82 min, écart-type 18 min ».

1. **Prédisez l'effet de 10 classes.** L'étendue va de 30 à 135 min environ : chaque classe couvrira une dizaine de minutes. Avec 600 visites, les barres seront hautes et la silhouette lisse.
2. **Prédisez l'effet de 55 classes.** Chaque classe ne couvre plus que 2 minutes : une douzaine de visites par barre en moyenne. Le dessin sera irrégulier, avec des creux et des bosses dus au hasard.
3. **Vérifiez sur la figure 2** : les deux prédictions se confirment. La cloche centrée vers 80 min est visible dans les deux versions — c'est elle, la forme robuste.

Le réflexe professionnel : quand une « bosse » disparaît en changeant légèrement le découpage, c'était du bruit, pas de la structure.

En pratique dans le code

```
import matplotlib.pyplot as plt
plt.hist(durees, bins=10)   # 10 classes
plt.hist(durees, bins=55)   # 55 classes, mêmes données
```

À retenir

- Un histogramme = des classes + des comptages. Le découpage est un choix de présentation.
- Classes trop larges : la forme est écrasée. Classes trop étroites : le bruit prend le dessus.
- Une forme réelle survit à un changement raisonnable de découpage.

4.3 Effectif, fréquence, densité : l'aire comme proportion

Deux histogrammes peuvent avoir exactement la même silhouette et pourtant ne pas dire la même chose : tout dépend de ce que mesure l'axe vertical. Trois conventions existent, et se tromper de convention fausse toutes les lectures chiffrées.

Définition — trois échelles verticales. Pour une classe donnée, l'**effectif** (*count*) est le nombre d'observations dans la classe ; la **fréquence** (*frequency*) est la part des observations, soit l'effectif divisé par l'effectif total ; la **densité** (*density*) est la fréquence divisée par la largeur de la classe. En densité, **l'aire d'une barre — pas sa hauteur — vaut la proportion** des observations dans la classe, et l'aire totale de l'histogramme vaut 1.

$$d = \frac{f}{h} = \frac{n_c}{n \cdot h}$$

- d : hauteur de la barre en densité (par unité de la variable)
- f : fréquence de la classe (proportion, entre 0 et 1)
- h : largeur de la classe (dans l'unité de la variable, ici en minutes)
- n_c : effectif de la classe
- n : effectif total

Cette formule dit simplement : la hauteur en densité s'obtient en étalant la proportion de la classe sur sa largeur. Conséquence capitale : proportion = hauteur × largeur. Une barre de hauteur 0,012 par minute sur une classe de 10 minutes représente 0,012 × 10 = 12 % des observations.

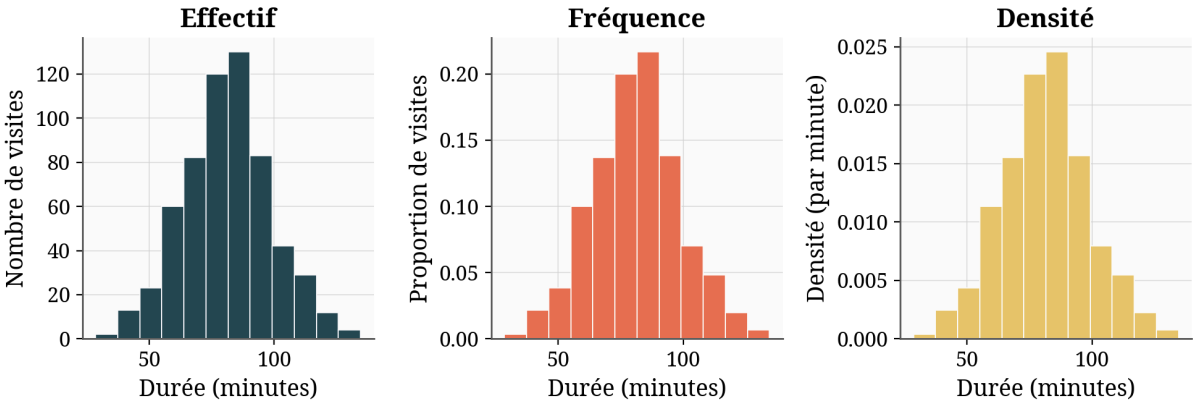


Figure 3 : Les mêmes 600 visites avec les trois échelles verticales. La silhouette est identique ; seules les graduations changent.

Analogie — la vitesse et la distance. La densité est à la proportion ce que la vitesse est à la distance : rouler à 50 km/h ne dit pas quelle distance vous avez parcourue — il faut multiplier par le temps. De même, une hauteur de 0,012 par minute ne dit pas quelle proportion la barre contient — il faut multiplier par sa largeur.

Exemple guidé — calculer une hauteur en densité.

Dans le fichier des 600 visites, la classe de 72,7 à 81,5 minutes contient 120 visites. Calculons sa hauteur dans les trois échelles.

1. **Effectif.** Hauteur = 120 visites. Direct.
2. **Fréquence.** Hauteur = 120 / 600 = 0,20, soit 20 % des visites.
3. **Densité.** La classe mesure 81,5 − 72,7 = 8,8 minutes de large. Hauteur = 0,20 / 8,8 ≈ 0,023 par minute. Vérification : 0,023 × 8,8 ≈ 0,20 — l'aire redonne bien la proportion.

Le réflexe : **lisez l'axe vertical avant d'interpréter la moindre hauteur.**

> **En pratique dans le code**
>
> ```
> plt.hist(durees, bins=12)                  # effectif (défaut)
> plt.hist(durees, bins=12, density=True)    # densité : l'aire vaut 1
> ```

> **À retenir**
>
> - Effectif = combien ; fréquence = quelle part ; densité = quelle part par unité.
> - En densité, la proportion d'une classe est l'**aire** de sa barre : hauteur × largeur.
> - Premier geste devant un histogramme : lire l'étiquette de l'axe vertical.

CHAPITRE B — LES FAMILLES DE DISTRIBUTIONS ET LEURS MÉCANISMES

4.4 La famille normale : la somme des petites causes

Certaines formes reviennent si souvent dans les données qu'on leur a donné des noms. La plus célèbre est la cloche symétrique — vous l'avez déjà rencontrée au cours 1 avec la règle des 68-95-99,7. Derrière cette silhouette se cache un mécanisme précis, et c'est lui qu'il faut retenir.

> **Définition — la loi normale.** La **loi normale** (*normal distribution*, aussi dite *gaussienne*) est une famille de distributions continues, symétriques et en cloche, entièrement décrite par deux paramètres : son centre μ (la moyenne) et son étalement σ (l'écart-type). Elle apparaît typiquement quand une valeur résulte de la **somme de nombreuses petites causes indépendantes** qui s'ajoutent les unes aux autres.

Le mécanisme est la clé. La durée de résolution d'un ticket téléphone, par exemple, résulte de dizaines de petites contributions qui s'ajoutent : le temps de compréhension de la demande, la recherche dans la base, la rédaction de la réponse, les interruptions… Chacune ajoute ou retire quelques minutes, indépendamment des autres. Le total s'accumule autour d'un centre : la plupart des tickets atterrissent près de la moyenne, et les écarts importants deviennent vite rares — d'où la cloche.

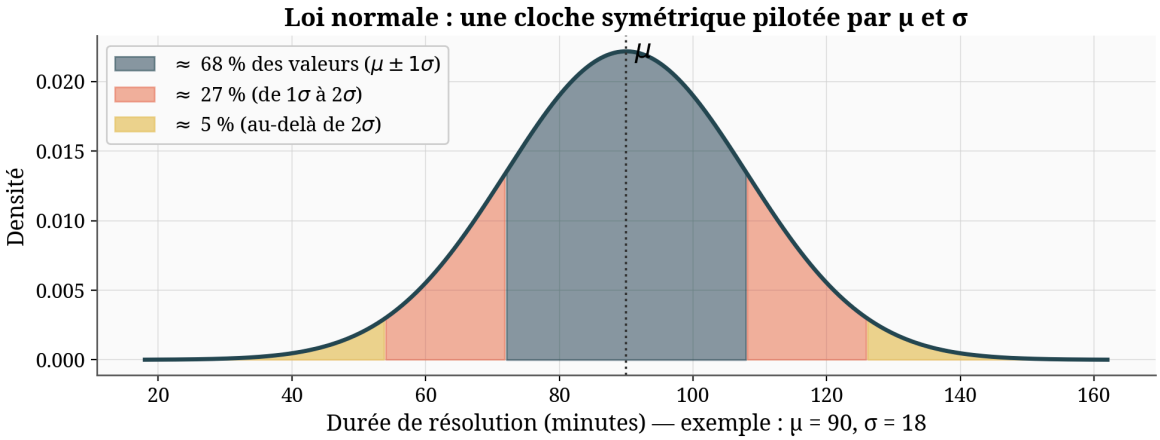


Figure 4 : La loi normale : une cloche symétrique. Avec μ = 90 min et σ = 18 min, environ 68 % des valeurs tombent entre 72 et 108 min.

> **Analogie — la recette de cuisine.** Le temps total pour préparer un plat est une somme : éplucher, cuire, assaisonner, dresser. Aucune étape ne domine ; chacune ajoute sa petite variation. C'est pour cela que vos temps de préparation, d'un jour à l'autre, dessinent une cloche autour de la durée habituelle — et pas une forme biscornue.

Exemple guidé — reconnaître la normale dans le canal « phone ».

1. **Signature du centre.** Moyenne 89,7 min ≈ médiane 90,2 min : le centre est partagé de façon équilibrée, indice de symétrie.
2. **Signature de la règle 68-95.** μ ± 1σ donne [71,7 ; 107,7] : sur le fichier, 71 % des tickets sont dans cette fourchette — très proche du 68 % théorique. μ ± 2σ donne [53,7 ; 125,7] : on y trouve 96 % des tickets, proche des 95 % attendus.
3. **Le mécanisme colle-t-il ?** Une résolution téléphonique est bien une somme de petites étapes indépendantes. Oui.
4. **Conclusion honnête.** « Une loi normale de centre 90 et d'écart 18 est un modèle plausible pour ce canal. » Plausible — pas prouvé : la section 4.8 y reviendra.

> **À retenir**
>
> - Normale = cloche symétrique, paramétrée par μ et σ ; moyenne ≈ médiane.
> - Mécanisme typique : la somme de nombreuses petites causes additives indépendantes.
> - La règle des 68-95-99,7 (cours 1) est la carte d'identité de cette famille.

4.5 La famille lognormale : les facteurs qui se multiplient

Beaucoup de grandeurs positives — revenus, prix immobiliers, durées de réparation — présentent le même profil : un gros paquet de valeurs modérées, puis une longue traîne de valeurs élevées. Cette silhouette a un nom, et un mécanisme très différent de la normale.

> **Définition — la loi lognormale.** La **loi lognormale** (*lognormal distribution*) est une famille de distributions continues, strictement positives et asymétriques à droite : la **queue droite** (*right tail*) étire quelques grandes valeurs loin du centre. Elle apparaît quand une valeur résulte du **produit de nombreux facteurs multiplicatifs positifs**. Sa signature statistique : mode < médiane < moyenne, parce que la queue tire la moyenne vers le haut sans déplacer la médiane.

Le mécanisme change tout. Un ticket chat traîne parce que les facteurs se *multiplient* : le client met deux fois plus de temps à décrire son problème, la recherche prend une fois et demie le temps prévu, la réponse doit être reformulée… Une succession de facteurs 2 × 1,5 × 1,3 fait exploser la durée, alors qu'une somme de petits retards l'aurait à peine allongée. C'est pourquoi la lognormale produit ces queues longues : quelques dossiers accumulent les facteurs défavorables.

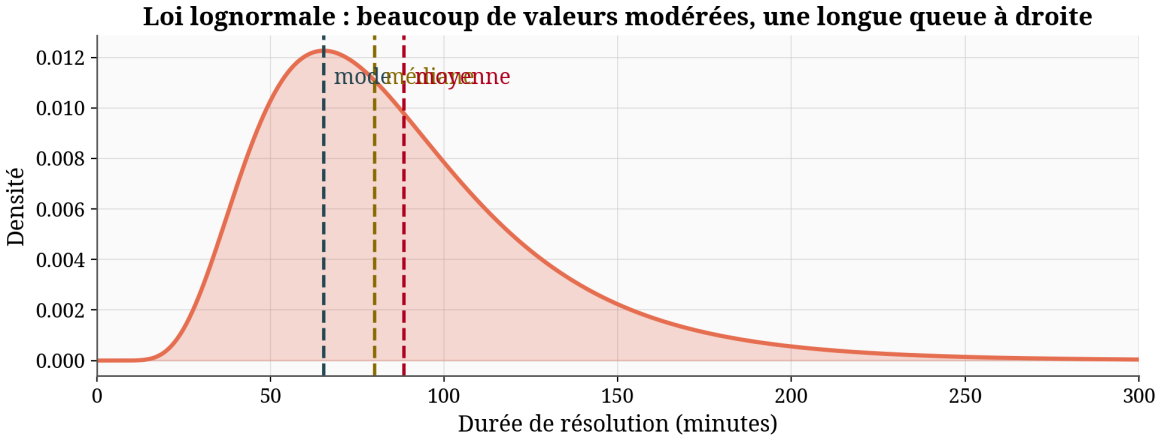


Figure 5 : La loi lognormale : beaucoup de valeurs modérées, quelques valeurs très grandes. Notez l'ordre mode < médiane < moyenne.

> **Analogie — les intérêts composés.** Un capital placé grandit par multiplications successives : × 1,05 chaque année. Deux placements qui partent pareil peuvent finir très loin l'un de l'autre, parce que les écarts se multiplient au lieu de s'additionner. La lognormale est la loi des grandeurs qui croissent « en pourcentage d'elles-mêmes ».

Exemple guidé — reconnaître la lognormale dans le canal « chat ».

1. **Signature du centre.** Moyenne 86,1 min, médiane 78,0 min : la moyenne dépasse nettement la médiane — la queue droite la tire.
2. **Signature de la dispersion.** Écart-type de 42,2 min, énorme par rapport à la médiane ; maximum à 296,9 min, soit presque 4 fois la médiane. L'IQR (47,4 min) reste modeste : le cœur est resserré, la traîne est longue.
3. **Le mécanisme colle-t-il ?** Un échange chat enchaîne des facteurs qui se multiplient (complexité du problème × réactivité du client × nombre de reformulations). Oui.
4. **Conséquence métier.** Pour ce canal, présenter la moyenne seule à un décideur serait trompeur : la médiane (78 min) décrit mieux le ticket « typique », et la queue se mesure séparément — c'est l'objet de la section 4.12.

> **En pratique dans le code**

```
import numpy as np
rng = np.random.default_rng(42)
x = rng.lognormal(mean=np.log(80), sigma=0.45, size=599)  # tirage lognormal
```

> **À retenir**

- Lognormale = valeurs positives, pic à gauche, longue queue à droite.
- Mécanisme typique : des facteurs qui se multiplient, pas qui s'additionnent.
- Signature : moyenne > médiane ; la médiane et l'IQR décrivent mieux le cœur.

4.6 La famille exponentielle : les temps d'attente

Dernière silhouette fréquente : une fréquence maximale tout au début, puis une décroissance régulière et longue. C'est la forme typique des **temps d'attente** : délai avant la prochaine panne, avant le prochain appel, avant la première réponse.

> **Définition — la loi exponentielle.** La **loi exponentielle** (*exponential distribution*) est une famille de distributions continues, positives, dont la densité décroît régulièrement depuis le départ. Elle modélise le **temps d'attente avant un événement** qui survient à **rythme constant** (*constant rate*) : la probabilité que l'événement arrive dans la prochaine minute ne dépend pas du temps déjà attendu — on dit que la loi est **sans mémoire** (*memoryless*).

Le mécanisme, ici, est un rythme. Les tickets e-mail arrivent et se traitent avec un délai minimal incompressible — le temps de lire et de qualifier la demande, disons 25 minutes — auquel s'ajoute une attente : certains dossiers trouvent leur réponse vite, d'autres attendent longtemps, et l'attente ne « use » pas le dossier : après deux heures, la chance d'être résolu dans la minute qui vient est la même qu'au début. On parle alors d'**exponentielle décalée** (*shifted exponential*) : 25 minutes + une exponentielle.

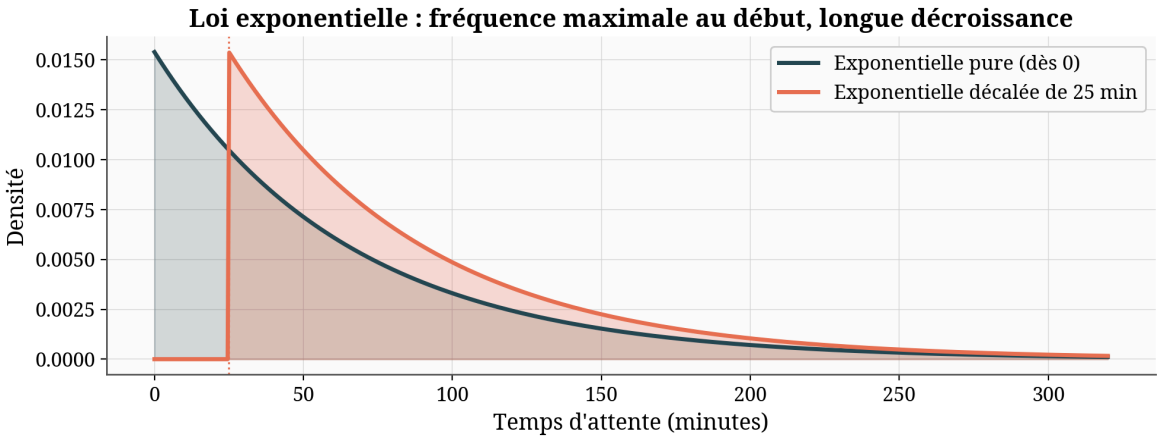


Figure 6 : La loi exponentielle : fréquence maximale au départ, longue décroissance. En pointillé, la version décalée : aucune valeur sous les 25 minutes.

> **Analogie — attendre le bus.** Si les bus passent « en moyenne toutes les 10 minutes » sans horaire fixe, attendre déjà depuis 20 minutes ne rapproche pas le prochain bus : chaque nouvelle minute a la même chance de le voir arriver. C'est exactement le « sans mémoire » de l'exponentielle.

Exemple guidé — reconnaître l'exponentielle dans le canal « e-mail ».

1. **Signature du centre.** Moyenne 89,3 min, médiane 66,4 min : un écart massif, encore plus marqué que pour la lognormale du chat.
2. **Signature du départ.** Minimum à 25,3 min : aucun ticket sous 25 minutes — l'indice d'un délai incompressible, donc d'une exponentielle *décalée*.
3. **Signature de la queue.** Maximum à 643,7 min : une traîne très longue reste plausible dans cette famille.
4. **Le mécanisme colle-t-il ?** Oui : qualification forfaitaire, puis attente à rythme à peu près constant.

> **En pratique dans le code**
>
> ```
> x = 25 + rng.exponential(scale=65, size=600)  # exponentielle décalée de 25 min
> ```

À retenir

- Exponentielle = décroissance régulière depuis le départ, valeurs positives.
- Mécanisme typique : temps d'attente à rythme constant, « sans mémoire ».
- Un plancher minimal dans les données suggère une version décalée.

4.7 Les mélanges de distributions

Il arrive qu'aucune des trois familles précédentes ne ressemble à votre histogramme : deux bosses, une épaule bizarre, un creux au milieu. Avant de chercher une loi exotique, posez la question la plus simple : **et si ce n'était pas une population, mais deux ?**

Définition — le mélange de distributions. Un **mélange de distributions** (*mixture distribution*) est la distribution obtenue quand des observations issues de **plusieurs sous-groupes distincts**, chacun avec sa propre distribution, sont analysées ensemble. Pics multiples, épaules ou queues inexpliquées en sont les indices typiques — et une variable de groupe ignorée en est souvent la cause.

Retour au musée. L'histogramme des 600 visites mélangées (figure 7, à gauche) montre une forme plutôt régulière, avec une bosse discrète sur l'épaule droite. Coloriez les mêmes lignes par type de visite (à droite) : tout s'explique. Les visites autonomes forment une grosse cloche autour de 72 minutes, les visites guidées une petite cloche vers 105 minutes, les groupes scolaires une cloche intermédiaire. La « bosse » n'était pas une anomalie : c'était un groupe.

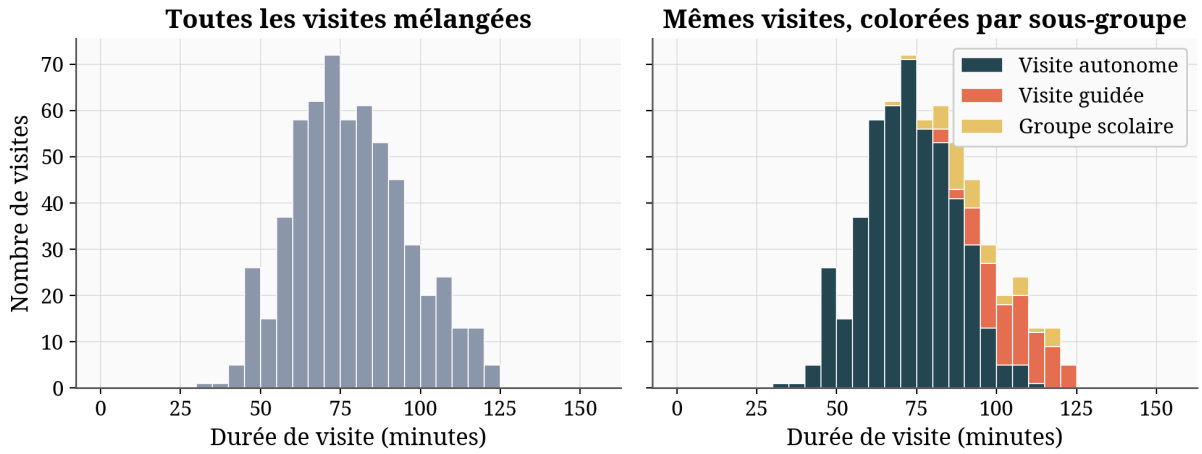


Figure 7 : Les mêmes 600 visites, mélangées puis séparées par type. Le mélange global cache trois populations de visiteurs.

Analogie — la soupe mixée. Mixez une soupe de poireaux avec une soupe de potiron : la couleur obtenue ne ressemble ni à l'une ni à l'autre, et aucun dosage ne la fera ressembler à une « soupe moyenne » qui existerait vraiment. Une moyenne calculée sur un mélange décrit un visiteur qui n'existe pas.

Exemple guidé — débusquer un mélange.

1. **Observez la forme.** Sur le mélange : moyenne 78,4 min, médiane 77,1 min — presque égales, donc « symétrique » en apparence. Mais la bosse vers 105 min dépasse du profil d'une cloche unique.
2. **Formulez l'hypothèse.** Une forme qui ne colle à aucune famille simple suggère un mélange. Quelle variable de groupe pourrait l'expliquer ? Le type de visite.
3. **Vérifiez en séparant.** Refaites l'histogramme par sous-groupe : trois cloches nettes apparaissent. L'hypothèse est confirmée.
4. **Décidez.** Tous les résumés se refont *par groupe* : « visite autonome : médiane 72 min » est une phrase utile ; « durée moyenne : 78 min » n'en est pas une.

À retenir

- Plusieurs pics ou une épaule inexpliquée : pensez mélange de sous-groupes.
- Le remède : trouver la variable de groupe et décrire chaque sous-groupe séparément.
- Un indicateur global calculé sur un mélange peut ne décrire personne.

4.8 De la forme au mécanisme : une hypothèse, pas une preuve

Vous savez maintenant reconnaître quatre silhouettes. Un avertissement professionnel s'impose avant d'aller plus loin, car c'est l'une des erreurs les plus fréquentes du métier : **reconnaître une forme ne prouve jamais la loi.**

Définition — l'hypothèse de modèle. Associer une famille de loi à une distribution observée est une **hypothèse de modèle** : une simplification utile qui sert à raisonner, pas une étiquette vraie collée sur les données. Elle se formule avec ses **hypothèses explicites** (mécanisme supposé, domaine de validité) et elle appelle une **vérification** auprès du métier : le processus qui produit les données correspond-il au mécanisme de la loi ?

La démarche correcte tient en trois temps : la silhouette suggère une famille ; la famille suggère un mécanisme ; le mécanisme se confronte à la réalité du terrain. Le tableau 1 résume les associations de ce cours et les vérifications qui les accompagnent.

Tableau 1 : De la forme observée à la vérification métier.

Silhouette observée	Famille suggérée	Mécanisme possible	Vérification à mener
Cloche symétrique	Normale	Somme de petites causes additives	Les causes sont-elles nombreuses, additives et sans cause dominante ?
Pic à gauche, queue droite	Lognormale	Facteurs multiplicatifs positifs	La grandeur croît-elle « en pourcentage d'elle-même » ?
Décroissance dès le départ	Exponentielle	Attente à rythme constant	Le rythme est-il stable ? Y a-t-il un plancher minimal ?
Plusieurs pics, épaule	Mélange	Plusieurs sous-groupes confondus	Existe-t-il une variable de groupe qui sépare les pics ?

Exemple guidé — formuler une hypothèse honnête.

Sur le canal chat, vous avez observé une queue droite (section 4.5). Rédiger l'hypothèse correctement, c'est écrire :

1. **Observation.** « La distribution des durées chat est asymétrique à droite (moyenne 86 min > médiane 78 min, max 297 min). »
2. **Hypothèse.** « Une lognormale est plausible : les durées chat pourraient résulter de facteurs multiplicatifs. »
3. **Vérification proposée.** « À confirmer avec l'équipe support : les dossiers longs cumulent-ils plusieurs facteurs de ralentissement ? »

Chaque phrase a un statut clair : ce qu'on voit, ce qu'on suppose, ce qu'il reste à vérifier.

À retenir

- Une silhouette suggère une question ; elle ne prouve jamais la loi.
- Le mécanisme vient avant la silhouette : contrôlez le domaine, la collecte, l'unité.
- Formulez toujours l'hypothèse avec sa vérification.

CHAPITRE C — LES LOIS DE COMPTAGE : BINOMIALE ET POISSON

Les familles du chapitre B décrivent des variables **continues** (des durées, des montants). Mais le métier d'analyste compte aussi : nombre d'achats, de pannes, de tickets par heure. Ces **variables de comptage** — des quantitatives discrètes, au sens du cours 1 — ont leurs propres familles. Les deux plus utiles suivent.

4.9 La loi binomiale : compter des succès

Parmi les 20 visiteurs du musée aujourd'hui, combien achèteront quelque chose à la boutique ? Chaque visiteur est un « essai » avec deux issues : achat ou pas d'achat. Si la probabilité d'achat est la même pour tous et que les visiteurs décident indépendamment, le nombre total d'achats suit une loi très documentée.

> **Définition — la loi binomiale.** La **loi binomiale** (*binomial distribution*) compte le nombre de **succès** obtenus en répétant n**essais identiques et indépendants**, chacun ayant la même probabilité p de succès (on parle d'*essais de Bernoulli*). Elle est entièrement décrite par deux paramètres : n (le nombre d'essais) et p (la probabilité de succès de chacun).

$$P(X = k) = \binom{n}{k} p^k \, (1-p)^{n-k}$$

- $P(X = k)$: probabilité d'obtenir exactement k succès
- n : nombre d'essais
- k : nombre de succès visé (de 0 à n)
- p : probabilité de succès d'un essai
- $\binom{n}{k}$: nombre de façons de choisir quels essais réussissent — lu « k parmi n » — qui vaut $\frac{n!}{k!\,(n-k)!}$, où $n!$ (« factorielle n ») est le produit $1 \times 2 \times \cdots \times n$

Lisez la formule comme un produit de trois idées. Le terme p^k est la probabilité que k essais précis réussissent ; le terme $(1-p)^{n-k}$, la probabilité que les $n-k$ autres échouent ; et le coefficient $\binom{n}{k}$ compte toutes les façons de répartir ces k succès parmi les n essais — car on ne se soucie pas de *quels* visiteurs achètent, seulement de *combien*. On retiendra aussi que l'espérance (la moyenne théorique) d'une binomiale vaut $n \times p$: avec 20 visiteurs et $p = 0{,}3$, on attend en moyenne 6 achats.

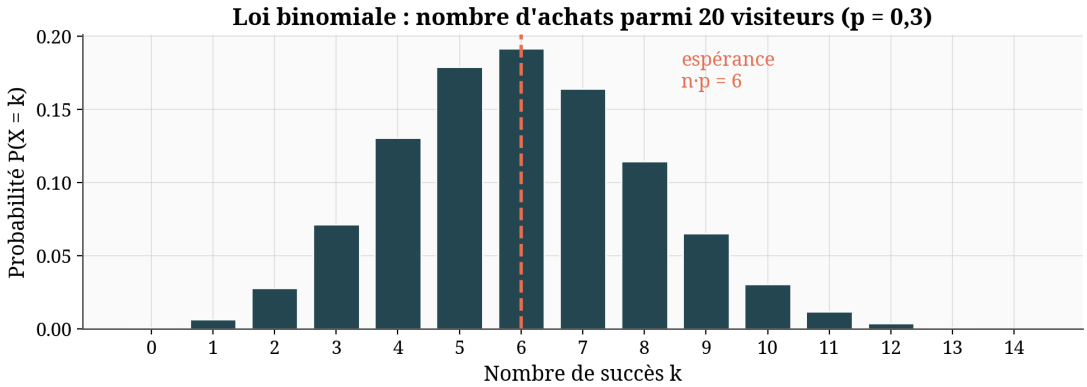


Figure 8 : La loi binomiale pour n = 20 et p = 0,3. Les valeurs probables se concentrent autour de l'espérance n × p = 6.

> **Analogie — le panier de free-throws.** Un joueur de basket tente 20 lancers francs, avec à chaque fois 30 % de réussite, sans que les tirs se fatiguent ou s'influencent. Le nombre de paniers marqués suit une binomiale : des essais identiques, indépendants, à deux issues.

Exemple guidé — la probabilité d'exactement 3 achats sur 10 visiteurs.

La boutique estime que 30 % des visiteurs achètent ($p = 0{,}3$). Sur un groupe de 10 visiteurs ($n = 10$), quelle est la probabilité qu'exactement 3 achètent ?

1. **Comptez les arrangements.** $\binom{10}{3} = \frac{10!}{3!\,7!} = 120$ façons de choisir quels 3 visiteurs achètent.
2. **Pondérez par les succès.** $p^3 = 0{,}3^3 = 0{,}027$.
3. **Pondérez par les échecs.** $(1-p)^7 = 0{,}7^7 \approx 0{,}0824$.
4. **Multipliez.** $P(X = 3) = 120 \times 0{,}027 \times 0{,}0824 \approx 0{,}267$. Soit environ **27 %** de chance — c'est l'issue la plus probable, logique puisque l'espérance vaut 3.

En pratique dans le code

```
from scipy import stats
stats.binom.pmf(3, n=10, p=0.3)   # 0.2668 : P(X = 3)
stats.binom.mean(n=10, p=0.3)     # 3.0 : espérance n × p
```

À retenir

- Binomiale = succès sur n essais identiques, indépendants, de probabilité p.
- Espérance : $n \times p$ — le nombre de succès « attendu ».
- Vérifiez les conditions avant d'utiliser la loi : essais identiques et indépendants.

4.10 La loi de Poisson : compter des événements

Autre comptage, autre situation : le standard reçoit des appels « en moyenne 4 par heure ». Il n'y a pas ici de nombre d'essais fixé — n'importe quel nombre d'appels est possible, de 0 à beaucoup. Ce qui est fixé, c'est le **rythme moyen** sur l'intervalle.

Définition — la loi de Poisson. La **loi de Poisson** (*Poisson distribution*) compte le nombre d'**événements** survenant dans un intervalle de temps (ou d'espace) fixé, quand ces événements arrivent **indépendamment les uns des autres**, à **rythme moyen constant** λ (*rate*, en événements par intervalle). Son paramètre unique λ est à la fois l'espérance et la variance de la loi.

$$P(X = k) = \frac{e^{-\lambda}\,\lambda^k}{k!}$$

- $P(X = k)$: probabilité d'observer exactement k événements
- λ : nombre moyen d'événements par intervalle
- k : nombre d'événements visé (0, 1, 2, …)
- e : constante mathématique ≈ 2,718 (base de l'exponentielle)
- $k!$: factorielle de k, soit $1 \times 2 \times \cdots \times k$

La formule compare chaque nombre d'événements possible au rythme moyen. Le terme λ^k grandit avec k, mais la factorielle au dénominateur grandit bien plus vite : c'est elle qui rend les gros nombres d'événements de plus en plus improbables. Le facteur $e^{-\lambda}$, lui, est la probabilité de n'observer *aucun* événement ($k = 0$) : avec $\lambda = 4$, une heure sans appel n'arrive qu'environ 1,8 % du temps.

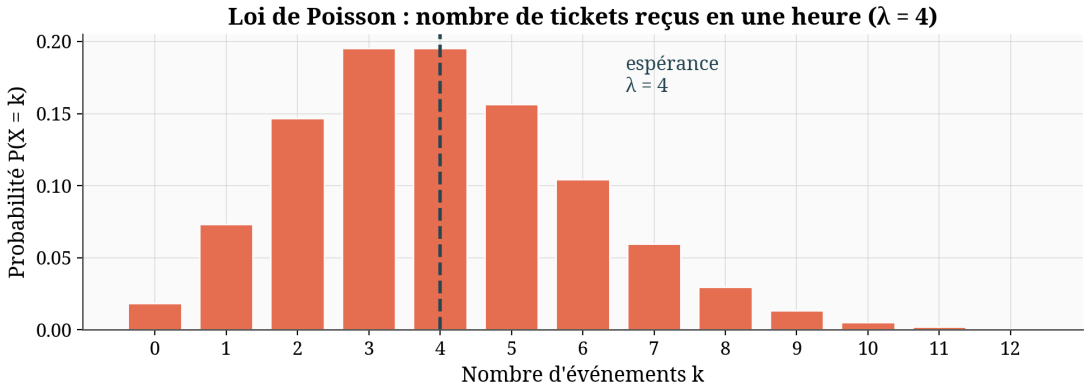


Figure 9 : La loi de Poisson pour λ = 4 : les heures à 3, 4 ou 5 appels dominent, mais 8 appels ou plus restent possibles.

> **Analogie — la pluie sur une dalle.** Comptez les gouttes qui tombent sur une dalle en une minute : elles arrivent au hasard, indépendamment, à un rythme moyen fixé par l'averse. Le nombre de gouttes suit une loi de Poisson — et une minute exceptionnellement chargée ne « fatigue » pas la pluie pour la minute suivante.

Exemple guidé — dimensionner une équipe.

Le standard reçoit en moyenne 4 appels par heure ($\lambda = 4$). Vous voulez la probabilité d'en recevoir exactement 6 une heure donnée — au-delà de 5, un seul agent est débordé.

1. **Écrivez la formule.** $P(X = 6) = \dfrac{e^{-4}\,4^6}{6!}$.
2. **Calculez chaque morceau.** $e^{-4} \approx 0{,}0183$; $4^6 = 4\,096$; $6! = 720$.
3. **Assemblez.** $P(X = 6) \approx \dfrac{0{,}0183 \times 4\,096}{720} \approx 0{,}104$, soit environ **10 %**.
4. **Lisez métier.** Une heure à 6 appels arrive environ une heure sur dix : ce n'est pas une anomalie, c'est à prévoir dans le dimensionnement de l'équipe.

> **En pratique dans le code**
>
> ```
> stats.poisson.pmf(6, mu=4)   # 0.1042 : P(X = 6) pour λ = 4
> ```

> **À retenir**
>
> - Poisson = événements indépendants dans un intervalle, à rythme moyen λ constant.
> - Un seul paramètre : λ, qui vaut à la fois la moyenne et la variance théoriques.
> - Binomiale ou Poisson ? Nombre d'essais fixé → binomiale ; rythme sur un intervalle → Poisson.

CHAPITRE D — ÉCHANTILLON, MODÈLE ET PROBABILITÉS OBSERVÉES

4.11 Échantillon observé et modèle théorique

Depuis le début de ce cours, vous manipulez deux objets sans les avoir distingués explicitement : d'un côté, des **lignes de données** — les 599 tickets du canal chat ; de l'autre, des **familles de lois** — la lognormale, la normale. Ces deux objets ne vivent pas dans le même monde, et les confondre est une source inépuisable d'erreurs de raisonnement.

Définition — échantillon observé contre modèle théorique. L'**échantillon observé** (*observed sample*) est l'ensemble fini des lignes réellement recueillies, avec ses effectifs, ses fréquences **empiriques** (*empirical*, c'est-à-dire mesurées sur les données) et ses statistiques. Le **modèle théorique** (*theoretical model*) est une construction mathématique — une famille de loi et ses **paramètres** — qui décrit le processus supposé avoir produit ces lignes. Le modèle permet de raisonner **au-delà des lignes observées** (prédire des fréquences pour des valeurs jamais vues), au prix d'**hypothèses explicites** et simplificatrices.

Tableau 2 : Deux objets, deux mondes — l'exemple du canal chat.

	Échantillon observé	Modèle théorique
Nature	599 lignes d'un fichier	Une famille (lognormale) et ses paramètres
Ce qu'il contient	Effectifs, fréquences empiriques, statistiques, figures	Probabilités théoriques, hypothèses, prédictions
Ses limites	Varie d'un tirage à l'autre ; ne montre que ce qui a eu lieu	Simplifie la réalité ; peut être faux
Son usage	Décrire ce qui s'est passé	Raisonner sur ce qui pourrait se passer

Analogie — la carte et le territoire. Une carte routière n'est pas le territoire : elle en est une simplification volontaire, qui omet les arbres et les nids-de-poule pour mieux guider. Le modèle est une carte du processus qui produit vos données : utile précisément parce qu'il simplifie — et dangereux si vous oubliez que ce n'est qu'une carte.

Exemple guidé — les deux objets sur le canal chat.

1. **Côté échantillon.** « Sur 599 tickets, la médiane est de 78,0 min et 22 tickets (3,7 %) ont dépassé 180 min. » Phrase 100 % descriptive, sans modèle.
2. **Côté modèle.** « Si l'on accepte une lognormale ajustée sur ces données, la probabilité théorique de dépasser 180 min est d'environ 4 %. » Phrase qui raisonne au-delà des lignes — sous une hypothèse explicite.
3. **Le lien.** Les deux chiffres se ressemblent : bon signe pour le modèle. Mais le premier existe même si le modèle est faux ; le second n'existe que si le modèle est accepté.

À retenir

- L'échantillon décrit le passé observé ; le modèle sert à raisonner au-delà, sous hypothèses.
- Un modèle est une simplification utile, jamais « l'étiquette vraie » des données.
- Fréquence empirique = comptée sur les lignes ; probabilité théorique = calculée par le modèle.

4.12 La probabilité de queue : une fréquence au-delà d'un seuil

« Quelle proportion de nos tickets dépasse 180 minutes ? » C'est une question de décideur : au-delà de ce seuil, le contrat de service est enfreint. Bonne nouvelle : pour y répondre, nul besoin de modèle. Il suffit de compter — avec le bon dénominateur.

Définition — la probabilité de queue empirique. La **probabilité de queue** (*tail probability*) au-delà d'un seuil est, dans sa version **empirique**, la **fréquence observée** des observations qui dépassent ce seuil : on compte les observations au-delà du seuil et on divise par l'effectif du groupe concerné. C'est une mesure de l'échantillon, qui ne suppose aucune loi théorique.

$$f_{\geq s} = \frac{n_{\geq s}}{n}$$

- $f_{\geq s}$: fréquence observée au-delà du seuil
- $n_{\geq s}$: nombre d'observations supérieures ou égales au seuil s
- n : effectif total du groupe étudié
- s : seuil (dans l'unité de la variable, ici 180 min)

La formule est un simple rapport, mais chaque mot du dénominateur compte : on divise par l'effectif *du groupe dont on parle*. La fréquence des tickets longs « du canal chat » se calcule sur les 599 tickets chat — pas sur les 1 798 tickets de tous canaux, qui mélangeraient des populations différentes.

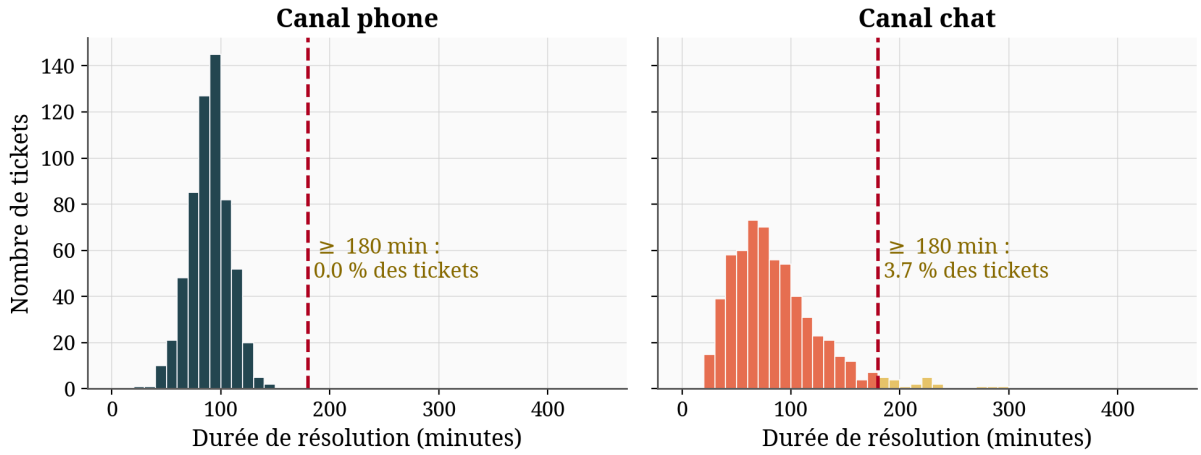


Figure 10 : Le même seuil de 180 minutes n'occupe pas la même position selon le canal : presque jamais atteint par téléphone, franchi dans 3,7 % des tickets chat.

Exemple guidé — comparer deux canaux au seuil de 180 minutes.

1. **Comptez dans chaque groupe.** Canal chat : 22 tickets ≥ 180 min sur 599. Canal e-mail : 51 sur 600.
2. **Divisez par le bon dénominateur.** Chat : 22 / 599 ≈ 3,7 %. E-mail : 51 / 600 = 8,5 %.
3. **Comparez à situation égale.** Les deux fréquences portent sur le même seuil et des effectifs proches : l'écart est parlant. Le risque de dépasser le seuil est plus de deux fois plus élevé par e-mail.
4. **Rédigez la limite.** Ce sont des fréquences de *ces* échantillons : elles décrivent ces semaines d'activité, pas une loi éternelle du service.

En pratique dans le code

```
chat = df[df["canal"] == "chat"]
(chat["duree"] >= 180).mean()   # 0.0367 : fréquence de queue à 180 min
```

À retenir

- Probabilité de queue empirique = compter au-delà du seuil, diviser par l'effectif du groupe.
- Le dénominateur fait le sens : un même seuil ne se compare qu'à groupe et unité nommés.
- Une fréquence observée décrit cet échantillon — pas encore une probabilité théorique.

4.13 Valeur inhabituelle ou erreur : décider avec une règle

Dans la queue d'une distribution, vous trouverez toujours des valeurs surprenantes. Réflexe à bannir : les supprimer « parce qu'elles déforment les moyennes ». Une valeur inhabituelle n'est pas une erreur — c'est une question posée. Et elle se juge avec une règle, pas à l'œil.

Définition — la valeur inhabituelle. Une **valeur inhabituelle** est une observation éloignée du cœur de la distribution — par exemple signalée par la règle des 1,5 × IQR du cours 1. Être inhabituelle ne la rend ni fausse ni supprimable : la décision (**conserver, corriger ou exclure**) découle d'une règle de validation et d'une vérification à la source, et elle est toujours **tracée**.

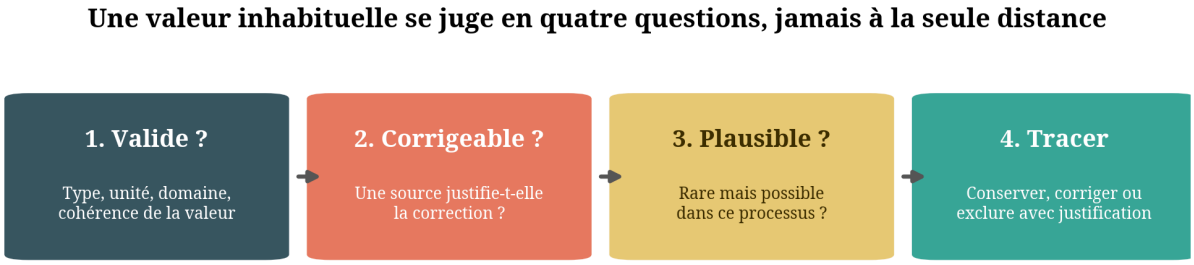


Figure 11 : La règle de décision en quatre questions. Un signal d'anomalie commande une enquête, jamais une suppression automatique.

Exemple guidé — trois cas du fichier support.

Trois lignes du fichier de tickets attirent votre attention. Appliquez la règle à chacune.

1. **Durée de −12 minutes.** *Valide ?* Non : une durée négative est impossible dans ce processus. *Corrigeable ?* La vraie durée est inconnue et aucune source ne la documente. **Décision : exclure la ligne du calcul, en la consignant au journal — elle n'est pas « corrigée à 0 » ni devinée.**
2. **Durée de 390 minutes.** *Valide ?* Oui, le format est correct. *Plausible ?* Pour le canal e-mail, la famille exponentielle rend les longues attentes rares mais possibles ; l'historique confirme des dossiers comparables. **Décision : conserver, et en discuter dans l'analyse — cette ligne est un phénomène réel, pas un parasite.**
3. **Le même ticket sur deux lignes.** *Valide ?* Chaque ligne prise seule, oui. Mais l'unité d'observation est violée : un ticket compte double. **Décision : ne garder qu'une copie, tracer la suppression du doublon.**

Notez ce qui s'est passé : une seule des trois lignes a quitté le calcul, et aucune décision n'a été prise « parce que la valeur était grande ».

> **À retenir**
> - Valeur inhabituelle ≠ erreur : rare n'est pas faux.
> - La règle : valide ? → corrigeable ? → plausible ? → tracer la décision.
> - Un signal d'anomalie commande une enquête, jamais une suppression automatique.

CHAPITRE E — SIMULATION ET HASARD D'ÉCHANTILLONNAGE

4.14 La variation d'échantillonnage

Voici l'expérience de pensée la plus importante du cours. Le musée tire au hasard 35 visites parmi ses archives : moyenne 81,5 minutes. Il recommence avec 35 autres visites : moyenne 95,2 minutes. Les archives n'ont pas changé entre les deux tirages. Alors pourquoi 13,7 minutes d'écart ?

> **Définition — la variation d'échantillonnage.** La **variation d'échantillonnage** (*sampling variability*) est le fait que **deux échantillons d'une même population diffèrent** — valeurs, moyennes, écarts-types — simplement parce que le hasard du tirage n'a pas sélectionné les mêmes lignes. Une statistique calculée sur un échantillon est donc elle-même variable : elle possède sa propre distribution, d'une répétition du tirage à l'autre.

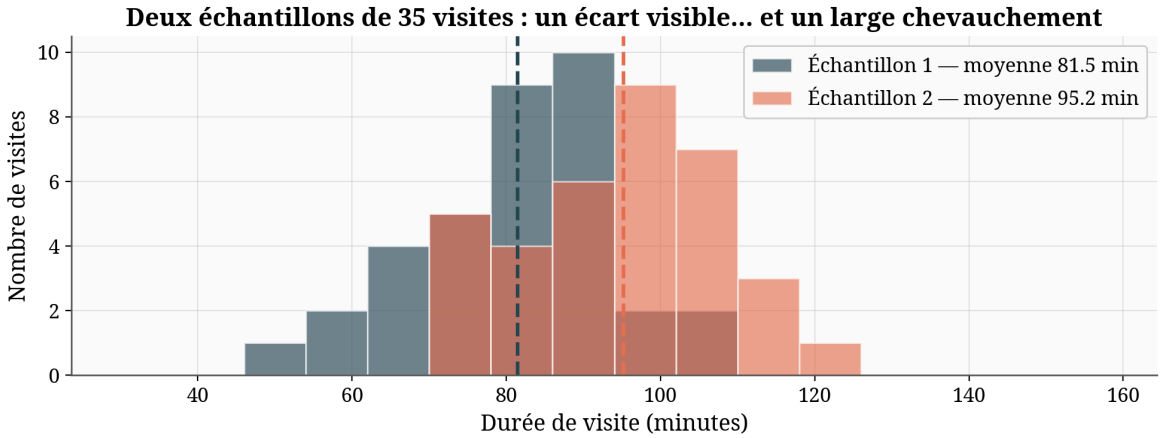


Figure 12 : Deux échantillons de 35 visites tirés de la même population. L'écart entre les moyennes (13,7 min) est visible — et le chevauchement des valeurs est large.

> **Analogie — les paniers de pommes.** Remplissez deux paniers dans le même verger : l'un tombera sur davantage de grosses pommes, l'autre sur davantage de petites. Personne ne conclura que les paniers viennent de deux vergers différents. Le verger est unique ; les paniers, eux, varient.

Exemple guidé — deux histoires compatibles avec la même image.

Face à la figure 12, un collègue conclut : « les populations sont différentes ». Vous, vous écrivez les deux histoires que la figure ne permet pas de départager :

1. **Histoire A — même processus.** Les deux échantillons viennent d'une même population ; l'écart de 13,7 min entre les moyennes n'est que la fluctuation habituelle entre petits échantillons (n = 35).
2. **Histoire B — processus différents.** Les deux échantillons viennent de populations réellement différentes ; l'écart observé reflète cette différence.
3. **Ce qui manque pour trancher.** Une règle qui quantifie « combien d'écart le seul hasard peut-il produire ? ». C'est exactement l'objet des sections 4.16 et 4.17 — et la porte d'entrée des tests d'hypothèses du cours 4.

La bonne réponse, à ce stade, n'est pas un verdict : c'est une question mieux posée.

> **À retenir**
> - Deux échantillons d'une même population diffèrent toujours un peu : c'est le hasard du tirage.
> - La figure montre des échantillons ; la question métier porte sur les populations.
> - Un écart visible entre échantillons n'est pas, à lui seul, une preuve de différence.

4.15 La graine aléatoire et la reproductibilité

Pour explorer le hasard sans quitter votre chaise, l'analyste utilise la **simulation** (*simulation*) : faire tirer des échantillons par l'ordinateur, selon un mécanisme qu'on contrôle. Mais un tirage « aléatoire » en informatique a une particularité précieuse : il est en réalité déterministe, et vous pouvez le rejouer à l'identique.

> **Définition — la graine aléatoire.** La **graine aléatoire** (*random seed*) est le nombre qui initialise le générateur de nombres pseudo-aléatoires de l'ordinateur. À graine identique, la suite de tirages est **strictement identique** : la simulation devient **reproductible** (*reproducibility*) — un collègue, ou vous-même dans six mois, obtiendra exactement les mêmes lignes, les mêmes moyennes, les mêmes figures. Changer la graine change le tirage — **jamais la population simulée**, dont les paramètres restent les mêmes.

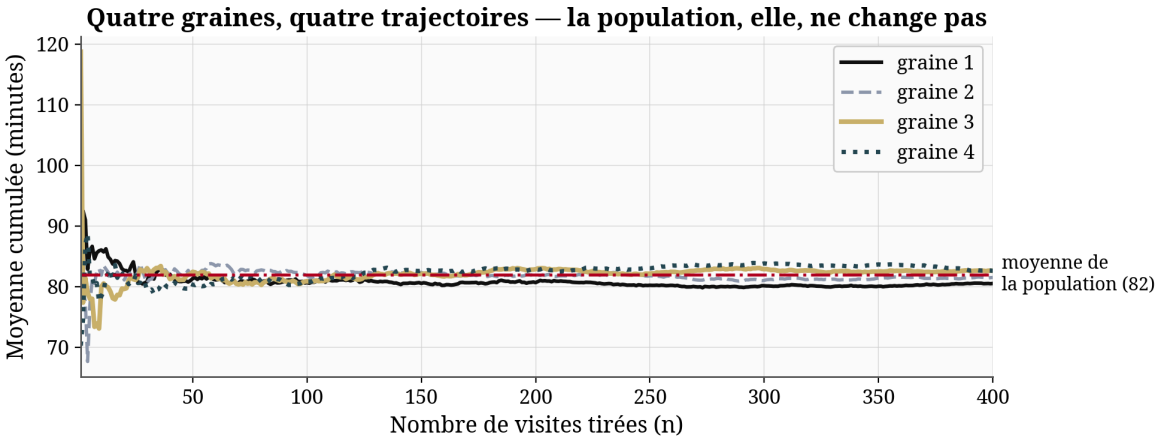


Figure 13 : Quatre graines, quatre trajectoires différentes de la moyenne cumulée — toutes issues de la même population (moyenne 82 min, pointillés).

> **Analogie — le départ de randonnée.** La graine est le point de départ d'un chemin balisé : partez du même panneau avec la même carte, et vous suivrez exactement le même sentier. Partez d'un autre panneau, le sentier change — mais la montagne, elle, n'a pas bougé.

Exemple guidé — rendre une simulation vérifiable.

Vous écrivez une simulation qui tire 600 durées de visite. Trois réflexes professionnels :

1. **Fixez la graine au début du script** et notez-la : `rng = np.random.default_rng(42)`. Toute personne qui exécute le script obtient vos mêmes 600 lignes.
2. **Distinguez les rôles.** La population est définie par ses paramètres (une normale de moyenne 82, d'écart-type 18) ; la graine ne choisit que « quelles » lignes sortent. Dire « je change la population » en changeant la graine est une erreur de vocabulaire — et de raisonnement.
3. **Explorez volontairement plusieurs graines.** Pour vérifier qu'une conclusion ne dépend pas d'un tirage chanceux, rejouez avec les graines 1, 2, 3, 4 (figure 13) : si la conclusion bouge à chaque graine, elle était fragile.

> **En pratique dans le code**
>
> ```
> rng = np.random.default_rng(42)        # graine fixée : tirages reproductibles
> visites = rng.normal(82, 18, size=600) # les mêmes 600 valeurs à chaque exécution
> ```

> **À retenir**
>
> - À graine fixée, une simulation se rejoue à l'identique : c'est la base de la reproductibilité.
> - Changer la graine change le tirage, pas la population.
> - Tester plusieurs graines, c'est tester la solidité d'une conclusion.

4.16 La stabilisation avec l'effectif

La variation d'échantillonnage n'est pas un caprice sans loi : elle obéit à une règle précise, et cette règle est une excellente nouvelle pour l'analyste. Plus l'échantillon est grand, moins sa moyenne fluctue d'un tirage à l'autre.

> **Définition — l'erreur-type de la moyenne.** L'**erreur-type de la moyenne** (*standard error*) est l'écart-type de la moyenne d'échantillon d'une répétition du tirage à l'autre. Elle mesure la **fluctuation** de la moyenne due au seul hasard d'échantillonnage, et elle décroît quand l'effectif n augmente : en divisant par $\sqrt{n}$, quadrupler l'échantillon ne divise la fluctuation que par deux.

$$\sigma_{\bar{x}} = \frac{\sigma}{\sqrt{n}}$$

- $\sigma_{\bar{x}}$: erreur-type de la moyenne (dans l'unité de la variable)
- σ : écart-type de la population
- n : effectif de l'échantillon

La formule dit que la précision d'une moyenne se paie en racine carrée d'observations. Avec des visites d'écart-type 18 minutes : 20 visites donnent une moyenne qui fluctue d'environ ± 4 minutes d'un tirage à l'autre ; il faut 100 visites pour ramener la fluctuation à ± 1,8 minute, et 400 pour ± 0,9 minute. Chaque gain de précision coûte quatre fois plus de lignes que le précédent.

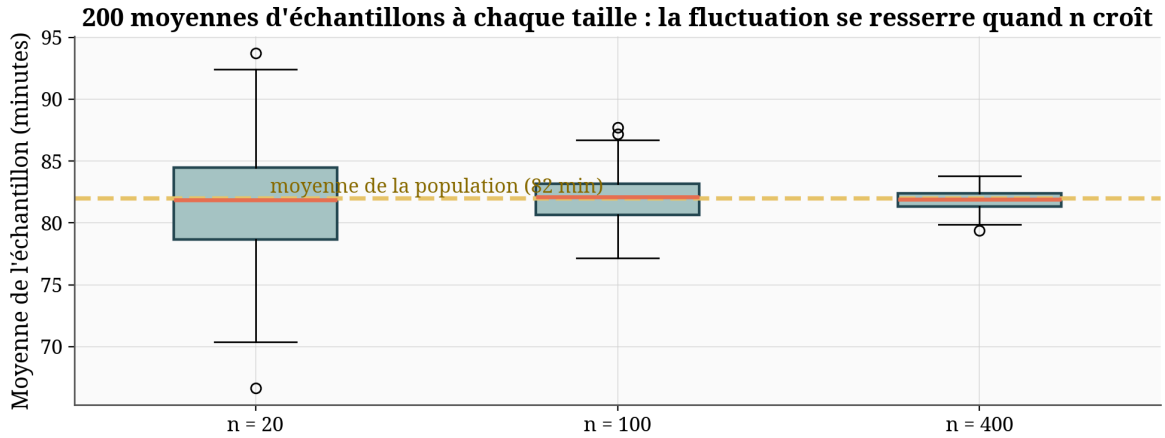


Figure 14 : 200 moyennes d'échantillons pour trois tailles. Les boîtes se resserrent autour de la moyenne de la population quand n croît — conformément à σ/√n.

Exemple guidé — prédire la taille la plus stable.

1. **La question.** On répète le tirage d'échantillons de tailles 20, 100 et 400 dans la même population. Quelle taille donnera les moyennes les plus variables ?
2. **La prédiction.** L'erreur-type étant en $1/\sqrt{n}$, c'est la plus petite taille : n = 20 fluctuera quatre fois plus que n = 400 ($\sqrt{400/20} = \sqrt{20} \approx 4{,}5$).
3. **La vérification.** La figure 14 confirme : la boîte n = 20 s'étale de 74 à 90 minutes, celle de n = 400 tient entre 81 et 84.
4. **La nuance honnête.** « En tendance » : un tirage précis de n = 20 peut tomber juste, et un tirage de n = 400 tomber un peu à côté. La règle décrit la fluctuation *typique*, pas chaque coup.

En pratique dans le code

```
moyennes = [rng.choice(population, size=n).mean()
            for _ in range(200)]      # 200 moyennes d'échantillons de taille n
```

À retenir

- La moyenne d'échantillon fluctue d'autant moins que n est grand : erreur-type $\sigma/\sqrt{n}$.
- Quadrupler n ne divise la fluctuation que par deux : la précision coûte cher.
- Moyenne *et* écart-type de l'échantillon se stabilisent quand n croît.

4.17 Le théorème central limite

Terminons par le résultat le plus étonnant de la statistique — celui qui relie tout ce que vous venez de voir : les familles de lois, la moyenne d'échantillon, la fluctuation en $\sigma/\sqrt{n}$. Il porte bien son nom : le **théorème central limite**.

Définition — le théorème central limite. Le **théorème central limite** (*central limit theorem*, CLT) énonce ceci : si l'on tire des échantillons indépendants de taille n dans *n'importe quelle* population de moyenne μ et d'écart-type σ, alors, pour n assez grand, **la moyenne de l'échantillon se comporte approximativement comme une loi normale** de centre μ et d'écart-type $\sigma / \sqrt{n}$. Et ce, **quelle que soit la forme de la distribution de départ** — asymétrique, en escalier, décroissante.

Savourez l'audace de l'énoncé : vous pouvez partir d'une population aussi biscornue qu'une exponentielle — pire cas d'asymétrie de ce cours — et les *moyennes* d'échantillons dessineront une cloche. C'est d'ailleurs pourquoi la loi normale est partout : la moyenne est une somme (divisée par n), et la somme de nombreuses petites contributions indépendantes produit une cloche — vous reconnaissez le mécanisme de la section 4.4.

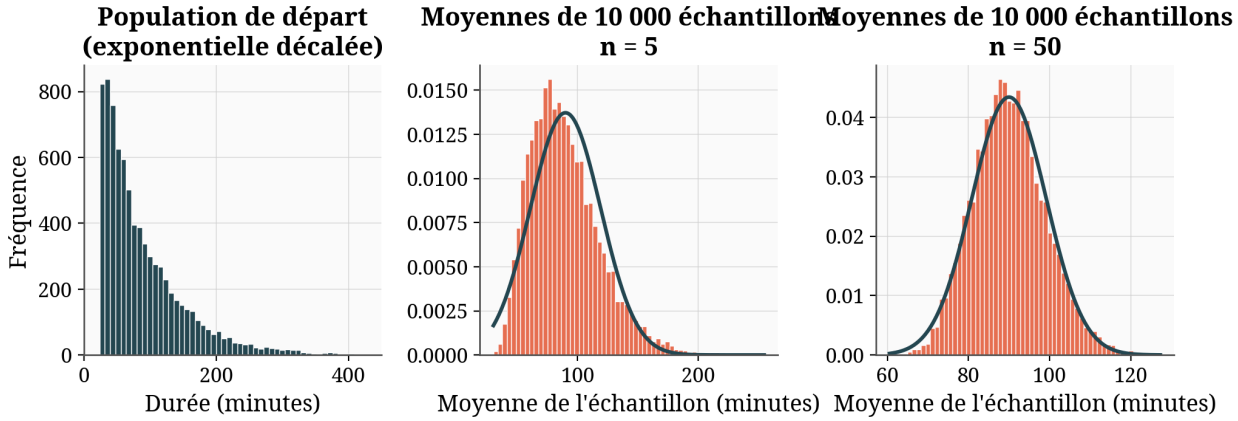


Figure 15 : À gauche, une population exponentielle décalée (moyenne 90 min). Au centre et à droite, les moyennes de 10 000 échantillons de taille 5 puis 50 : la cloche apparaît, centrée sur 90, d'autant plus étroite que n est grand.

Exemple guidé — vérifier le théorème par la simulation.

1. **La population de départ.** 25 + une exponentielle d'échelle 65 : moyenne $\mu = 90$ min, écart-type $\sigma = 65$ min, forme très asymétrique.
2. **La prédiction du théorème pour n = 50.** Les moyennes devraient former une cloche centrée sur 90, d'erreur-type $65 / \sqrt{50} \approx 9{,}2$ min.
3. **La vérification.** Sur 10 000 moyennes d'échantillons de 50 tickets : moyenne des moyennes = 89,95 min, écart-type = 9,3 min. La prédiction est au rendez-vous — et l'histogramme a la silhouette d'une cloche (figure 15, à droite).
4. **Ce que le théorème ne dit pas.** Les *tickets* eux-mêmes ne deviennent jamais normaux : la population garde sa forme asymétrique, quelle que soit la taille des échantillons. Le théorème ne parle que de la moyenne.

À retenir

- La moyenne d'un échantillon suit approximativement une normale $\left(\mu,\ \sigma / \sqrt{n}\right)$ pour n assez grand — quelle que soit la loi de départ.
- Le théorème porte sur la **moyenne**, pas sur les données elles-mêmes.
- C'est le fondement de toute l'inférence du cours 4 : on sait combien une moyenne peut fluctuer, donc on pourra juger si un écart est « trop grand pour être le hasard ».

5. Erreurs fréquentes et pièges

Piège 1 — Lire une hauteur de densité comme une proportion.

Erreur : « la barre monte à 0,023, donc 2,3 % des visites ». **Pourquoi c'est faux :** en densité, la hauteur est « par unité » ; la proportion est l'*aire* de la barre (hauteur × largeur de classe). **Réflexe :** avant tout chiffre lu sur un histogramme, regarder l'axe vertical : effectif, fréquence ou densité ?

Piège 2 — Décréter la loi à partir de la silhouette.

Erreur : « l'histogramme fait une cloche, donc c'est une loi normale ». **Pourquoi c'est faux :** beaucoup de processus produisent des formes proches ; la ressemblance visuelle est une hypothèse, pas une preuve. **Réflexe :** formuler famille *plausible* + mécanisme supposé + vérification métier à mener.

Piège 3 — Supprimer automatiquement une valeur inhabituelle.

Erreur : « 390 minutes, c'est impossible, je l'enlève ». **Pourquoi c'est faux :** dans une lognormale ou une exponentielle, les grandes valeurs sont rares mais légitimes ; les supprimer fausse la moyenne et cache un phénomène réel. **Réflexe :** valide ? corrigeable ? plausible ? → décider et tracer.

Piège 4 — Croire qu'une nouvelle graine change la population.

Erreur : « j'ai changé la graine pour obtenir une autre population ». **Pourquoi c'est faux :** la population est définie par ses paramètres ; la graine ne choisit que le tirage. **Réflexe :** fixer la graine pour la reproductibilité, en tester plusieurs pour la robustesse — sans jamais confondre tirage et population.

Piège 5 — Croire que le théorème central limite normalise les données.

Erreur : « avec un grand échantillon, mes données seront normales ». **Pourquoi c'est faux :** le TCL décrit la distribution de la *moyenne* d'échantillon ; la population garde sa forme, asymétrique ou non, quelle que soit la taille de l'échantillon. **Réflexe :** se demander « de quelle distribution parle-t-on : celle des données, ou celle de la moyenne ? ».

6. Exercices

6.1 Auto-évaluation

À faire sans relire le cours. Le corrigé se trouve en fin de document.

Question 1. Sur un histogramme en **densité**, une classe de 10 minutes de large a une hauteur de 0,012 par minute. Quelle proportion des observations cette classe contient-elle ?

☐ a) 1,2 %
☐ b) 12 %
☐ c) 0,12 %
☐ d) On ne peut pas le savoir sans l'effectif total.

Question 2. Associez chaque mécanisme à la famille la plus plausible : (1) somme de petites causes additives indépendantes ; (2) produit de facteurs multiplicatifs positifs ; (3) temps d'attente à rythme constant — parmi : normale, lognormale, exponentielle.

Question 3. Vrai ou faux ? « Changer la graine aléatoire d'une simulation modifie la population simulée. » Justifiez en une phrase.

Question 4. Citez deux différences entre un échantillon observé et un modèle théorique.

Question 5. Pour calculer la fréquence des tickets chat dépassant 180 minutes, quel dénominateur faut-il utiliser ?

☐ a) Les 1 798 tickets de tous les canaux

☐ b) Les 599 tickets du canal chat
☐ c) Les 22 tickets qui dépassent 180 minutes
☐ d) Le nombre de canaux

Question 6. Vrai ou faux ? « Grâce au théorème central limite, un échantillon assez grand suit toujours une loi normale. » Justifiez en une phrase.

Question 7. Un histogramme présente deux pics nets séparés par un creux. Quelle est la *première* hypothèse à vérifier ?

☐ a) Que les données suivent une loi de Poisson
☐ b) Que les classes de l'histogramme sont mal choisies, puis, si la forme persiste, qu'il existe un mélange de sous-groupes
☐ c) Que les valeurs du creux sont des erreurs à supprimer
☐ d) Que la moyenne a été mal calculée

6.2 Application guidée

Exercice 1 — Trois canaux, trois familles ? Le tableau ci-dessous résume les durées de résolution des trois canaux du service support (en minutes). Pour chaque canal : **(a)** comparez moyenne et médiane ; **(b)** observez le maximum par rapport à la médiane ; **(c)** proposez une famille plausible et le mécanisme qui l'accompagnerait, en rédigeant votre réponse comme une hypothèse vérifiable.

Canal	n	Moyenne	Médiane	Écart-type	Q1	Q3	Max
phone	599	89,7	90,2	18,0	78,6	101,1	147,2
chat	599	86,1	78,0	42,2	57,6	105,0	296,9
email	600	89,3	66,4	69,2	42,0	111,9	643,7

Étapes indiquées : 1) calculer l'écart moyenne − médiane par canal ; 2) calculer le ratio max / médiane ; 3) relier chaque signature à une famille ; 4) rédiger trois phrases « hypothèse + vérification ».

Exercice 2 — Le contrat des 180 minutes. Le contrat de service pénalise les résolutions au-delà de 180 minutes. On vous donne : canal chat, 22 tickets au-delà du seuil sur 599 ; canal e-mail, 51 sur 600. **(a)** Calculez les deux fréquences de queue. **(b)** Rédigez une phrase de conclusion pour la responsable support, en précisant la nature exacte de ces chiffres. *Étapes indiquées :* 1) identifier le numérateur et le dénominateur ; 2) diviser et convertir en pourcentage ; 3) comparer les deux canaux ; 4) formuler la limite de l'observation.

6.3 Application autonome

Exercice 3 — Le tribunal des trois lignes. Dans le fichier des tickets, trois lignes posent question : (1) une durée de −12 minutes ; (2) une durée de 390 minutes sur le canal e-mail ; (3) le ticket T-4471 présent sur deux lignes. Pour chacune, appliquez la règle en quatre questions (valide ? corrigeable ? plausible ? tracer) et rédigez la ligne de journal correspondante : « ligne / constat / décision / justification ».

Exercice 4 (entrelacé, cours 1 + 2) — Le mystérieux indicateur. Une variable « panier moyen par commande » d'un site e-commerce vous est livrée sous forme de résumé : n = 2 400 commandes ; moyenne 124,0 € ; médiane 98,0 € ; écart-type 72,0 € ; Q1 = 74,0 € ; Q3 = 152,0 € ; maximum 590,0 €. **(a)** Décrivez centre, dispersion et forme avec le vocabulaire du cours 1 (quel indicateur de centre choisiriez-vous, et pourquoi ?). **(b)** Proposez une famille plausible et son mécanisme. **(c)** La direction veut « un seul chiffre » pour son tableau de bord : lequel recommandez-vous, et quelle prudence joignez-vous ?

7. Fiche récapitulative

La grille de lecture — quatre questions, toujours. Combien (effectif, groupe, unité) ? Où (centre) ? Combien ça varie (dispersion) ? Quelle silhouette (forme, queues, pics) ?

Tableau 3 : Les familles de lois du cours et leurs signatures.

Famille	Mécanisme	Signature	Exemple type
Normale	Somme de causes additives	Cloche symétrique ; moyenne ≈ médiane	Durées de production, tailles
Lognormale	Produit de facteurs multiplicatifs	Queue droite ; moyenne > médiane	Revenus, prix, durées de réparation
Exponentielle	Attente à rythme constant	Décroissance dès le départ	Temps d'attente, délais avant panne
Mélange	Plusieurs sous-groupes confondus	Plusieurs pics, épaule	Population avec groupes cachés
Binomiale	Succès sur n essais identiques	Comptage discret ; espérance n × p	Achats parmi n visiteurs
Poisson	Événements à rythme λ constant	Comptage discret ; moyenne = variance = λ	Appels par heure, pannes par mois

Les formules à connaître.

- Densité d'une barre : $d = \dfrac{f}{h}$ — en densité, la proportion est l'**aire** (hauteur × largeur).
- Probabilité de queue empirique : $f_{\geq s} = \dfrac{n_{\geq s}}{n}$ — le dénominateur est l'effectif *du groupe étudié*.
- Binomiale : $P(X = k) = \binom{n}{k} p^k (1-p)^{n-k}$; espérance $n \times p$.
- Poisson : $P(X = k) = \dfrac{e^{-\lambda} \lambda^k}{k!}$.
- Erreur-type de la moyenne : $\sigma_{\bar{x}} = \dfrac{\sigma}{\sqrt{n}}$.
- Théorème central limite : pour n assez grand, la moyenne d'échantillon ≈ normale de centre μ, d'écart-type $\sigma / \sqrt{n}$ — quelle que soit la loi des données.

Les réflexes.

- Lire l'axe vertical avant toute interprétation d'un histogramme ; changer le découpage pour tester la robustesse d'une forme.
- Une forme suggère une famille ; le mécanisme la confirme — jamais le dessin seul.
- Valeur inhabituelle : valide ? → corrigeable ? → plausible ? → tracer.
- Fixer la graine pour reproduire ; en tester plusieurs pour vérifier la robustesse.
- Deux échantillons d'une même population diffèrent : un écart visible n'est pas une preuve.

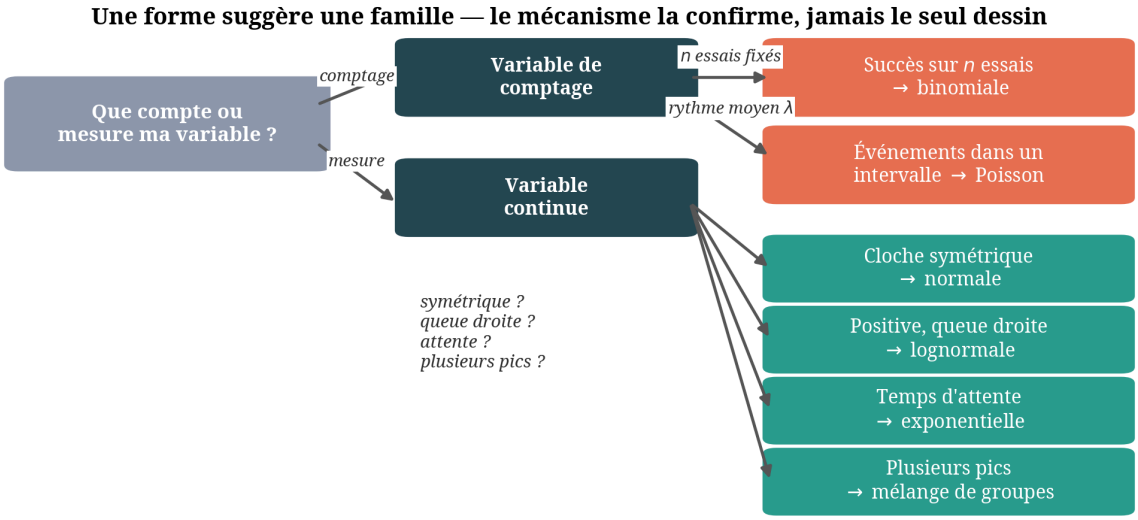


Figure 16 : Schéma de synthèse : de la nature de la variable à la famille plausible.

8. Pour aller plus loin

Section optionnelle, pour les curieux.

- **Comparer visuellement un échantillon à une loi : le Q-Q plot.** Plutôt que de juger une silhouette à l'œil, le diagramme quantile-quantile (*Q-Q plot*) confronte les quantiles de votre échantillon à ceux d'une loi théorique : des points alignés signalent un bon accord. Un outil à explorer quand vous serez à l'aise avec les quartiles.
- **La loi des grands nombres.** Vous avez vu la moyenne se stabiliser quand n croît ; la loi des grands nombres (*law of large numbers*) est le théorème qui garantit cette convergence vers la moyenne de la population. C'est la sœur discrète du théorème central limite.
- **Vers le cours 3.** La règle « valide ? corrigeable ? plausible ? » n'est que l'amorce d'une démarche complète de validation des données : contrat d'une table, contrôles ordonnés, traçabilité, éthique — le programme du prochain cours.
- **Vers le cours 4.** « Deux échantillons, deux histoires compatibles » : le cours 4 transformera cette question en méthode formelle — hypothèses H0/H1, statistique de test, valeur p. Tout ce que vous avez construit ici sur la variation d'échantillonnage y sera mobilisé.

Corrigé détaillé des exercices

Auto-évaluation

Question 1 — Réponse b) 12 %. En densité, la proportion est l'aire de la barre : 0,012 × 10 = 0,12, soit 12 %. La hauteur seule ne vaut rien sans la largeur de la classe.

Question 2. (1) → normale ; (2) → lognormale ; (3) → exponentielle. Le réflexe inverse — de la forme au mécanisme — est une hypothèse à vérifier, jamais une preuve.

Question 3 — Faux. La population est définie par ses paramètres (famille, moyenne, écart-type) ; la graine ne détermine que le tirage. Changer la graine change les lignes obtenues, pas la population qui les produit.

Question 4. Au choix, deux parmi : l'échantillon est un ensemble fini de lignes réelles, le modèle une construction mathématique ; l'échantillon donne des fréquences empiriques, le modèle des probabilités théoriques ; l'échantillon varie d'un tirage à l'autre, le modèle est fixe une fois ses paramètres posés ; l'échantillon décrit ce qui s'est passé, le modèle sert à raisonner au-delà, au prix d'hypothèses.

Question 5 — Réponse b). La fréquence se calcule *à l'intérieur du groupe dont on parle* : les 599 tickets chat. Diviser par les 1 798 tickets de tous les canaux diluerait la mesure dans d'autres populations ; utiliser 22 comme dénominateur n'aurait aucun sens.

Question 6 — Faux. Le TCL porte sur la distribution de la *moyenne* d'échantillon, qui devient approximativement normale quand n croît. Les données elles-mêmes conservent la forme de leur population, asymétrique ou non, quelle que soit la taille de l'échantillon.

Question 7 — Réponse b). Avant toute conclusion sur un mélange, on vérifie que la forme n'est pas un artefact du découpage (changer le nombre de classes) ; si les deux pics persistent, on cherche la variable de groupe qui les sépare. Le creux n'est pas une zone d'« erreurs » à supprimer.

Application guidée

Exercice 1 — Trois canaux, trois familles ?

Phone. Écart moyenne − médiane : 89,7 − 90,2 = −0,5 min, quasi nul ; max / médiane ≈ 1,6. Distribution symétrique, dispersion modérée : **normale** plausible — une résolution téléphonique comme somme de petites étapes additives. Vérification : les étapes sont-elles nombreuses et sans cause dominante ?

Chat. Écart : 86,1 − 78,0 = 8,1 min en faveur de la moyenne ; max / médiane ≈ 3,8. Queue droite marquée avec un cœur resserré : **lognormale** plausible — des facteurs qui se multiplient (complexité × réactivité × reformulations). Vérification : les dossiers longs cumulent-ils plusieurs facteurs de ralentissement ?

Email. Écart : 89,3 − 66,4 = 22,9 min, le plus grand des trois ; max / médiane ≈ 9,7 ; et surtout, aucune durée sous 25 minutes (plancher). Décroissance dès un minimum incompressible : **exponentielle décalée** plausible — qualification forfaitaire puis attente à rythme constant. Vérification : le rythme de traitement est-il stable, et le plancher de 25 minutes est-il confirmé par le métier ?

Exercice 2 — Le contrat des 180 minutes.

(a) Chat : 22 / 599 ≈ 0,0367, soit **3,7 %**. E-mail : 51 / 600 = 0,085, soit **8,5 %**. (b) Rédaction attendue, par exemple : « Sur ces échantillons, la fréquence observée des dépassements du seuil contractuel de 180 minutes est de 3,7 % pour le chat et de 8,5 % pour l'e-mail : le risque de dépassement y est plus de deux fois plus élevé. Il s'agit de fréquences mesurées sur les tickets de la période — elles décrivent ces semaines, pas une loi permanente du service. »

Application autonome

Exercice 3 — Le tribunal des trois lignes.

(1) *Durée −12 min.* Valide ? Non — une durée négative est impossible. Corrigeable ? Non — la vraie valeur est inconnue et aucune source ne la justifie. Journal : « ligne n°… / durée −12 min (impossible) / **exclue du calcul** / valeur invalide non corrigeable ».

(2) *Durée 390 min, canal e-mail.* Valide ? Oui — format correct. Corrigeable ? Sans objet, rien à corriger. Plausible ? Oui — le canal e-mail suit une forme de type exponentielle, où les longues attentes sont rares mais réelles ; l'historique confirme. Journal : « ligne n°… / durée 390 min (queue de distribution) / **conservée** / valeur rare mais plausible, discutée dans l'analyse ».

(3) *Ticket T-4471 en double.* Valide ? Chaque ligne est valide prise seule, mais l'unité d'observation (une ligne = un ticket) est violée. Journal : « lignes n°… / doublon exact du ticket T-4471 / **une seule copie conservée** / dédoublonnage tracé, effectif −1 ».

Exercice 4 (entrelacé) — Le mystérieux indicateur.

(a) *Description.* Centre : la moyenne (124 €) dépasse nettement la médiane (98 €) — la signature d'une asymétrie à droite ; la médiane est donc l'indicateur de centre à privilégier (cours 1). Dispersion : écart-type élevé (72 €) mais IQR de 78 €, comparable ; le maximum (590 €) vaut six fois la médiane : longue queue droite. Forme : asymétrique à droite, quelques très gros paniers.

(b) *Famille et mécanisme.* Une **lognormale** est plausible : un panier résulte de facteurs qui se multiplient (nombre d'articles × prix des articles choisis × options). Vérification à proposer : les très gros paniers cumulent-ils plusieurs facteurs ?

(c) *Recommandation.* Présenter la **médiane (98 €)** comme « panier typique », complétée de l'IQR pour le cœur des commandes — la moyenne, gonflée par quelques très gros paniers, surestimerait le client ordinaire. Prudence à joindre : un indicateur seul ne dit ni la queue ni les gros paniers ; si la direction pilote le chiffre d'affaires, la moyenne reste utile *en complément*, jamais seule.