Programme de formation théorique

Data Analyst — cursus segmenté en cours progressifs

Construit à partir de l'analyse des supports de cours du projet
Théorie uniquement — les travaux pratiques sont conçus séparément
Novembre 2026

1. Principes de construction du programme

Ce programme organise en cours successifs l'ensemble des contenus théoriques identifiés dans les supports du projet. Il obéit à quatre règles :

- Progressivité : chaque cours ne s'appuie que sur des notions déjà enseignées dans les cours précédents ; les prérequis sont explicités pour chaque cours.
- Théorie uniquement : aucun cours ne contient de travaux pratiques, d'exercices ni de tutoriel logiciel ; la partie pratique de la formation sera construite séparément.
- Traçabilité : chaque cours indique le ou les fichiers du projet qui traitent son sujet, pour servir de base à la rédaction ultérieure des cours.
- Complétude : lorsqu'un concept important du métier de data analyst manque dans les fichiers du projet, il est proposé comme ajout et signalé explicitement par la mention « [Ajout — absent des fichiers du projet] ».

Le cursus commence par le Cours 1, déjà rédigé et présent dans le projet (« Cours 1 — Introduction à l'analyse de données.pdf »). Les cours suivants sont à rédiger : ce document n'en fournit que le plan, les objectifs et les références.

2. Architecture générale du cursus

Le cursus compte quinze cours, organisés en cinq blocs. Le premier bloc pose les fondations (décrire, valider, comprendre le hasard) ; le deuxième construit le raisonnement statistique (tester, relier, prédire) ; le troisième ouvre l'analyse exploratoire avancée (factoriel et segmentation) ; le quatrième traite de la restitution et du pilotage ; le cinquième couvre l'environnement professionnel de l'analyste.

Bloc	Cours	Contenu
Bloc I — Fondations	Cours 1 à 3	Vocabulaire et indicateurs de base ; lecture des distributions et hasard d'échantillonnage ; qualité, validation et éthique des données.
Bloc II — Raisonnement statistique	Cours 4 à 7	Inférence et tests d'hypothèses ; association, régression et causalité ; évaluation de modèles ; classification supervisée.
Bloc III — Analyse exploratoire avancée	Cours 8 à 10	Géométrie des données et ACP ; ACM pour les données qualitatives ; segmentation CAH et K-means.
Bloc IV — Restitution et pilotage	Cours 11 à 13	Indicateurs et KPI ; visualisation ; tableaux de bord et pilotage de la performance ; séries temporelles.
Bloc V — Environnement professionnel	Cours 14 et 15	Versioning, données relationnelles et performance (concepts) ; intelligence artificielle et écosystème de l'analyste.

3. Le programme, cours par cours

Bloc I — Fondations (cours 1 à 3)

Cours 1 — Introduction à l'analyse de données : décrire et comprendre ses données

Statut : déjà rédigé — fichier « Cours 1 — Introduction à l'analyse de données.pdf » (33 pages). Aucune réécriture nécessaire ; il ouvre le cursus.

Prérequis : aucun (premier cours de la formation ; calculs de niveau lycée).

Objectifs :

- Identifier observation, variable, jeu de données et l'unité d'observation d'un tableau.
- Distinguer statistique descriptive et statistique inférentielle, population et échantillon.
- Typer toute variable (qualitative nominale ou ordinale, quantitative discrète ou continue) et en déduire les indicateurs autorisés.
- Calculer et interpréter centre (moyenne, médiane, mode), dispersion (étendue, variance, écart-type, écart interquartile, EAM, MAD, coefficient de variation) et forme (asymétrie).
- Mesurer le lien linéaire entre deux variables (covariance, corrélation de Pearson).

Contenu théorique du cours :

- Observation, variable, donnée, jeu de données ; l'unité d'observation fixe le sens des calculs.
- Statistique descriptive contre inférentielle ; population, échantillon, échantillonnage ; le diviseur n – 1.
- Types de variables et conséquences sur les calculs permis ; la démarche d'analyse (de la question métier à la conclusion).
- Tendance centrale : moyenne, médiane (robustesse aux extrêmes), mode et classe modale.
- Dispersion : étendue, variance, écart-type ; la règle des 68-95-99,7 ; quartiles, écart interquartile et détection des valeurs aberrantes ; dispersions robustes (écart absolu moyen, MAD) ; coefficient de variation pour comparer des séries en unités différentes.
- Forme : l'asymétrie d'une distribution.
- Deux variables : covariance, coefficient de corrélation de Pearson (première approche).

Fichiers de référence (projet) : Cours 1 — Introduction à l'analyse de données.pdf.

> Aucun ajout nécessaire : le contenu est entièrement couvert par les fichiers du projet.

Cours 2 — Lire les distributions : familles de lois, simulation et hasard d'échantillonnage

Statut : à rédiger.

Prérequis : Cours 1 (centre, dispersion, forme, asymétrie ; population et échantillon).

Objectifs :

- Lire une distribution complète : centre, dispersion, forme, valeurs extrêmes.

- Reconnaître les grandes familles de distributions et relier chaque forme à un mécanisme générateur.
- Distinguer échantillon observé et modèle théorique ; comprendre la variation d'échantillonnage.
- Garantir la reproductibilité d'une simulation par la graine aléatoire ; observer la convergence des statistiques quand l'effectif croît.

Contenu théorique du cours :

- Lecture d'une distribution : classes, effectif, fréquence, densité ; l'aire comme proportion ; le groupe et l'unité visibles dans toute comparaison.
- Familles et mécanismes : la normale (somme de causes additives), la lognormale (produit de facteurs multiplicatifs, queue droite), l'exponentielle (temps d'attente) ; les mélanges de distributions ; reconnaître une forme suggère des questions, ne prouve pas la loi.
- Échantillon et modèle : deux objets différents ; le modèle sert à raisonner au-delà des lignes, au prix d'hypothèses explicites.
- Probabilité de queue comme fréquence observée au-delà d'un seuil ; valeur inhabituelle ≠ erreur (décision par règle et vérification).
- Variation d'échantillonnage : deux échantillons d'une même population diffèrent ; trajectoires selon les seeds ; stabilisation de la moyenne et de l'écart-type quand n croît.
- Graine aléatoire et reproductibilité des simulations.

Fichiers de référence (projet) : diapositives-3.pdf (identique à diapositives-3-1.pdf) ; 2026-09-17_individual_project.pptx ; 2026-09-18_review_and_two_gaussians.pptx.

Concepts à ajouter lors de la rédaction :

+ **[Ajout — absent des fichiers du projet]** Le théorème central limite, formalisé : les fichiers en montrent l'effet par simulation sans jamais l'énoncer.
+ **[Ajout — absent des fichiers du projet]** Les familles discrètes utiles aux données de comptage (loi binomiale, loi de Poisson), absentes des supports.

Cours 3 — Qualité, validation et éthique des données

Statut : à rédiger.

Prérequis : Cours 1 (types de variables, écart interquartile) ; cours 2 (valeurs extrêmes et forme).

Objectifs :

- Écrire le contrat d'une table avant de la regarder ; définir la validité pour un usage donné.
- Appliquer une batterie ordonnée de contrôles et classer chaque règle (bloquante ou alerte).
- Choisir la bonne décision face à une anomalie : corriger, exclure, imputer, signaler — et la tracer.
- Appliquer les principes éthiques du métier à chaque étape du traitement des données.

Contenu théorique du cours :

- Une table valide : le « fit for use » ; pas de validité absolue ; le contrat de la table, écrit avec le métier avant l'examen des données.
- Les dimensions de la qualité : structure, validité, complétude, unicité, cohérence (dans la ligne et entre tables), actualité, exactitude.
- Les quinze contrôles dans l'ordre : taille annoncée, colonnes, lignes vides, types lisibles, dates au format imposé, complétude (obligatoire bloquant, facultatif alerte), doublons exacts et conflits

de clé, domaines autorisés, plages métier, formats, cohérence intra-ligne, intégrité référentielle, valeurs aberrantes (seuil interquartile : une alerte, jamais une suppression), période, rapprochement avec la source — seul contrôle qui prouve l'exactitude.

- Valeurs manquantes : une valeur manquante n'est pas un zéro ; représentations selon le type (NaN, pd.NA, NaT) ; pseudo-manquants (« - », « ? », « N/A »).
- Décider : la question « la bonne valeur est-elle certaine ? » ; corriger et tracer, sinon marquer et renvoyer à la source ; exclure sans effacer ; n'imputer que sur règle métier validée (jamais un identifiant ni une date contractuelle) ; revalider après chaque correction.
- Traçabilité : original intact, journal des corrections, statut par ligne, rapprochement final expliqué.
- Éthique : intégrité, transparence, confidentialité, minimisation et finalité, équité (l'effet des exclusions sur les groupes), responsabilité ; protection des données personnelles dans les livrables.

Fichiers de référence (projet) : Valider_table_donnees1.pptx ; 2026-09-25_python_architecture_et_sql.pptx (valeurs manquantes et typage) ; 2026-09-17_individual_project.pptx (contrôle qualité avant analyse).

Concepts à ajouter lors de la rédaction :

+ **[Ajout — absent des fichiers du projet]** Le cadre juridique complet de la protection des données (RGPD : droits des personnes, registre des traitements, durées de conservation), seulement effleuré par les supports.
+ **[Ajout — absent des fichiers du projet]** La gouvernance des données en organisation (rôles, cycle de vie de la donnée), absente des fichiers.

Bloc II — Raisonnement statistique (cours 4 à 7)

Cours 4 — Inférence statistique : tester une différence

Statut : à rédiger.

Prérequis : Cours 1 et 2 (population/échantillon, variation d'échantillonnage, variance).

Objectifs :

- Formuler des hypothèses H■ et H■ portant sur les populations.
- Construire et interpréter un test de comparaison de moyennes (test de Welch) et sa statistique t.
- Lire correctement une valeur p et un intervalle de confiance ; distinguer significativité et importance pratique.
- Étendre la comparaison aux variances, à la forme, puis à une distance globale entre distributions.

Contenu théorique du cours :

- Du descriptif à l'inférentiel : une figure montre des échantillons, la question porte sur les populations ; H■ et H■ comme deux scénarios concurrents.
- Simulation sous H■ : construire la distribution de la statistique quand H■ est vraie ; la valeur p comme probabilité sous H■.
- Le test de Welch : pourquoi lui (variances inégales) ; la statistique t, un écart rapporté à l'erreur-type ; formuler la question avant le calcul.
- Intervalle de confiance : estimer avant de conclure ; l'écart chiffré avec son incertitude.

- Interprétation : ce que p permet et interdit de dire ; le seuil ; « significatif » ne veut pas dire « important » ; le rôle de l'effectif (un petit écart peut devenir significatif sans gagner en importance).
- Comparer au-delà des moyennes : tests sur les variances (F, Levene) et sur la forme (Kolmogorov-Smirnov).
- Distances globales entre distributions : Wasserstein-2 (formule gaussienne), recouvrement, divergence de Kullback-Leibler ; une distance n'est pas un test.

Fichiers de référence (projet) : 2026-09-29_gaussian_project_and_distribution_comparison.pptx ; 2026-10-01_age_purchase_association.pptx (rappels du test) ; 2026-10-13_reprendre_les_questions_du_bilan.pptx (statistique t, valeur p, du test à la décision).

Concepts à ajouter lors de la rédaction :

+ **[Ajout — absent des fichiers du projet]** Les erreurs de type I et II et la puissance statistique, jamais nommées dans les supports.
+ **[Ajout — absent des fichiers du projet]** Les comparaisons multiples (risque cumulé, corrections de type Bonferroni), absentes.
+ **[Ajout — absent des fichiers du projet]** Le test du χ^2 d'indépendance pour les variables qualitatives, absent.
+ **[Ajout — absent des fichiers du projet]** L'ANOVA pour comparer plus de deux groupes, absente.
+ **[Ajout — absent des fichiers du projet]** Un test non paramétrique de référence (Mann-Whitney) pour les distributions non gaussiennes, absent.

Cours 5 — Association, régression linéaire et causalité

Statut : à rédiger.

Prérequis : Cours 1 (covariance et Pearson, premières approches) ; cours 4 (logique de test, pour le test de corrélation).

Objectifs :

- Interpréter covariance et corrélation de Pearson sans dépasser ce qu'elles mesurent.
- Identifier les limites de la corrélation : non-linéarité, points atypiques, effet du périmètre.
- Ajuster et interpréter une régression linéaire simple (pente, ordonnée à l'origine, résidus, R^2).
- Distinguer association et causalité ; repérer une variable de confusion ; proposer une comparaison plus informative.

Contenu théorique du cours :

- Covariance : contribution de chaque point ; conservation des unités ; lecture de la matrice de covariance.
- Corrélation de Pearson : la covariance standardisée ; signe et force ; lecture d'un r imparfait en trois étapes ; le test de corrélation (r dans l'échantillon, ρ dans la population).
- Limites : r proche de 0 n'exclut pas une relation non linéaire ; l'influence d'un point atypique ; le résultat dépend du périmètre d'analyse.
- Régression linéaire simple : pente a = Cov(x, y) / Var(x), ordonnée à l'origine b = ■ – a·x■ ; la droite passe par le point des moyennes ; le résidu, écart signé ; R^2 comme gain apporté par la droite ; comprendre contre prédire.

- Confusion et composition : une troisième variable peut créer la tendance globale ; le paradoxe de Simpson ; la décomposition d'un écart entre groupes.
- Vers la causalité : observation contre intervention ; le plan croisé (les mêmes individus sous deux conditions) et ce qu'il permet de conclure.

Fichiers de référence (projet) : 2026-10-01_age_purchase_association.pptx ; 2026-10-06_correlation.pptx ; 2026-10-13_reprendre_les_questions_du_bilan.pptx (variation des pentes, association, observation et intervention).

Concepts à ajouter lors de la rédaction :

+ **[Ajout — absent des fichiers du projet]** La corrélation de rang de Spearman (relations monotones non linéaires), absente des supports.
+ **[Ajout — absent des fichiers du projet]** Les conditions d'application du test de corrélation, non explicitées.
+ **[Ajout — absent des fichiers du projet]** Le vocabulaire causal complet (contrefactuel, randomisation, groupe témoin), au-delà du seul plan croisé présent dans les fichiers.

Cours 6 — Évaluer un modèle prédictif : jeux de données, erreurs et surapprentissage

Statut : à rédiger.

Prérequis : Cours 5 (résidus, R^2, ajustement d'une droite).

Objectifs :

- Expliquer pourquoi une bonne prédiction se juge sur des données non utilisées pour apprendre.
- Attribuer le bon rôle à chaque jeu : entraînement, validation, test — et respecter l'usage unique du test.
- Mesurer l'erreur (MAE) et comparer des modèles candidats sans se tromper de critère.
- Reconnaître le surapprentissage et prévenir la fuite de données (séparation par groupe).

Contenu théorique du cours :

- Décrire, expliquer, prédire : trois ambitions différentes ; la prédiction se juge sur d'autres observations.
- Trois jeux distincts : ajuster sur l'entraînement, choisir sur la validation, évaluer une seule fois sur le test ; distinguer choisir et évaluer.
- Du résidu à la MAE ; une même mesure, deux usages ; le classement des modèles peut s'inverser entre entraînement et validation.
- Surapprentissage : suivre les points d'entraînement, perdre ailleurs ; le cas du polynôme et le choix du degré.
- Fuite de données : garder toutes les observations d'une même entité (client) dans le même ensemble.
- Règle connue contre coefficients estimés ; définir le périmètre de validité du modèle ; le danger de l'extrapolation.

Fichiers de référence (projet) : 2026-10-08_git_et_evaluation_modeles.pptx (partie évaluation de modèles) ; 2026-10-09_collaboration_et_simulation.pptx (partie trois jeux et MAE) ; 2026-10-13_reprendre_les_questions_du_bilan.pptx (séparation par groupe, comparaison

d'erreurs, évaluation indépendante) ; 2026-10-22-23_pipeline_polynomes_heart_modeles.pptx (parties évaluer un modèle et forme du modèle).

Concepts à ajouter lors de la rédaction :

+ **[Ajout — absent des fichiers du projet]** La validation croisée (k-fold), absente des supports alors que le corpus insiste sur la fragilité d'un seul découpage.
+ **[Ajout — absent des fichiers du projet]** Le compromis biais-variance, formalisé : le surapprentissage est décrit, la décomposition jamais nommée.
+ **[Ajout — absent des fichiers du projet]** Les autres métriques d'erreur (RMSE, erreur médiane) et la notion de modèle de référence (baseline), absentes.

Cours 7 — Classification supervisée : mesures, seuils et algorithmes de référence

Statut : à rédiger.

Prérequis : Cours 6 (évaluation, jeux de données, surapprentissage).

Objectifs :

- Construire et lire une matrice de confusion ; dériver sensibilité, spécificité et précision.
- Expliquer pourquoi l'accuracy peut être trompeuse et choisir la mesure selon l'objectif métier.
- Comprendre la régression logistique : du score à la probabilité, du seuil à l'arbitrage d'erreurs.
- Distinguer algorithmes déterministes et stochastiques ; décrire Random Forest et gradient boosting (CatBoost).

Contenu théorique du cours :

- Poser la question de prédiction : prédire quoi, à quel moment ; la cible et les variables d'entrée.
- La matrice de confusion : vrais et faux positifs, vrais et faux négatifs ; de quels cas parle chaque nombre.
- Les mesures : accuracy et ses limites sur classes déséquilibrées ; sensibilité (rappel), spécificité, précision ; quel objectif permet de choisir.
- Régression logistique : un score pondéré devient une probabilité (sigmoïde) ; le seuil de décision ; baisser le seuil, c'est accepter un échange entre faux positifs et faux négatifs.
- Déterministe contre stochastique : le hasard peut intervenir pendant l'apprentissage.
- Random Forest : moyenner les prédictions d'arbres variés ; CatBoost : ajouter des arbres qui corrigent le score (gradient boosting).
- Plusieurs variables et plusieurs modalités : vocabulaire (entrées, sorties, modalités) ; lire un coefficient en fixant les autres entrées ; combiner des formes d'information différentes.

Fichiers de référence (projet) : 2026-10-22-23_pipeline_polynomes_heart_modeles.pptx.

Concepts à ajouter lors de la rédaction :

+ **[Ajout — absent des fichiers du projet]** Le F1-score et l'arbitrage précision-rappel formalisé, absents des supports.
+ **[Ajout — absent des fichiers du projet]** La courbe ROC et l'AUC pour évaluer un modèle sur tous les seuils, absentes.
+ **[Ajout — absent des fichiers du projet]** La gestion des classes déséquilibrées (pondération, rééchantillonnage), absente.

+ **[Ajout — absent des fichiers du projet]** L'arbre de décision seul, base intuitive des forêts aléatoires, jamais présenté ; le k plus proches voisins, absent.

Bloc III — Analyse exploratoire avancée (cours 8 à 10)

Cours 8 — Analyse multidimensionnelle : géométrie des données et ACP

Statut : à rédiger.

Prérequis : Cours 1 (variance, corrélation) ; cours 5 (liaisons linéaires).

Objectifs :

- Représenter un tableau de données comme un nuage de points dans un espace à p dimensions.
- Définir distance, centre de gravité, inertie et centrage-réduction.
- Expliquer la projection et le critère des axes factoriels (maximum d'inertie) ; relier valeurs propres et inertie expliquée.
- Conduire une ACP complète : contrôle des données, choix des axes, interprétation des variables et des individus, exploitation métier.

Contenu théorique du cours :

- Pourquoi dépasser le bivarié : p variables, c'est p(p–1)/2 paires ; les questions de l'analyse multidimensionnelle.
- Le tableau comme nuage : individu-vecteur ; nuage des individus et nuage des variables.
- Notions géométriques : distance entre individus ; centre de gravité et inertie ; centrer et réduire.
- Projection : l'analogie de l'ombre ; le produit scalaire comme coordonnée ; ce que la projection garde et perd.
- Axes factoriels : critère du maximum d'inertie ; vecteurs propres et valeurs propres ; inertie expliquée par axe ; plan factoriel ; cercle des corrélations ; précautions de lecture.
- ACP pas à pas : détection des aberrants (univariée, distance de Mahalanobis, influence) et leurs quatre traitements ; statut actif contre supplémentaire ; diagonalisation de la matrice de corrélation ; choix du nombre d'axes (Kaiser, bâton brisé, éboulis) ; les trois indicateurs (coordonnées-corrélations, contributions, $\cos^2$) ; nommer les axes par leurs pôles ; individus et variables supplémentaires.
- Exploitation : construire des indicateurs composites ; la matrice de positionnement ; les pièges à éviter.

Fichiers de référence (projet) : Analyse_multidimensionnelle_intro.pptx ; ACP_pas_a_pas_agences.pptx.

Aucun ajout nécessaire : le contenu est entièrement couvert par les fichiers du projet.

Cours 9 — Données qualitatives : analyse des correspondances multiples (ACM)

Statut : à rédiger.

Prérequis : Cours 8 (géométrie factorielle, inertie, indicateurs).

Objectifs :

- Transformer correctement des données qualitatives pour l'analyse factorielle (catégorisation, modalités rares).
- Mesurer la liaison entre variables qualitatives (V de Cramér).
- Conduire une ACM complète et choisir ses axes avec les critères adaptés (1/p, correction de Benzécri).
- Interpréter axes, modalités et profils-types, en identifiant l'effet Guttman.

Contenu théorique du cours :

- Préparer les variables : catégoriser une variable continue (seuils métier, classes d'effectifs égaux, k-means unidimensionnel, seuils naturels de Jenks) ; pourquoi les modalités rares posent problème et comment les ventiler ; l'équilibre des variables.
- Liaisons entre variables qualitatives : le V de Cramér ; statut actif contre supplémentaire.
- Codage : le tableau disjonctif complet (TDC) et le tableau de Burt ; l'ACM comme AFC du TDC.
- Spécificités de l'ACM : des taux d'inertie bruts toujours faibles ; le critère 1/p ; la correction de Benzécri ; l'éboulis et la décision.
- Interprétation : indicateurs des modalités ; la matrice de discrimination (eta²) ; nommer les axes ; l'effet Guttman (fer à cheval) ; les cos² en lecture relative ; modalités et individus sur le plan.
- Exploitation : vérifier les pôles ; construire et décrire des profils-types ; les pièges à éviter.

Fichiers de référence (projet) : ACM_pas_a_pas_jackstream.pptx ; Analyse_multidimensionnelle_intro.pptx (panorama des méthodes factorielles).

Concepts à ajouter lors de la rédaction :

+ **[Ajout — absent des fichiers du projet]** L'AFC simple (analyse d'un tableau de contingence à deux variables), citée comme famille de méthodes mais jamais enseignée : à traiter avant l'ACM pour asseoir la progression.

Cours 10 — Segmentation : classification ascendante hiérarchique et K-means

Statut : à rédiger.

Prérequis : Cours 8 (distances, inertie, standardisation) ; cours 9 recommandé (données mixtes).

Objectifs :

- Choisir une mesure de distance adaptée aux données (quantitatives, qualitatives, mixtes).
- Construire une classification ascendante hiérarchique et lire un dendrogramme.
- Décrire l'algorithme des K-means et son critère (inertie intra-classe).
- Choisir le nombre de classes, comparer deux partitions et exploiter des segments métier.

Contenu théorique du cours :

- Pourquoi classifier ; le principe : regrouper d'abord les plus proches.
- Les distances : euclidienne, Manhattan, Minkowski, Chebyshev, Mahalanobis ; Hamming et Gower pour le qualitatif et le mixte ; le piège de l'échelle et la standardisation.
- CAH : matrice des distances ; fusions successives ; méthodes d'agrégation (lien simple, complet, moyen, Ward et son intuition d'inertie) ; le dendrogramme et la coupe.

- K-means : centres initiaux, affectation, recalcul des centres de gravité, itérations jusqu'à stabilité ; l'inertie intra-classe J.
- Choisir K : méthode du coude ; coefficient de silhouette.
- Comparer deux partitions : aligner les classes (numéros arbitraires) ; mesurer l'accord ; visualiser sur le plan de l'ACP.
- Exploitation : profiler et nommer les segments ; carte thermique des profils ; variables structurantes ; classer un nouvel individu ; les pièges à éviter.

Fichiers de référence (projet) : CAH_Kmeans.pptx ; segmentation_kmeans_cah_pas_a_pas.pptx.

Concepts à ajouter lors de la rédaction :

+ **[Ajout — absent des fichiers du projet]** La consolidation d'une partition (CAH suivie d'un K-means), méthode mixte classique absente des fichiers.
+ **[Ajout — absent des fichiers du projet]** Le clustering par densité (DBSCAN) et les modèles de mélange gaussien (GMM) pour les classes non sphériques, absents.

Bloc IV — Restitution et pilotage (cours 11 à 13)

Cours 11 — Indicateurs, KPI et visualisation

Statut : à rédiger.

Prérequis : Cours 1 (indicateurs statistiques) ; cours 5 (paradoxe de Simpson, déjà rencontré).

Objectifs :

- Distinguer mesure, indicateur et KPI ; relier chaque indicateur à un lecteur, une décision, une population.
- Construire une fiche indicateur complète et non ambiguë (calcul, population, fréquence, seuil).
- Reconnaître les dérives : décider sans mesurer, mesurer la mauvaise chose (loi de Goodhart), lire un pourcentage sans son contexte.
- Choisir le bon graphique à partir de la question et éviter les trois grands pièges de la visualisation.

Contenu théorique du cours :

- Mesure et indicateur ; la chaîne données, information, intelligence, décision ; un indicateur relie un lecteur, une décision, une population.
- Types d'indicateurs : volume, moyenne, proportion ; typologie par finalité (activité, résultat, efficacité, efficience, impact, anticipation, alerte).
- Les dangers : décider sans mesurer (le signal faible invisible) ; mesurer la mauvaise chose (Goodhart : une mesure devenue objectif cesse d'être une bonne mesure) ; contextualiser (Simpson ; absolu contre relatif).
- Construction : les quatre questions (qui, quelle décision, quel seuil, quel rythme) ; la fiche indicateur ; exigences de définition sans ambiguïté, de calcul reproductible et de seuil assumé.
- KPI : aligné sur un objectif, porté par un décideur, suivi au bon niveau, régulier et comparable ; les qualités d'un bon KPI ; l'aide SMART.
- Visualisation : un type de graphique par question (barres, courbe, camembert, barres empilées, nuage de points, histogramme) ; règles de lecture ; les trois pièges (axe tronqué, camembert

illisible ou 3D, double échelle dissimulée).

Fichiers de référence (projet) : Indicateurs-cours 02.pptx ; Graphiques-KPI-cours.pptx.

Concepts à ajouter lors de la rédaction :

+ **[Ajout — absent des fichiers du projet]** Le data storytelling (structurer un récit d'analyse pour un public de décideurs), absent des fichiers.

Cours 12 — Pilotage de la performance et tableaux de bord

Statut : à rédiger.

Prérequis : Cours 11 (indicateurs et KPI).

Objectifs :

- Définir un tableau de bord et ses rôles ; distinguer les niveaux stratégique, gestion et opérationnel.
- Relier la stratégie aux indicateurs, notamment avec le Balanced Scorecard.
- Choisir et combiner une démarche d'élaboration (BSC, Voyer, GIMSI, JANUS, OVAR).
- Mener la construction jusqu'à la livraison : hiérarchie, fréquences, support, preuves.

Contenu théorique du cours :

- Notion de tableau de bord : les définitions de Voyer, Bergeron et Taïeb ; piloter, c'est décider et agir ; un écart déclenche une vérification, il ne révèle ni sa cause ni la bonne action ; le périmètre explique le pourcentage.
- Les cinq rôles ; la typologie par niveau d'organisation (stratégique, gestion, opérationnel) : destinataires, questions, rythmes.
- De la stratégie aux indicateurs : vision, objectifs, indicateurs et cibles, actions ; le Balanced Scorecard de Kaplan et Norton (quatre perspectives) ; une chaîne d'objectifs reste une hypothèse à examiner (corrélation n'est pas causalité).
- Cinq démarches d'élaboration : BSC (Kaplan et Norton), la méthode des besoins de Voyer, GIMSI (Fernandez), JANUS (Selmer), OVAR (Löning) ; les combiner selon la situation.
- Construction : buts, indicateurs clés (SMART), hiérarchie et consolidation, fréquences ; choix du support selon les contraintes (clé en main contre code ; coûts complets).
- Livraison : la feuille de route et ses preuves ; conserver définitions et sources ; un tableau de bord est un outil vivant, revu régulièrement ; la démarche participative compte autant que l'outil.

Fichiers de référence (projet) : Pilotage-de-la-performance-Dashboards-et-TB.pptx.

Aucun ajout nécessaire : le contenu est entièrement couvert par les fichiers du projet.

Cours 13 — Séries temporelles : suivre et prévoir des indicateurs datés

Statut : à rédiger entièrement — aucun fichier du projet ne traite ce sujet.

Prérequis : Cours 1 (indicateurs) ; cours 6 (évaluation d'un modèle prédictif).

Objectifs :

- Décomposer une série temporelle en tendance, saisonnalité et bruit.
- Lisser une série (moyennes mobiles, lissage exponentiel) et lire une autocorrélation.

- Comprendre la stationnarité et ses conséquences pour la modélisation.
- Poser correctement un problème de prévision et l'évaluer sans fuite temporelle.

Contenu théorique du cours :

- Ce qu'est une série temporelle ; pourquoi l'ordre des observations y change tout.
- Les composantes : tendance, saisonnalité, cycle, bruit ; la décomposition additive et multiplicative.
- Lissage : moyennes mobiles simples et centrées ; lissage exponentiel.
- Stationnarité et autocorrélation : définitions, lecture, conséquences.
- Introduction aux modèles de prévision (persistance, lissages, premiers modèles de type ARIMA) ; évaluer une prévision en respectant l'ordre temporel (pas de mélange passé-futur).

Fichiers de référence (projet) : Aucun — cours à créer de toutes pièces..

Concepts à ajouter lors de la rédaction :

+ **[Ajout — absent des fichiers du projet]** Le cours entier est un ajout : les séries temporelles, centrales dans le métier de data analyst (suivi d'indicateurs, prévision des ventes), ne figurent dans aucun fichier du projet.

Bloc V — Environnement professionnel (cours 14 et 15)

Cours 14 — Outils du travail d'équipe : versioning, données relationnelles et performance (concepts)

Statut : à rédiger.

Prérequis : aucun prérequis statistique ; placé en fin de cursus car il outille la pratique future.

Objectifs :

- Expliquer les concepts de la gestion de versions : commit, branche, fusion, conflit, états d'un dépôt.
- Décrire l'organisation d'un projet reproductible (environnement isolé, dépendances déclarées).
- Lire un modèle de données relationnel : tables, clés, cardinalités, modèle en étoile.
- Ordonner les idées de performance : interprété contre compilé, vectorisation, parallélisme.

Contenu théorique du cours :

- Git en concepts : un commit comme version ; branches et historique commun ; avance rapide, divergence, fusion à deux parents ; conflit et sa résolution ; local, référence distante et dépôt partagé ; lire, restaurer, annuler : trois besoins distincts ; vérifier après chaque intégration.
- Reproductibilité d'un projet : environnement virtuel et dépendances ; séparer calculer, décrire, afficher ; transformer une vérification en test répétable.
- Données relationnelles : table plate contre modèle organisé ; tables de faits et de dimensions ; clés et cardinalités (un-à-plusieurs, plusieurs-à-plusieurs) ; modèle en étoile contre flocon ; propagation des filtres.
- Performance : compiler ou interpréter ; la vectorisation ; threads et mémoire partagée ; le GPU et le coût des transferts ; mesurer avec un protocole, pas à l'impression.
- Travailler avec une assistance IA : donner un problème vérifiable ; une réponse plausible peut être fausse ; contexte et fichiers partagés.

Fichiers de référence (projet) : 2026-10-08_git_et_evaluation_modeles.pptx (partie Git) ; 2026-10-09_collaboration_et_simulation.pptx (partie Git collaboratif) ; 2026-10-16_git_diagnostiquer_integrer_retrouver.pptx ; 2026-09-22_python_architecture_packages_parallelism.pptx (concepts) ; 2026-09-24_python_tools_parallelism_course.pptx (concepts) ; 2026-09-25_python_architecture_et_sql.pptx (concepts) ; ModuleBI_Modelisation_DAX.pptx (uniquement pour ses concepts de modélisation : faits, dimensions, étoile, cardinalités — le support lui-même est un cours logiciel, hors périmètre).

Concepts à ajouter lors de la rédaction :

+ **[Ajout — absent des fichiers du projet]** Le langage SQL en théorie (sélection, jointures, agrégations, sous-requêtes), quasi absent des fichiers alors qu'il est indispensable au métier.
+ **[Ajout — absent des fichiers du projet]** Une introduction aux bases NoSQL et aux formats de données (JSON, Parquet), absente.

Cours 15 — Intelligence artificielle et écosystème de l'analyste : comprendre, situer, vérifier

Statut : à rédiger.

Prérequis : Cours 6 et 7 (modèles, apprentissage, évaluation).

Objectifs :

- Définir l'IA, l'apprentissage et la génération ; relier IA prédictive et IA générative.
- Décrire un réseau de neurones : neurones, paramètres, entraînement ; expliquer la notion de boîte noire.
- Identifier biais, erreurs et limites ; situer les facteurs de succès d'un projet d'IA.
- Comprendre le protocole MCP et la vérifiabilité des réponses ; formuler la valeur ajoutée de l'analyste face aux outils d'IA.

Contenu théorique du cours :

- Définitions : l'intelligence comme capacité à apprendre, comprendre, s'adapter ; IA prédictive et générative, une même technologie de prédiction du suivant ; GPT et les grands modèles de langage.
- Réseaux de neurones : le neurone (entrées pondérées, seuil) ; les paramètres ; l'entraînement et sa dépendance aux conditions initiales ; ordres de grandeur (du jouet à la grappe de calcul) ; asymétrie des coûts entraînement/utilisation.
- Boîte noire : des milliers de milliards de paramètres non interprétables directement ; conséquences pour la confiance.
- Biais et limites : reproduire les biais des données d'entraînement ; erreurs manifestes et subtiles ; mésinformation et désinformation ; domaines encadrés (conseil médical, juridique).
- Facteurs de succès : environ 5 % des projets aboutissent ; l'intégration et l'entraînement sur ses propres données et règles ; contexte industriel (investissements, emploi, force brute).
- MCP : un protocole d'échange entre application et serveurs de données ou d'outils ; trois types de contenu ; d'une question métier à une réponse vérifiable.
- La valeur de l'analyste : la sémantique métier ne se connecte pas toute seule ; un outil utile précise entrées, sorties et limites ; une réponse répétable peut être fausse — la vérifiabilité

comme compétence centrale.

Fichiers de référence (projet) : 2025-11_Introduction_à_l'IA_final.pptx ; 2026-10-30_mcp_usages_et_debouches.pptx.

Concepts à ajouter lors de la rédaction :

+ **[Ajout — absent des fichiers du projet]** Une introduction au cadre réglementaire européen de l'IA (AI Act : niveaux de risque, obligations), absente des fichiers.
+ **[Ajout — absent des fichiers du projet]** L'évaluation systématique des réponses d'un modèle génératif (jeux de test, traçabilité), seulement suggérée par les supports.

4. Vue d'ensemble : progression et références

Le tableau suivant résume le cursus : pour chaque cours, ses prérequis directs et les fichiers du projet à utiliser comme sources de rédaction. Les mentions « Ajout » rappellent les cours qui demanderont des contenus non présents dans les fichiers.

N°	Cours	Prérequis	Fichiers de référence (projet)	Ajouts hors fichiers
1	Introduction à l'analyse de données	—	Cours 1 — Introduction à l'analyse de données.pdf	Déjà rédigé
2	Lire les distributions : familles, simulation, échantillonnage	1	diapositives-3.pdf ; 2026-09-17_individual_project ; 2026-09-18_review_and_two_gaussians	Ajouts : TCL, binomiale, Poisson
3	Qualité, validation et éthique des données	1, 2	Valider_table_donnees1 ; 2026-09-25_python_architecture_et_sql ; 2026-09-17_individual_project	Ajouts : RGPD, gouvernance
4	Inférence : tester une différence	1, 2	2026-09-29_gaussian_project… ; 2026-10-01_age_purchase_association ; 2026-10-13_reprendre_les_questions_du_bilan	Ajouts : types I/II, χ^2, ANOVA, Mann-Whitney
5	Association, régression et causalité	1, 4	2026-10-01_age_purchase_association ; 2026-10-06_correlation ; 2026-10-13_reprendre_les_questions_du_bilan	Ajouts : Spearman, vocabulaire causal
6	Évaluer un modèle prédictif	5	2026-10-08_git_et_evaluation_modeles ; 2026-10-09_collaboration_et_simulation ; 2026-10-13_reprendre_les_questions_du_bilan ; 2026-10-22-23_pipeline_polynomes_heart_modeles	Ajouts : k-fold, biais-variance, baseline
7	Classification supervisée	6	2026-10-22-23_pipeline_polynomes_heart_modeles	Ajouts : F1, ROC/AUC, déséquilibre, arbres, k-NN
8	Analyse multidimensionnelle et ACP	1, 5	Analyse_multidimensionnelle_intro ; ACP_pas_a_pas_agences	—
9	ACM et données qualitatives	8	ACM_pas_a_pas_jackstream ; Analyse_multidimensionnelle_intro	Ajout : AFC simple
10	Segmentation : CAH et K-means	8 (9)	CAH_Kmeans ; segmentation_kmeans_cah_pas_a_pas	Ajouts : consolidation, DBSCAN, GMM
11	Indicateurs, KPI et visualisation	1, 5	Indicateurs-cours 02 ; Graphiques-KPI-cours	Ajout : data storytelling
12	Pilotage de la performance et tableaux de bord	11	Pilotage-de-la-performance-Dashboards-et-TB	—
13	Séries temporelles	1, 6	aucun fichier	Cours entièrement à créer

N°	Cours	Prérequis	Fichiers de référence (projet)	Ajouts hors fichiers
14	Versioning, données relationnelles, performance	—	2026-10-08, 2026-10-09, 2026-10-16 (Git) ; 2026-09-22, 2026-09-24, 2026-09-25 (concepts Python) ; ModuleBI_Modelisation_DAX (concepts de modélisation uniquement)	Ajouts : SQL, NoSQL et formats
15	IA et écosystème de l'analyste	6, 7	2025-11_Introduction_à_l'IA_final ; 2026-10-30_mcp_usages_et_debouches	Ajout : AI Act, évaluation des réponses

Rappels : les fichiers sont cités par leur nom exact dans le projet. Les supports Power BI, Power Query, DAX, les ateliers d'installation et les énoncés d'exercices restent hors périmètre théorique ; seuls les concepts de modélisation relationnelle du support DAX sont réutilisés (cours 14). Les fichiers de données CSV et les énoncés Markdown serviront à la conception des travaux pratiques, traitée séparément.