# Qualité, validation et éthique des données

*À l'issue de ce cours, vous saurez écrire le contrat d'une table, la contrôler en quinze étapes ordonnées, décider face à chaque anomalie — et appliquer les principes éthiques et légaux du métier.*

Bloc I — Fondations

Cours 3

Novembre 2026

# Sommaire

**1. Objectifs d'apprentissage** 3

**2. Prérequis et rappels** 4

**3. Pourquoi c'est important** 5

**4. Corps du cours** 6

4.1 La validité est relative à l'usage 6

4.2 Le contrat de la table 6

4.3 Les sept dimensions de la qualité 7

4.4 Une valeur manquante n'est pas un zéro 8

4.5 Représentations du manquant et pseudo-manquants 9

4.6 L'ordre des contrôles et les deux sévérités 9

4.7 Le contenant : taille, colonnes, lignes vides 11

4.8 Types lisibles et dates au format imposé 11

4.9 La complétude : obligatoire bloquant, facultatif alerte 12

4.10 L'unicité : doublons exacts et conflits de clé 13

4.11 Domaines, plages et formats 14

4.12 Les valeurs ensemble : cohérence et intégrité référentielle 15

4.13 Le sens : aberrantes, actualité, rapprochement avec la source 15

4.14 La question décisive : la bonne valeur est-elle certaine ? 17

4.15 Les quatre actions : corriger, exclure, imputer, signaler 18

4.16 Traçabilité et revalidation 18

4.17 Les six principes éthiques du métier 20

4.18 Le cadre juridique : le RGPD 21

4.19 La gouvernance des données en organisation 22

**5. Erreurs fréquentes et pièges** 24

**6. Exercices** 25

**7. Fiche récapitulative** 27

**8. Pour aller plus loin** 28

**Corrigé détaillé des exercices** 29

# 1. Objectifs d'apprentissage

À l'issue de ce cours, vous saurez :

- **Écrire** le contrat d'une table avant de la regarder, et **définir** la validité pour un usage donné ;
- **Appliquer** une batterie ordonnée de quinze contrôles et **classer** chaque règle — bloquante ou alerte ;
- **Choisir** la bonne décision face à une anomalie — corriger, exclure, imputer, signaler — et la **tracer** ;
- **Appliquer** les principes éthiques du métier et le cadre légal de la protection des données à chaque étape du traitement.

## 2. Prérequis et rappels

**Prérequis.** Ce cours suppose acquis : les types de variables (qualitative nominale ou ordinale, quantitative discrète ou continue) et l'écart interquartile (cours 1) ; la distinction entre valeur inhabituelle et erreur (cours 2).

**Rappels de cours précédents.** Au cours 1, vous avez appris à détecter les valeurs atypiques par la règle des 1,5 × IQR : au-delà de $Q_3 + 1{,}5 \times \mathrm{IQR}$, une valeur mérite un examen. Au cours 2, vous avez posé une règle essentielle : une valeur inhabituelle n'est pas une erreur — rare ne veut pas dire faux, et tout signal d'anomalie commande une enquête, jamais une suppression automatique. Vous y avez aussi vu la règle de décision en quatre questions (valide ? corrigeable ? plausible ? tracer) et le journal des exclusions. Ce cours reprend ces réflexes et les organise en une méthode complète : la validation d'une table, du premier contrôle jusqu'à la livraison.

# 3. Pourquoi c'est important

Vous êtes analyste dans une institution de microfinance. Chaque mois, le système informatique vous transmet l'extraction du portefeuille de prêts : plusieurs centaines de lignes, une par prêt. Votre direction veut suivre l'encours et le risque par agence. Avant le premier graphique, une question décide de tout le reste : **peut-on travailler sur cette table, et à quelles conditions ?**

Ce qui se passe si l'on ignore cette question est simple : on calcule des moyennes sur des montants faux, on compte deux fois le même prêt, on classe des clients « à risque » à cause d'une saisie erronée. Et les conséquences ne sont pas abstraites : derrière chaque ligne, il y a un crédit accordé ou refusé, un client classé, un agent jugé sur ses chiffres. Une table « nettoyée » sans trace est même pire qu'une table sale : personne ne peut plus savoir ce qui était vrai.

La qualité n'est donc pas une impression ni un coup d'œil au fichier : c'est le **résultat d'une liste de contrôles écrite avant de regarder les données**. Ce cours vous donne cette méthode complète — le contrat, les quinze contrôles dans l'ordre, les décisions, la traçabilité — et le cadre éthique et légal qui l'encadre, car ces données concernent des personnes.

**LE FIL ROUGE DU COURS**

Tout le cours s'appuie sur un cas réaliste et fictif : **Nkap Microfinance** transmet l'extraction de son portefeuille de prêts au 30/09/2026, pour un suivi mensuel de l'encours et du risque par agence. La table contient 609 lignes et 17 colonnes ; la source annonce 600 prêts et 435 653 000 FCFA de montants. Un référentiel liste les 8 agences. Les défauts de cette table sont ceux qu'on rencontre dans les vraies extractions — nous les rencontrerons un par un, dans l'ordre.

# 4. Corps du cours

## 4.1 La validité est relative à l'usage

Ouvrez n'importe quelle table et demandez-vous : « est-elle valide ? » La question est mal posée. Il n'existe pas de validité absolue, pas de table « propre » en soi. La bonne question est : **cette table est-elle assez bonne pour ce que je veux en faire ?** En anglais, on parle de *fit for use* — adaptée à l'usage.

Une même table peut passer pour un usage et échouer pour un autre. Notre portefeuille de prêts, par exemple, peut suffire pour un suivi mensuel interne de l'activité, où quelques montants « à vérifier » changent peu les tendances. Le même fichier serait inacceptable pour une déclaration réglementaire, où chaque franc doit être expliqué.

> **DÉFINITION — TABLE VALIDE**
>
> Une table est **valide** (*fit for use*) lorsque ses caractéristiques satisfont les **exigences écrites pour son usage**. La validité n'est pas une propriété de la table seule : c'est une relation entre la table et ce qu'on veut en faire.

**Tableau 1.** La même table, deux usages, deux verdicts.

| Usage prévu | Exigence dominante | Verdict possible sur la même table |
|---|---|---|
| Tableau de bord interne mensuel | Tendances fiables, quelques tolérances | Valide *sous conditions* : alertes examinées |
| Déclaration réglementaire | Chaque montant exact et prouvé | Non valide tant que le rapprochement avec la source n'est pas complet |

Conséquence pratique : on ne juge jamais une table sans avoir écrit, **avant**, ce qu'elle doit respecter. C'est l'objet de la section suivante.

> **À RETENIR**
>
> - La validité est relative à un usage : pas de validité absolue.
> - La question à poser : « assez bonne pour quoi faire ? »
> - Une table devient valide pour un usage donné, preuve à l'appui — elle ne l'est jamais par défaut.

## 4.2 Le contrat de la table

Puisque la validité se mesure à des exigences, il faut les écrire. Ce document s'appelle le **contrat de la table** (*data contract*). Il se rédige **avec le métier, avant d'ouvrir le fichier** — jamais après, car écrire les règles en regardant les données, c'est laisser la table dicter ses propres exigences.

Pour chaque colonne, le contrat fixe quatre choses : le **type** attendu, le caractère **obligatoire ou facultatif**, et la **règle** précise à respecter (format, domaine, plage, référence).

**Tableau 2.** Extrait du contrat de la table des prêts (fil rouge).

| Colonne | Type | Obligatoire | Règle |
|---|---|---|---|
| `id_pret` | texte | oui | Format PR-99999, unique |
| `id_client` | texte | oui | Format CL-9999 |
| `nom_client, telephone, email` | texte | non | Données personnelles ; téléphone +237 6XX XX XX XX |
| `sexe` | texte | non | F ou M |

| | | | |
|---|---|---|---|
| `date_naissance` | date jj/mm/aaaa | non | Âge à l'octroi entre 18 et 75 ans |
| `agence` | texte | oui | Présente dans le référentiel des agences |
| `date_octroi` | date jj/mm/aaaa | oui | Antérieure ou égale à la date d'extraction |
| `duree_mois` | entier | oui | 6, 12, 18, 24 ou 36 |
| `montant` | entier, sans séparateur | oui | De 25 000 à 10 000 000 FCFA |
| `taux_annuel` | décimal, virgule | oui | De 0,05 à 0,30 |
| `statut` | texte | oui | En cours, Soldé, En retard, Contentieux |
| `encours` | entier | oui | Positif, inférieur au montant, nul si Soldé |

**EXEMPLE GUIDÉ — RÉDIGER UNE LIGNE DE CONTRAT**

Le métier vous dit : « le montant d'un prêt, c'est toujours un nombre entier de francs, entre vingt-cinq mille et dix millions, et sans montant le prêt n'existe pas ». Traduction en ligne de contrat, pas à pas : **type** — « entier, sans séparateur », parce qu'un montant « 565 000 » avec espaces doit être repéré comme non conforme ; **obligatoire** — « oui », parce qu'un prêt sans montant n'a pas de sens métier ; **règle** — « de 25 000 à 10 000 000 FCFA », les bornes commerciales fournies par le métier. Chaque phrase du métier devient une règle testable : c'est exactement cela, écrire un contrat.

**À RETENIR**

- Le contrat s'écrit avec le métier, **avant** d'ouvrir le fichier.
- Pour chaque colonne : type, obligatoire ou facultatif, règle précise.
- Pas de contrat, pas de validité : le contrat est la référence de tous les contrôles.

## 4.3 Les sept dimensions de la qualité

Le contrat liste les règles ; il reste à les organiser. La qualité d'une table (*data quality*) se décompose en **sept dimensions** (*data quality dimensions*), chacune répondant à une question différente. Les apprendre par cœur n'est pas le but : elles servent de grille pour n'oublier aucune famille de défauts.

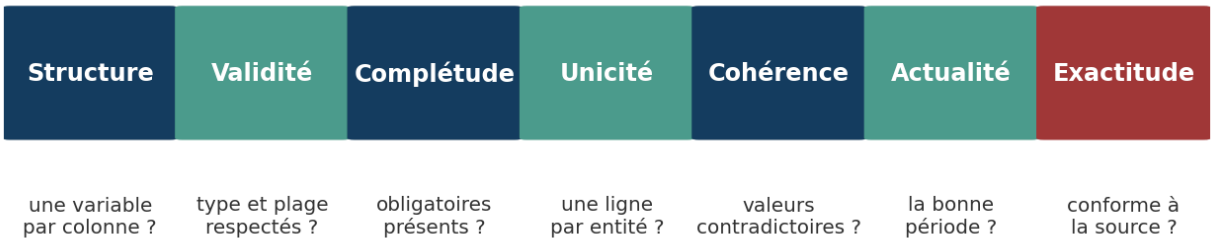



**Figure 1.** Les sept dimensions de la qualité d'une table, et la question posée par chacune.

**Tableau 3.** Les sept dimensions, avec un exemple de défaut pour chacune.

| Dimension | La question posée | Exemple de défaut |
|---|---|---|
| **Structure** | Une variable par colonne, une observation par ligne, un seul en-tête ? | Colonne nommée « Montant » avec une espace finale |
| **Validité** | Type, format, domaine et plage respectés ? | Un taux saisi « 18 » au lieu de 0,18 |
| **Complétude** | Les valeurs obligatoires sont-elles présentes ? | Un prêt sans agence |

| | | |
|---|---|---|
| **Unicité** | Chaque entité apparaît-elle une seule fois ? | Le même prêt sur deux lignes |
| **Cohérence** | Les valeurs se contredisent-elles, dans la ligne ou entre tables ? | Un prêt « Soldé » avec un encours positif |
| **Actualité** | Les données reflètent-elles la période annoncée ? | Un prêt octroyé après la date d'extraction |
| **Exactitude** | Les données correspondent-elles à la réalité, à la source ? | Le total des montants ne concorde pas avec le bordereau |

**ATTENTION — VALIDE NE VEUT PAS DIRE EXACT**

Une cellule peut être remplie, au bon format, dans la bonne plage… et fausse. Un montant de 662 000 saisi 95 000 000 respecte le type et la plage : aucun contrôle de forme ne le détecte. Seuls le rapprochement avec la source et l'examen des valeurs suspectes révèlent ce genre d'erreur — nous y reviendrons à la section 4.13.

**À RETENIR**

- Sept dimensions : structure, validité, complétude, unicité, cohérence, actualité, exactitude.
- Chaque dimension répond à une question différente — la grille évite les oublis.
- La forme ne prouve pas le fond : une valeur bien formée peut être fausse.

## 4.4 Une valeur manquante n'est pas un zéro

Avant même de contrôler une table, il faut se mettre d'accord sur ce qu'est une **valeur manquante** (*missing value*) : une information **absente**. Ce n'est ni un zéro, ni une chaîne vide à ignorer — c'est l'aveu qu'on ne sait pas. Confondre les deux change les résultats.

**ANALOGIE**

Au restaurant, « le client n'a pas encore commandé » et « le client commande pour zéro euro » ne veulent pas dire la même chose. Le premier ticket est incomplet ; le second est un ticket à zéro. Dans une moyenne de panier, l'un doit être ignoré, l'autre compte.

**EXEMPLE GUIDÉ — L'EFFET SUR UNE MOYENNE**

Trois tickets support ont des durées de résolution : 30 minutes, *inconnue*, 0 minute (le ticket a été résolu immédiatement — c'est une vraie valeur). Quelle est la durée moyenne ?

$$\bar{x} = \frac{30 + 0}{2} = 15 \text{ min}$$

$\bar{x}$ : durée moyenne de résolution, en minutes
30, 0 : les deux durées connues, en minutes
2 : nombre de valeurs *connues* — la case inconnue n'est pas comptée

On moyenne les valeurs connues, et seulement elles : la case inconnue n'apporte rien, elle ne pèse pas. Si l'on remplaçait la case inconnue par un 0, on obtiendrait $(30 + 0 + 0)/3 = 10$ minutes — un autre résultat, construit sur une autre hypothèse : « ce ticket a mis zéro minute ». Avant de remplir une case vide, demandez-vous toujours ce que la valeur ajoutée *signifierait*.

**EN PRATIQUE DANS LE CODE**

```
values = pd.Series([30, None, 0], dtype="Float64")
values.count()   # 2 : la case inconnue n'est pas comptée
values.mean()    # 15.0 : moyenne des valeurs connues
```

**À RETENIR**

- Manquant = absence d'information ; zéro = valeur connue qui vaut zéro.
- Les calculs standard ignorent les manquants — les remplacer par 0 change l'hypothèse et le résultat.
- Toute imputation se justifie, jamais par commodité (voir section 4.15).

## 4.5 Représentations du manquant et pseudo-manquants

Dans les outils du métier, le manquant prend plusieurs visages selon le type de la colonne. Et dans les fichiers réels, il se déguise : un tiret, un « ? », un « N/A » ne sont pas des cellules vides, mais ne disent rien — ce sont des **pseudo-manquants** (*sentinel values*, valeurs sentinelles).

**Tableau 4.** Les marqueurs de manquant selon le type de colonne.

| Marqueur | Où on le rencontre | Exemple |
|---|---|---|
| `NaN` | Colonne numérique classique (flottants) | Un montant illisible après conversion |
| `pd.NA` | Type pandas prévu pour accepter le manquant (texte, entier « nullable ») | Un e-mail absent |
| `NaT` | Colonne de dates ou de durées | Une date d'échéance absente |

**EXEMPLE GUIDÉ — TRIER UN EXTRAIT DE COLONNE**

Dans la colonne `telephone` du fil rouge, on lit : « +237 699 12 34 56 », « », « - », « ? », « N/A ». Classez : la première est une **valeur** (elle respecte le format) ; la deuxième est **vide** ; les trois dernières sont des **pseudo-manquantes** : remplies, donc invisibles à un simple comptage des cases vides, mais sans information. Un contrôle de complétude sérieux compte les deux familles ensemble — c'est exactement ce que la section 4.9 mettra en œuvre.

**EN PRATIQUE DANS LE CODE**

```
MANQUANTES = {"", "-", "?", "N/A", "NA", "null"}
s.isna() | s.str.strip().isin(MANQUANTES)   # vides + pseudo-manquants
pd.read_csv(f, dtype=str, keep_default_na=False)  # lire en texte, rien deviné
```

**À RETENIR**

- Le marqueur dépend du type : NaN (nombres), pd.NA (types dédiés), NaT (dates).
- Pseudo-manquants : « - », « ? », « N/A »… remplis mais vides de sens — les compter avec les vrais manquants.
- Lire le fichier en texte, sans rien deviner, pour voir les données telles qu'elles sont.

## 4.6 L'ordre des contrôles et les deux sévérités

Contrôler une table, ce n'est pas pêcher des erreurs au hasard : c'est appliquer une **batterie ordonnée de quinze contrôles**. L'ordre va du contenant au contenu, et du simple au composé : d'abord le fichier et sa structure, puis les valeurs une à une, puis les valeurs entre elles, et enfin le sens. Inverser l'ordre, c'est chercher une incohérence dans une colonne qui n'existe pas.

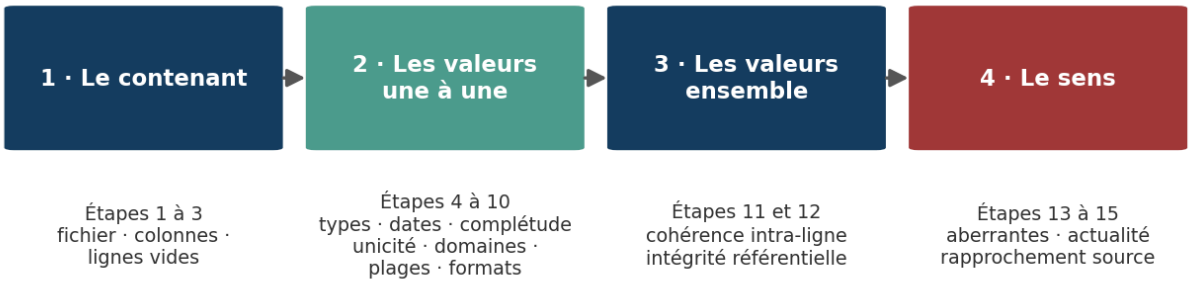



**Figure 2.** Les quinze contrôles en quatre phases : contenant, valeurs une à une, valeurs ensemble, sens.

Chaque règle reçoit en outre une **sévérité** : **bloquante** (*blocking rule*) si son échec invalide la table pour l'usage prévu, ou **alerte** (*warning*) si elle signale un point à examiner sans interdire la suite. Une table est déclarée valide quand il ne reste **zéro règle bloquante en échec** et que toutes les alertes ont été examinées. Dernier principe, valable pour chaque étape : on **signale sans modifier** — le diagnostic compte les lignes en échec et les range dans un rapport, il ne touche pas aux données.

**Tableau 5.** Les quinze contrôles dans l'ordre, avec leur sévérité habituelle.

| # | Contrôle | La question | Sévérité type |
|---|---|---|---|
| 1 | Taille du fichier | Autant de lignes que la source l'annonce ? | alerte |
| 2 | Colonnes | Toutes les colonnes du contrat, et seulement elles ? | bloquante |
| 3 | Lignes vides | Des lignes entièrement vides à écarter ? | alerte |
| 4 | Types lisibles | Chaque valeur est-elle lisible selon le type du contrat ? | bloquante |
| 5 | Dates | Au format imposé, et réelles ? | bloquante |
| 6 | Complétude | Les obligatoires sont-ils renseignés ? | bloquante / alerte |
| 7 | Unicité | Doublons exacts ? Conflits de clé ? | alerte / bloquante |
| 8 | Domaines | Chaque valeur fait-elle partie des valeurs autorisées ? | bloquante |
| 9 | Plages métier | Chaque nombre est-il dans ses bornes ? | bloquante |
| 10 | Formats | Identifiants, téléphones, e-mails bien formés ? | bloquante / alerte |
| 11 | Cohérence intra-ligne | Les valeurs d'une même ligne se contredisent-elles ? | bloquante |
| 12 | Intégrité référentielle | Chaque code existe-t-il dans la table qu'il désigne ? | bloquante |
| 13 | Valeurs aberrantes | Au-delà du seuil interquartile ? Une alerte, jamais une suppression | alerte |
| 14 | Actualité | Les dates dans la période annoncée ? | bloquante |
| 15 | Rapprochement avec la source | Les totaux concordent-ils avec ce que la source annonce ? | bloquante |

**À RETENIR**

- Quatre phases, dans l'ordre : contenant → valeurs une à une → valeurs ensemble → sens.
- Chaque règle est classée : bloquante (invalide) ou alerte (à examiner).
- Valide = zéro bloquant en échec, alertes examinées ; on signale sans modifier.

## 4.7 Le contenant : taille, colonnes, lignes vides (étapes 1 à 3)

Premier réflexe : le fichier a-t-il la **taille annoncée** par la source ? Puis : les **colonnes du contrat** sont-elles toutes là, et seulement elles ? Enfin, y a-t-il des **lignes entièrement vides** ? Une ligne vide n'est pas une donnée : on la compte, on l'écarte de la suite, on le note — elle explique souvent une partie de l'écart de taille.

Deux subtilités sur les colonnes : les outils sont sensibles à la **casse et aux espaces** (« Montant » avec une espace finale n'est pas « montant »), et une colonne en trop mais entièrement vide reste un défaut de structure à signaler.

**EXEMPLE GUIDÉ — LE CONTENANT DU FIL ROUGE**

La source annonce 600 prêts ; le fichier en contient 609 lignes. L'écart vaut investigation, pas panique. Étape 2 : la colonne `montant` semble manquer — en fait elle s'appelle « Montant » avec une espace finale ; et une colonne « commentaire », absente du contrat, est entièrement vide. La structure se corrige tout de suite (renommage, retrait), et la correction se trace. Étape 3 : trois lignes entièrement vides, aux lignes 41, 251 et 386 du fichier. Écart expliqué en partie : 609 lues − 3 vides = 606 lignes de données, pour 600 prêts annoncés — le reste de l'écart attendra l'étape 7 (les doublons).

**EN PRATIQUE DANS LE CODE**

```
df = pd.read_csv("prets.csv", sep=";", dtype=str, keep_default_na=False)
len(df)                                    # 609 lignes lues, pour 600 annoncées
[c for c in ATTENDUES if c not in df.columns]   # colonnes manquantes
[c for c in df.columns if c not in ATTENDUES]   # colonnes en trop
```

**À RETENIR**

- Comparer la taille lue à la taille annoncée ; tout écart s'explique.
- Colonnes : manquantes, en trop, vides — attention à la casse et aux espaces.
- Ligne vide : compter, écarter, noter.

## 4.8 Types lisibles et dates au format imposé (étapes 4 et 5)

Une valeur présente mais **illisible selon le contrat** est un échec de type : « 565 000 » avec des espaces de milliers n'est pas un entier lisible. La bonne méthode est la **conversion stricte** : on tente la conversion, ce qui échoue devient un manquant, et on compte ces échecs — on ne supprime rien.

Pour les dates, on **impose toujours le format**. Sans format explicite, l'outil devine : et le 03/04 peut devenir le 4 mars au lieu du 3 avril, sans aucun message d'erreur. Il faut ensuite distinguer deux familles de défauts : la **mauvaise forme, valeur certaine** (« 2023-07-21 » est la même date sous une autre écriture, récupérable) et la **valeur impossible** (« 31/02/2025 » n'existe pas : à renvoyer à la source, on ne devine pas).

**EXEMPLE GUIDÉ — MONTANTS ET DATES DU FIL ROUGE**

**Tableau 6.** Brute → diagnostic → destin.

| Valeur brute | Diagnostic | Destin |
|---|---|---|
| `« 565 000 » (×12)` | Mauvaise forme : espaces de milliers ; la valeur est certaine | Corrigible (section 4.15), à tracer |
| `« N/A » (×2)` | Pseudo-manquant, pas une valeur illisible | Compté à la complétude (étape 6) |
| `« 2023-07-21 » (×15)` | Même date, autre écriture ; la valeur est certaine | Corrigible, à tracer |
| `« 31/02/2025 » (×2)` | Date impossible : le 31 février n'existe pas | Marquer, renvoyer à la source |

Bilan de l'étape : 12 montants illisibles (tous récupérables) et 17 dates d'octroi refusées, dont 15 récupérables et 2 impossibles. Remarquez la méthode : on n'a encore **rien corrigé** — on a diagnostiqué et classé.

**EN PRATIQUE DANS LE CODE**

```
pd.to_numeric(s, errors="coerce")                    # strict : l'illisible devient NaN, et on le compte
pd.to_datetime(s, format="%d/%m/%Y", errors="coerce") # format imposé, jamais deviné
```

**À RETENIR**

- Conversion stricte : l'illisible devient manquant et se compte — rien ne disparaît en silence.
- Dates : toujours imposer le format, sinon l'outil devine et peut intervertir jour et mois.
- Mauvaise forme ≠ valeur fausse : « 2023-07-21 » se corrige, « 31/02/2025 » se renvoie.

## 4.9 La complétude : obligatoire bloquant, facultatif alerte (étape 6)

La **complétude** (*completeness*) mesure si les valeurs promises sont là. Le contrat tranche la sévérité : un obligatoire manquant est **bloquant**, un facultatif manquant est une **alerte**. Et on compte les deux familles de manquants : les cases vides *et* les pseudo-manquants de la section 4.5 — un « - » n'est pas vide, mais ne dit rien.

**EXEMPLE GUIDÉ — LA COMPLÉTUDE DU FIL ROUGE**

Sur les 606 lignes non vides : côté obligatoire, l'agence manque 4 fois (saisie « - ») et le montant 2 fois (« N/A ») — bloquant, ces prêts ne sont pas exploitables en l'état. Côté facultatif : téléphone 21 manquants, e-mail 35, sexe 8 (dont deux « ? ») — alertes, à signaler sans bloquer.

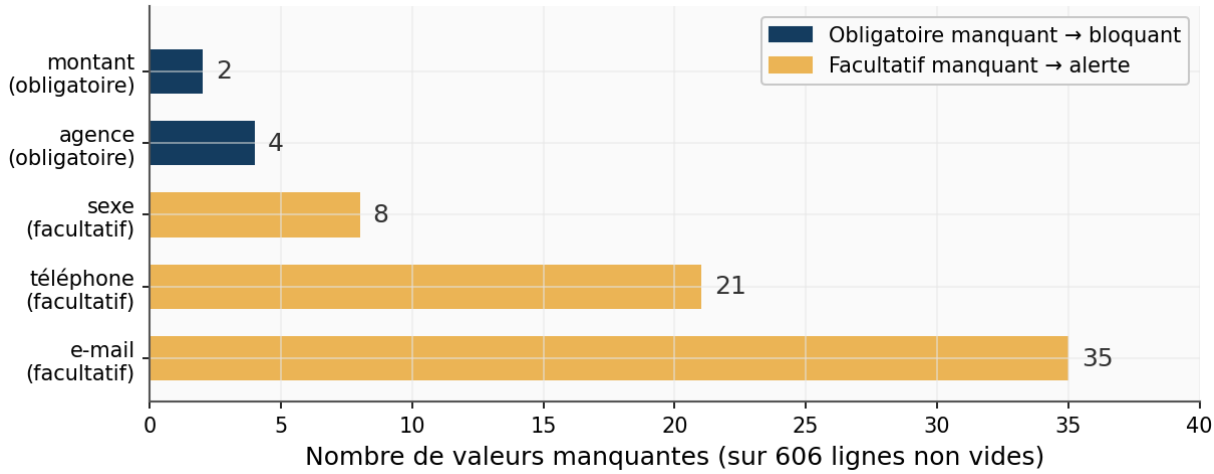



**Figure 3.** Valeurs manquantes par colonne dans le fil rouge : le caractère obligatoire (foncé, bloquant) ou facultatif (clair, alerte) fixe la sévérité.

**EN PRATIQUE DANS LE CODE**

```
est_manquant(t["agence"]).sum()    # 4 : obligatoire → bloquant
est_manquant(t["email"]).sum()     # 35 : facultatif → alerte
```

**À RETENIR**

- Obligatoire manquant = bloquant ; facultatif manquant = alerte.
- Compter vides + pseudo-manquants, sinon les « - » passent pour des valeurs.
- Un manquant obligatoire se renvoie à la source — il ne s'invente pas (section 4.15).

## 4.10 L'unicité : doublons exacts et conflits de clé (étape 7)

Le contrat promet une ligne par prêt. Deux situations très différentes menacent cette promesse. Le **doublon exact** (*exact duplicate*) : la même ligne, deux fois, sans ambiguïté — on garde une copie, on trace. Le **conflit de clé** (*key conflict*) : le même identifiant pour deux contenus différents — lequel est vrai ? On ne devine pas : c'est une question pour la source.

**EXEMPLE GUIDÉ — DOUBLONS ET CONFLITS DU FIL ROUGE**

**Tableau 7.** Deux situations, deux décisions.

| id_pret | montant | statut | Situation | Décision |
|---|---|---|---|---|
| PR-00189 | 350000 | En cours | Doublon exact (4 cas dans la table) | Garder une copie, tracer |
| PR-00189 | 350000 | En cours | | |
| PR-00543 | 480000 | En cours | Conflit de clé (PR-00543 et PR-00600) | Marquer, renvoyer à la source |
| PR-00543 | 730000 | Soldé | | |

Après écartement des 4 doublons et résolution des 2 conflits, la table compte exactement 600 prêts distincts — l'écart de taille de l'étape 1 est maintenant entièrement expliqué : 609 lues = 3 vides + 4 doublons + 2 doublures de conflit + 600 prêts.

**EN PRATIQUE DANS LE CODE**

```
t.duplicated(keep="first")            # doublons exacts : 4
u.duplicated("id_pret", keep=False)   # conflits de clé : PR-00543, PR-00600
```

**À RETENIR**

- Doublon exact = sans ambiguïté : une copie gardée, la trace écrite.
- Conflit de clé = même identifiant, contenus différents : jamais de choix à l'intuition.
- L'unicité explique souvent l'écart entre lignes lues et entités annoncées.

## 4.11 Domaines, plages et formats (étapes 8 à 10)

Trois contrôles de validité, trois questions différentes. Le **domaine** (*domain*) : la valeur fait-elle partie des valeurs autorisées ? La comparaison est volontairement sensible à la casse et aux espaces — on *veut* voir chaque variante (« en cours », « EN COURS ») pour la corriger ensuite proprement. La **plage** (*range*) : chaque nombre a des bornes métier, écrites dans le contrat. Le **format** : les identifiants, téléphones et e-mails respectent-ils leur motif (décrit par une *expression régulière*, c.-à-d. un motif de texte comme `PR-` suivi de cinq chiffres) ?

**EXEMPLE GUIDÉ — TROIS CONTRÔLES SUR LE FIL ROUGE**

**Tableau 8.** Domaines, plages, formats : les échecs du fil rouge.

| Contrôle | Échecs relevés | Lecture |
|---|---|---|
| Domaine de `statut` | 9 valeurs : « en cours » (×4), « EN COURS » (×3), « Solde » (×2) | Variantes de casse et d'accent : la bonne valeur est certaine → corrigibles |
| Domaines de `sexe` et `duree_mois` | 3 « Femme » ; 2 prêts de 15 mois | « Femme » → F : certain, corrigible ; 15 mois n'est pas au catalogue → question à la source |
| Plages de `montant`, `taux_annuel`, âge | −150 000 ; 0 ; 95 000 000 ; taux « 18 » (×4) ; emprunteurs de 16 ans (×2) | Hors bornes métier : aucune ne se corrige à l'intuition |
| Formats | 2 identifiants « PR00390A » ; 7 téléphones ; 5 e-mails sans @ | La clé mal formée est bloquante ; les champs facultatifs sont des alertes |

Retenez le réflexe commun : un échec de domaine, de plage ou de format **classe la valeur, il ne la corrige pas**. La décision viendra au chapitre 4.14.

**EN PRATIQUE DANS LE CODE**

```
~t["statut"].isin({"En cours", "Soldé", "En retard", "Contentieux"})  # domaine
~m.between(25_000, 10_000_000)     # plage métier
~t["id_pret"].str.match(r"^PR-\d{5}$")  # format : motif de texte
```

**À RETENIR**

- Domaine : liste de valeurs autorisées ; la sensibilité à la casse est voulue.
- Plage : bornes métier du contrat — un hors-plage n'est jamais corrigé à l'intuition.
- Format : motif sur les identifiants ; une clé mal formée est bloquante.

## 4.12 Les valeurs ensemble : cohérence intra-ligne et intégrité référentielle (étapes 11 et 12)

Jusqu'ici, chaque valeur était testée seule. Mais chaque valeur peut être valide *seule* et la **ligne incohérente** : c'est la **cohérence intra-ligne**. Exemples du contrat : l'échéance doit égaler octroi + durée ; un prêt « Soldé » doit avoir un encours nul ; l'encours ne peut dépasser le montant. Et attention : les erreurs se propagent — un taux saisi « 18 » au lieu de 0,18 fausse aussi la mensualité calculée.

Deuxième contrôle, entre tables cette fois : l'**intégrité référentielle** (*referential integrity*) exige que chaque code existe dans la table qu'il désigne — ici, chaque agence du portefeuille doit figurer dans le référentiel des agences.

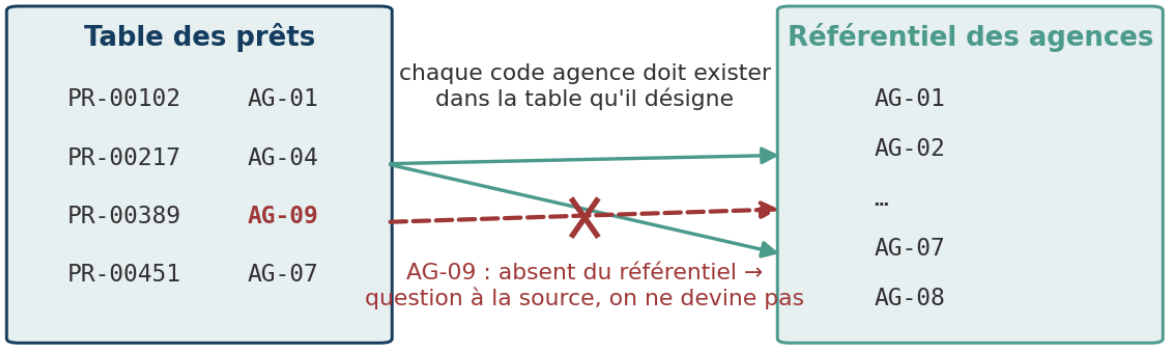



**Figure 4.** Intégrité référentielle : chaque code de la table des prêts doit exister dans le référentiel. « AG-09 » n'y figure pas.

**EXEMPLE GUIDÉ — LES INCOHÉRENCES DU FIL ROUGE**

Étape 11 : six échéances différentes de « octroi + durée », six prêts « Soldé » avec un encours positif, cinq encours supérieurs au montant, dix mensualités différentes du calcul (alerte). Étape 12 : quatre prêts rattachés à « AG-09 », une agence absente du référentiel. Erreur de saisie, ou agence ouverte et pas encore déclarée ? Les deux histoires sont plausibles — c'est précisément pourquoi **on pose la question à la source au lieu de deviner**.

**EN PRATIQUE DANS LE CODE**

```
(t["statut"] == "Soldé") & (encours > 0)          # incohérence intra-ligne
~t["agence"].isin(referentiel["code_agence"])   # intégrité référentielle
pd.merge(t, referentiel, how="left", indicator=True)  # variante par jointure
```

**À RETENIR**

- Valide seule ≠ ligne cohérente : tester les relations entre colonnes.
- Intégrité référentielle : chaque code doit exister dans la table qu'il désigne.
- Les erreurs se propagent : une cause peut expliquer plusieurs échecs.

## 4.13 Le sens : aberrantes, actualité, rapprochement avec la source (étapes 13 à 15)

La table a maintenant la bonne forme. Reste la dernière question : **dit-elle vrai ?** Trois contrôles, trois regards.

**Les valeurs aberrantes** (*outliers*) d'abord. Au cours 1, la règle des 1,5 × IQR servait à *détecter* des valeurs atypiques pour l'exploration. Pour la validation, on utilise un seuil plus conservateur, réservé à l'alerte :

$$S = Q_3 + 3 \times \text{IQR} \qquad \text{avec} \quad \text{IQR} = Q_3 - Q_1$$

$S$ : seuil d'alerte qualité, dans l'unité de la variable
$Q_1$, $Q_3$ : premier et troisième quartiles de la colonne
IQR : écart interquartile, dans l'unité de la variable

Le seuil se place à trois fois la largeur des 50 % centraux au-dessus du troisième quartile : seules des valeurs vraiment exceptionnelles le dépassent. Au-delà, la valeur est **signalée** — c'est une alerte, jamais une suppression. La distinction d'avec le seuil des 1,5 × IQR du cours 1 est une affaire d'usage : détecter pour explorer (sensible) contre alerter pour valider (conservateur).

**L'actualité** ensuite : les dates doivent tomber dans la période annoncée — ni dans le futur, ni anormalement anciennes. Comparer la première et la dernière date à la période déclarée détecte aussi une extraction incomplète.

**Le rapprochement avec la source** enfin : les totaux de la table concordent-ils avec ce que la source annonce (bordereau, récapitulatif) ? C'est **le seul contrôle qui prouve l'exactitude** — tous les autres vérifient la forme, celui-ci confronte au réel. Un écart qu'on ne sait pas expliquer interdit de conclure.

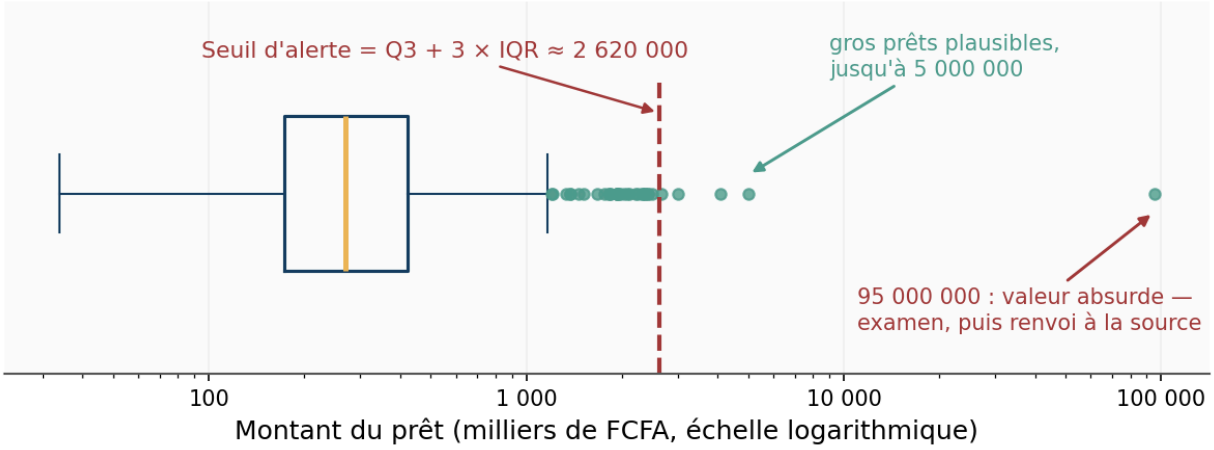



**Figure 5.** Montants des prêts (échelle logarithmique) : au-delà du seuil d'alerte, quinze lignes signalées — quatorze gros prêts plausibles, une valeur absurde. Seul l'examen fait la différence.

EXEMPLE GUIDÉ — LES TROIS CONTRÔLES DU FIL ROUGE

**Aberrantes.** Seuil calculé : 2 620 000 FCFA. Quinze lignes dépassent : quatorze sont de gros prêts plausibles, jusqu'au plafond commercial de 5 000 000 ; une seule est absurde (95 000 000 — déjà repérée hors plage à l'étape 9). L'alerte commande l'examen, pas la suppression : supprimer ces quinze lignes ferait disparaître les plus gros clients du portefeuille.

**Actualité.** Deux prêts sont « octroyés » le 15/11/2026 — après la date d'extraction du 30/09/2026. Impossible : bloquant.

**Rapprochement.** Bonne nouvelle : 600 prêts distincts pour 600 annoncés. Mais le total des montants lisibles atteint 517 362 000 FCFA pour 435 653 000 annoncés : 81,7 millions d'écart. Et tant que douze montants restent illisibles, ce total n'est même pas complet. **Impossible de conclure en l'état** — le rapprochement se refera après correction (section 4.16).

**EN PRATIQUE DANS LE CODE**

```
q1, q3 = m.quantile([0.25, 0.75]);  seuil = q3 + 3 * (q3 - q1)   # alerte, jamais suppression
octroi.min(), octroi.max()          # la période couverte, contre la période annoncée
m.sum()                             # total lu, à comparer au bordereau de la source
```

**À RETENIR**

- Aberrantes : seuil d'alerte $Q_3 + 3 \times \mathrm{IQR}$ — signaler, examiner, jamais supprimer.
- Actualité : ni futur, ni passé anormal ; la période couverte doit coller à l'annonce.
- Rapprochement avec la source : seul contrôle qui prouve l'exactitude ; un écart inexpliqué interdit de conclure.

## 4.14 La question décisive : la bonne valeur est-elle certaine ?

Le diagnostic du fil rouge est complet : 47 règles contrôlées, 31 en échec dont 18 bloquantes, 195 anomalies relevées, 81 lignes touchées par au moins une règle bloquante sur 606. Verdict : **NON VALIDE en l'état** — on ne lance aucune analyse sur cette table telle quelle. Le rapport se lit de haut en bas, dans l'ordre des étapes : la première règle bloquante en échec dit par où commencer.

Face à chaque anomalie, une seule question guide la décision : **la bonne valeur est-elle certaine ?** Si oui — défaut de forme, casse, format — on corrige et on trace. Sinon, on ne devine pas : on marque et on renvoie à la source, chez qui se trouve la vérité.

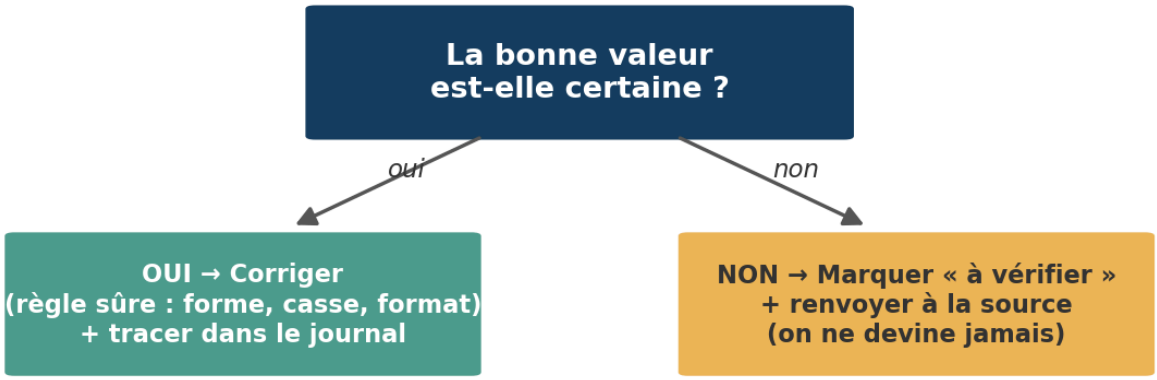



**Figure 6.** La question décisive, et les deux branches de la décision.

**EXEMPLE GUIDÉ — SIX ANOMALIES DU FIL ROUGE PASSÉES AU FILTRE**

« 565 000 » (espaces de milliers) : la valeur est certaine → **corriger, tracer**. « EN COURS » : variante de casse certaine → **corriger, tracer**. « Solde » : l'accent manquant ne prête à aucune confusion → **corriger, tracer**. « 31/02/2025 » : la vraie date est inconnue → **marquer, renvoyer**. Taux « 18 » : s'agit-il de 0,18 ? Probable… mais pas certain → **marquer, renvoyer**. « AG-09 » : saisie ou agence non déclarée ? → **marquer, renvoyer**. Remarquez la discipline : « probable » n'est pas « certain ».

**À RETENIR**

- Une seule question : la bonne valeur est-elle certaine ?
- Certain → corriger et tracer ; incertain → marquer et renvoyer à la source.
- « Probable » n'est pas « certain » : on ne devine jamais.

## 4.15 Les quatre actions : corriger, exclure, imputer, signaler

La question décisive se décline en quatre actions. Chacune a son cas d'usage, son risque et sa trace obligatoire.

**Tableau 9.** Les quatre actions face à une anomalie.

| Action | Quand la choisir | Le risque | La trace exigée |
|---|---|---|---|
| **Corriger** | La bonne valeur est certaine : forme, casse, format | Aucun, si la règle est sûre | Journal : règle et nombre de lignes |
| **Exclure** | La ligne est inutilisable pour l'usage prévu | Biaiser l'analyse si un groupe est touché | Nombre et montant exclus, par groupe |
| **Imputer** | Une valeur manque et une règle métier *validée* la déduit | Inventer une donnée, réduire la variance | Colonne indicatrice « imputé » |
| **Signaler** | La vérité est chez le producteur de la donnée | Aucun : c'est le réflexe par défaut | Liste des anomalies transmise |

Deux précisions capitales. **Exclure n'est pas effacer** : la ligne reste dans la table, marquée « rejetée », et le rapport dit combien et pourquoi. **L'imputation** (*imputation* — remplacer un manquant par une valeur déduite) n'est admise que sur règle métier validée, et **jamais** sur un identifiant ni une date contractuelle : ce sont des faits, pas des estimations.

> **ATTENTION — LE BIAIS D'EXCLUSION**
>
> Si les lignes rejetées appartiennent surtout à un même groupe (une agence, une tranche d'âge, un type de prêt), les exclure déforme l'analyse et pénalise ce groupe. Avant d'exclure : compter les exclusions par groupe, et l'écrire dans le rapport. Nous retrouverons ce réflexe dans le principe d'équité (section 4.17).

> **À RETENIR**
>
> - Quatre actions : corriger (certain), exclure (inutilisable, sans effacer), imputer (règle validée), signaler (réflexe par défaut).
> - Jamais d'imputation d'identifiant ni de date contractuelle.
> - Chaque action laisse une trace écrite : c'est ce qui rend l'analyse défendable.

## 4.16 Traçabilité et revalidation

La **traçabilité** (*audit trail*) repose sur quatre piliers : l'**original reste intact** (le diagnostic ne modifie rien, les corrections se font sur une copie) ; le **journal des corrections** (chaque action, avec la règle, le nombre de lignes et la justification) ; un **statut par ligne** (« valide », « à vérifier », « rejetée ») ; et le **rapprochement final expliqué**, franc par franc.




**Figure 7.** Le cycle de validation. Après chaque correction, on relance toute la batterie : une correction peut révéler une erreur.

La **revalidation** n'est pas une formalité. Sur le fil rouge, harmoniser « Solde » en « Soldé » a fait passer la règle « soldé ⇒ encours nul » de 6 à 7 échecs : une correction a *révélé* un prêt soldé qui gardait un encours, invisible tant que le statut était mal orthographié. On relance donc toute la batterie après chaque correction, jusqu'à ce que le rapport se stabilise.

#### EXEMPLE GUIDÉ — LE RAPPROCHEMENT FINAL DU FIL ROUGE

Après correction, les douze montants sont lisibles et le total se précise : 527 811 000 FCFA lus, pour 435 653 000 annoncés. L'écart de 92 158 000 s'explique ligne à ligne, avec les réponses de la source :

**Tableau 10.** Chaque franc d'écart expliqué : la réconciliation avec la source.

| Origine de l'écart | Effet sur le total (FCFA) |
|---|---|
| PR-00356 : 95 000 000 saisi au lieu de 662 000 | + 94 338 000 |
| PR-00300 : −150 000 saisi au lieu de 1 423 000 | − 1 573 000 |
| PR-00535 : 0 saisi au lieu de 237 000 | − 237 000 |
| 2 montants « N/A » (370 000 et 500 000) | − 870 000 |
| 2 conflits de clé : la version lue en premier était majorée de 250 000 chacune | + 500 000 |
| **Écart total expliqué** | **+ 92 158 000** |

La table est réconciliée avec sa source. Les livrables : une **table d'analyse** (557 prêts : 465 valides et 92 à vérifier, débarrassée des données personnelles directes), la **liste des 148 anomalies** transmise à la source avec les valeurs personnelles masquées, et le **journal des corrections** avec le rapport de validation. Le journal du fil rouge tient en une phrase : 4 doublons retirés, 3 lignes vides exclues, 12 montants, 15 dates, 9 statuts et 3 sexes harmonisés, 5 pseudo-manquants rendus explicites — tout le reste a été signalé, rien n'a été deviné.

#### EN PRATIQUE DANS LE CODE

```
df = df_brut.copy()                    # l'original reste intact
c["statut_validation"] = "valide"      # puis "à vérifier" / "rejetée" selon les règles
journaliser("montant : espaces retirés", n, "« 565 000 » vaut 565000")   # règle, lignes, justification
```

**À RETENIR**

- Original intact, copie de travail, journal, statut par ligne, rapprochement expliqué.
- Revalider toujours : une correction peut révéler une erreur (6 → 7 échecs).
- Livrer : table d'analyse sans données personnelles, anomalies masquées pour la source, journal et rapport.

## 4.17 Les six principes éthiques du métier

Valider une table, c'est certifier qu'elle dit vrai — et d'autres décideront sur cette base. La technique dit *comment* corriger ; l'éthique dit *ce qu'on a le droit* de corriger, de garder et de montrer. Six principes structurent l'éthique (*data ethics*) du data analyst.

**Tableau 11.** Les six principes, et ce qu'ils exigent concrètement.

| Principe | Ce qu'il exige du data analyst |
|---|---|
| **Intégrité** | Ne pas maquiller les données, ne pas rapporter que les résultats attendus |
| **Transparence** | Documenter sources, traitements et gestion des valeurs manquantes |
| **Confidentialité** | Protéger la vie privée des personnes et la confidentialité de leurs données |
| **Minimisation et finalité** | N'utiliser que les données nécessaires, pour l'usage prévu |
| **Équité** | Vérifier que les erreurs et les exclusions ne pénalisent pas un groupe |
| **Responsabilité** | Assumer ses choix, les justifier, signaler ce qui ne va pas |

**ANALOGIE**

L'analyste valide une table comme un expert-comptable certifie des comptes : il n'invente pas les chiffres, il ne fait pas disparaître les lignes gênantes, et sa signature engage sa responsabilité. C'est exactement ce que les normes professionnelles attendent : communiquer « les traitements et transformations, y compris la gestion des données manquantes ».

**Tableau 12.** Ce que l'éthique change dans la validation quotidienne.

| Situation | Le mauvais réflexe | Le réflexe professionnel |
|---|---|---|
| Une valeur semble fausse | La remplacer par ce qu'on croit juste | La marquer, demander à la source |
| Une ligne gêne l'analyse | La supprimer sans le dire | L'exclure, la compter, l'écrire au journal |
| Le résultat déçoit | Changer les règles jusqu'à ce qu'il plaise | Fixer les règles avant, rapporter tout |
| Une anomalie contient un téléphone | Copier la ligne entière dans le rapport | Ne transmettre que l'identifiant et la règle |
| Les erreurs touchent surtout un groupe | Les exclure toutes | Vérifier l'effet de l'exclusion sur ce groupe |
| On partage la table d'analyse | Envoyer le fichier complet | Retirer les données personnelles directes |

De ces principes découlent les **trois règles d'or** qui ont guidé tout ce cours : l'original reste intact, chaque correction est tracée, les données personnelles ne sortent pas.

**À RETENIR**

- Six principes : intégrité, transparence, confidentialité, minimisation et finalité, équité, responsabilité.
- La validation elle-même fait partie de ce qu'on doit rendre visible.
- Trois règles d'or : original intact, corrections tracées, données personnelles protégées.

## 4.18 Le cadre juridique : le RGPD

L'éthique fixe les principes ; la loi fixe les obligations. En Europe, le **Règlement général sur la protection des données** (*General Data Protection Regulation*, RGPD, en vigueur depuis 2018) encadre tout traitement de **données personnelles** (*personal data*) — c'est-à-dire toute information qui permet d'identifier une personne, directement (nom, téléphone) ou indirectement (identifiant client croisé avec d'autres données). La table du fil rouge en contient : noms, téléphones, e-mails, dates de naissance.

> **DÉFINITION — TRAITEMENT**
>
> Au sens du RGPD, un **traitement** (*processing*) est toute opération sur des données personnelles : collecte, lecture, correction, croisement, conservation, suppression… Valider une table de prêts est donc déjà un traitement, soumis au règlement.

Le règlement repose sur des principes qui se traduisent en gestes concrets pour l'analyste :

**Tableau 13.** Les principes du RGPD traduits en gestes d'analyste.

| Principe du RGPD | Le geste concret dans un projet d'analyse |
|---|---|
| **Finalité** : une collecte pour un but déterminé et légitime | N'exploiter la table que pour l'usage prévu — pas « pour voir ce qu'on y trouverait » |
| **Minimisation** : seules les données nécessaires | Retirer nom, téléphone, e-mail, date de naissance de la table d'analyse |
| **Exactitude** : des données exactes et tenues à jour | Signaler les anomalies à la source — la validation est une obligation, pas un luxe |
| **Conservation limitée** : pas de durée infinie | Définir une durée, puis archiver ou détruire ; ne pas garder de copie « au cas où » |
| **Sécurité et confidentialité** | Accès limité aux habilités ; masquer les valeurs personnelles dans les rapports |
| **Responsabilité** (*accountability*) : prouver sa conformité | Tenir journal, contrat et rapport — la trace devient une preuve |

Quatre points méritent d'être retenus nommément. Les **droits des personnes** : toute personne peut demander l'accès à ses données, leur rectification, leur effacement, la limitation ou l'opposition au traitement, et leur portabilité — vos traitements doivent rendre ces demandes possibles. Le **registre des traitements** : l'organisation y consigne chaque traitement (quelles données, pour quel but, quelle durée, quels destinataires) ; votre projet d'analyse y figure. Les **durées de conservation** : fixées par la finalité, jamais indéfinies. Et les **sanctions** : en France, la CNIL (Commission nationale de l'informatique et des libertés) contrôle et sanctionne — les amendes peuvent atteindre 20 millions d'euros ou 4 % du chiffre d'affaires mondial annuel.

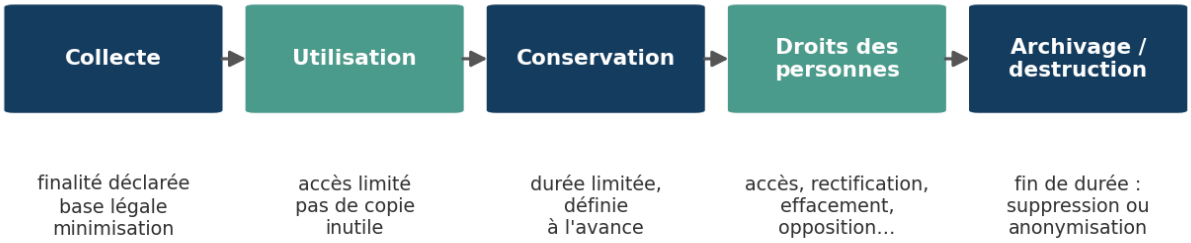



**Figure 8.** La vie d'une donnée personnelle sous le RGPD : de la collecte motivée à la destruction programmée.

Dernière distinction utile : **pseudonymiser** (remplacer le nom par un identifiant) réduit le risque mais reste des données personnelles ; **anonymiser** (rendre la ré-identification impossible) fait sortir les données du champ du RGPD — et c'est difficile à garantir. Quand le fil rouge retire les colonnes personnelles de la table d'analyse et ne transmet que les identifiants des anomalies, il applique la minimisation : c'est le geste de base, toujours, avant tout partage.

**EXEMPLE GUIDÉ — QUE PEUT-ON TRANSMETTRE ?**

La source doit corriger les 148 anomalies. Le rapport pourrait contenir la ligne complète de chaque prêt — nom, téléphone, e-mail compris. Question : est-ce nécessaire à la finalité (« permettre la correction ») ? Non : l'identifiant du prêt, la règle en échec et la colonne suffisent. On transmet donc `id_pret`, règle, colonne — et rien d'autre. Minimisation appliquée : même contenu utile, risque divisé.

**À RETENIR**

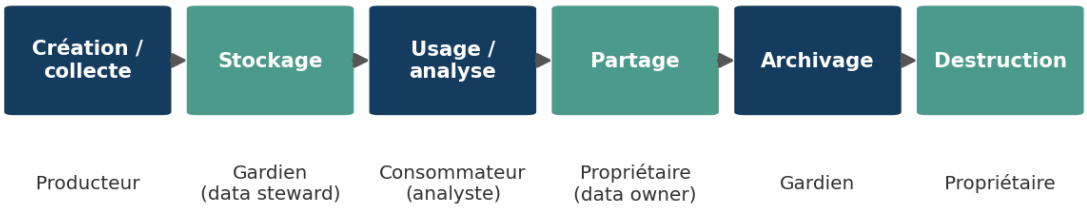
- Donnée personnelle = toute information qui identifie une personne, même indirectement.
- Finalité, minimisation, exactitude, conservation limitée, sécurité, responsabilité.
- Droits des personnes, registre des traitements, durées de conservation ; contrôle par la CNIL.
- Avant tout partage : ne transmettre que le nécessaire — l'identifiant et la règle suffisent souvent.

## 4.19 La gouvernance des données en organisation

Dernière pièce du tableau : la qualité n'est pas qu'une affaire individuelle. Dans une organisation, la **gouvernance des données** (*data governance*) attribue des rôles et suit la donnée tout au long de sa vie. Comprendre qui fait quoi, c'est savoir à qui parler quand une anomalie apparaît.

**Tableau 14.** Les rôles de la gouvernance, vus depuis votre poste d'analyste.

| Rôle | Responsabilité | Dans le fil rouge |
|---|---|---|
| **Propriétaire** (*data owner*) | Responsable métier des données : définit les règles, les usages autorisés | La direction des opérations, qui valide le contrat de la table |
| **Gardien** (*data steward*) | Suit la qualité au quotidien, applique les contrôles, coordonne les corrections | Celui qui reçoit votre liste d'anomalies et suit leur résolution |
| **Producteur** | Le système ou l'équipe qui crée la donnée | Le logiciel de gestion des prêts et les agents de saisie |
| **Consommateur** | Utilise la donnée pour un usage précis | Vous, l'analyste — et la direction qui lit vos tableaux |




*À chaque étape, un rôle identifié répond de la qualité — les anomalies remontent au producteur via le propriétaire.*

**Figure 9.** Le cycle de vie de la donnée (*data lifecycle*) : à chaque étape, un rôle identifié répond de la qualité.

Tout se recoupe : le **contrat** de la section 4.2 est un outil de gouvernance, co-écrit avec le propriétaire ; « renvoyer à la source » prend une adresse précise — le producteur, via le gardien ; les durées de conservation du RGPD décident des étapes d'archivage et de destruction. Votre travail d'analyste s'inscrit dans une chaîne de responsabilités : la validation est le maillon qui garantit que la chaîne tient.

**À RETENIR**

- Quatre rôles : propriétaire (les règles), gardien (la qualité au quotidien), producteur (la création), consommateur (l'usage).
- Le cycle de vie : création → stockage → usage → partage → archivage → destruction.
- Le contrat de la table et le journal des corrections sont des outils de gouvernance.

# 5. Erreurs fréquentes et pièges

#### PIÈGE 1 — LAISSER L'OUTIL DEVINER LES TYPES ET LES DATES

**L'erreur :** lire le fichier « tel quel » et convertir les dates sans format. **Pourquoi c'est faux :** l'identifiant « 007 » devient 7, le « NA » devient vide, et le 03/04 devient le 4 mars — sans aucun message d'erreur. **Le réflexe :** lire tout en texte (`dtype=str, keep_default_na=False`), imposer le format de date, convertir strictement et compter les échecs.

#### PIÈGE 2 — SUPPRIMER LES VALEURS ABERRANTES

**L'erreur :** retirer toutes les lignes au-delà du seuil d'alerte « pour nettoyer ». **Pourquoi c'est faux :** sur le fil rouge, quatorze des quinze lignes signalées étaient de gros prêts plausibles — les supprimer faisait disparaître les plus gros clients du portefeuille. **Le réflexe :** le seuil déclenche un examen, jamais une suppression (cours 2 : valeur inhabituelle ≠ erreur).

#### PIÈGE 3 — REMPLACER LES MANQUANTS PAR ZÉRO « POUR FAIRE SIMPLE »

**L'erreur :** combler les cases vides avec des 0 avant de calculer. **Pourquoi c'est faux :** un manquant est une absence d'information, pas une valeur nulle — la moyenne des durées est passée de 15 à 10 minutes dans notre exemple, sur une hypothèse jamais formulée. **Le réflexe :** avant de remplir, expliquer ce que la valeur ajoutée signifierait ; n'imputer que sur règle métier validée.

#### PIÈGE 4 — CORRIGER SANS JOURNAL, OU SUR L'ORIGINAL

**L'erreur :** corriger directement le fichier reçu, au fil de l'eau. **Pourquoi c'est faux :** une table « nettoyée » sans trace est pire qu'une table sale : plus personne ne peut savoir ce qui était vrai, ni refaire le calcul. **Le réflexe :** original intact, travail sur copie, et une ligne de journal par correction (règle, nombre de lignes, justification).

#### PIÈGE 5 — NE PAS REVALIDER APRÈS CORRECTION

**L'erreur :** corriger, puis livrer sans relancer les contrôles. **Pourquoi c'est faux :** une correction peut révéler une erreur — harmoniser « Solde » a fait apparaître un prêt soldé avec encours (6 → 7 échecs). **Le réflexe :** relancer toute la batterie après chaque vague de corrections, jusqu'à stabilisation du rapport.

# 6. Exercices

## 6.1 Auto-évaluation

*À faire sans relire le cours. Le corrigé est en fin de document.*

1. **Vrai ou faux ?** Une table peut être valide pour un usage et invalide pour un autre.
2. **QCM.** Le contrat de la table s'écrit : (a) après l'exploration des données ; (b) avec le métier, avant d'ouvrir le fichier ; (c) par l'outil, automatiquement ; (d) seulement si la table contient des erreurs.
3. **Classez.** Dans une colonne de dates : « 12/04/2026 », « », « N/A », « NaT ». Lesquelles sont des valeurs, des vides, des pseudo-manquantes, des marqueurs de manquant ?
4. **QCM.** Un champ obligatoire est manquant sur douze lignes. C'est : (a) une alerte à examiner ; (b) une règle bloquante en échec ; (c) une valeur aberrante ; (d) un conflit de clé.
5. **Vrai ou faux ?** « Exclure une ligne » signifie la supprimer définitivement de la table.
6. **QCM.** Le seul contrôle qui prouve l'exactitude d'une table est : (a) le contrôle des types ; (b) le seuil interquartile ; (c) le rapprochement avec la source ; (d) le contrôle des doublons.
7. **Question ouverte courte.** Un collègue propose de transmettre au prestataire la table complète — noms et téléphones inclus — « pour gagner du temps ». Quels deux principes (un éthique, un légal) suffisent à objecter, et que proposez-vous à la place ?

## 6.2 Application guidée — le contrat d'une table d'inscriptions

**Situation.** La boutique en ligne « Mira » veut suivre les inscriptions à sa newsletter. Le fichier comporte cinq colonnes : `id_client`, `email`, `date_inscription`, `code_postal`, `consentement`. L'extraction est datée du 12/11/2026.

**Consignes du métier.** L'identifiant suit le format CL- suivi de quatre chiffres et ne se répète jamais. L'e-mail est indispensable : sans lui, pas d'inscription. La date d'inscription est toujours connue et ne peut pas être dans le futur. Le code postal est facultatif ; quand il est présent, il compte cinq chiffres — et attention, un code postal se manipule comme du texte (cours 1 : des chiffres ne font pas une quantité). Le consentement vaut « oui » ou « non », sans exception.

**Étape 1.** Rédigez le contrat de la table : pour chaque colonne, type, caractère obligatoire ou facultatif, et la règle précise.

**Étape 2.** Six anomalies sont relevées. Pour chacune : la règle violée, la sévérité (bloquante ou alerte), et l'action (corriger / exclure / imputer / signaler), avec la trace à écrire.

**Tableau 15.** Les six anomalies à traiter.

| Cas | Anomalie relevée |
|---|---|
| a | `code_postal : « 75015 » (espaces autour)` |
| b | `email : « fatou.ndiaye » (sans @)` |
| c | `date_inscription : « 23/05/2027 »` |
| d | `consentement : « peut-être »` |
| e | `id_client CL-0042 sur deux lignes, avec deux e-mails différents` |
| f | une ligne entièrement vide |

**Étape 3.** Rédigez les lignes du journal de corrections correspondant aux actions « corriger » retenues à l'étape 2 (action, nombre de lignes, justification).

## 6.3 Application autonome

**Exercice A — validation complète (exercice entrelacé : cours 1 et 3).** La librairie « Kasaï » vous transmet ses ventes du mois, une ligne par vente. Le contrat, écrit avec la gérante : `id_vente` (texte, format V-999, unique, obligatoire) ; `date_vente` (date jj/mm/aaaa, obligatoire, jamais dans le futur — extraction au 31/03/2026) ; `canal` (obligatoire, valeurs autorisées : Web, Magasin, Téléphone) ; `montant` (entier en euros, obligatoire, de 1 à 5 000 €).

**Tableau 16.** La table des ventes à valider (12 lignes).

| Ligne | id_vente | date_vente | canal | montant (€) |
|---|---|---|---|---|
| 2 | V-001 | 12/03/2026 | Web | 120 |
| 3 | V-002 | 13/03/2026 | Magasin | 150 |
| 4 | V-003 | 13/03/2026 | web | 130 |
| 5 | V-004 | 14/03/2026 | Téléphone | 145 |
| 6 | V-005 | 14/03/2026 | - | 135 |
| 7 | V-006 | 31/02/2026 | Web | 140 |
| 8 | V-007 | 15/03/2026 | Web | 155 |
| 9 | V-007 | 15/03/2026 | Web | 155 |
| 10 | V-008 | 16/03/2026 | Magasin | 125 |
| 11 | V-009 | 16/03/2026 | Web | 150 |
| 12 | V-010 | 17/03/2026 | Magasin | -50 |
| 13 | V-011 | 17/03/2026 | Web | 890 |

1. Appliquez la batterie de contrôles **dans l'ordre** et dressez la liste des anomalies : règle, sévérité, lignes concernées.
2. Pour chaque anomalie, choisissez l'action (corriger / exclure / imputer / signaler) et écrivez le journal des corrections.
3. Sur une autre extraction de la même librairie — douze ventes d'une journée — les montants sont : 120, 130, 130, 135, 140, 145, 150, 155, 155, 160, 165 et 890 €. En utilisant l'écart interquartile (cours 1 : $Q_1$ et $Q_3$ sont les médianes des moitiés basse et haute), calculez le seuil d'alerte $Q_3 + 3 \times \mathrm{IQR}$, puis décidez du sort de la vente à 890 €.
4. Concluez en trois phrases : la table est-elle validée ? sous quelles conditions ? que reste-t-il à obtenir de la source ?

**Exercice B — éthique et droit.** Votre responsable vous demande d'envoyer au prestataire qui maintient le logiciel de caisse la table des ventes *complète*, incluant les colonnes `nom_client` et `telephone` qui s'y trouvent, « pour qu'il corrige lui-même ». Rédigez votre réponse en cinq à huit lignes : le ou les principes éthiques et l'obligation légale en jeu, ce que vous proposez à la place, et comment vous tracez votre décision.

# 7. Fiche récapitulative

Le cours condensé en une page — à réviser seule, régulièrement.

### Valider, c'est prouver

- **Valide** (*fit for use*) = conforme aux exigences écrites **pour un usage** ; pas de validité absolue.
- **Contrat de la table** (*data contract*) : écrit avec le métier, **avant** d'ouvrir le fichier ; pour chaque colonne : type, obligatoire ou facultatif, règle.
- **Sept dimensions** : structure · validité · complétude · unicité · cohérence · actualité · **exactitude** (la forme ne prouve pas le fond).

### Les valeurs manquantes

- Manquant ≠ zéro : absence d'information ; les calculs standard ignorent les manquants.
- Marqueurs : `NaN` (nombres), `pd.NA` (types dédiés), `NaT` (dates) ; pseudo-manquants : « - », « ? », « N/A » — à compter avec les vides.

### Les quinze contrôles, dans l'ordre

**Contenant** : 1 taille annoncée · 2 colonnes · 3 lignes vides — **Valeurs une à une** : 4 types lisibles · 5 dates au format · 6 complétude (obligatoire bloquant, facultatif alerte) · 7 unicité (doublon exact ≠ conflit de clé) · 8 domaines · 9 plages · 10 formats — **Valeurs ensemble** : 11 cohérence intra-ligne · 12 intégrité référentielle — **Sens** : 13 aberrantes ($Q_3 + 3 \times \mathrm{IQR}$ : une alerte, jamais une suppression) · 14 actualité · 15 rapprochement avec la source (seul contrôle qui prouve l'exactitude).

- Sévérités : **bloquante** (invalide la table) ou **alerte** (à examiner). Valide = zéro bloquant, alertes examinées.
- On **signale sans modifier** ; chaque contrôle compte et range dans le rapport.

### Décider et tracer

- La question décisive : **la bonne valeur est-elle certaine ?** Oui → corriger + tracer ; non → marquer + renvoyer à la source. « Probable » n'est pas « certain ».
- Quatre actions : **corriger** (forme, casse, format) · **exclure** (sans effacer : statut « rejetée ») · **imputer** (règle métier validée, jamais identifiant ni date contractuelle) · **signaler** (réflexe par défaut).
- Traçabilité : original intact · journal (règle, lignes, justification) · statut par ligne · rapprochement final expliqué franc par franc.
- **Revalider** toute la batterie après chaque correction : une correction peut révéler une erreur.

### Éthique et droit

- Six principes : intégrité · transparence · confidentialité · minimisation et finalité · équité · responsabilité.
- Trois règles d'or : original intact, corrections tracées, données personnelles protégées.
- **RGPD** : finalité, minimisation, exactitude, conservation limitée, sécurité, responsabilité ; droits des personnes (accès, rectification, effacement, opposition, portabilité) ; registre des traitements ; contrôle CNIL.
- Avant tout partage : l'identifiant et la règle suffisent — jamais la ligne entière.
- **Gouvernance** : propriétaire (règles) · gardien (qualité au quotidien) · producteur (création) · consommateur (usage) ; cycle de vie : création → stockage → usage → partage → archivage → destruction.

# 8. Pour aller plus loin

*Optionnel — pour les curieux.*

- **Les normes de qualité des données** : les dimensions de ce cours descendent des normes ISO 8000 et ISO/IEC 25012, qui formalisent la qualité des données en entreprise — un bon vocabulaire pour vos futurs audits.
- **Le site de la CNIL** (cnil.fr) : guides pratiques RGPD, modèles de registre des traitements, fiches sur les durées de conservation — la référence française, accessible aux non-juristes.
- **Les *data contracts* outillés** : dans l'industrie, le contrat de la table devient un fichier versionné et testé automatiquement à chaque livraison de données — la version industrielle de notre section 4.2.
- **Question ouverte** : quand une décision automatisée (un crédit refusé par un algorithme) repose sur une table invalide, qui est responsable — l'analyste, le propriétaire de la donnée, ou l'organisation ? Le RGPD donne des éléments de réponse (encadrement des décisions automatisées) ; la gouvernance donne les rôles. À discuter en groupe.

# Corrigé détaillé des exercices

## Auto-évaluation

1. **Vrai.** La validité est relative à l'usage (*fit for use*) : une table peut suffire pour un tableau de bord interne et être inacceptable pour une déclaration réglementaire.
2. **(b).** Le contrat s'écrit avec le métier, avant d'ouvrir le fichier — sinon la table dicte ses propres exigences.
3. « 12/04/2026 » est une **valeur** ; « » est un **vide** ; « N/A » est un **pseudo-manquant** (rempli mais sans information) ; « NaT » est le **marqueur** de date manquante après conversion.
4. **(b).** Un obligatoire manquant est une règle bloquante en échec : ces lignes ne sont pas exploitables en l'état.
5. **Faux.** Exclure n'est pas effacer : la ligne reste dans la table, marquée « rejetée », et le rapport dit combien et pourquoi.
6. **(c).** Le rapprochement avec la source est le seul contrôle qui prouve l'exactitude ; les autres vérifient la forme.
7. Éthique : la **minimisation** (n'utiliser que le nécessaire). Droit : le **RGPD** (même principe, et sécurité des données personnelles). Proposition : transmettre uniquement les identifiants de tickets, la règle en échec et la colonne concernée — valeurs personnelles masquées.

## Application guidée — le contrat d'une table d'inscriptions

**Étape 1 — le contrat.**

| Colonne | Type | Obligatoire | Règle |
|---|---|---|---|
| `id_client` | texte | oui | Format CL-9999, unique |
| `email` | texte | oui | Format e-mail (un @, un domaine) |
| `date_inscription` | date jj/mm/aaaa | oui | ≤ 12/11/2026 (date d'extraction) |
| `code_postal` | texte | non | Cinq chiffres |
| `consentement` | texte | oui | Domaine : {oui, non} |

**Étape 2 — les six anomalies.**

| Cas | Règle violée | Sévérité | Action et trace |
|---|---|---|---|
| a | Format (espaces parasites) | alerte (champ facultatif) | **Corriger** : « 75015 » → « 75015 », valeur certaine ; journaliser (règle, 1 ligne, justification) |
| b | Format e-mail | bloquante (champ obligatoire) | **Signaler** et renvoyer à la source — la vraie adresse ne se devine pas |
| c | Actualité (date future) | bloquante | **Signaler** : impossible après le 12/11/2026 ; question à la source |
| d | Domaine du consentement | bloquante | **Signaler** : « peut-être » n'est pas une réponse ; ne jamais convertir en « non » par défaut |
| e | Unicité (conflit de clé) | bloquante | **Signaler** : deux contenus pour un même identifiant — lequel est vrai ? |
| f | Structure (ligne vide) | alerte | **Exclure** de la suite des contrôles, compter et noter |

**Étape 3 — le journal.** Une seule correction certaine : `corriger — code_postal : espaces retirés — 1 ligne — « 75015 » vaut « 75015 »`. Tout le reste est signalé ; rien n'est deviné.

## Application autonome — exercice A (validation complète)

**Question 1 — le diagnostic dans l'ordre.** *Contenant* : 12 lignes lues (la ligne 1 porte les en-têtes), structure conforme au contrat, aucune ligne vide. *Valeurs une à une* : types et dates lisibles… sauf la ligne 7, « 31/02/2026 », une date impossible (bloquant) ; complétude : canal manquant (pseudo-manquant « - ») ligne 6, obligatoire → bloquant ; unicité : lignes 8 et 9, doublon exact de V-007 (alerte) ; domaine : « web » ligne 4, variante de casse (bloquant en l'état) ; plages : −50 € ligne 12, hors [1 ; 5 000] (bloquant) ; 890 € est *dans* la plage — aucun échec de plage pour cette ligne. *Valeurs ensemble* : pas de règle intra-ligne ni de référentiel ici. *Sens* : aberrantes à calculer (question 3) ; actualité : la date impossible est déjà comptée ; rapprochement : aucun bordereau fourni — à demander à la source.

**Question 2 — décisions et journal.**

| Ligne(s) | Anomalie | Décision | Trace au journal |
|---|---|---|---|
| 4 | « web » hors domaine | Corriger : la casse seule diffère, valeur certaine | « canal : casse harmonisée — 1 ligne — 'web' vaut 'Web' » |
| 8, 9 | Doublon exact V-007 | Exclure une copie (sans effacer : statut « rejetée ») | « doublon exact retiré — 1 ligne — lignes identiques » |
| 7 | Date impossible | Marquer « rejetée », renvoyer à la source | — (rien à corriger : liste des anomalies pour la source) |
| 6 | Canal obligatoire manquant | Marquer « rejetée », demander à la source | — (anomalie transmise ; pas d'imputation : aucune règle métier validée) |
| 12 | Montant −50 € hors plage | Marquer « rejetée », renvoyer à la source | — (la bonne valeur n'est pas certaine) |

**Question 3 — le seuil d'alerte.** Série ordonnée : 120, 130, 130, 135, 140, 145, 150, 155, 155, 160, 165, 890. Douze valeurs : la moitié basse est (120, 130, 130, 135, 140, 145), la moitié haute (150, 155, 155, 160, 165, 890).

$$Q_1 = \frac{130 + 135}{2} = 132{,}5 \qquad Q_3 = \frac{155 + 160}{2} = 157{,}5$$

$Q_1$, $Q_3$ : premier et troisième quartiles, en €
Moitiés de six valeurs : médiane = moyenne des 3e et 4e valeurs

Chaque moitié contient six valeurs : sa médiane tombe entre la troisième et la quatrième — on prend leur moyenne.

$$\mathrm{IQR} = 157{,}5 - 132{,}5 = 25 \qquad S = 157{,}5 + 3 \times 25 = 232{,}5$$

IQR : écart interquartile, en €
$S$ : seuil d'alerte qualité, en €

Le seuil se place à trois largeurs interquartiles au-dessus de $Q_3$ : la vente à 890 € le dépasse largement — elle est **signalée**.

Sort de la vente à 890 € : **alerte, examen, pas de suppression**. Elle respecte la plage métier (1 à 5 000 €) : un achat en gros est plausible. Elle reste dans la table, marquée « à vérifier » ; une confirmation à la source peut être demandée. Notez la nuance : le seuil statistique signale, la plage métier valide — les deux répondent à des questions différentes.

**Question 4 — conclusion.** La table n'est pas validée en l'état : trois règles bloquantes échouent (date impossible, canal manquant, montant hors plage) sur trois lignes distinctes, rejetées en attente des réponses de la source. Après corrections certaines (casse, doublon), elle est exploitable sous conditions : huit ventes valides, une à vérifier (890 €), trois rejetées et tracées. Restent à obtenir de la source : la vraie date de la ligne 7, le canal de la ligne 6, le montant de la ligne 12 — et un bordereau pour le rapprochement final.

## Application autonome — exercice B (éthique et droit)

Éléments attendus dans la réponse :

- **Minimisation et finalité** (éthique et RGPD) : le prestataire a besoin de comprendre les défauts de saisie, pas d'identifier les clients ; nom et téléphone ne sont pas nécessaires à cette finalité.
- **Obligation légale** : nom et téléphone sont des données personnelles ; les transmettre sans nécessité enfreint le principe de minimisation du RGPD et expose l'organisation (contrôle CNIL, amendes possibles).
- **Proposition** : transmettre la liste des anomalies avec `id_vente`, la règle en échec et la colonne concernée, valeurs personnelles masquées ; si le prestataire a réellement besoin d'une donnée personnelle, cadrer par écrit finalité, durée et destinataires.
- **Traçabilité** : la décision et sa justification sont consignées dans le journal — responsabilité : assumer et pouvoir prouver ses choix.