**Bloc II — Raisonnement statistique**

# Cours 4
# Inférence statistique : tester une différence

*À l'issue de ce cours, vous saurez décider, chiffres à l'appui, si une différence observée entre deux groupes traduit une vraie différence dans la population — ou une simple fluctuation du hasard.*

Formation Data Analyst — Novembre 2026

# Sommaire

**1. Objectifs d'apprentissage**

**2. Prérequis et rappels**

**3. Pourquoi c'est important**

**4. Corps du cours**

**PARTIE A — LA LOGIQUE DU TEST**

4.1 De la différence observée à la question sur les populations
4.2 $H_0$ et $H_1$ : deux scénarios concurrents
4.3 Simuler le monde où $H_0$ est vraie
4.4 La valeur p
4.5 Le seuil α et la règle de décision

**PARTIE B — SE TROMPER : ERREURS ET PUISSANCE**

4.6 Les erreurs de type I et de type II
4.7 La puissance statistique

**PARTIE C — LE TEST DE WELCH**

4.8 Choisir le test de Welch
4.9 La statistique t

**PARTIE D — ESTIMER ET INTERPRÉTER**

4.10 L'intervalle de confiance
4.11 Significatif ne veut pas dire important

**PARTIE E — TESTER DANS D'AUTRES SITUATIONS**

4.12 Comparer plus de deux groupes : l'ANOVA
4.13 Variables qualitatives : le test du $\chi^2$ d'indépendance
4.14 Distributions non gaussiennes : le test de Mann-Whitney
4.15 Multiplier les tests : le piège des comparaisons multiples

**PARTIE F — COMPARER DES DISTRIBUTIONS ENTIÈRES**

4.16 La fonction de répartition empirique (ECDF)
4.17 Comparer variances et formes : F/Levene et Kolmogorov-Smirnov
4.18 Mesurer une distance globale entre deux distributions

**PARTIE G — SYNTHÈSE OPÉRATIONNELLE**

4.19 Choisir la bonne stratégie : du résultat à la décision

**5. Erreurs fréquentes et pièges**

**6. Exercices**

6.1 Auto-évaluation
6.2 Application guidée
6.3 Application autonome

**7. Fiche récapitulative**

**8. Pour aller plus loin**

**9. Corrigé des exercices**

# 1. Objectifs d'apprentissage

À l'issue de ce cours, vous saurez :

- **formuler** des hypothèses $H_0$ et $H_1$ portant sur les populations, avant tout calcul ;
- **construire et interpréter** un test de comparaison de moyennes — le test de Welch — et sa statistique t ;
- **lire correctement** une valeur p et un intervalle de confiance, et **distinguer** significativité statistique et importance pratique ;
- **choisir l'outil adapté** pour comparer des variances, des formes de distribution ou des variables qualitatives, et **quantifier** une distance globale entre deux distributions.

# 2. Prérequis et rappels

**Prérequis :** cours 1 (description d'un jeu de données) et cours 2 (distributions et hasard d'échantillonnage). Le cours 3 (validation des données) est un réflexe utile : on ne teste jamais une table non validée.

**Rappels des notions mobilisées ici :**

- Une moyenne d'échantillon, notée $\bar{x}$, estime la moyenne de population, notée $\mu$. L'écart-type $s$ mesure la dispersion d'un échantillon (diviseur $n - 1$).
- Deux échantillons tirés d'une même population diffèrent par pur hasard : c'est la **variation d'échantillonnage**. L'erreur-type de la moyenne vaut $\sigma / \sqrt{n}$ ; elle décroît quand l'effectif $n$ augmente.
- Le **théorème central limite** garantit que, pour $n$ assez grand, la moyenne d'un échantillon suit approximativement une loi normale, quelle que soit la forme de la population.
- Une simulation se rend reproductible en fixant une **graine aléatoire** (*seed*).

# 3. Pourquoi c'est important

Vous êtes analyste pour une enseigne de vente au détail. Votre direction vous transmet les montants d'achat de 2 000 transactions : 1 200 dans le magasin A, 800 dans le magasin B. Le panier moyen est de 100,07 € en A et de 105,93 € en B. Le directeur vous demande : « Le magasin B vend-il vraiment plus, ou est-ce le hasard ? ».

Cette question, vous la rencontrerez chaque semaine sous des formes variées : une nouvelle page web convertit-elle mieux que l'ancienne ? Une campagne promotionnelle a-t-elle augmenté les ventes ? Deux lignes de production ont-elles la même qualité ? À chaque fois, vous observez une **différence dans un échantillon**, alors que la décision porte sur la **population entière** — tous les clients, toutes les pièces, tous les jours à venir.

Sans les outils de ce cours, deux réflexes font perdre de l'argent. Le premier consiste à conclure sur du bruit : voir un effet dans chaque fluctuation et lancer des actions coûteuses sur des mirages. Le second consiste à attendre une certitude absolue qui n'arrive jamais : paralyser la décision en répétant « on ne sait pas ». L'inférence statistique offre une troisième voie : **mesurer ce que le hasard peut produire, puis décider avec un risque connu, chiffré et annoncé**. C'est exactement ce que font les équipes data pour les tests A/B, le contrôle qualité ou les études marketing.

Dans tout ce cours, nous suivrons un fil rouge : les deux magasins A et B ci-dessus. Les montants sont exprimés en euros et les calculs sont réels : vous pourrez refaire chaque opération vous-même.

# 4. Corps du cours

### PARTIE A — LA LOGIQUE DU TEST

## 4.1 De la différence observée à la question sur les populations

Regardons d'abord nos données. La figure 1 montre les montants d'achat des deux magasins. Les deux distributions se chevauchent largement : beaucoup de clients dépensent entre 80 et 130 € dans les deux magasins. Et pourtant, les moyennes diffèrent : 100,07 € en A contre 105,93 € en B, soit un écart de **5,86 €**.

La tentation est forte de conclure immédiatement : « B vend 5,86 € de plus par client ». Mais réfléchissez : ces 2 000 transactions ne sont qu'un échantillon. Le mois prochain, avec d'autres clients, vous obtiendriez d'autres moyennes — vous savez depuis le cours 2 que deux échantillons d'une même population diffèrent par hasard. La vraie question n'est donc pas « que vaut l'écart ici ? » mais : **les deux populations de clients ont-elles des moyennes différentes ?**

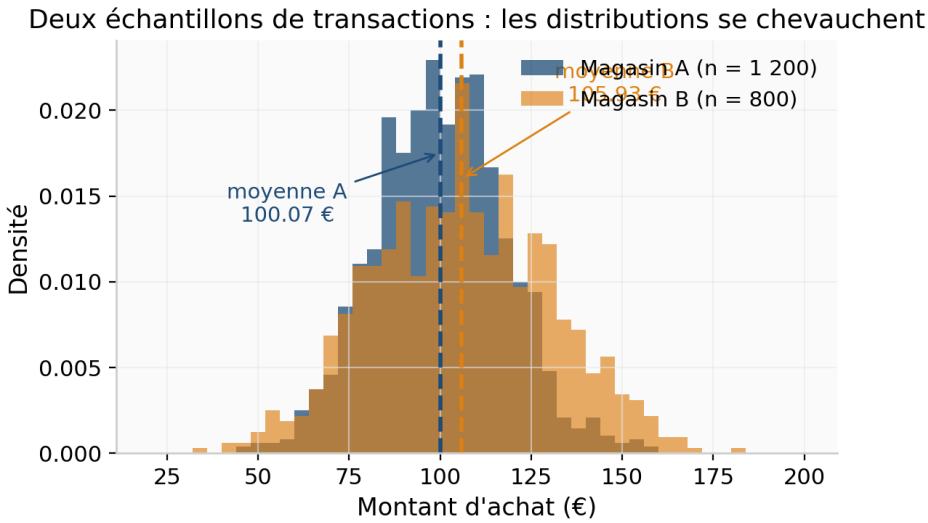



*Figure 1 : les montants d'achat observés dans les deux magasins. Les distributions se recouvrent en grande partie ; les moyennes d'échantillon (pointillés) diffèrent de 5,86 €.*

**Définition — l'inférence statistique**

L'**inférence statistique** (*statistical inference*) est l'ensemble des méthodes qui permettent de tirer des conclusions sur une **population** à partir d'un **échantillon**, en quantifiant l'incertitude liée au hasard du tirage. Décrire un échantillon relève de la statistique descriptive ; parier sur la population, avec un risque mesuré, relève de l'inférence.

**Analogie**

Goûter une cuillère de soupe pour juger l'assaisonnement de toute la marmite : si la soupe est bien mélangée, une cuillère suffit à se faire une idée — mais pas une certitude absolue. De même, un échantillon renseigne sur la population, avec une marge d'incertitude que ce cours apprend à calculer.

**Exemple guidé — reformuler la question**

**Situation.** Vous calculez : moyenne de B − moyenne de A = 105,93 − 100,07 = 5,86 €.

**Étape 1.** Nommer ce que décrit ce nombre : c'est l'écart des moyennes *dans cet échantillon* de 2 000 transactions. On fait ce calcul parce qu'il résume les données — pas parce qu'il répond déjà à la question du directeur.

**Étape 2.** Identifier les populations : « tous les achats possibles au magasin A » et « tous les achats possibles au magasin B », cette année, dans les conditions actuelles. Leurs moyennes, inconnues, se notent $\mu_A$ et $\mu_B$.

**Étape 3.** Reformuler la question métier en question sur les populations : « $\mu_B - \mu_A$ vaut-il zéro, ou pas ? » C'est cette question — pas l'écart de 5,86 € — que le reste du cours va traiter.

**À retenir**

- Une figure montre des **échantillons** ; la question de décision porte sur les **populations**.
- L'écart observé mélange toujours deux choses : une éventuelle vraie différence, et la fluctuation du hasard.
- Premier réflexe professionnel : reformuler toute question de comparaison en question sur les paramètres de population ($\mu_A$, $\mu_B$).

### 4.2 $H_0$ et $H_1$ : deux scénarios concurrents

Pour trancher entre « vraie différence » et « effet du hasard », la statistique procède comme un débat contradictoire : elle met en concurrence deux scénarios sur les populations, puis examine lequel est compatible avec les données.

Le premier scénario est le **scénario de référence** : il n'y a aucune différence entre les populations, et l'écart observé n'est qu'une fluctuation. Le second est le **scénario alternatif** : les populations diffèrent réellement. Toute la mécanique du test consiste ensuite à évaluer ce que le premier scénario permet d'attendre — et à vérifier si nos données s'y trouvent encore.

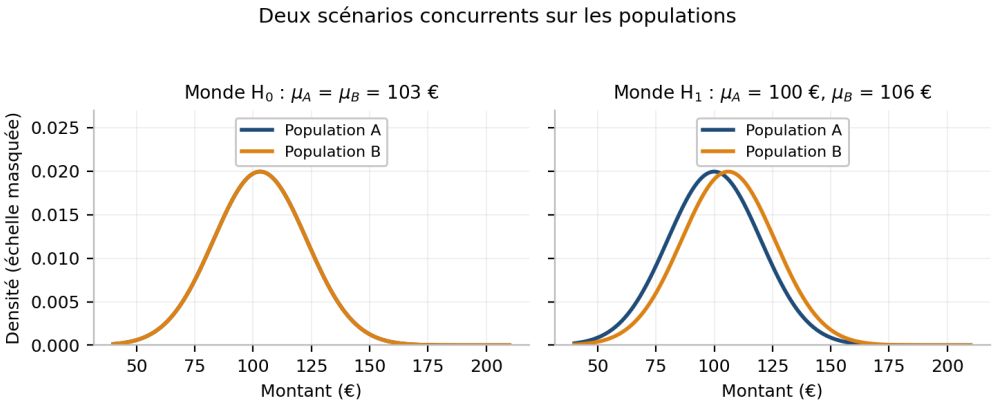



*Figure 2 : les deux scénarios concurrents. À gauche, le monde $H_0$ où les deux populations ont la même moyenne ; à droite, un monde $H_1$ où elles diffèrent.*

**Définition — les hypothèses $H_0$ et $H_1$**

L'**hypothèse nulle** (*null hypothesis*), notée **$H_0$**, est le scénario de référence qui décrit l'absence d'effet ou de différence. Pour comparer deux moyennes : $H_0 : \mu_A = \mu_B$, c'est-à-dire $\mu_B - \mu_A = 0$.

L'**hypothèse alternative** (*alternative hypothesis*), notée **$H_1$**, est le scénario concurrent : $H_1 : \mu_A \neq \mu_B$. Quand aucune direction n'est imposée à l'avance (ni « B > A », ni « B < A »), le test est dit **bilatéral** (*two-tailed test*).

Trois disciplines sont essentielles. D'abord, les hypothèses portent sur les **populations** (les $\mu$), jamais sur les moyennes observées — celles-ci, on les connaît déjà. Ensuite, on formule $H_0$ et $H_1$ **avant** de regarder les résultats, comme on annonce une règle de jeu avant de jouer ; sinon, la tentation est grande d'arranger la question après coup. Enfin, un test ne « prouve » ni $H_0$ ni $H_1$ : il mesure la **compatibilité des données avec $H_0$**.

**Exemple guidé — formuler $H_0$ et $H_1$ pour trois questions métier**

**Question 1 (notre fil rouge).** « Le panier moyen diffère-t-il entre les magasins A et B ? » → $H_0 : \mu_A = \mu_B$ ; $H_1 : \mu_A \neq \mu_B$. Test bilatéral, car rien n'imposait un sens avant l'analyse.

**Question 2.** « Le diamètre moyen des pièces a-t-il changé après le réglage de la machine ? » → $H_0 : \mu_{\text{avant}} = \mu_{\text{après}}$ ; $H_1 : \mu_{\text{avant}} \neq \mu_{\text{après}}$. On vérifie que les pièces mesurées avant et après sont bien des groupes indépendants (pas les mêmes pièces mesurées deux fois).

**Question 3.** « La proportion de clients satisfaits diffère-t-elle entre deux campagnes ? » → Attention : la variable est qualitative (satisfait / non satisfait). Les hypothèses porteraient sur des proportions, pas des moyennes : il faudra un autre test (le $\chi^2$, section 4.13). Bien formuler les hypothèses, c'est déjà choisir le bon outil.

**À retenir**

- $H_0$ est le scénario « rien de spécial » ; $H_1$ est le scénario « il se passe quelque chose ».
- Les hypothèses portent sur les populations et se formulent **avant** le calcul.
- Un test mesure la compatibilité des données avec $H_0$ ; il ne prouve jamais une hypothèse.

### 4.3 Simuler le monde où $H_0$ est vraie

Voici le cœur du raisonnement. Si $H_0$ était vraie — si les deux populations avaient exactement la même moyenne —, quelles différences de moyennes le pur hasard produirait-il ? Vous savez déjà (cours 2) simuler des tirages : nous allons fabriquer des milliers de mondes parallèles où $H_0$ est vraie, et regarder ce qui s'y passe.

Concrètement, on reprend les caractéristiques de nos données — 1 200 transactions en A, 800 en B, écarts-types de 18 et 24 € — mais on impose la **même moyenne de 103 € aux deux populations**. On tire alors les deux échantillons, on calcule moy(B) − moy(A), et on recommence 5 000 fois avec une graine différente à chaque fois. La figure 3 montre le résultat.

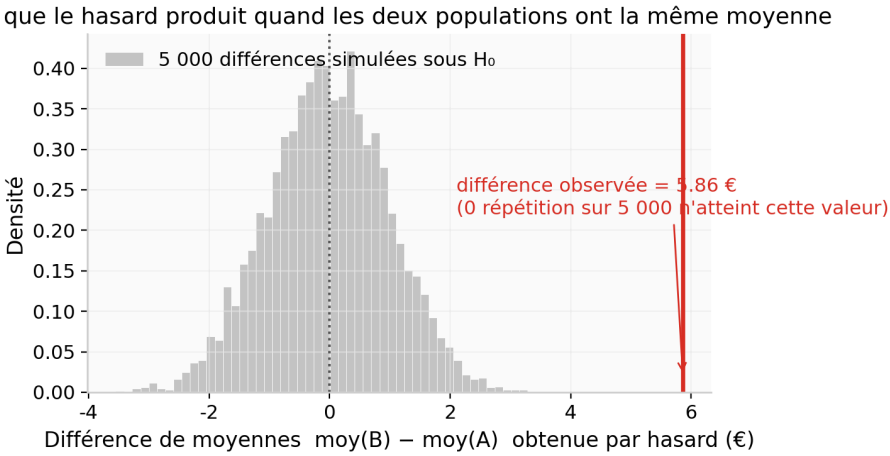



*Figure 3 : distribution de 5 000 différences de moyennes obtenues par hasard dans des mondes où $H_0$ est vraie. La différence réellement observée (5,86 €, trait rouge) n'y apparaît jamais.*

**Définition — la distribution sous $H_0$**

La **distribution sous $H_0$** (*null distribution*) est la distribution que prend une statistique (ici, la différence de moyennes) lorsqu'on répète l'échantillonnage dans un monde où $H_0$ est vraie. Elle décrit ce que le hasard seul peut produire : c'est la référence à laquelle on compare le résultat observé.

**Analogie**

C'est le principe de la répétition générale au théâtre : avant de juger la première, on rejoue la pièce à vide, sans les imprévus, pour savoir à quoi ressemble un déroulement « normal ». Si le soir de la première tout se passe dans les limites de la répétition, rien d'anormal ; si un acteur chute du balcon, on sait que ce soir-là n'était pas un soir ordinaire.

**Exemple guidé — construire la référence en cinq étapes**

**Étape 1.** Poser le monde $H_0$ : $\mu_A = \mu_B = 103$ € (la moyenne commune importe peu ; c'est l'égalité qui compte).

**Étape 2.** Conserver tout le reste du dispositif : les effectifs (1 200 et 800) et les dispersions (18 et 24 €). On change la graine, pas le plan de collecte — sinon on ne comparerait pas le même hasard.

**Étape 3.** Tirer les deux échantillons et calculer moy(B) − moy(A).

**Étape 4.** Répéter 5 000 fois et dessiner la distribution obtenue : elle est centrée sur 0, avec un écart-type d'environ 1 €. C'est la fluctuation normale du hasard pour ce dispositif.

**Étape 5.** Placer la différence observée, 5,86 €, sur cette distribution : elle est à près de 6 écarts-types du centre. **Aucune des 5 000 répétitions n'a produit un écart aussi grand.** Conclusion de l'étape : nos données ne ressemblent pas du tout à un monde où $H_0$ serait vraie.

**En pratique dans le code**

```
rng = np.random.default_rng(99)
diffs = [rng.normal(103, 24, 800).mean() - rng.normal(103, 18, 1200).mean()
         for _ in range(5000)]   # distribution des écarts sous H0
```

**À retenir**

- La distribution sous $H_0$ décrit ce que le **hasard seul** peut produire avec le même dispositif de collecte.
- On y compare le résultat observé : s'il y est banal, $H_0$ reste plausible ; s'il y est extraordinaire, $H_0$ perd toute crédibilité.
- La simulation rend cette logique visible ; les sections suivantes la calculent sans simulation.

### 4.4 La valeur p

Dans la section précédente, nous avons compté : « 0 répétition sur 5 000 n'atteint 5,86 € ». La valeur p généralise exactement ce comptage : c'est la **proportion des résultats au moins aussi extrêmes que le vôtre, dans un monde où $H_0$ est vraie**. Au lieu de simuler, on la calcule à partir de la distribution théorique de la statistique — mais le sens reste le même que celui de la figure 3.

**Définition — la valeur p**

La **valeur p** (*p-value*) est la probabilité, calculée **sous $H_0$** et sous les hypothèses du test, d'obtenir un résultat **au moins aussi extrême** que celui observé. « Au moins aussi extrême » s'entend dans les deux sens pour un test bilatéral : un écart de +5,86 € ou de −5,86 € compte également.

$$p = P\big(\,|T| \geq |t_{\text{obs}}| \;\big|\; H_0\,\big)$$

$p$ : valeur p, probabilité entre 0 et 1
$T$ : statistique du test sur un échantillon hypothétique sous $H_0$
$t_{\text{obs}}$ : valeur de cette statistique calculée sur vos données
$\mid H_0$ : « sachant que $H_0$ est vraie » — la probabilité est calculée dans ce monde-là

Cette formule se lit : « si $H_0$ était vraie, quelle serait la probabilité que la statistique dépasse, en valeur absolue, celle que j'ai obtenue ? ». La statistique T résume le résultat en le rapportant à sa variabilité (nous la construirons en 4.9) ; la valeur p mesure la surface des queues de la distribution sous $H_0$ au-delà de votre résultat, comme le montre la figure 4.

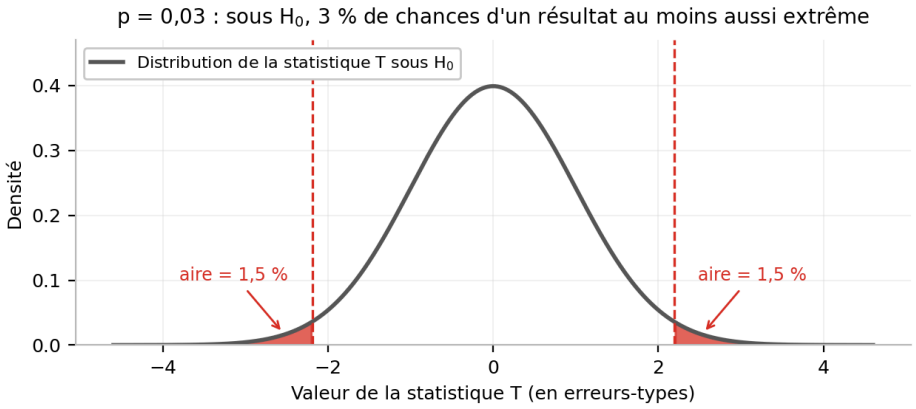



*Figure 4 : lecture d'une valeur p = 0,03. Sous $H_0$, les deux zones rouges totalisent 3 % de la surface : un résultat au moins aussi extrême que t = 2,19 (dans un sens ou dans l'autre) n'a que 3 % de chances de survenir par hasard.*

Une petite valeur p signale donc une **faible compatibilité** entre vos données et le scénario $H_0$. Soyez maintenant très vigilant sur ce qu'elle **n'est pas** :

- ce n'est **pas** la probabilité que $H_0$ soit vraie — elle est calculée en *supposant* $H_0$ vraie ;
- ce n'est **pas** la probabilité que le résultat soit « dû au hasard » en général ;
- ce n'est **pas** la taille de la différence ;
- ce n'est **pas** une preuve de causalité.

**Exemple guidé — lire p = 0,03 phrase par phrase**

**Situation.** Une comparaison de deux moyennes de dépense donne p = 0,03, avec des hypothèses de test respectées (groupes indépendants, seuil fixé à 5 % avant l'analyse).

**Lecture correcte.** « Si les deux populations avaient la même moyenne, et sous les hypothèses du test, la probabilité d'observer un écart au moins aussi extrême que le nôtre serait de 3 %. »

**Lecture incorrecte n°1.** « Il y a 3 % de chances que $H_0$ soit vraie » — faux : p ne dit rien sur la probabilité de $H_0$ elle-même. **Lecture incorrecte n°2.** « La différence est faible » ou « importante » — on ne sait pas encore : p ne mesure pas l'ampleur (section 4.11).

**Conclusion de l'étape.** p = 0,03 affaiblit fortement le scénario $H_0$ ; il reste à chiffrer l'écart et son incertitude avant toute décision.

**À retenir**

- La valeur p est une probabilité **conditionnée par $H_0$** : « sous $H_0$, un résultat au moins aussi extrême ».
- Petite valeur p = données peu compatibles avec $H_0$ ; ce n'est ni $P(H_0)$, ni une taille d'effet, ni une preuve de cause.
- Le bon réflexe de lecture : toujours commencer la phrase par « *Sous* $H_0$… ».

### 4.5 Le seuil α et la règle de décision

Une probabilité de 3 % est-elle « petite » ? Pour trancher sans débat d'humeur, on fixe **avant l'analyse** une frontière : le seuil α. C'est la règle du jeu, annoncée à l'avance — exactement comme on fixe la barre d'un saut en hauteur avant le concours, pas après avoir vu le saut.

**Définition — le seuil de significativité**

Le **seuil de significativité** (*significance level*), noté **α**, est le risque maximal de fausse alerte que l'on accepte de courir, fixé **avant** l'analyse — le plus souvent α = 5 %. La règle de décision est alors : si **p < α**, on **rejette** $H_0$ (le résultat est dit *statistiquement significatif*, *statistically significant*) ; sinon, on **ne rejette pas** $H_0$.

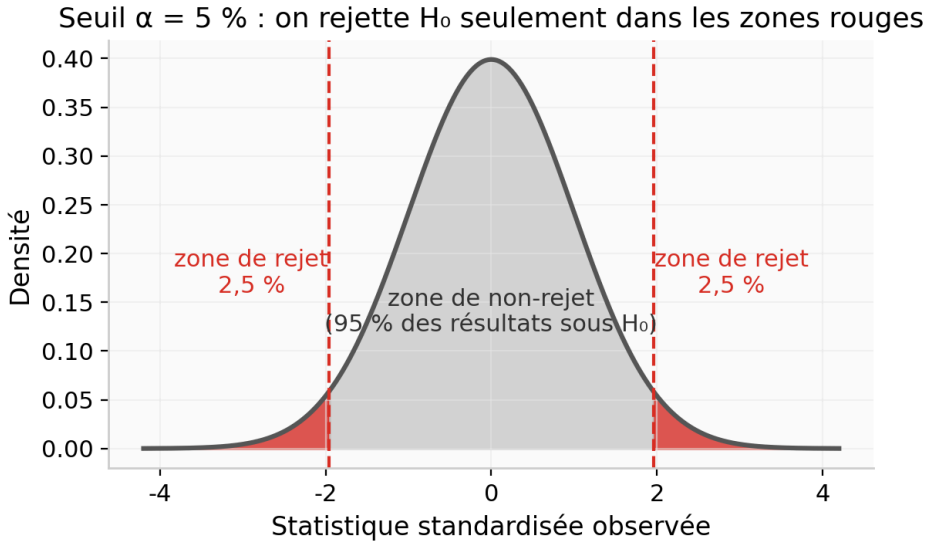



*Figure 5 : la règle de décision au seuil de 5 %. Sous $H_0$, 95 % des résultats tombent dans la zone centrale (non-rejet) ; les 5 % restants, répartis aux deux extrémités, déclenchent le rejet de $H_0$.*

Deux points de langage protègent vos conclusions. D'abord, on dit « ne pas rejeter $H_0$ » et jamais « accepter $H_0$ » : un test non concluant signifie que les données n'ont pas permis de trancher, pas que les moyennes sont égales — l'égalité pourrait être vraie, ou l'effectif simplement insuffisant pour la détecter (sections 4.7 et 4.11). Ensuite, même en cas de rejet, **une erreur reste possible** : rejeter $H_0$ à tort, c'est précisément l'erreur de type I, dont la probabilité est α ; c'est l'objet de la section suivante.

**Exemple guidé — appliquer la règle dans les deux cas**

**Cas 1 : p = 0,03, α = 5 %.** 0,03 < 0,05 → on rejette $H_0$. Phrase de conclusion : « au seuil de 5 %, les données sont incompatibles avec l'égalité des moyennes ; une fausse alerte reste possible avec une probabilité de 5 % maximum ».

**Cas 2 : p = 0,12, α = 5 %.** 0,12 > 0,05 → on ne rejette pas $H_0$. Phrase de conclusion : « les données ne permettent pas de conclure à une différence au seuil de 5 % ; cela ne prouve pas l'égalité — l'écart estimé et son intervalle restent à examiner ».

**À retenir**

- α se fixe **avant** l'analyse ; la règle est : p < α → rejeter $H_0$, sinon ne pas rejeter.
- « Non significatif » ne prouve pas l'égalité : c'est une absence de conclusion, pas une conclusion d'absence.
- Toute décision au seuil α s'accompagne d'un risque d'erreur connu : la suite du cours le détaille.

## PARTIE B — SE TROMPER : ERREURS ET PUISSANCE

### 4.6 Les erreurs de type I et de type II

Décider avec un risque connu, c'est bien ; encore faut-il savoir **de quels risques** on parle. Face à $H_0$, votre décision peut être juste ou fausse de deux façons différentes, qui n'ont ni le même coût ni la même probabilité.

**Définition — les deux erreurs d'un test**

L'**erreur de type I** (*type I error*), ou **fausse alerte**, consiste à rejeter $H_0$ alors qu'elle est vraie : on déclare une différence qui n'existe pas. Sa probabilité est exactement le seuil **α** choisi.

L'**erreur de type II** (*type II error*) consiste à ne pas rejeter $H_0$ alors qu'elle est fausse : on **manque un effet réel**. Sa probabilité se note **β** (*beta*).

| | **Décision : ne pas rejeter $H_0$** | **Décision : rejeter $H_0$** |
|---|---|---|
| **$H_0$ vraie (pas de différence)** | Bonne décision | Erreur de type I — probabilité α |
| **$H_0$ fausse (différence réelle)** | Erreur de type II — probabilité β | Bonne décision |

*Tableau 1 : les quatre issues possibles d'un test. Chaque ligne correspond à un « monde » ; on ne sait jamais dans lequel on est — on choisit seulement la colonne.*

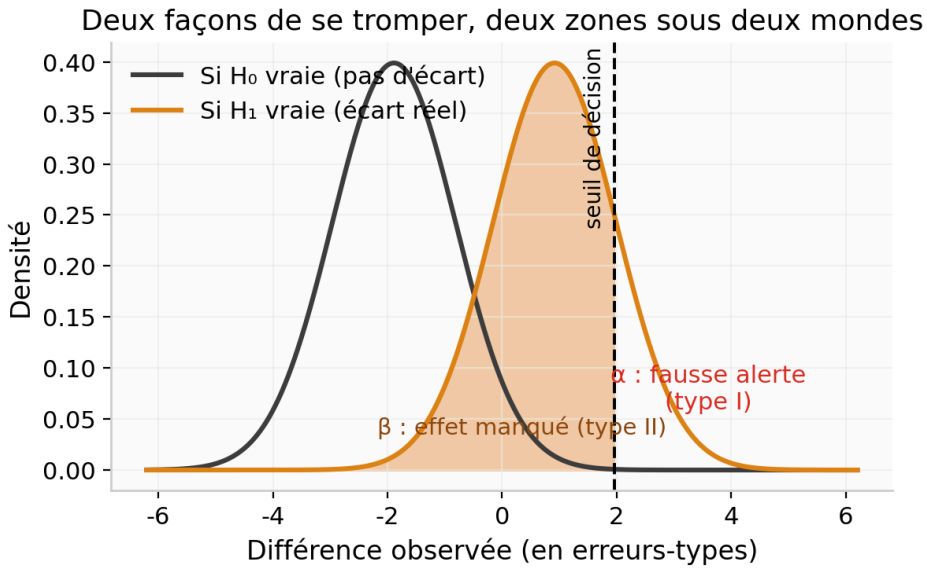



*Figure 6 : les deux erreurs en image. La zone rouge α est la probabilité de dépasser le seuil quand $H_0$ est vraie ; la zone claire β est la probabilité de rester sous le seuil quand un écart réel existe.*

**Analogie**

Un procès criminel : $H_0$ est « l'accusé est innocent ». L'erreur de type I condamne un innocent — la justice la redoute tellement qu'elle exige des preuves accablantes (α très petit). L'erreur de type II relaxe un coupable. Durcir les règles pour ne jamais condamner d'innocent augmente mécaniquement les relaxes : on ne peut pas réduire les deux erreurs en même temps, à informations égales.

**Exemple guidé — mettre des coûts métier sur les deux erreurs**

**Situation.** Vous testez si une offre promotionnelle augmente la dépense moyenne. L'offre coûte 2 € par client qui la reçoit.

**Erreur de type I.** Vous concluez « l'offre marche » alors qu'elle ne change rien → l'entreprise déploie une offre coûteuse et inutile sur 100 000 clients. Coût : direct et massif.

**Erreur de type II.** Vous concluez « rien de probant » alors que l'offre rapporte réellement 3 € par client → l'entreprise abandonne une opportunité rentable. Coût : un manque à gagner, invisible dans les comptes.

**Conclusion de l'étape.** Les deux erreurs n'ont pas le même prix. Le choix d'α (5 %, 1 %…) et l'effort de collecte (section suivante) s'ajustent au coût relatif de chaque erreur — c'est une décision métier, pas seulement statistique.

**À retenir**

- Type I = fausse alerte (rejeter $H_0$ à tort), probabilité α ; type II = effet manqué (ne pas rejeter à tort), probabilité β.
- À données égales, baisser α fait monter β : on choisit un arbitrage, pas la perfection.
- Le bon arbitrage dépend des **coûts métier** de chaque erreur.

### 4.7 La puissance statistique

Comment réduire β, la probabilité de manquer un effet réel ? En donnant au test davantage d'information : c'est le rôle de la puissance. Si la section 4.6 était le procès, la puissance mesure la qualité de l'enquête menée avant le verdict.

**Définition — la puissance statistique**

La **puissance statistique** (*statistical power*) d'un test est la probabilité de **détecter un effet réel** lorsqu'il existe : puissance = $1 - \beta$. Une puissance de 80 % signifie que, si la différence existe, le test la repère 8 fois sur 10.

Quatre leviers font monter la puissance :

- **l'ampleur de l'effet** : une grosse différence est plus facile à repérer qu'une petite ;
- **la dispersion des données** : moins les valeurs fluctuent, plus le signal ressort ;
- **le seuil α** : accepter plus de fausses alertes (α plus grand) rend le test plus sensible — au prix du type I ;
- **l'effectif n** : c'est le levier que vous contrôlez le plus souvent, et de loin le plus efficace.

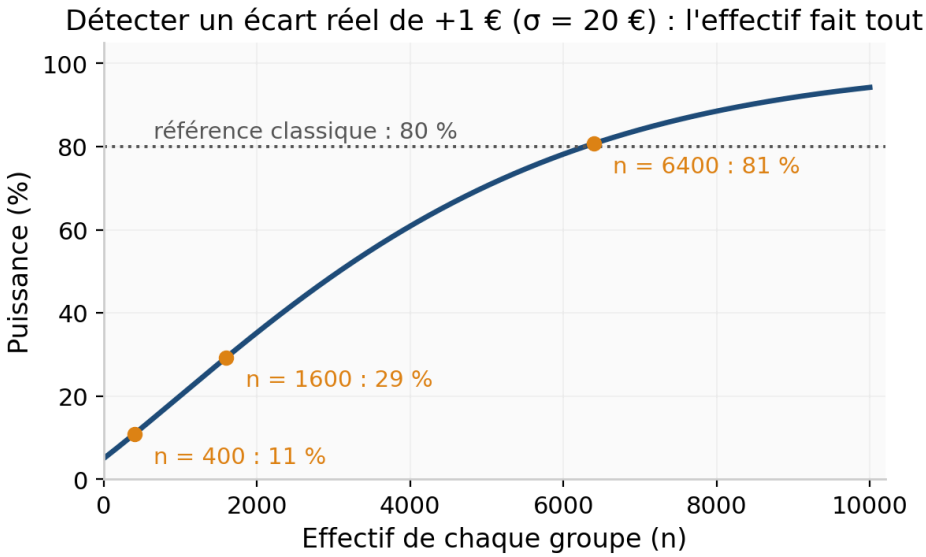



*Figure 7 : puissance pour détecter un écart réel de +1 € (écart-type 20 €, seuil 5 %). Avec 400 clients par groupe, le test ne détecte l'effet que 11 % du temps ; il en faut environ 6 400 pour atteindre 80 %.*

La figure 7 porte une leçon inconfortable : pour un **petit** effet, un test non significatif sur un petit échantillon ne dit à peu près rien. Si vous testez +1 € avec 400 clients par groupe et obtenez p = 0,20, vous ne pouvez pas conclure « pas d'effet » : votre test n'avait qu'une chance sur dix de repérer l'effet s'il existait. **L'absence de preuve n'est pas la preuve de l'absence.** C'est pourquoi les équipes sérieuses estiment la puissance **avant** de collecter les données : « quel effectif me faut-il pour repérer l'effet minimal qui m'intéresse ? ».

**Exemple guidé — lire une puissance concrète**

**Situation.** Pour l'offre promotionnelle (60 clients par groupe, erreur-type de l'écart = 1,37 €), l'effet réel — s'il existe — vaudrait +3 €.

**Étape 1.** Exprimer l'effet en erreurs-types : 3 / 1,37 ≈ 2,19. L'effet réel se situe à 2,19 erreurs-types du zéro.

**Étape 2.** Comparer au seuil de décision (1,96 erreur-type pour α = 5 % bilatéral) : l'effet dépasse à peine la barre. En répétant l'expérience, on ne la franchirait qu'environ 59 % du temps : **la puissance est d'environ 59 %.**

**Étape 3.** Conclure en praticien : avec ce dispositif, un résultat non significatif resterait fréquent (4 fois sur 10) même si l'offre fonctionne vraiment. Pour viser 80 % de puissance, il faudrait augmenter l'effectif — ici, passer à environ 95 clients par groupe.

**À retenir**

- Puissance = 1 − β = probabilité de détecter un effet réel ; la référence classique est 80 %.
- Levier principal : l'effectif. Petit effet + petit échantillon = test presque aveugle.
- Un test non significatif ne prouve rien si la puissance était faible : regardez toujours l'effectif avant de conclure « pas d'effet ».

PARTIE C — LE TEST DE WELCH

## 4.8 Choisir le test de Welch

Nous voici à l'outil central du cours. Pour comparer deux moyennes, le réflexe professionnel est le test de Welch — une version robuste du célèbre « test t ». Pourquoi lui plutôt qu'un autre ? Parce qu'il ne suppose **pas** que les deux groupes ont la même dispersion, ce qui est le cas général en pratique (nos magasins : 18,09 € contre 24,51 €).

**Définition — le test de Welch**

Le **test t de Welch** (*Welch's t-test*) compare les moyennes de deux populations à partir de deux échantillons **indépendants**, sans supposer l'égalité des variances. Ses conditions d'application :

- la variable est **quantitative** et la moyenne répond à la question posée ;
- les deux groupes sont **non appariés** (aucune ligne du groupe A ne correspond à une ligne du groupe B) ;
- les observations sont **indépendantes** (la valeur d'une mesure ne détermine pas une autre) ;
- les effectifs et les variances peuvent être **inégaux** — c'est précisément sa force.

| Situation | Welch adapté ? | Pourquoi |
|---|---|---|
| Panier moyen de deux magasins (clients distincts) | Oui | Groupes indépendants, moyenne pertinente |
| Dépense des *mêmes* clients avant / après une offre | Non | Données appariées → méthode appariée |
| Temps de réponse de deux services, distribution très asymétrique, 12 lignes par groupe | Plutôt non | Moyenne peu fiable ici → Mann-Whitney (4.14) |
| Taux de satisfaction (oui/non) de deux campagnes | Non | Variable qualitative → $\chi^2$ (4.13) |
| Panier moyen de trois magasins | Non | Plus de deux groupes → ANOVA (4.12) |

*Tableau 2 : le plan de collecte et le type de variable commandent le choix du test — jamais l'habitude.*

**Vigilance — l'indépendance ne se lit pas dans les données**

L'indépendance des observations est une propriété du **plan de collecte**, pas du fichier : aucun calcul ne peut la prouver. Plusieurs visites d'un même client, des mesures répétées sur la même machine, des ventes du même jour partageant une météo : autant de dépendances qui invalident le test standard. Vérifiez-la en interrogeant la façon dont les données ont été produites.

**Exemple guidé — valider les conditions sur notre fil rouge**

**Condition 1.** Le montant d'achat est quantitatif, et la question du directeur porte bien sur le panier moyen. ✔

**Condition 2.** Les transactions de A et de B sont des achats de clients différents, dans deux magasins distincts : non appariés. ✔

**Condition 3.** Chaque transaction est indépendante des autres (pas de client présent dans les deux groupes sur la période, pas de journée unique commune). ✔ — vérifiée auprès de l'équipe qui a extrait les données.

**Condition 4.** Les variances diffèrent nettement ($18{,}09^2$ contre $24{,}51^2$) : c'est exactement le cas que Welch gère et que le test de Student classique aurait mal traité. ✔

**Conclusion de l'étape.** Le test de Welch est légitime ici ; nous pouvons passer au calcul.

**À retenir**

- Welch compare deux moyennes avec effectifs et variances inégaux : c'est le choix par défaut pour deux groupes indépendants.
- Données appariées, variable qualitative ou plus de deux groupes → autre outil (4.12 à 4.14).
- L'indépendance se vérifie dans le plan de collecte, pas dans le fichier.

### 4.9 La statistique t

Le test de Welch résume toute la situation en un seul nombre : la statistique t. Son idée est d'une élégance redoutable — **mesurer l'écart observé en unités de bruit**. Un écart de 5,86 € est-il grand ? Tout dépend du bruit de fond : face à une fluctuation naturelle de 1 €, il est énorme ; face à 10 €, il serait banal.

**Définition — la statistique de test**

Une **statistique de test** (*test statistic*) est un nombre calculé à partir des échantillons qui résume l'écart entre les données et $H_0$, en le rapportant à la variabilité attendue. Pour le test de Welch, c'est la statistique **t** : l'écart des moyennes divisé par son erreur-type.

$$t = \frac{\bar{x}_B - \bar{x}_A}{\sqrt{\dfrac{s_A^2}{n_A} + \dfrac{s_B^2}{n_B}}}$$

$\bar{x}_A, \bar{x}_B$ : moyennes observées des échantillons A et B, en €
$s_A^2, s_B^2$ : variances observées (diviseur $n - 1$), en €²
$n_A, n_B$ : effectifs des deux échantillons, sans unité
$t$ : écart exprimé en nombre d'erreurs-types, sans unité

Le numérateur est le **signal** : l'écart observé entre les moyennes. Le dénominateur est le **bruit** : l'erreur-type de cet écart, c'est-à-dire l'amplitude de sa fluctuation naturelle d'un tirage à l'autre (chaque groupe apporte sa contribution $s^2/n$, vous reconnaissez le $\sigma/\sqrt{n}$ du cours 2). Le rapport dit donc : « l'écart vaut tant d'erreurs-types ». Un $|t|$ grand peut venir d'un grand écart, d'une faible dispersion, d'un grand effectif — ou des trois.

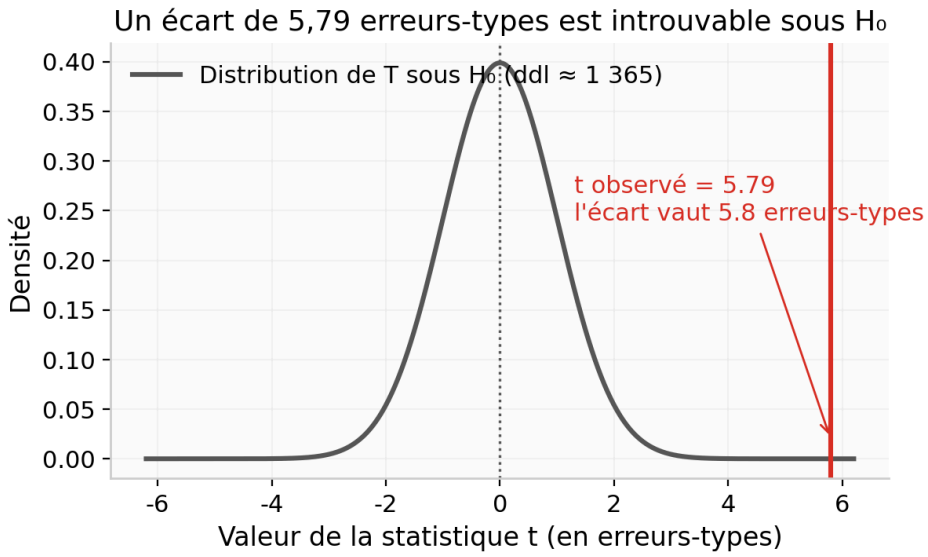



*Figure 8 : sous $H_0$, la statistique t fluctue autour de 0 ; notre valeur observée (5,79) se trouve à près de 6 erreurs-types du centre — hors de portée du hasard.*

**Exemple guidé 1 — un calcul à la main (petit cas)**

**Situation.** Deux groupes de 60 clients : l'écart de dépense estimé vaut +3 €, avec une erreur-type de 1,37 €.

**Étape 1.** t = 3 / 1,37 ≈ 2,19. L'écart vaut 2,19 erreurs-types.

**Étape 2.** Comparer à la distribution sous $H_0$ (figure 4) : un tel dépassement n'arrive que dans 3 % des tirages → p = 0,03. Au seuil de 5 %, on rejette $H_0$.

**Exemple guidé 2 — lire le résultat complet du fil rouge**

**Étape 1.** Erreur-type : $\sqrt{18{,}09^2/1200 + 24{,}51^2/800} = \sqrt{1{,}02} \approx 1{,}01$ €.

**Étape 2.** Statistique : t = 5,86 / 1,01 ≈ 5,79 — l'écart vaut près de 6 erreurs-types.

**Étape 3.** L'outil calcule aussi les **degrés de liberté** (*degrees of freedom*, ddl), ici ≈ 1 365 : le nombre effectif d'informations indépendantes, que Welch ajuste pour tenir compte des deux variances inégales. Avec un tel ddl, la distribution de référence est quasi normale.

**Étape 4.** Résultat complet : t ≈ 5,79, ddl ≈ 1 365, **p ≈ 8,5 × 10⁻⁹**. Probabilité infime : au seuil de 5 %, on rejette $H_0$ sans hésitation — les données sont incompatibles avec l'égalité des moyennes.

**En pratique dans le code**

```
from scipy import stats
res = stats.ttest_ind(montants_B, montants_A, equal_var=False)  # Welch
res.statistic, res.pvalue            # t ≈ 5.79 ; p ≈ 8.5e-09
```

**À retenir**

- t = signal ÷ bruit : l'écart des moyennes rapporté à son erreur-type, sans unité.
- Un grand |t| peut venir de l'écart, de la dispersion ou de l'effectif — le test ne les démêle pas, c'est votre travail d'interprétation.
- Le résultat se lit en entier : estimation, t, ddl, valeur p — puis l'intervalle de confiance (section suivante).

PARTIE D — ESTIMER ET INTERPRÉTER

## 4.10 L'intervalle de confiance

Le test répond à « y a-t-il une différence ? ». La question suivante arrive immédiatement : « elle vaut combien ? ». Répondre « 5,86 € » seul serait présenter une estimation sans sa marge d'erreur — comme donner un rendez-vous « vers 15 h » sans dire si c'est à 5 minutes ou à 1 heure près. L'intervalle de confiance chiffre cette précision.

**Définition — l'intervalle de confiance**

Un **intervalle de confiance** (*confidence interval*, IC) à 95 % pour un paramètre est un intervalle construit à partir de l'échantillon selon une procédure qui, **si l'on répétait l'échantillonnage**, produirait des intervalles contenant la vraie valeur dans environ 95 % des cas. Il rassemble les valeurs du paramètre qui restent plausibles au vu des données.

Attention à deux lectures fautives, très répandues. L'IC ne contient pas « 95 % des montants d'achat » — il porte sur la **différence des moyennes de population**, pas sur les valeurs individuelles. Et le « 95 % » qualifie la **procédure** (elle réussit 19 fois sur 20 sur des tirages répétés), comme le montre la figure 9 : ce n'est pas une probabilité portant sur cet intervalle-ci, qui est désormais fixe.

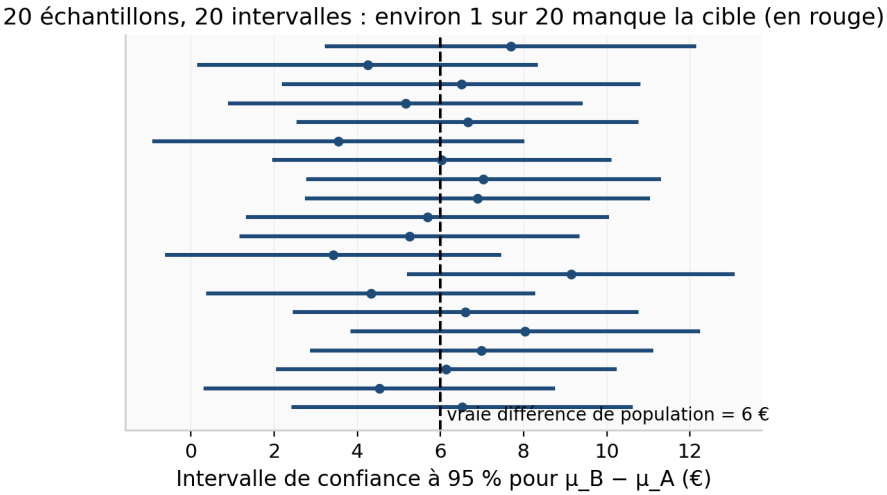



*Figure 9 : vingt échantillons simulés de la même population, vingt intervalles à 95 %. En moyenne, un intervalle sur vingt (en rouge) manque la vraie valeur — c'est le prix des 5 %.*

Lien pratique avec le test : pour un test bilatéral au seuil de 5 %, **l'IC à 95 % exclut 0 si et seulement si p < 5 %**. Les deux outils racontent la même évidence, mais l'intervalle dit en plus **l'ampleur et sa précision** : présentez toujours les deux ensemble.

**Exemple guidé — lire l'intervalle du fil rouge, puis celui de l'offre**

**Fil rouge.** Écart estimé = 5,86 € ; IC à 95 % = [3,88 ; 7,85] €. Lecture : les valeurs plausibles pour l'écart réel $\mu_B - \mu_A$ vont de 3,88 à 7,85 € — toutes positives, et le pire cas plausible reste confortable : +3,88 € par panier.

**Offre promotionnelle.** Écart estimé = +3 € ; IC à 95 % = [+0,3 ; +5,7] €. Lecture : l'effet réel pourrait n'être que +0,3 € — positif, mais très faible. L'intervalle exclut 0 (cohérent avec p = 0,03), mais il prévient : l'ampleur est incertaine, et le bas de la fourchette peut changer la rentabilité (section suivante).

**Cas inverse.** Un IC = [−1 ; +9] € contient 0 : l'absence d'effet reste compatible avec les données — sans que l'égalité soit prouvée, puisque +9 € est également compatible.

**En pratique dans le code**

```
res = stats.ttest_ind(montants_B, montants_A, equal_var=False)
res.confidence_interval(confidence_level=0.95)   # IC à 95 % : [3.88 ; 7.85]
```

**À retenir**

- Estimer avant de conclure : toujours présenter l'écart **et** son intervalle avec la valeur p.
- 95 % qualifie la procédure sur des tirages répétés ; l'IC porte sur le paramètre, pas sur les valeurs individuelles.
- IC qui exclut 0 ↔ test significatif au seuil correspondant ; l'intervalle ajoute l'ampleur et la précision.

### 4.11 Significatif ne veut pas dire important

Voici la section qui distingue l'analyste junior de l'analyste crédible. Un résultat peut être **statistiquement significatif et commercialement négligeable** — ou l'inverse. Les deux adjectifs mesurent des choses différentes, et confondre les deux coûte cher.

**Définition — significativité statistique, importance pratique, taille d'effet**

La **significativité statistique** (*statistical significance*) indique seulement que les données sont incompatibles avec $H_0$ au seuil choisi. L'**importance pratique** (*practical significance*) juge si l'écart vaut la peine d'agir, au regard d'un seuil métier, d'un coût ou d'une conséquence concrète.

Pour comparer les ampleurs entre études, on utilise une **taille d'effet** (*effect size*) ; la plus courante est le **d de Cohen** (*Cohen's d*) : l'écart des moyennes divisé par l'écart-type, donc sans unité. Repères usuels : $|d| \approx 0{,}2$ effet faible ; 0,5 moyen ; 0,8 fort.

Le piège tient en une phrase : **avec un effectif assez grand, n'importe quel écart, même dérisoire, devient significatif**. Un écart de +0,20 € sur le panier moyen, avec deux millions de transactions, produira une valeur p minuscule et un IC très étroit — l'évidence est forte, mais le gain peut être inférieur au coût de l'action. À l'inverse, un écart de +3 mm mesuré sur 8 prototypes peut être critique pour la sécurité, avec un test non concluant faute de données : l'ampleur est peut-être là, l'information manque. La figure 10 montre ce mécanisme : à écart et dispersion constants, seul l'effectif déplace la conclusion.

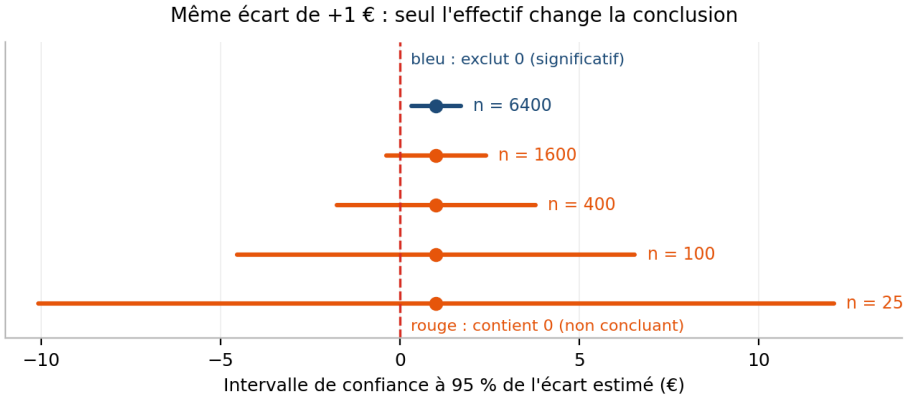



*Figure 10 : même écart de +1 €, même dispersion (20 €) ; seul l'effectif varie. L'intervalle se rétrécit jusqu'à exclure 0 : le « significatif » ne dit rien de l'importance.*

Sur notre fil rouge, l'écart vaut 5,86 € pour des écarts-types autour de 21 € : d ≈ 0,28, un effet plutôt faible à l'échelle statistique — mais multiplié par le volume annuel de transactions, il peut représenter une somme très concrète. L'importance pratique se juge ainsi, en euros et en conséquences, jamais en regardant seulement p.

**Exemple guidé — une décision chiffrée de bout en bout (l'offre promotionnelle)**

**Données.** Offre attribuée au hasard à 60 clients (60 autres servent de comparaison). Dépense mensuelle : 50 € sans offre, 53 € avec. Écart = +3 € ; IC = [+0,3 ; +5,7] € ; p = 0,03. Marge de l'enseigne : 30 %. Coût de l'offre : 2 € par client qui la reçoit.

**Étape 1 — l'évidence.** p = 0,03 < 0,05 : l'écart est significatif. ✔ mais ce n'est que le début.

**Étape 2 — l'ampleur en euros.** Gain de marge estimé = 30 % × 3 € = 0,90 € par client.

**Étape 3 — le coût.** Solde estimé = 0,90 − 2 = **−1,10 € par client** : l'offre détruit de la valeur à l'estimation centrale.

**Étape 4 — la décision.** Significatif, oui ; rentable, non. Et l'intervalle rappelle que même le meilleur cas (+5,7 € → marge 1,71 €) ne couvre pas le coût de 2 €. Recommandation rédigée : « l'offre augmente significativement la dépense (+3 €, IC [ 0,3 ; 5,7 ]), mais son coût dépasse le gain de marge dans toute la fourchette plausible ; ne pas déployer en l'état ».

**À retenir**

- Significatif = incompatible avec $H_0$ ; important = vaut la peine d'agir. Les deux se décident avec des outils différents.
- Le grand effectif rend tout significatif ; regardez la taille d'effet (d de Cohen) et l'intervalle.
- La décision combine estimation, intervalle, seuil métier, coût et conséquence — rédigez-la toujours ainsi.

## PARTIE E — TESTER DANS D'AUTRES SITUATIONS

### 4.12 Comparer plus de deux groupes : l'ANOVA

Votre directeur, convaincu, élargit la question : « et nos trois magasins ? ». Première idée — mauvaise : tester A contre B, B contre C, A contre C. Trois tests à 5 %, c'est trois occasions de fausse alerte, et la probabilité globale d'en déclencher au moins une grimpe (section 4.15, en avant-première : ≈ 14 % ici). Il faut un test **global**, qui pose une seule question pour tous les groupes à la fois.

**Définition — l'analyse de variance (ANOVA)**

L'**analyse de variance** (*analysis of variance*, ANOVA) compare les moyennes de **trois groupes ou plus** en un seul test. Ses hypothèses :

$$H_0 : \mu_1 = \mu_2 = \cdots = \mu_k \text{ contre } H_1 : \text{au moins une moyenne diffère des autres.}$$

L'idée, visible sur la figure 11, est une mise en balance de deux variabilités. Si les groupes ne diffèrent pas, les écarts entre leurs moyennes ne reflètent que le bruit — celui-là même qu'on observe à l'intérieur de chaque groupe. Mais si les moyennes s'écartent **nettement plus** que ce que le bruit interne autorise, c'est qu'au moins un groupe joue dans une autre catégorie. La statistique **F** rapporte ces deux variabilités : variance *entre* les groupes divisée par variance *à l'intérieur* des groupes. Un F nettement supérieur à 1 plaide contre $H_0$.

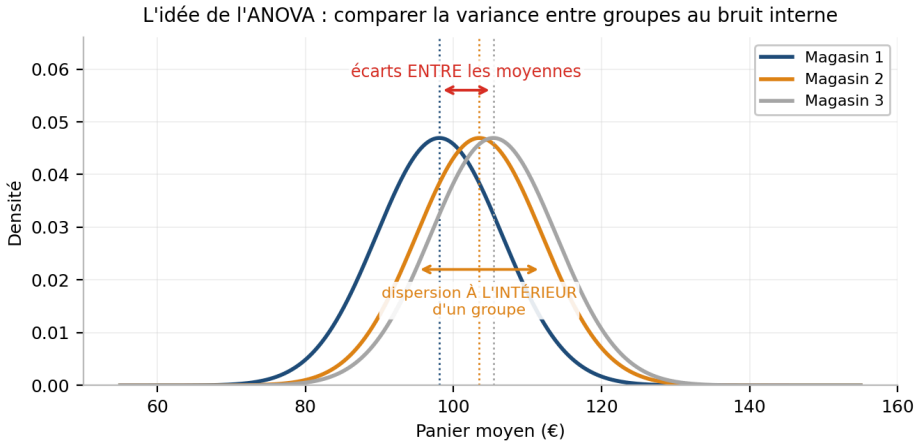



*Figure 11 : le raisonnement de l'ANOVA. La statistique F compare les écarts entre les moyennes des groupes (flèche rouge) à la dispersion à l'intérieur de chaque groupe (double flèche orange).*

Une limite à connaître d'emblée : l'ANOVA conclut « au moins un groupe diffère », **sans dire lequel**. Pour identifier les groupes en cause, on enchaîne avec des comparaisons deux à deux dites *post-hoc*, protégées contre les comparaisons multiples (section 4.15).

**Exemple guidé — lire un résultat d'ANOVA**

**Situation.** Trois magasins, 30 jours de ventes chacun : paniers moyens de 98,1 €, 103,5 € et 105,4 € ; dispersion interne (écart-type) ≈ 8,5 € dans chaque magasin.

**Étape 1.** Variance entre les moyennes des groupes (× effectif) ≈ 430 ; variance à l'intérieur des groupes = $8{,}5^2 = 72{,}25$.

**Étape 2.** F = 430 / 72,25 ≈ 6,0 : les moyennes s'écartent six fois plus que le bruit interne ne l'expliquerait.

**Étape 3.** La valeur p associée vaut ≈ 0,004 < 0,05 : on rejette $H_0$. Conclusion rédigée : « au moins un magasin a un panier moyen différent des autres » — et c'est tout : l'identification du ou des magasins demande l'étape suivante (comparaisons post-hoc).

**En pratique dans le code**

```
stats.f_oneway(ventes_magasin1, ventes_magasin2, ventes_magasin3)  # F ≈ 6.0 ; p ≈ 0.004
```

**À retenir**

- Trois groupes ou plus → un test global (ANOVA), jamais une chaîne de tests t non protégée.
- F = variance entre groupes ÷ variance interne ; grand F → au moins une moyenne diffère.
- L'ANOVA ne dit pas quel groupe diffère : les comparaisons post-hoc prennent le relais.

### 4.13 Variables qualitatives : le test du $\chi^2$ d'indépendance

Jusqu'ici, nous comparions des moyennes de variables quantitatives. Mais beaucoup de questions métier croisent deux variables **qualitatives** : le canal de vente (web / magasin) et l'achat (oui / non), le département et le type de contrat, la tranche d'âge et la catégorie de produit préférée. Pour celles-là, le $\chi^2$ est l'outil de référence.

**Définition — le test du $\chi^2$ d'indépendance**

Le **test du $\chi^2$ d'indépendance** (*chi-squared test of independence*) évalue si deux variables qualitatives sont **liées** dans la population, à partir d'un **tableau de contingence** (*contingency table*) qui compte les effectifs de chaque combinaison de modalités. $H_0$ : les deux variables sont indépendantes ; $H_1$ : elles sont liées. Condition d'usage : les effectifs théoriques doivent être d'au moins 5 environ dans chaque case.

Le raisonnement reprend celui que vous connaissez déjà : construire ce que $H_0$ prévoit, puis mesurer l'écart avec l'observé. Sous indépendance, la répartition des achats devrait être **la même** sur le web et en magasin ; on calcule alors les **effectifs théoriques** de chaque case (effectif de la ligne × effectif de la colonne ÷ total). La statistique $\chi^2$ additionne, case par case, les écarts entre observés et théoriques, standardisés :

$$\chi^2 = \sum_{\text{cases}} \frac{(O - E)^2}{E}$$

$O$ : effectif observé d'une case du tableau
$E$ : effectif théorique de la même case sous l'hypothèse d'indépendance
$\chi^2$ : statistique du test, sans unité — d'autant plus grande que les écarts sont marqués

Chaque case contribue d'autant plus qu'elle s'écarte de l'indépendance : le numérateur $(O - E)^2$ mesure l'écart (au carré, pour que les signes ne se compensent pas) et le dénominateur $E$ le rapporte à ce qu'on attendait — un écart de 10 sur 20 attendus pèse plus lourd que sur 200 attendus. Un $\chi^2$ grand signale donc des cases qui dérogent trop à l'indépendance pour être le fait du hasard.

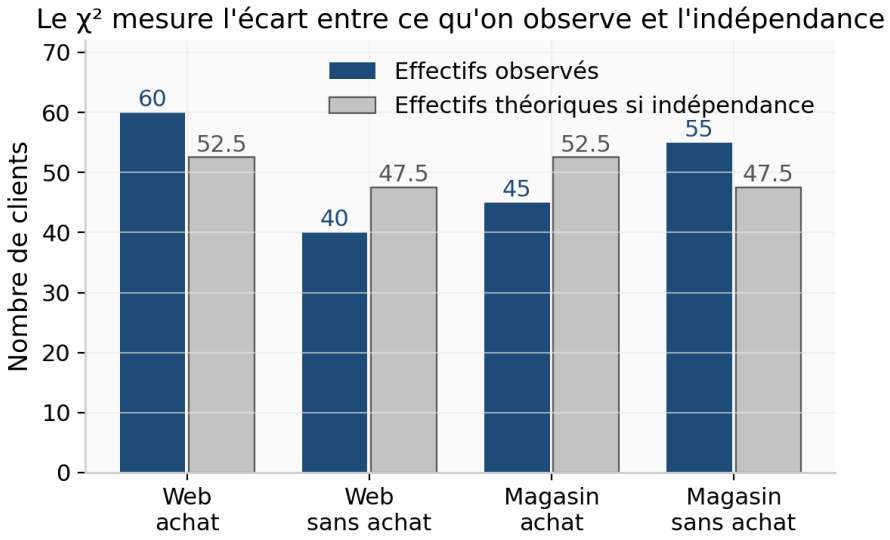



*Figure 12 : l'exemple guidé en image. Les effectifs observés (bleu) s'écartent nettement des effectifs théoriques sous indépendance (gris) : le web convertit mieux que le magasin.*

**Exemple guidé — le calcul complet, case par case**

**Données.** 200 visiteurs : sur le web, 60 achètent et 40 n'achètent pas ; en magasin, 45 achètent et 55 n'achètent pas. Total des achats : 105 ; total sans achat : 95.

**Étape 1 — effectifs théoriques.** Sous indépendance : web-achat = 100 × 105 / 200 = 52,5 ; web-sans achat = 47,5 ; magasin-achat = 52,5 ; magasin-sans achat = 47,5.

**Étape 2 — contributions.** Web-achat : $(60 - 52{,}5)^2 / 52{,}5 \approx 1{,}07$ ; web-sans achat : $(40 - 47{,}5)^2 / 47{,}5 \approx 1{,}18$ ; et de façon symétrique 1,07 et 1,18 pour le magasin.

**Étape 3 — statistique et conclusion.** $\chi^2 = 1{,}07 + 1{,}18 + 1{,}07 + 1{,}18 \approx 4{,}51$ ; avec 1 degré de liberté, $p \approx 0{,}034 < 0{,}05$. Conclusion : canal et achat sont liés au seuil de 5 % — le taux d'achat observé est plus élevé sur le web (60 %) qu'en magasin (45 %). La causalité, elle, reste à établir : peut-être les visiteurs web sont-ils déjà plus intentionnés.

**En pratique dans le code**

```
stats.chi2_contingency([[60, 40], [45, 55]])   # χ² ≈ 4.51 ; p ≈ 0.034
```

**À retenir**

- Deux variables qualitatives → tableau de contingence → $\chi^2$ d'indépendance.
- Le $\chi^2$ additionne les écarts standardisés entre effectifs observés et théoriques (sous indépendance).
- Vérifiez la condition (effectifs théoriques ≥ 5 environ) ; « liées » ne veut jamais dire « l'une cause l'autre ».

### 4.14 Distributions non gaussiennes : le test de Mann-Whitney

Le test de Welch s'appuie sur les moyennes, et les moyennes deviennent peu fiables quand la distribution est très asymétrique ou que l'effectif est petit — vous l'avez vu au cours 1 avec les valeurs extrêmes, et au cours 2 avec les lognormales. Pour ces situations, il existe un test qui ne mise pas sur les moyennes, mais sur les **rangs**.

**Définition — le test de Mann-Whitney**

Le **test de Mann-Whitney** (*Mann-Whitney U test*, aussi appelé test des rangs de Wilcoxon, *Wilcoxon rank-sum test*) compare deux groupes indépendants **sans hypothèse sur la forme** des distributions : c'est un test **non paramétrique** (*non-parametric test*). $H_0$ : les deux distributions sont identiques. Le principe : on réunit les deux groupes, on remplace chaque valeur par son **rang**, et l'on compare la somme des rangs des deux groupes ; si $H_0$ était vraie, les rangs se mélangeraient équitablement.

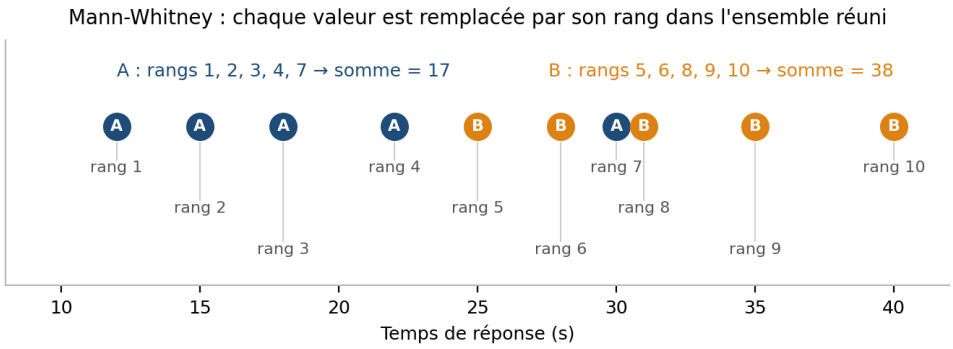



*Figure 13 : le mécanisme des rangs sur dix temps de réponse. Le groupe A concentre les petits rangs (somme 17) ; sous $H_0$, sa somme attendue serait de 27,5 — l'écart plaide contre l'égalité des distributions.*

Pourquoi les rangs sont-ils robustes ? Parce qu'ils effacent l'échelle : une valeur de 400 € ou de 4 000 € occupe le même rang si c'est la plus grande. Les valeurs extrêmes ne peuvent plus faire dérailler le test, et la forme de la distribution importe peu. Le prix à payer : le test ne porte plus sur les moyennes, mais sur les distributions entières — et il est un peu moins puissant que Welch quand les données sont bien gaussiennes.

**Exemple guidé — comparer deux temps de réponse en cinq rangs**

**Situation.** Temps de réponse de deux chatbots (en secondes), 5 mesures chacun : A = {12, 15, 18, 22, 30} ; B = {25, 28, 31, 35, 40}. Les effectifs sont minuscules : Welch serait imprudent.

**Étape 1.** Réunir et ordonner les 10 valeurs ; attribuer les rangs 1 à 10 (figure 13).

**Étape 2.** Somme des rangs de A = 1 + 2 + 3 + 4 + 7 = 17 ; somme de B = 38. Sous $H_0$, chaque groupe attendrait la moitié de la somme totale (55 / 2 = 27,5).

**Étape 3.** A est très en dessous de l'attendu : ses valeurs sont systématiquement petites. Le calcul complet donne U = 2, $p \approx 0{,}032 < 0{,}05$ : on rejette l'égalité des distributions au seuil de 5 %.

**Conclusion rédigée.** « Les temps de réponse de A sont globalement plus courts que ceux de B (test de Mann-Whitney, $p \approx 0{,}03$) ; les médianes respectives (18 s contre 31 s) illustrent l'écart. »

**En pratique dans le code**

```
stats.mannwhitneyu(temps_A, temps_B)   # U = 2.0 ; p ≈ 0.032
```

**À retenir**

- Forte asymétrie, valeurs extrêmes ou petit effectif → Mann-Whitney plutôt que Welch.
- Le test travaille sur les rangs : il compare les distributions, pas les moyennes.
- Complétez toujours le résultat par les médianes des groupes pour raconter l'ampleur.

### 4.15 Multiplier les tests : le piège des comparaisons multiples

Chaque test au seuil de 5 % accepte une fausse alerte une fois sur vingt. Que se passe-t-il quand on enchaîne les tests — vingt variables, vingt comparaisons, vingt occasions de « découvrir » quelque chose ? Le risque se cumule, et vite : c'est le problème des **comparaisons multiples**.

> **Définition — le risque cumulé des comparaisons multiples**
>
> Avec **comparaisons multiples** (*multiple comparisons*), la probabilité de commettre **au moins une** erreur de type I sur l'ensemble des tests dépasse le seuil α de chaque test pris isolément. Si les m tests sont indépendants, cette probabilité globale vaut : $1 - (1 - \alpha)^m$.

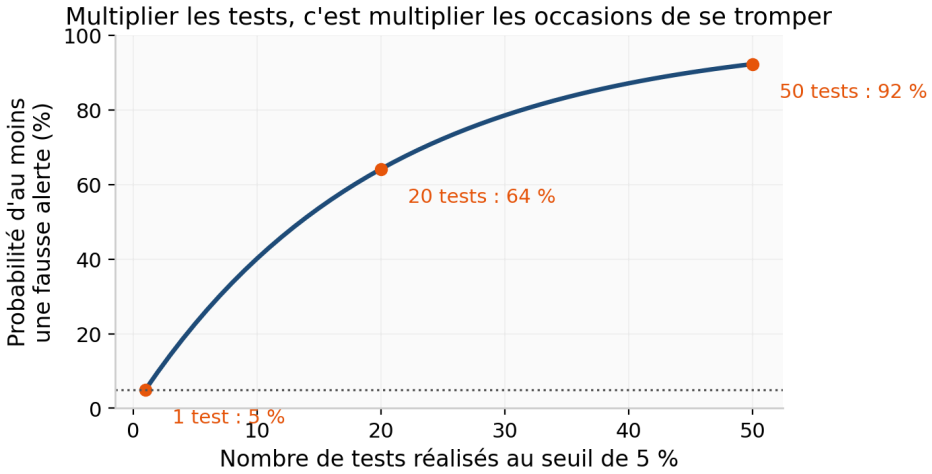



*Figure 14 : le risque global de fausse alerte en fonction du nombre de tests au seuil de 5 %. Vingt tests suffisent à porter le risque à 64 %.*

La parade la plus simple est la **correction de Bonferroni** (*Bonferroni correction*) : diviser le seuil par le nombre de tests. Pour m = 20 tests et un risque global de 5 %, chaque test doit passer sous α/m = 0,05 / 20 = 0,0025. Une valeur p de 0,01, séduisante isolément, ne passe plus la barre — et c'est voulu : parmi vingt tests, un p de 0,01 n'a rien d'extraordinaire. Le prix de cette sévérité est une puissance réduite ; des méthodes plus fines existent (voir « Pour aller plus loin »), mais le réflexe fondamental reste le même : **décider des questions avant de regarder les données**, et corriger quand on en pose plusieurs.

> **Exemple guidé — le data dredging démasqué**
>
> **Situation.** Un collègue teste 20 variables pour expliquer l'écart de panier entre A et B : âge, météo, jour de la semaine, couleur préférée… Il revient triomphant : « le jour de la semaine est lié au panier : p = 0,008 ! ».
>
> **Étape 1.** Risque global sans correction : $1 - 0{,}95^{20} \approx 64$ %. Même si *rien* n'est lié au panier, il avait presque deux chances sur trois de « trouver » quelque chose.
>
> **Étape 2.** Seuil corrigé de Bonferroni : 0,05 / 20 = 0,0025. Sa valeur p de 0,008 ne passe pas.
>
> **Étape 3.** Conclusion rédigée : « au regard des 20 tests menés, ce résultat n'est pas probant ; à confirmer sur de nouvelles données, avec une question formulée à l'avance ».

> **À retenir**
>
> - m tests à 5 % → risque global $\approx 1 - 0{,}95^{m}$ ; 20 tests : 64 % de chances d'au moins une fausse alerte.
> - Correction de Bonferroni : seuil par test = α / m — simple, sûre, un peu conservatrice.
> - Le meilleur remède reste préventif : limiter et annoncer les questions **avant** l'analyse.

PARTIE F — COMPARER DES DISTRIBUTIONS ENTIÈRES

## 4.16 La fonction de répartition empirique (ECDF)

Comparer des moyennes ou des variances, c'est résumer chaque distribution en un nombre avant de comparer. Pour comparer les distributions **entières**, il faut d'abord un outil qui les dessine sans rien perdre : la fonction de répartition empirique. C'est aussi la clé du test de Kolmogorov-Smirnov (section suivante).

> **Définition — la fonction de répartition empirique**
>
> La **fonction de répartition empirique** (*empirical cumulative distribution function*, ECDF) d'un échantillon donne, pour chaque valeur x, la **proportion d'observations inférieures ou égales à x**. C'est une courbe en escalier qui part de 0 et monte jusqu'à 1 (100 %).

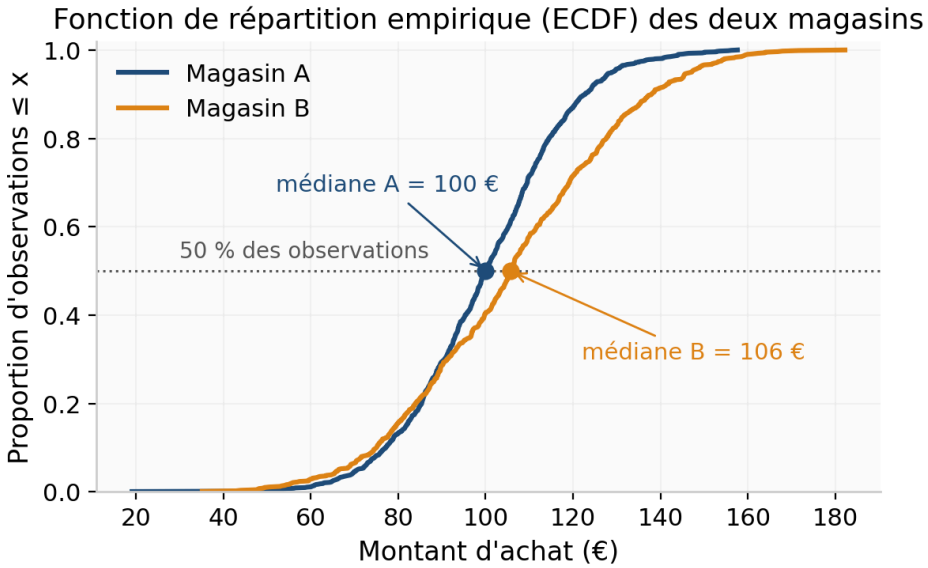



*Figure 15 : les ECDF des deux magasins. À hauteur de 50 %, on lit les médianes ; la courbe de B est décalée vers la droite — ses montants sont globalement plus élevés.*

La lecture est directe et riche. La **hauteur** de la courbe en un point répond à « quelle proportion des observations est en dessous de ce montant ? » ; la médiane se lit à hauteur 0,5. La **pente** indique la concentration : raide, les valeurs sont resserrées ; étalée, elles sont dispersées. Et quand deux ECDF sont tracées ensemble, tout **écart vertical** entre elles signale une zone où les groupes diffèrent — sans choisir de classes comme dans un histogramme, sans résumer comme une moyenne.

> **Exemple guidé — trois lectures sur la figure 15**
>
> **Lecture 1 (médianes).** À hauteur 0,5 : médiane de A ≈ 99 €, médiane de B ≈ 104 €.
>
> **Lecture 2 (proportions).** À x = 110 € : environ 70 % des achats de A sont ≤ 110 €, contre environ 57 % pour B — B a davantage de gros paniers.
>
> **Lecture 3 (dispersion).** La courbe de B monte plus lentement : ses montants sont plus étalés, ce que confirme son écart-type (24,51 € contre 18,09 €). Un seul graphique a livré centre, dispersion et proportion — sans aucun calcul nouveau.

**À retenir**

- L'ECDF donne, pour tout x, la proportion d'observations ≤ x ; elle décrit la distribution entière.
- Médiane à hauteur 0,5 ; pente raide = valeurs concentrées ; décalage à droite = valeurs plus grandes.
- Deux ECDF superposées préparent la comparaison globale de deux distributions (section suivante).

### 4.17 Comparer variances et formes : F/Levene et Kolmogorov-Smirnov

Deux distributions peuvent différer sans que leurs moyennes bougent : dispersion élargie, forme déformée, queue allongée. Deux familles de tests répondent à ces questions, chacune avec sa discipline.

**Comparer les variances.** Le test **F** rapporte les deux variances ($F = s_1^2/s_2^2$, $H_0 : \sigma_1^2 = \sigma_2^2$) ; simple, mais il exige des distributions proches de la normale — il devient trompeur sinon. Le **test de Levene** (*Levene's test*) répond à la même question avec une robustesse bien supérieure : c'est le choix par défaut en pratique.

**Comparer les distributions entières.** Le **test de Kolmogorov-Smirnov** (*Kolmogorov-Smirnov test*, KS) mesure l'écart vertical maximal **D** entre les deux ECDF (figure 16), avec $H_0$ : « les deux échantillons viennent de la même loi ». Sa grande qualité — ne rien supposer sur la forme — est aussi sa limite : un rejet annonce « les distributions diffèrent » sans préciser *ce qui* diffère (centre ? dispersion ? forme ?). Retour aux graphiques, ensuite, pour raconter la différence.

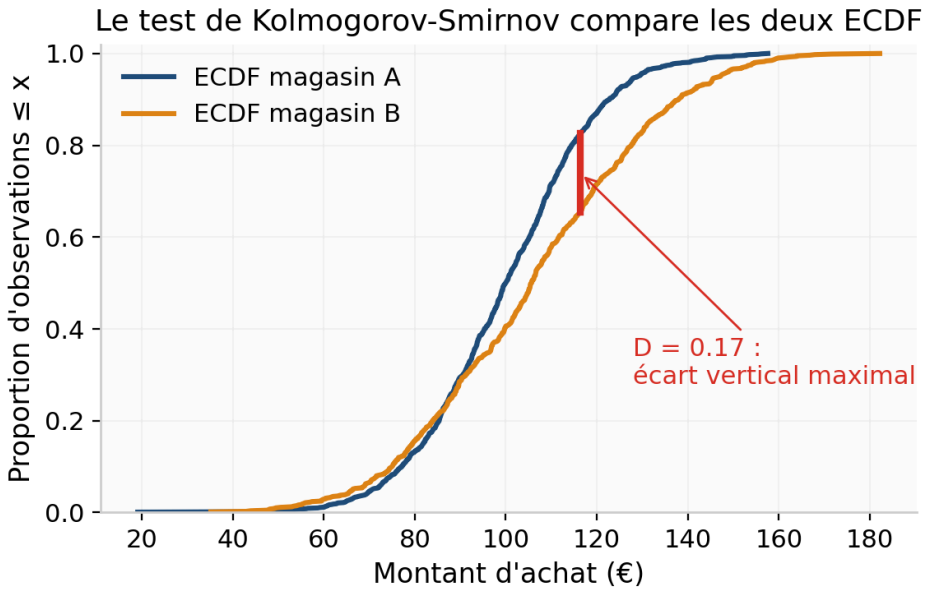



*Figure 16 : la statistique D de Kolmogorov-Smirnov est l'écart vertical maximal entre les deux ECDF — ici D = 0,17, atteint vers 116 €.*

**Définition — tests de variance et test de Kolmogorov-Smirnov**

Le **test de Levene** évalue l'égalité des variances de deux groupes ou plus, de façon robuste à la non-normalité ($H_0$ : variances égales). Le **test de Kolmogorov-Smirnov** évalue l'égalité de deux distributions continues via l'écart maximal de leurs ECDF ($H_0$ : même loi de population).

**Exemple guidé — le fil rouge au-delà des moyennes**

**Question 1 — les dispersions diffèrent-elles ?** Levene sur les deux magasins : F = 90,0, p ≈ 6,5 × $10^{-21}$. Les variances diffèrent massivement (18,09² contre 24,51²) : le choix de Welch en 4.8 était pleinement justifié.

**Question 2 — les distributions entières diffèrent-elles ?** KS : D = 0,172, p ≈ 7,3 × $10^{-13}$. Les deux distributions ne suivent pas la même loi.

**Étape de synthèse.** Le KS ne dit pas ce qui change ; les figures 1 et 15 le racontent : un centre décalé (+5,86 €) *et* une dispersion élargie. La conclusion complète combine les trois résultats : moyennes, variances, distributions.

| Question | Test | $H_0$ | Vigilance |
|---|---|---|---|
| Les moyennes diffèrent-elles ? | Welch | $\mu_1 = \mu_2$ | Groupes indépendants |
| Les variances diffèrent-elles ? | Levene (ou F) | $\sigma_1^2 = \sigma_2^2$ | F exige la normalité ; préférer Levene |
| Les distributions diffèrent-elles ? | Kolmogorov-Smirnov | Même loi | Le rejet ne dit pas ce qui a changé |

*Tableau 3 : trois questions distinctes, trois tests — formuler la question avant de choisir.*

**En pratique dans le code**

```
stats.levene(montants_A, montants_B)    # F ≈ 90.0 ; p ≈ 6.5e-21
stats.ks_2samp(montants_A, montants_B)  # D ≈ 0.172 ; p ≈ 7.3e-13
```

**À retenir**

- Variances : Levene par défaut (le test F exige la normalité).
- Distributions entières : KS et sa statistique D, écart maximal entre ECDF.
- Un rejet KS appelle le graphique : il signale une différence sans la décrire.

### 4.18 Mesurer une distance globale entre deux distributions

Dernier outil de la boîte, et un changement de logique : au lieu de *tester* une différence, on peut la **mesurer**, comme on mesure la distance entre deux villes. Une distance chiffre l'écart global entre deux distributions — utile pour suivre une dérive dans le temps ou comparer des campagnes — mais elle ne rend pas de verdict.

**Définition — trois mesures d'écart entre distributions**

La **distance de Wasserstein-2** (*Wasserstein distance*) mesure le « travail » minimal nécessaire pour déplacer une distribution sur l'autre ; pour deux lois normales, elle combine simplement l'écart des centres et celui des dispersions. Le **coefficient de recouvrement** (*overlap coefficient*) mesure l'aire commune aux deux distributions, de 0 (aucun chevauchement) à 1 (identiques). La **divergence de Kullback-Leibler** (*Kullback-Leibler divergence*, KL) mesure à quel point une distribution Q représente bien une distribution P ; elle est **directionnelle** : KL(P ‖ Q) ≠ KL(Q ‖ P).

$$W_2 = \sqrt{(\mu_1 - \mu_2)^2 + (\sigma_1 - \sigma_2)^2}$$

$W_2$ : distance de Wasserstein-2, dans l'unité de la variable (ici, €)

$\mu_1, \mu_2$ : moyennes des deux lois normales

$\sigma_1, \sigma_2$ : écarts-types des deux lois normales (pas les variances !)

Pour deux lois normales, la distance se lit comme un théorème de Pythagore : le décalage des centres et le décalage des dispersions sont les deux côtés d'un triangle, et $W_2$ en est l'hypoténuse. Deux lois ne sont donc « proches » que si leurs moyennes **et** leurs écarts-types sont proches ; $W_2 = 0$ exige les deux égalités. La figure 17 illustre ces deux contributions.

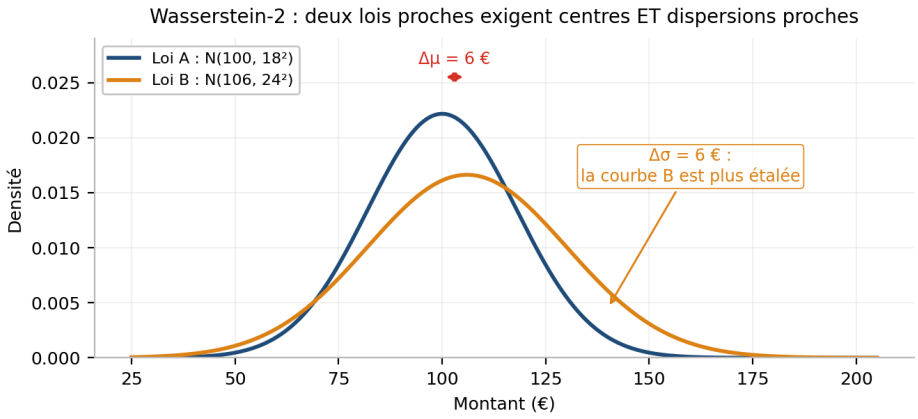



*Figure 17 : la distance de Wasserstein-2 entre deux lois normales combine l'écart des centres (Δμ) et l'écart des dispersions (Δσ).*

Le point de discipline qui termine cette partie : **une distance n'est pas un test**. Elle quantifie une ampleur selon une définition choisie, mais elle ne fournit ni valeur p, ni seuil, ni risque d'erreur. « $W_2$ = 8,5 € » ne répond pas à « est-ce significatif ? » ; si vous avez besoin d'une incertitude sur une distance, il faudra la construire (par bootstrap ou permutation — voir « Pour aller plus loin »).

**Exemple guidé — calculer $W_2$ sur le fil rouge**

**Étape 1.** Écart des centres : $|100{,}07 - 105{,}93| = 5{,}86$ €.

**Étape 2.** Écart des dispersions : $|18{,}09 - 24{,}51| = 6{,}42$ €.

**Étape 3.** $W_2 = \sqrt{(5{,}86^2 + 6{,}42^2)} = \sqrt{(34{,}3 + 41{,}2)} = \sqrt{75{,}5} \approx 8{,}7$ €.

**Lecture.** « Déplacer la distribution de A sur celle de B représente un travail d'environ 8,7 € — les deux tiers venant du décalage des dispersions. » Aucune valeur p ici : c'est une photographie de l'écart, pas un verdict.

**À retenir**

- Wasserstein-2 (centres + dispersions, même unité que la variable), recouvrement (aire commune, 0 à 1), KL (directionnelle) : trois façons de mesurer un écart global.
- Une distance quantifie ; un test statue. Ne demandez jamais à une distance une valeur p.
- Ces mesures brillent pour la **surveillance d'une dérive** (même calcul répété dans le temps).

## PARTIE G — SYNTHÈSE OPÉRATIONNELLE

### 4.19 Choisir la bonne stratégie : du résultat à la décision

Vous disposez maintenant de toute la boîte à outils. Encore faut-il l'ouvrir dans le bon ordre. La démarche professionnelle tient en cinq temps, qu'aucun outil ne remplace : **décrire → quantifier → évaluer l'incertitude → interpréter l'ampleur → annoncer les limites**. Sauter directement à la valeur p, c'est raconter le dénouement d'un film sans l'avoir vu.

| Étape | Question | Outil du cours | Produit |
|---|---|---|---|
| 1. Décrire | Que montrent les données ? | Histogrammes, ECDF (cours 2, 4.16) | Chevauchement, formes, dispersion |
| 2. Quantifier | Quel écart ? | Différence des moyennes, d de Cohen (4.11), $W_2$ (4.18) | Estimation chiffrée, unité explicite |
| 3. Évaluer l'incertitude | Le hasard peut-il l'expliquer ? | Test adapté + IC (4.8 à 4.14) | Valeur p, intervalle, conditions vérifiées |
| 4. Interpréter l'ampleur | Cela vaut-il la peine ? | Taille d'effet, seuil métier, coûts (4.11) | Lecture en euros et conséquences |
| 5. Annoncer les limites | Que ne sait-on pas ? | Plan de collecte, puissance (4.7), causalité | Réserve explicite dans la conclusion |

*Tableau 4 : le cadre de lecture complet — chaque étape a sa question, son outil et son livrable.*

| Situation | Outil | $H_0$ |
|---|---|---|
| Deux moyennes, groupes indépendants | Welch (4.8-4.9) | $\mu_1 = \mu_2$ |
| Trois moyennes ou plus | ANOVA (4.12) | Toutes les moyennes égales |
| Deux variables qualitatives | $\chi^2$ d'indépendance (4.13) | Indépendance |
| Deux groupes, forme non gaussienne / petit n | Mann-Whitney (4.14) | Même distribution |
| Deux variances | Levene (4.17) | $\sigma_1^2 = \sigma_2^2$ |
| Deux distributions entières | Kolmogorov-Smirnov (4.17) | Même loi |
| Écart global à suivre (sans verdict) | $W_2$, recouvrement, KL (4.18) | — (pas un test) |
| Plusieurs tests enchaînés | Bonferroni (4.15) | Seuil corrigé α/m |

*Tableau 5 : la carte de la boîte à outils — la question commande l'outil, jamais l'inverse.*

**Exemple guidé — la conclusion professionnelle du fil rouge, en cinq lignes**

« Sur 2 000 transactions (1 200 en A, 800 en B), le panier moyen du magasin B dépasse celui de A de **5,86 €**, IC à 95 % = [3,88 ; 7,85] € (Welch, $p \approx 10^{-8}$ ; taille d'effet $d \approx 0{,}28$, faible à modérée). La dispersion est également plus forte en B (Levene, $p < 10^{-20}$) : les distributions diffèrent dans leur ensemble (KS, $D = 0{,}17$). Rapporté au volume annuel, l'écart représente un enjeu financier réel ; il appelle une recherche d'explication (assortiment, clientèle, zone) avant toute action, car la comparaison observée n'établit pas la cause. »

Notez la structure : estimation → incertitude → ampleur → suite et limite. Toute conclusion de test que vous rédigerez suivra cette trame.

**À retenir**

- Décrire → quantifier → évaluer l'incertitude → interpréter l'ampleur → annoncer les limites.
- La question commande l'outil ; l'outil ne remplace ni la figure ni la rédaction.
- Une conclusion professionnelle cite toujours estimation, intervalle, valeur p, ampleur et limite.

# 5. Erreurs fréquentes et pièges

**Piège 1 — « p = 0,03, donc 3 % de chances que $H_0$ soit vraie ».** C'est l'inversion de la conditionnelle, l'erreur la plus répandue du métier. La valeur p est calculée *en supposant* $H_0$ vraie : elle ne peut pas, par construction, mesurer la probabilité de $H_0$. **Réflexe correct :** commencer toute lecture par « *Sous* $H_0$, la probabilité d'un résultat au moins aussi extrême est… » (4.4).

**Piège 2 — « Non significatif, donc les moyennes sont égales ».** Un test non concluant peut simplement manquer de puissance : petit échantillon, forte dispersion, petit effet. **Réflexe correct :** regarder l'intervalle de confiance (quelles ampleurs restent plausibles ?) et l'effectif ; rédiger « les données ne permettent pas de conclure » plutôt que « il n'y a pas de différence » (4.5, 4.7, 4.10).

**Piège 3 — « Significatif, donc important ».** Avec un grand effectif, +0,20 € devient significatif sans créer de valeur ; inversement, un effet critique peut échapper à un test sous-dimensionné. **Réflexe correct :** juxtaposer systématiquement estimation, intervalle, taille d'effet et arithmétique métier (coût, marge, volume) — comme dans l'exemple de l'offre (4.11).

**Piège 4 — Tester jusqu'à trouver quelque chose.** Vingt tests à 5 %, c'est 64 % de chances d'au moins une fausse alerte : la « découverte » est alors presque garantie, et presque toujours illusoire. **Réflexe correct :** annoncer les questions à l'avance ; corriger le seuil (Bonferroni) quand plusieurs tests sont menés ; exiger une confirmation sur de nouvelles données pour toute piste exploratoire (4.15).

**Piège 5 — Appliquer Welch à des données appariées ou dépendantes.** Mesurer les mêmes clients avant et après une offre, puis traiter les deux colonnes comme des groupes indépendants, fausse entièrement le calcul de l'erreur-type. **Réflexe correct :** interroger le plan de collecte avant le type de test — apparié, dépendant, qualitatif, plus de deux groupes : à chaque structure son outil (4.8, tableau 2).

# 6. Exercices

Faites ces exercices sans relire le cours — c'est en forçant la récupération que la matière se consolide. Le corrigé détaillé se trouve en fin de document (section 9).

### 6.1 Auto-évaluation

**Q1 (vrai ou faux).** « Une valeur p de 0,03 signifie qu'il y a 3 % de chances que $H_0$ soit vraie. » Justifiez en une phrase.

**Q2 (QCM).** Une valeur p mesure :

a) la probabilité que le résultat soit dû au hasard ;
b) sous $H_0$ et les hypothèses du test, la probabilité d'un résultat au moins aussi extrême que celui observé ;
c) la probabilité que $H_1$ soit vraie ;
d) la taille de l'effet rapportée à sa variabilité.

**Q3.** Vous comparez le temps de chargement moyen de deux versions d'un site (visiteurs distincts sur chaque version). Formulez $H_0$ et $H_1$, précisez si le test est bilatéral, et citez une condition à vérifier.

**Q4.** Un test donne p = 0,08 au seuil fixé de 5 %. Que conclut-on ? Que serait-il interdit de conclure ?

**Q5.** L'intervalle de confiance à 95 % pour $\mu_B - \mu_A$ vaut $[-2{,}1\ ;\ +0{,}4]$ €. Le test bilatéral à 5 % est-il significatif ? L'égalité des moyennes est-elle prouvée ?

**Q6.** Vous menez 10 tests indépendants au seuil de 5 %. Quelle est la probabilité de commettre au moins une erreur de type I ?

**Q7.** Associez chaque situation au bon outil (Welch, ANOVA, $\chi^2$, Mann-Whitney) : (a) panier moyen de 4 magasins ; (b) lien entre type de contrat et satisfaction (oui/non) ; (c) montants très asymétriques, 12 clients par groupe ; (d) dépense moyenne de clients distincts de deux campagnes.

### 6.2 Application guidée

**Exercice 1 — calculer un test de Welch à la main**

Deux échantillons indépendants de dépenses mensuelles (en €) : groupe A : n = 100, moyenne = 48,20 €, s = 12 € ; groupe B : n = 120, moyenne = 51,50 €, s = 15 €.

**Étapes indiquées :** (1) formulez $H_0$ et $H_1$ ; (2) calculez l'écart des moyennes ; (3) calculez l'erreur-type $\sqrt{s_A^2/n_A + s_B^2/n_B}$ ; (4) calculez t ; (5) sachant que la valeur p associée vaut ≈ 0,07, concluez au seuil de 5 % en deux phrases — décision et limite.

**Exercice 2 — un $\chi^2$ pas à pas**

On croise le mode de réception (livraison / retrait) et la satisfaction (satisfait / non satisfait) pour 200 commandes : livraison : 70 satisfaits, 30 non satisfaits ; retrait : 50 satisfaits, 50 non satisfaits.

**Étapes indiquées :** (1) formulez $H_0$ ; (2) calculez les quatre effectifs théoriques sous indépendance ; (3) calculez la contribution de chaque case puis $\chi^2$ ; (4) sachant que p ≈ 0,004, concluez ; (5) pourquoi ne peut-on pas dire que la livraison *cause* la satisfaction ?

### 6.3 Application autonome

**Exercice 3 — la décision complète.** Une enseigne teste une nouvelle offre, attribuée **au hasard** : écart de dépense estimé = +4 €/client, IC à 95 % = [−1 ; +9] €, p = 0,12, seuil prévu = 5 %. Marge : 25 % ; coût de l'offre : 2 € par client qui la reçoit.

(1) Formulez $H_0$ et interprétez p sous les hypothèses du test. (2) Concluez au seuil de 5 % — peut-on affirmer l'égalité ? (3) Calculez le gain net estimé par client à l'estimation centrale. (4) Expliquez en deux phrases pourquoi la décision reste incertaine, et proposez la suite.

**Exercice 4 (entrelacé — cours 1 à 4).** Vous recevez les temps de réponse (en secondes) de deux centres d'appels, X et Y, pour comparer leurs performances. En explorant le fichier, vous constatez : les deux distributions ont une longue queue à droite (forme typique des durées) ; quelques valeurs dépassent le seuil des 1,5 × IQR ; la colonne « temps » contient 3 % de mentions « N/A » ; chaque groupe compte 45 appels, passés par des clients différents.

(1) Que faites-vous des « N/A » avant tout calcul, et pourquoi (cours 3) ? (2) Quels indicateurs citez-vous en priorité pour décrire ces distributions, et pourquoi (cours 1 et 2) ? (3) Quel test choisissez-vous pour comparer X et Y ? Justifiez contre l'alternative (cours 4). (4) Quelle figure présentez-vous à la direction pour étayer la comparaison (cours 2 et 4) ? (5) Rédigez la synthèse en cinq lignes maximum pour la direction.

## 7. Fiche récapitulative

### Les définitions en une phrase

| Notion | Définition éclair |
|---|---|
| $H_0$ / $H_1$ | Scénario de référence (« rien ») / scénario concurrent ; portent sur les populations, formulées avant le calcul. |
| Valeur p | Sous $H_0$, probabilité d'un résultat au moins aussi extrême que l'observé. |
| Seuil α | Risque de fausse alerte accepté, fixé à l'avance (souvent 5 %) ; $p < \alpha \rightarrow$ rejeter $H_0$. |
| Erreur I / II | Rejeter $H_0$ à tort (α) / manquer un effet réel (β). |
| Puissance | $1 - \beta$ : probabilité de détecter un effet réel ; monte avec l'effectif. |
| IC 95 % | Valeurs plausibles du paramètre ; la procédure réussit 95 % du temps sur tirages répétés. |
| Taille d'effet | Ampleur standardisée (d de Cohen : 0,2 faible, 0,5 moyen, 0,8 fort). |

### Les formules clés

$$t = \frac{\bar{x}_B - \bar{x}_A}{\sqrt{s_A^2/n_A + s_B^2/n_B}} \qquad \chi^2 = \sum \frac{(O-E)^2}{E} \qquad W_2 = \sqrt{(\mu_1-\mu_2)^2 + (\sigma_1-\sigma_2)^2} \qquad 1-(1-\alpha)^m$$

### Choisir l'outil

| Question | Outil | Fonction Python |
|---|---|---|
| 2 moyennes, groupes indépendants | Welch | `stats.ttest_ind(b, a, equal_var=False)` |
| 3 moyennes ou plus | ANOVA | `stats.f_oneway(g1, g2, g3)` |
| 2 variables qualitatives | $\chi^2$ d'indépendance | `stats.chi2_contingency(tableau)` |
| 2 groupes, non gaussien / petit n | Mann-Whitney | `stats.mannwhitneyu(a, b)` |
| 2 variances | Levene | `stats.levene(a, b)` |
| 2 distributions entières | Kolmogorov-Smirnov | `stats.ks_2samp(a, b)` |
| Écart global (sans verdict) | $W_2$, recouvrement, KL | — (une distance n'est pas un test) |

**La phrase garde-fou :** « Sous $H_0$, un résultat au moins aussi extrême avait une probabilité p ; l'écart estimé vaut … [IC] ; au regard du coût/seuil métier, … ; limites : … ».

# 8. Pour aller plus loin (optionnel)

- **Le test de Student** : l'ancêtre du test de Welch, qui suppose l'égalité des variances ; comprendre pourquoi la pratique moderne lui préfère Welch par défaut.
- **Benjamini-Hochberg (FDR)** : une correction des comparaisons multiples qui contrôle la proportion de fausses découvertes plutôt que toute fausse alerte — plus puissante que Bonferroni.
- **Tests de permutation et bootstrap** : construire la distribution sous $H_0$ par rééchantillonnage des données elles-mêmes, sans formule — la généralisation calculatoire de la section 4.3.
- **Tests unilatéraux** : quand la direction de l'effet est fixée à l'avance, et pourquoi ils doivent rester exceptionnels et annoncés.
- **Vers la causalité** : un test dit *que* deux groupes diffèrent, jamais *pourquoi* ; randomisation, groupe témoin et variables de confusion seront au cœur du prochain cours.

# 9. Corrigé des exercices

### 9.1 Auto-évaluation

**Q1 — Faux.** La valeur p est calculée *en supposant* $H_0$ vraie : c'est la probabilité, sous $H_0$, d'un résultat au moins aussi extrême que celui observé — pas la probabilité de $H_0$ elle-même (piège 1).

**Q2 — Réponse b.** Les réponses a et c attribuent à p une probabilité qu'elle ne mesure pas ; la réponse d décrit la statistique t, pas la valeur p.

**Q3.** $H_0$ : $\mu_{\text{ancienne}} = \mu_{\text{nouvelle}}$ ; $H_1$ : $\mu_{\text{ancienne}} \neq \mu_{\text{nouvelle}}$ ; test bilatéral (aucune direction imposée à l'avance). Condition à vérifier : l'indépendance des observations (visiteurs distincts, pas de mesures répétées d'une même session), et la pertinence de la moyenne pour une variable de durée, souvent asymétrique — sinon, Mann-Whitney.

**Q4.** p = 0,08 > 0,05 : on ne rejette pas $H_0$ — les données ne permettent pas de conclure à une différence au seuil de 5 %. Il est interdit de conclure que les moyennes sont égales : le test peut manquer de puissance ; il faut examiner l'estimation et l'intervalle (piège 2).

**Q5.** L'intervalle contient 0 : le test bilatéral à 5 % n'est pas significatif. L'égalité n'est pas prouvée pour autant : des écarts de $-2{,}1$ à $+0{,}4$ € restent tous compatibles avec les données.

**Q6.** $1-(1-0{,}05)^{10} = 1-0{,}95^{10} \approx 0{,}40$, soit environ **40 %** de chances d'au moins une fausse alerte.

**Q7.** (a) ANOVA ; (b) $\chi^2$ d'indépendance ; (c) Mann-Whitney ; (d) Welch.

## 9.2 Application guidée

**Exercice 1 — test de Welch à la main.** (1) $H_0$ : $\mu_A = \mu_B$ ; $H_1$ : $\mu_A \neq \mu_B$. (2) Écart = 51,50 − 48,20 = 3,30 €. (3) Erreur-type = √(144/100 + 225/120) = √(1,44 + 1,875) = √3,315 ≈ 1,82 €. (4) t = 3,30 / 1,82 ≈ 1,81 — l'écart vaut moins de 2 erreurs-types. (5) p ≈ 0,07 > 0,05 : on ne rejette pas $H_0$ ; l'écart de 3,30 € reste compatible avec le hasard au seuil de 5 %, sans que l'égalité soit prouvée — un effectif plus important serait nécessaire pour trancher.

**Exercice 2 — $\chi^2$.** (1) $H_0$ : le mode de réception et la satisfaction sont indépendants. (2) Totaux : 120 satisfaits, 80 non satisfaits, 100 par mode ; effectifs théoriques : 100 × 120 / 200 = 60 et 100 × 80 / 200 = 40 pour chaque mode. (3) Contributions : $(70-60)^2/60 \approx 1{,}67$ ; $(30-40)^2/40 = 2{,}50$ ; idem par symétrie pour le retrait ; $\chi^2$ = 1,67 + 2,50 + 1,67 + 2,50 = 8,33. (4) p ≈ 0,004 < 0,05 : on rejette l'indépendance ; la satisfaction observée est plus élevée en livraison (70 %) qu'en retrait (50 %). (5) Les clients *choisissent* leur mode de réception : une troisième variable (urgence, profil, zone) peut expliquer à la fois le choix et la satisfaction — association n'est pas causalité.

## 9.3 Application autonome

**Exercice 3 — la décision complète.** (1) $H_0$ : l'offre ne change pas la dépense moyenne ($\mu_{\text{avec}} = \mu_{\text{sans}}$) ; p = 0,12 : sous $H_0$, un écart au moins aussi extrême que +4 € avait 12 % de chances de survenir. (2) 0,12 > 0,05 : on ne rejette pas $H_0$ ; on ne peut pas affirmer l'égalité — l'intervalle [−1 ; +9] € contient des effets substantiels. (3) Gain net estimé = 25 % × 4 € − 2 € = 1 − 2 = **−1 € par client** : à l'estimation centrale, l'offre n'est pas rentable. (4) Incertitude double : l'effet réel peut valoir de −1 à +9 € (le meilleur cas, +9 €, donnerait un solde de +0,25 €) ; et l'estimation centrale est déjà défavorable. Suite proposée : ne pas déployer en l'état ; si l'enjeu le justifie, recueillir davantage de données pour resserrer l'intervalle autour d'un effet qui devrait dépasser +8 € pour être rentable (seuil : 2 / 0,25).

**Exercice 4 (entrelacé).** (1) Les « N/A » sont des pseudo-manquants : ils se traitent comme des valeurs manquantes (conversion stricte en nombre, l'illisible devient manquant) et se comptent ; 3 % est faible, mais on vérifie qu'ils ne se concentrent pas dans un centre — sinon, biais d'exclusion. (2) Distributions asymétriques (longue queue droite, typique des durées — lognormale) : médiane et écart interquartile en priorité, moyenne et écart-type en complément, avec une figure (cours 1 et 2). (3) **Mann-Whitney** : effectifs modestes (45) et forte asymétrie rendent la moyenne peu fiable ; Welch resterait défendable en complément sur des effectifs plus grands, mais le test des rangs est ici le choix robuste — et il porte sur les distributions, ce qui convient à la question de performance globale. (4) Les deux ECDF superposées (ou deux boîtes à moustaches) : elles montrent centre, dispersion et queue sans choix de classes. (5) Synthèse type : « Après traitement des 3 % de valeurs manquantes (réparties entre les centres), les temps de réponse de X et Y (45 appels chacun) ont été comparés par un test de Mann-Whitney, adapté à la forte asymétrie des durées : médianes de … et …, p = …. [Conclusion au seuil de 5 %.] Les durées restent dispersées dans les deux centres ; la comparaison ne porte que sur la période étudiée et n'établit pas les causes de l'écart. »