Bloc II — Raisonnement statistique

Cours 5
Association, régression linéaire et causalité

À l'issue de ce cours, vous saurez mesurer le lien entre deux variables quantitatives, ajuster et interpréter une droite de régression, et distinguer une association d'une relation de cause à effet.

Formation Data Analyst — Novembre 2026

Sommaire

1. Objectifs d'apprentissage

2. Prérequis et rappels

3. Pourquoi c'est important

4. Corps du cours

PARTIE A — MESURER L'ASSOCIATION ENTRE DEUX VARIABLES

4.1 Le nuage de points : voir la relation avant de la mesurer
4.2 La covariance : la co-variation point par point
4.3 La corrélation de Pearson : la covariance standardisée
4.4 Le test de corrélation : de l'échantillon à la population

PARTIE B — LES LIMITES DE LA CORRÉLATION

4.5 Limite 1 : Pearson ne voit que les relations linéaires
4.6 La corrélation de Spearman : raisonner sur les rangs
4.7 Limite 2 : l'influence des points atypiques
4.8 Limite 3 : le résultat dépend du périmètre d'analyse

PARTIE C — LA RÉGRESSION LINÉAIRE SIMPLE

4.9 Résumer un nuage par une droite : les moindres carrés
4.10 Pente et ordonnée à l'origine : calcul et lecture
4.11 Le résidu : ce que la droite n'explique pas
4.12 Le coefficient de détermination R^2
4.13 Comprendre ou prédire : deux ambitions différentes

PARTIE D — DE L'ASSOCIATION À LA CAUSALITÉ

4.14 Variables de confusion et paradoxe de Simpson
4.15 Tester une cause : observation, intervention, plan croisé

5. Erreurs fréquentes et pièges

6. Exercices

6.1 Auto-évaluation
6.2 Application guidée
6.3 Application autonome

7. Fiche récapitulative

8. Pour aller plus loin

9. Corrigé des exercices

1. Objectifs d'apprentissage

À l'issue de ce cours, vous saurez :

- **interpréter** une covariance et une corrélation de Pearson sans dépasser ce qu'elles mesurent (signe, force, unité, périmètre) ;
- **tester** une corrélation (hypothèse nulle $\rho = 0$) après avoir vérifié ses conditions d'application, et **choisir** entre Pearson et Spearman ;
- **ajuster et interpréter** une régression linéaire simple : pente, ordonnée à l'origine, résidus et coefficient de détermination R^2 ;
- **distinguer** association et causalité, **repérer** une variable de confusion ou un paradoxe de Simpson, et **proposer** une comparaison mieux conçue (randomisation, groupe témoin).

2. Prérequis et rappels

Prérequis : cours 1 (décrire un jeu de données, premières approches de la covariance et de la corrélation) et cours 4 (logique du test statistique). Les cours 2 et 3 interviennent en appui : la variation d'échantillonnage et la conduite à tenir face aux valeurs aberrantes.

Rappels des notions mobilisées ici :

- Chaque ligne d'un tableau est une **observation**, chaque colonne une **variable** ; l'**unité d'observation** (le client, la visite, la transaction…) fixe le sens de tous les calculs.
- La **moyenne** $\bar{x}$ et l'**écart-type** s décrivent le centre et la dispersion d'un échantillon (diviseur $n - 1$) ; la **variance** est le carré de l'écart-type.
- La **corrélation de Pearson** r, vue au cours 1, résume la force et le sens d'une relation *linéaire* : ce cours la reprend en profondeur.
- Deux échantillons d'une même population diffèrent par pur hasard : c'est la **variation d'échantillonnage** (cours 2). Toute statistique observée — y compris une corrélation ou une pente — fluctue d'un tirage à l'autre.
- Un **test statistique** (cours 4) compare un résultat observé à ce que produirait le hasard sous l'hypothèse nulle H_0 ; la **valeur p** se lit toujours « sous H_0… » et se compare à un seuil α annoncé à l'avance.
- Une valeur aberrante est une **alerte qui déclenche une enquête, jamais une suppression automatique** (cours 3).

3. Pourquoi c'est important

Vous êtes analyste pour une enseigne de vente au détail. La direction marketing vous demande : « Les clients plus âgés dépensent-ils davantage ? Et cette nouvelle promotion, est-ce qu'elle fait vraiment vendre plus ? ». Ces deux questions ont l'air jumelles. Elles sont pourtant de nature très différente, et les confondre coûte cher.

La première porte sur une **association** : quand l'âge augmente, le montant d'achat tend-il à augmenter ? Vous disposez des outils pour la mesurer — la covariance, la corrélation, la régression — à condition de connaître leurs limites : une relation en courbe peut passer inaperçue, un client exceptionnel peut gonfler le coefficient, et le résultat change selon que vous analysez tous les magasins ensemble ou séparément.

La seconde porte sur une **cause** : est-ce *parce que* la promotion existe que les clients dépensent plus — ou les gros acheteurs choisissent-ils simplement plus souvent la promotion ? Aucun coefficient de corrélation, aussi fort soit-il, ne tranchera cette question. Seule la façon dont les données ont été produites — observer ou intervenir — le permet.

Dans tout ce cours, nous suivrons un fil rouge : les 2 000 transactions de deux magasins A et B, avec l'âge du client, le montant de l'achat, la distance domicile–magasin et le temps d'attente en caisse. Tous les calculs sont réels : vous pourrez refaire chaque opération vous-même.

4. Corps du cours

PARTIE A — MESURER L'ASSOCIATION ENTRE DEUX VARIABLES

4.1 Le nuage de points : voir la relation avant de la mesurer

Avant tout calcul, il faut voir les données. Quand deux variables quantitatives sont mesurées sur les mêmes observations — l'âge et le montant d'achat d'une même transaction, par exemple — chaque observation devient un point dans un repère : la première variable en abscisse (horizontale), la seconde en ordonnée (verticale).

La lecture d'un nuage repose sur trois questions, toujours les mêmes. La **direction** : le nuage monte-t-il (relation croissante), descend-il (décroissante), ou ne s'incline-t-il ni dans un sens ni dans l'autre ? La **force** : les points sont-ils resserrés autour d'une tendance nette, ou très dispersés ? La **forme** : la tendance est-elle une ligne droite, une courbe, ou le nuage se scinde-t-il en plusieurs groupements ?

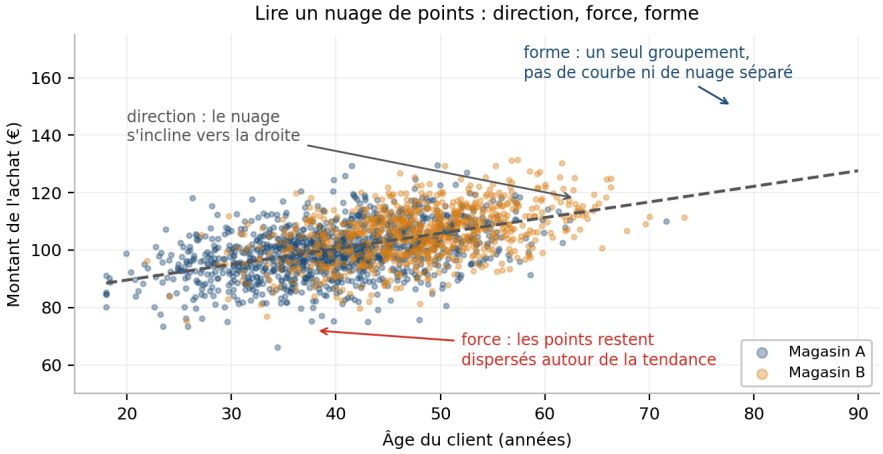


Figure 1 : le nuage âge–montant des 2 000 transactions du fil rouge, lu avec les trois questions : direction (le nuage s'incline vers la droite), force (les points restent dispersés), forme (un seul groupement, pas de courbe).

Définition — le nuage de points

Le **nuage de points** (*scatter plot*) est la représentation de deux variables quantitatives mesurées sur les mêmes observations : chaque observation est un point dont l'abscisse est sa valeur sur la première variable et l'ordonnée sa valeur sur la seconde. C'est l'outil de base de toute analyse d'association — et le premier réflexe, avant tout coefficient.

Analogie

Observer un nuage de points, c'est comme regarder une carte aérienne avant de calculer un itinéraire : on y voit d'un coup la direction générale, les zones denses et les points isolés. Le coefficient de corrélation, lui, ne donnera qu'un nombre ; la carte montre *pourquoi* ce nombre vaut ce qu'il vaut.

Exemple guidé — lire le nuage âge–montant (figure 1)

Étape 1 — Nommer les points. Chaque point est une transaction : son âge en abscisse, son montant en ordonnée. L'unité d'observation est la transaction ; deux points peuvent venir du même client — on y reviendra.

Étape 2 — Direction. Le nuage s'incline vers la droite : les âges élevés vont en moyenne avec des montants plus élevés. Relation *croissante*.

Étape 3 — Force. Les points forment un large ruban autour de la tendance : à âge donné, les montants varient beaucoup. Relation *réelle mais imparfaite*.

Étape 4 — Forme. Un seul groupement oblique, pas de courbe en U ni de deuxième nuage isolé. La tendance est compatible avec une droite — la mesure qui suit (Pearson) est donc pertinente ici.

Étape 5 — Ce que le nuage ne dit pas. Il ne dit ni pourquoi (un mécanisme), ni ce qui se passerait hors de la plage observée (au-delà de 75 ans, aucune donnée).

En pratique dans le code

```
plt.scatter(df["age"], df["montant"], s=8, alpha=0.4)
plt.xlabel("Âge du client (années)") ; plt.ylabel("Montant de l'achat (€)")
```

À retenir

- Un point = une observation ; vérifiez toujours quelle est l'unité d'observation avant de lire le nuage.
- Lecture en trois questions : **direction**, **force**, **forme**.
- Le nuage vient **avant** le calcul : aucun coefficient ne se lit correctement sans lui.

4.2 La covariance : la co-variation point par point

Pour mesurer ce que le nuage montre, commençons par une idée simple. Prenez chaque point et comparez ses deux valeurs à leurs moyennes respectives : l'âge à l'âge moyen, le montant au montant moyen. Si un point est au-dessus de la moyenne sur les deux variables — ou en dessous sur les deux —, ses deux écarts ont le *même signe* et leur produit est positif : ce point **contribue positivement** à l'association. Si les écarts sont de signes opposés, le produit est négatif : le point tire dans l'autre sens.

La covariance additionne ces contributions point par point, puis les rapporte au nombre d'observations (avec le diviseur $n - 1$ de l'échantillon, déjà rencontré au cours 1 pour la variance). La figure 2 montre cette mécanique sur cinq points : le point des moyennes $(\bar{x}, \bar{y})$ partage le plan en quatre quadrants, et chaque point contribue selon le quadrant où il tombe.

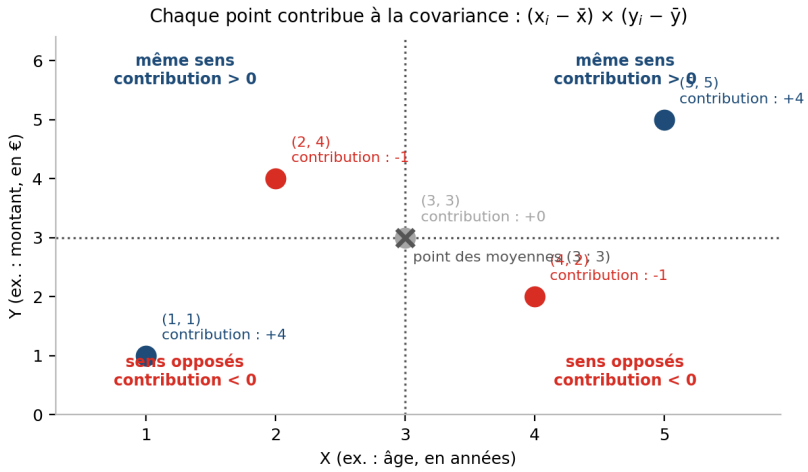


Figure 2 : cinq observations et leurs contributions au numérateur de la covariance. Les points situés au-dessus (ou en dessous) de la moyenne sur les deux variables à la fois contribuent positivement ; les autres, négativement.

> **Définition — la covariance**
>
> La **covariance** (*covariance*) entre deux variables quantitatives X et Y est la moyenne (au diviseur $n - 1$ près) des produits des écarts à leurs moyennes. Son **signe** s'interprète — positive : les variables s'écartent de leur moyenne plutôt dans le même sens ; négative : en sens opposés — mais pas sa **grandeur**, qui dépend des unités.

$$\operatorname{Cov}(X, Y) = \frac{1}{n-1} \sum_{i=1}^{n} (x_i - \bar{x})\,(y_i - \bar{y})$$

x_i, y_i : valeurs des variables X et Y pour l'observation i

$\bar{x}, \bar{y}$: moyennes des n valeurs observées de X et de Y

n : nombre d'observations

$n - 1$: diviseur de l'échantillon (correction de Bessel, cours 1)

Comment lire cette formule. Pour chaque observation, on calcule l'écart à la moyenne sur X, l'écart à la moyenne sur Y, et on multiplie les deux : c'est la contribution signée du point. On additionne ces contributions puis on divise par $n - 1$. Si les points « concordants » (même signe des deux écarts) l'emportent, la somme est positive et la covariance aussi. Les contributions positives et négatives se compensent partiellement : la covariance est le solde de ce bras de fer.

> **Analogie**
>
> Imaginez deux amis qui notent chaque jour leur humeur de 0 à 10. Si, les jours où l'un est au-dessus de sa moyenne, l'autre l'est aussi (et pareil en dessous), leurs humeurs « co-varient » positivement. La covariance fait exactement ce compte-là, jour par jour, puis en tire le solde.

Exemple guidé — cinq semaines, deux variables

Situation. Cinq semaines d'activité : X = budget publicitaire (centaines €), Y = nombre de commandes (dizaines). Les cinq couples : (1 ; 1), (2 ; 4), (3 ; 3), (4 ; 2), (5 ; 5).

Étape 1 — Les moyennes. $\bar{x} = (1+2+3+4+5)/5 = 3$; $\bar{y} = (1+4+3+2+5)/5 = 3$.

Étape 2 — Les contributions. Semaine 1 : $(1-3)(1-3) = (+4)$; semaine 2 : $(2-3)(4-3) = (-1)$; semaine 3 : $(3-3)(3-3) = 0$; semaine 4 : $(4-3)(2-3) = (-1)$; semaine 5 : $(5-3)(5-3) = (+4)$. On fait ce produit parce qu'il capture le sens de l'écart conjoint — c'est le cœur de la définition.

Étape 3 — Additionner et diviser. Somme des contributions : $4-1+0-1+4 = 6$. Covariance : $6/(5-1) = 1{,}5$.

Étape 4 — Interpréter. Le signe est positif : budget et commandes varient plutôt dans le même sens. La valeur 1,5, elle, s'exprime en « centaines d'euros × dizaines de commandes » : impossible de la comparer à une covariance calculée sur d'autres unités. **Seul le signe est universellement lisible.**

Étape 5 — La matrice de covariance. Avec plusieurs variables, on range tout dans un tableau carré : la diagonale contient les variances (une variable avec elle-même), les cases hors diagonale les covariances deux à deux.

	X (budget)	**Y (commandes)**
X (budget)	Var(X) = 2,5	Cov(X, Y) = 1,5
Y (commandes)	Cov(X, Y) = 1,5	Var(Y) = 2,5

Tableau 1 : la matrice de covariance des cinq semaines — symétrique, variances sur la diagonale, covariances hors diagonale.

En pratique dans le code

```
df.cov(numeric_only=True)          # matrice de covariance (diviseur n - 1)
np.cov(data, rowvar=False, ddof=1) # équivalent numpy : colonnes = variables
```

À retenir

- La covariance est une **moyenne de produits d'écarts signés** : chaque observation y contribue.
- Elle **conserve les unités** (années × euros ici) : son signe s'interprète, sa grandeur ne se compare pas entre jeux de variables différents.
- La matrice de covariance range les variances sur la diagonale et les covariances hors diagonale ; elle est symétrique.

4.3 La corrélation de Pearson : la covariance standardisée

La covariance a un défaut rédhibitoire : sa grandeur dépend des unités. Exprimez les montants en centimes plutôt qu'en euros, et elle est multipliée par 100 — sans que le lien entre les variables ait changé le moins du monde. Impossible, dans ces conditions, de dire si une covariance est « forte » ou « faible », ni de comparer deux covariances calculées sur des variables différentes.

La solution consiste à **standardiser** : on divise la covariance par le produit des deux écarts-types. Les unités s'éliminent (des années × euros divisés par des années × euros), et le résultat se retrouve coincé entre -1 et $+1$. C'est le coefficient de corrélation de Pearson, déjà croisé au cours 1 : nous allons maintenant apprendre à le lire sans jamais lui faire dire plus qu'il ne sait.

Définition — la corrélation de Pearson

Le **coefficient de corrélation de Pearson** (*Pearson correlation coefficient*), noté r dans l'échantillon, est la covariance de deux variables quantitatives divisée par le produit de leurs écarts-types. Sans unité, il est toujours compris entre -1 et $+1$. Il mesure la **force et le sens de la tendance linéaire** entre les deux variables — rien d'autre.

$$r = \frac{\mathrm{Cov}(X, Y)}{s_X \times s_Y}$$

r : coefficient de corrélation de Pearson, sans unité, entre -1 et $+1$
$\mathrm{Cov}(X, Y)$: covariance des variables X et Y
s_X, s_Y : écarts-types de X et Y, dans leurs unités respectives

La mécanique est celle d'une mise à l'échelle : la covariance porte le *sens* de la relation (positive ou négative), mais sa grandeur est polluée par les unités et la dispersion des variables. En divisant par les deux écarts-types, on ramène ce numérateur à une échelle universelle : r ne peut plus dépasser 1 en valeur absolue, atteint exactement +1 ou −1 quand les points sont parfaitement alignés, et vaut 0 quand il n'y a aucune tendance linéaire.

La figure 3 donne les points de repère visuels. Retenez l'essentiel : le **signe** indique la direction (croissante si $r > 0$, décroissante si $r < 0$), et la **distance à 0** indique la force de la tendance linéaire. Un r de 0,8 ne décrit pas une relation « deux fois plus forte » qu'un r de 0,4 : l'échelle n'est pas proportionnelle, elle est seulement ordonnée.

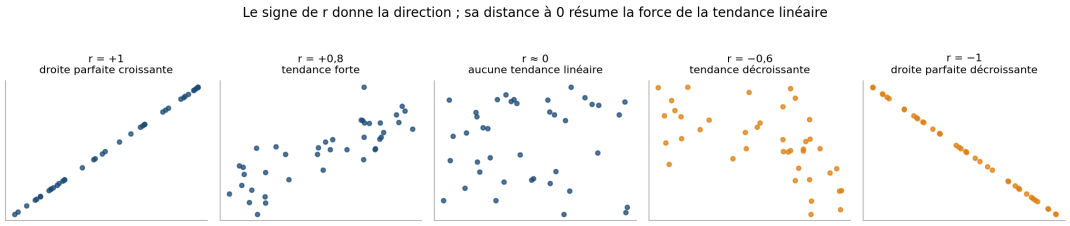


Figure 3 : galerie de nuages et de leurs coefficients. Entre les deux extrêmes (droites parfaites, $r = \pm 1$), toutes les situations intermédiaires existent — et un même r peut correspondre à des nuages d'aspect différent.

Analogie

La covariance ressemble à une distance exprimée « en pas » : elle dépend de la longueur des jambes de chacun. Le coefficient de corrélation, lui, exprime la distance « en fraction du chemin total possible » : tout le monde peut se comparer, quelle que soit sa pointure.

Exemple guidé — calculer puis lire un coefficient

Étape 1 — Reprendre les cinq semaines. Nous avons calculé à la section 4.2 : $\mathrm{Cov}(X, Y) = 1{,}5$, et les variances valent $s_X^2 = s_Y^2 = 2{,}5$, donc $s_X = s_Y \approx 1{,}58$.

Étape 2 — Standardiser. $r = 1{,}5/(1{,}58 \times 1{,}58) = 1{,}5/2{,}5 = 0{,}6$. On divise par les écarts-types parce que c'est eux qui portaient l'échelle : une fois divisés, il ne reste que la tendance.

Étape 3 — Lire en trois questions. *Sens* : $r > 0$, la relation est croissante. *Force* : 0,6 est une tendance modérée — visible, mais loin d'un alignement parfait (coherent avec le nuage très dispersé de la figure 2). *Périmètre* : ce 0,6 décrit ces cinq semaines, rien d'autre.

Étape 4 — Appliquer au fil rouge. Sur les 2 000 transactions, $r = 0{,}51$ entre âge et montant. Lecture : croissante (+), modérée (les points restent très dispersés, voir figure 1), valable pour *ces transactions, tous magasins confondus*. Ni « les clients âgés dépensent 51 % de plus », ni « l'âge explique la moitié du montant » : ces deux phrases sont des lectures fausses — nous verrons pourquoi aux sections 4.12 et 4.14.

Étape 5 — Vérifier l'invariance aux unités. Exprimez les montants en centimes : la covariance passe de 43,10 à 4 310, mais l'écart-type du montant est aussi multiplié par 100, et r reste **exactement 0,51**. C'est la garantie que r mesure le lien, pas l'unité.

En pratique dans le code

```
df["age"].corr(df["montant"])     # r entre deux colonnes (Pearson par défaut)
df.corr(numeric_only=True)        # matrice de corrélation : toutes les paires
np.corrcoef(df["age"], df["montant"])  # équivalent numpy (matrice 2 × 2)
```

La **matrice de corrélation** reprend la logique de la matrice de covariance (section 4.2), en standardisé : des 1 sur la diagonale (chaque variable est parfaitement corrélée à elle-même), et les r deux à deux hors diagonale, symétriquement. Elle offre une vue d'ensemble des liaisons linéaires d'un tableau — à relire toujours avec les nuages correspondants.

À retenir

- r est une covariance **standardisée** : sans unité, bornée entre −1 et +1, invariante si l'on change d'unité.
- Lecture en trois questions : **sens** (signe), **force** (distance à 0), **périmètre** (sur quelles données, quelle unité d'observation ?).
- r ne mesure que la tendance **linéaire** — les sections 4.5 à 4.8 montrent tout ce qu'il ne voit pas.

4.4 Le test de corrélation : de l'échantillon à la population

Vous observez $r = 0{,}51$ sur vos 2 000 transactions. Question légitime : ce lien existe-t-il dans la **population** — tous les clients potentiels de l'enseigne — ou est-ce un simple coup de hasard d'échantillonnage ? Après tout, deux variables sans aucun lien produisent presque toujours un r légèrement différent de 0 sur un échantillon fini. La variation d'échantillonnage (cours 2) frappe aussi les corrélations.

On distingue donc deux objets : r, le coefficient calculé sur votre échantillon, et ρ (lettre grecque « rhô »), le coefficient inconnu de la population. Le test de corrélation suit la logique du cours 4 : il compare le r observé à ce que le hasard produirait si ρ valait 0.

> **Définition — le test de corrélation**
>
> Le **test de corrélation** (*correlation test*) évalue l'hypothèse nulle $H_0 : \rho = 0$ (aucune liaison linéaire dans la population) contre $H_1 : \rho \neq 0$. La statistique du test convertit r en une valeur t qui, sous H_0, suit une loi de Student à $n - 2$ degrés de liberté. La **valeur p** est la probabilité, sous H_0, d'obtenir un $|r|$ au moins aussi grand que celui observé.

$$t = r\sqrt{\frac{n-2}{1-r^2}}$$

t : statistique du test, sans unité ; sous H_0, loi de Student à $n - 2$ degrés de liberté
r : coefficient de corrélation observé dans l'échantillon
n : nombre d'observations (paires de valeurs)

La formule combine deux ingrédients : la **force du signal** (r, au numérateur) et la **quantité de données** ($n - 2$, sous la racine). À r égal, plus l'échantillon est grand, plus t est grand — c'est-à-dire plus le résultat est difficile à expliquer par le hasard. C'est la même mécanique « signal ÷ bruit » que le test de Welch du cours 4, appliquée à une corrélation.

La figure 4 rend l'idée concrète. On simule 5 000 échantillons de 30 paires de variables *sans aucun lien* (population avec $\rho = 0$), et l'on calcule r à chaque fois. Résultat : r fluctue autour de 0, parfois jusqu'à ±0,4 par pur hasard. Un r observé de +0,38 tombe dans les 3,9 % les plus extrêmes de cette distribution (1,9 % de chaque côté) : c'est la valeur p.

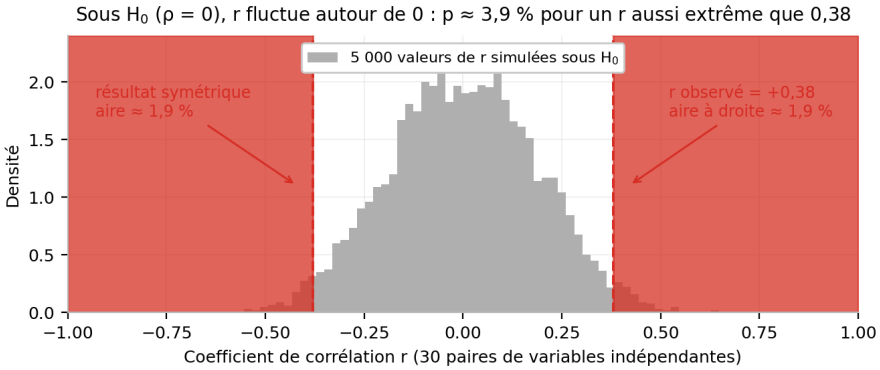


Figure 4 : distribution de r sous H_0 pour des échantillons de 30 paires, obtenue par simulation. Les zones rouges matérialisent la valeur p : la probabilité, sous H_0, d'un résultat au moins aussi extrême que $r = +0{,}38$.

> **Conditions d'application — à vérifier AVANT de tester**
>
> Un test de corrélation n'a de sens que si toutes ces conditions tiennent :
>
> - **Relation linéaire** : le nuage est compatible avec une droite (sinon, voir sections 4.5 et 4.6 ; tester $\rho = 0$ sur une courbe en U ne répond à aucune question utile).
> - **Observations indépendantes** : chaque paire apporte une information nouvelle. Attention au fil rouge : un même client peut apparaître dans plusieurs transactions — ces points ne sont pas indépendants. L'idéal est de regrouper d'abord par client (un point = un client).
> - **Variables quantitatives** mesurées sur les mêmes observations.
> - **Pas de point dominant** : un point très éloigné peut fabriquer à lui seul la significativité (section 4.7).
> - **Périmètre nommé** : le test porte sur la population que représente votre échantillon — tous magasins confondus n'est pas chaque magasin (section 4.8).

Exemple guidé — deux tests, deux tailles d'échantillon

Cas 1 — un petit échantillon. Vous mesurez $r = +0{,}38$ entre deux indicateurs sur $n = 30$ semaines, seuil annoncé $\alpha = 5\,\%$, test bilatéral (aucune direction imposée à l'avance).

Étape 1 — Formuler les hypothèses. H_0 : $\rho = 0$ (pas de liaison linéaire) contre H_1 : $\rho \neq 0$. On les écrit avant tout calcul, comme toujours.

Étape 2 — Calculer la statistique. $t = 0{,}38 \times \sqrt{28/(1 - 0{,}38^2)} = 0{,}38 \times \sqrt{28/0{,}856} \approx 2{,}17$, avec $30 - 2 = 28$ degrés de liberté.

Étape 3 — Lire la valeur p. La probabilité, sous H_0, d'obtenir $|t| \geq 2{,}17$ vaut environ 3,9 % (c'est la lecture de la figure 4). Comme $p < \alpha$, on rejette H_0 : la liaison est *statistiquement significative* au seuil de 5 %.

Étape 4 — Mesurer ce que ça ne dit pas. « Significative » ne veut pas dire « forte » ni « utile » : $r = 0{,}38$ reste une tendance modeste. Le test écarte une explication — le pur hasard — il ne valide ni l'importance, ni une cause.

Cas 2 — le fil rouge. $r = 0{,}51$ sur $n = 2\,000$ transactions : $t \approx 26{,}7$ pour 1 998 degrés de liberté, et la valeur p est astronomiquement petite ($\approx 10^{-134}$). Avec 2 000 paires, même un $|r|$ de 0,05 serait significatif : **le grand effectif rend tout significatif, sans rien rendre important**. Votre conclusion citera donc l'estimation ($r = 0{,}51$), sa significativité, et la limite : une association modérée, sur ces transactions, qui ne dit rien d'une éventuelle causalité.

En pratique dans le code

```
stats.pearsonr(df["age"], df["montant"])
# renvoie le r observé et la valeur p (test bilatéral de H0 : rho = 0)
```

À retenir

- Le test compare r (échantillon) au scénario $\rho = 0$ (population) ; la valeur p se lit « sous H_0… ».
- La statistique t combine **force du signal** et **effectif** : à r égal, plus n est grand, plus le test est puissant.
- Conditions à vérifier avant : relation linéaire, observations indépendantes, pas de point dominant, périmètre nommé.
- Significatif $\neq$ important : concluez toujours avec l'estimation de r et son périmètre, pas avec la valeur p seule.

PARTIE B — LES LIMITES DE LA CORRÉLATION

4.5 Limite 1 : Pearson ne voit que les relations linéaires

Voici le premier piège, et il est grossier : r ne mesure que la tendance *linéaire*. Or la nature et les comportements adorent les courbes. La consommation d'une voiture est élevée à basse vitesse (trajets urbains, démarrages), minimale à vitesse stabilisée, et remonte à haute vitesse (résistance de l'air). La relation entre vitesse moyenne et consommation dessine un **U** — et une droite ne peut épouser un U.

Sur la figure 5, la relation est pourtant visible à l'œil nu : les points descendent puis remontent nettement. Mais la droite des moindres carrés est presque horizontale, et $r \approx -0{,}05$: pour Pearson, « rien ». Conclure « pas de lien entre vitesse et consommation » serait une erreur d'interprétation — le coefficient n'a pas dit qu'il n'y avait pas de relation, il a dit qu'il n'y avait pas de relation *linéaire*.

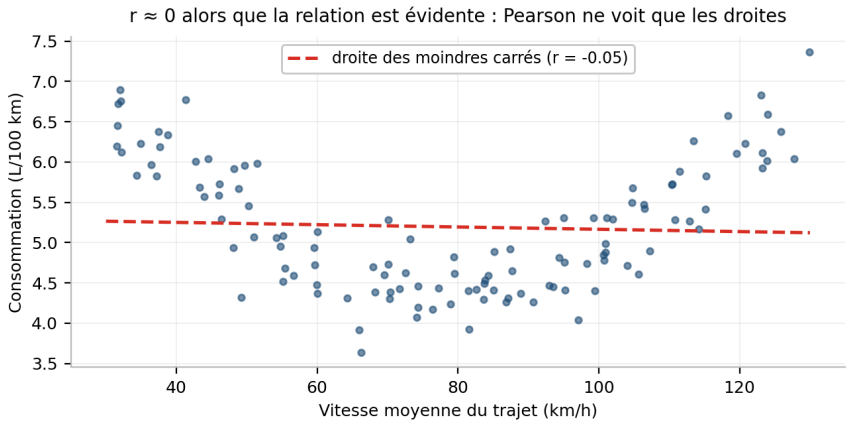


Figure 5 : consommation en fonction de la vitesse moyenne de 120 trajets. La relation en U est évidente visuellement ; le coefficient de Pearson ($\approx -0{,}05$) et la droite ajustée passent complètement à côté.

Définition — relation linéaire, relation non linéaire

Une relation est dite **linéaire** quand Y varie à taux constant quand X augmente — le nuage s'organise autour d'une droite. Elle est **non linéaire** (*nonlinear relationship*) quand le taux de variation change avec X : courbe en U, en cloche, croissance qui plafonne… Le coefficient de Pearson ne capture que la première ; **un r proche de 0 n'exclut jamais une relation non linéaire, même très forte**.

Analogie

Demander à Pearson d'évaluer une relation en U, c'est comme juger la forme d'une vallée en tendant une règle entre ses deux bords : la règle reste à peu près horizontale, et vous concluez « terrain plat » — alors que vous êtes au bord d'un creux de 20 mètres.

Exemple guidé — le bon réflexe face à un r proche de 0

Étape 1 — Ne pas conclure sur le seul coefficient. $r = -0{,}05$: la tentation est grande d'écrire « pas de lien ». C'est précisément la conclusion interdite.

Étape 2 — Regarder le nuage. La figure montre une descente nette jusqu'à environ 80 km/h, puis une remontée. La relation existe, elle est même forte — elle n'est simplement pas traduisible par une droite.

Étape 3 — Nommer la forme. « Relation en U, minimale autour de 75–85 km/h » : cette phrase apporte infiniment plus au métier que le coefficient.

Étape 4 — Adapter l'outil. Deux options : décrire la relation par morceaux (un r sous 80 km/h, un autre au-delà), ou utiliser un coefficient qui détecte les relations *monotones* — c'est l'objet de la section suivante.

À retenir

- Pearson mesure **uniquement** la tendance linéaire : $r \approx 0$ ne signifie pas « pas de relation ».
- Le nuage de points est votre garde-fou : il révèle les formes en U, en cloche ou à palier que r ignore.
- Face à une courbe : décrire la forme en français, découper par plages, ou passer à un coefficient adapté (Spearman, section 4.6).

4.6 La corrélation de Spearman : raisonner sur les rangs

Reprenons la relation en courbe de la section précédente — mais seulement dans sa moitié croissante : le salaire qui augmente avec l'ancienneté, de moins en moins vite, jusqu'à plafonner. Le lien est indéniable : plus d'ancienneté va *toujours* avec un salaire au moins aussi élevé. Mais la croissance ralentit : la courbe n'est pas une droite, et Pearson sous-estime le lien.

L'idée de Spearman est d'une élégance redoutable : **remplacer les valeurs par leurs rangs**. Le salarié le moins ancien reçoit le rang 1, le suivant le rang 2, et ainsi de suite ; pareil pour les salaires. Peu importe alors que la croissance ralentisse : si les deux classements avancent ensemble, la relation est parfaitement mesurable. On calcule ensuite un coefficient de Pearson *sur les rangs* : c'est le coefficient de Spearman.

Définition — la corrélation de Spearman

Le **coefficient de corrélation des rangs de Spearman** (*Spearman's rank correlation coefficient*), noté ρ_s ou r_s, est le coefficient de Pearson calculé sur les **rangs** des deux variables au lieu de leurs valeurs. Compris entre -1 et $+1$, il mesure la force et le sens de la relation **monotone** (*monotonic relationship*) : le fait que les deux variables progressent ensemble, que ce soit en ligne droite ou en courbe. Une relation est dite monotone croissante quand Y ne diminue jamais quand X augmente.

$$\rho_s = 1 - \frac{6 \sum_{i=1}^{n} d_i^2}{n\left(n^2 - 1\right)}$$

ρ_s : coefficient de Spearman, sans unité, entre -1 et $+1$
d_i : écart entre le rang de l'observation i sur X et son rang sur Y
n : nombre d'observations

Cette écriture, valable quand il n'y a pas d'ex æquo, montre la mécanique : si les deux classements coïncident parfaitement, tous les d_i valent 0 et $\rho_s = 1$; chaque inversion de rang augmente la somme des d_i^2 et fait reculer le coefficient. En cas d'ex æquo, on attribue à chacun le rang moyen de son groupe et l'on calcule simplement Pearson sur les rangs — c'est ce que font les logiciels.

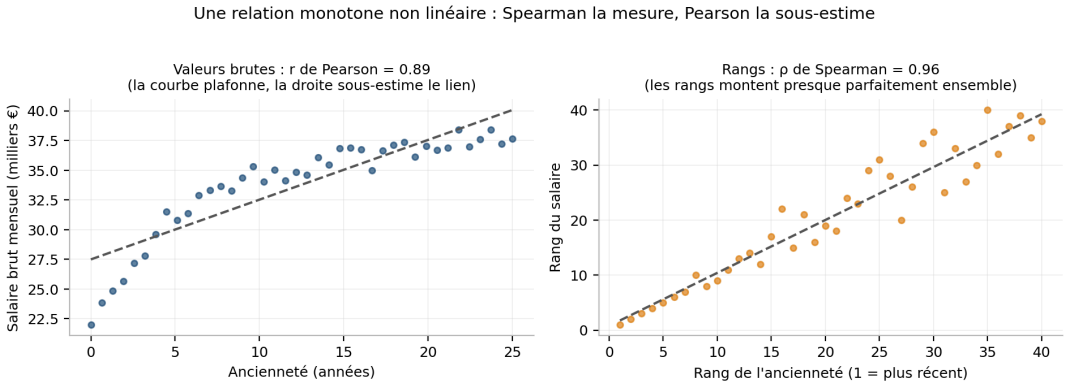


Figure 6 : ancienneté et salaire de 40 salariés. À gauche, les valeurs brutes : la courbe plafonne et Pearson lit $r = 0{,}89$. À droite, les mêmes données transformées en rangs : la progression commune est presque parfaite et Spearman lit $\rho_s = 0{,}96$.

Exemple guidé — calculer un Spearman à la main

Situation. Cinq clients d'un site marchand, classés par temps passé sur le site (X, en minutes) : 4, 8, 12, 15, 20. Leurs paniers moyens (Y, en €) : 35, 30, 50, 55, 48. La relation est-elle monotone ?

Étape 1 — Remplacer par les rangs. Sur X, le client 1 a le rang 1, le client 5 le rang 5. Sur Y, le plus petit panier (30 €) prend le rang 1, le plus grand (55 €) le rang 5.

Client	X (min)	Y (€)	Rang X	Rang Y	d_i	d_i^2
1	4	35	1	2	-1	1
2	8	30	2	1	$+1$	1
3	12	50	3	3	0	0
4	15	55	4	5	-1	1
5	20	48	5	4	$+1$	1

Tableau 2 : des valeurs aux rangs — les écarts de rang d_i alimentent la formule.

Étape 2 — Sommer les carrés. $\sum d_i^2 = 1 + 1 + 0 + 1 + 1 = 4$.

Étape 3 — Appliquer la formule. $\rho_s = 1 - (6 \times 4)/(5 \times 24) = 1 - 24/120 = 0{,}8$.

Étape 4 — Interpréter. Les deux classements avancent largement ensemble ($\rho_s = 0{,}8$) : le temps passé et le panier évoluent dans le même sens, sans exiger que la relation soit une droite. À titre de comparaison, Pearson sur les valeurs brutes donne ici $r \approx 0{,}76$: proche, car la relation est presque linéaire — l'écart entre les deux coefficients se creuse quand la courbe se prononce (figure 6).

	Pearson	Spearman
Ce qu'il mesure	Tendance **linéaire**	Tendance **monotone** (droite ou courbe)
Ce qu'il utilise	Les valeurs et leurs écarts à la moyenne	Les rangs seuls
Sensibilité aux points extrêmes	Forte (un point éloigné peut tout changer)	Faible (un point éloigné garde juste le dernier rang)
Quand le choisir	Nuage compatible avec une droite	Relation monotone courbe, valeurs extrêmes, échelle ordinale

Tableau 3 : Pearson ou Spearman ? Le nuage de points tranche — jamais l'habitude.

En pratique dans le code

```
stats.spearmanr(df["ancienneté"], df["salaire"])   # rho_s et valeur p
df.corr(method="spearman", numeric_only=True)       # matrice en rangs
```

À retenir

- Spearman = **Pearson sur les rangs** : il mesure la relation monotone, pas seulement linéaire.
- Sans ex æquo : $\rho_s = 1 - 6\sum d_i^2/(n(n^2-1))$; des classements identiques donnent $\rho_s = 1$.
- Robuste aux points extrêmes et aux échelles ordinales ; inadapté aux relations en U (non monotones).

4.7 Limite 2 : l'influence des points atypiques

Le coefficient de Pearson additionne les contributions de tous les points — et les points très éloignés du centre contribuent *démesurément*, car leurs écarts à la moyenne sont grands et se multiplient entre eux. Résultat : une seule observation isolée peut gonfler un coefficient inexistant, ou détruire un coefficient solide. La figure 7 reprend nos cinq semaines et montre les deux catastrophes possibles.

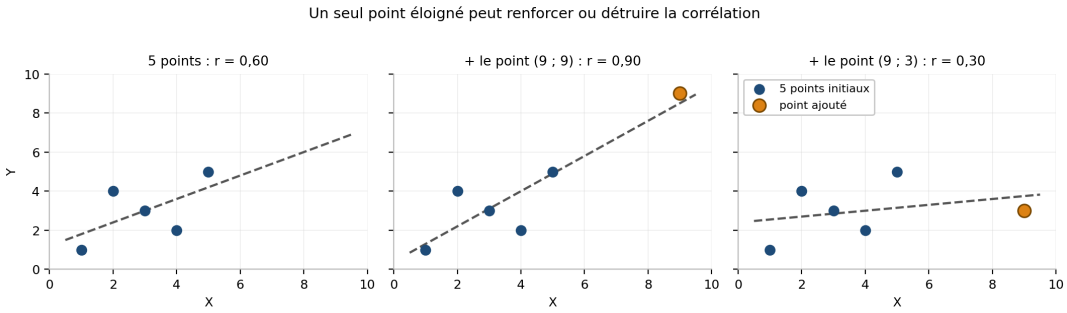


Figure 7 : les cinq semaines de référence ($r = 0{,}60$), puis le même jeu augmenté d'un seul point : (9 ; 9) propulse r à 0,90 ; (9 ; 3) l'effondre à 0,30. Un point, deux conclusions opposées.

Définition — le point influent

Un **point influent** (*influential point*) est une observation dont le retrait modifie sensiblement le résultat d'une analyse — ici, le coefficient de corrélation ou la pente de la droite. Il combine en général deux propriétés : être éloigné du centre du nuage sur X, et ne pas suivre la tendance des autres points.

Analogie

Un point influent joue le rôle d'un convive très lourd au bout d'une balançoire à bascule : à lui seul, il fait basculer la planche. Les cinq autres, près du pivot, beaux se déplacer, ne pèsent presque rien.

Exemple guidé — un point change tout, que fait-on ?

Étape 1 — Détecter. C'est le nuage qui alerte : un point isolé, loin du groupe, dans une direction qui prolonge (ou contredit) la tendance. Aucun seuil automatique ne remplace ce regard.

Étape 2 — Mesurer l'influence. Recalculer le coefficient sans le point : 0,90 redescend à 0,60 sans (9 ; 9) ; 0,30 remonte à 0,60 sans (9 ; 3). Si le résultat change du tout au tout, le point est influent.

Étape 3 — Enquêter, pas supprimer. La conduite du cours 3 s'applique : erreur de saisie ? Client exceptionnel réel (un achat en gros) ? Groupe différent (une entreprise parmi des particuliers) ? La réponse commande la décision — et toute exclusion se justifie et se consigne dans le journal des corrections.

Étape 4 — Rapporter en transparence. Si la valeur est légitime et conservée, présenter les deux résultats : « $r = 0{,}60$ sur l'ensemble ; 0,90 si l'on inclut la commande exceptionnelle du 14 mars ». Le lecteur doit savoir que la conclusion repose sur un point.

À retenir

- Un point éloigné peut **fabriquer** une corrélation (0,6 → 0,9) ou la **détruire** (0,6 → 0,3).
- Réflexe : repérer sur le nuage, mesurer l'influence (recalcul sans le point), **enquêter** sur sa cause — jamais de suppression automatique.
- Spearman (section 4.6) est naturellement protégé : le point extrême ne reçoit que le dernier rang.

4.8 Limite 3 : le résultat dépend du périmètre d'analyse

Dernière limite, la plus subtile : un coefficient calculé sur un ensemble peut n'avoir aucun équivalent dans les sous-groupes qui le composent — et réciproquement. Dans le fil rouge, la distance domicile–magasin semble liée au montant quand on regroupe les deux magasins ($r = 0{,}28$) ; magasin par magasin, le lien s'évanouit ($r \approx 0$ dans A comme dans B). La figure 8 montre la mécanique.

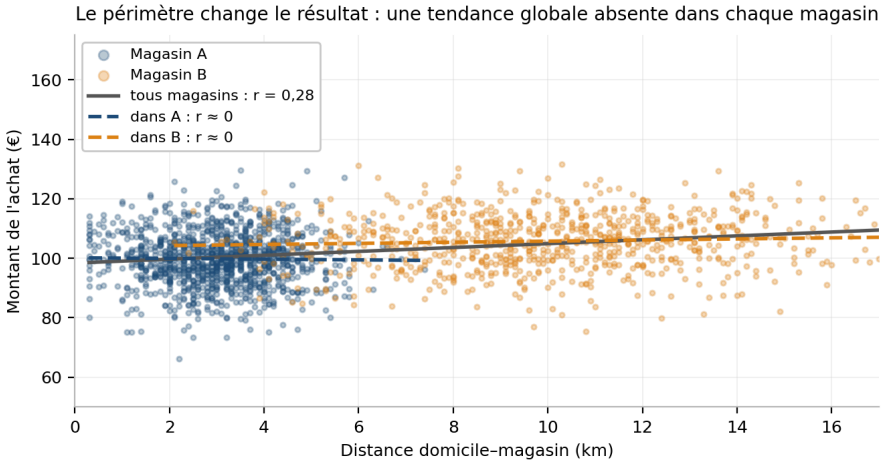


Figure 8 : distance et montant des 2 000 transactions. Les clients de B habitent plus loin et dépensent un peu plus ; réunir les deux magasins fabrique une tendance globale qu'aucun des deux ne possède.

Définition — l'effet de composition

Un **effet de composition** (*composition effect*) apparaît quand un résultat global provient non d'une relation réelle entre les variables, mais du **mélange de groupes différents** : si les groupes occupent des positions distinctes dans le nuage, leur réunion dessine une pente qui n'existe dans aucun d'eux. Le coefficient global mesure alors la composition de l'échantillon, pas une relation.

Exemple guidé — démonter l'illusion, pas à pas

Étape 1 — Constater l'écart. Global : $r = 0{,}28$. Dans A : $r \approx -0{,}02$. Dans B : $r \approx 0{,}06$. La tendance globale ne se retrouve nulle part.

Étape 2 — Identifier le mélange. B cumule deux particularités : des clients qui habitent en moyenne plus loin (10 km contre 3 km) et un panier moyen légèrement plus élevé. Placés côte à côte, le groupe A (à gauche, plus bas) et le groupe B (à droite, plus haut) dessinent mécaniquement une pente ascendante.

Étape 3 — Conclure correctement. « Habiter loin fait dépenser plus » est une lecture fausse : aucun des deux magasins ne la montre. La phrase correcte : « le magasin B attire une clientèle plus éloignée et dépensant en moyenne davantage » — une différence de *clientèle*, pas un effet de la distance.

Étape 4 — Généraliser le réflexe. Avant de commenter un coefficient, demandez-vous toujours : « mon échantillon mélange-t-il des groupes ? » et coloriez le nuage par groupe. La section 4.14 donnera un nom à la variable qui se cache derrière : la variable de confusion.

À retenir

- Un r global peut être un pur **effet de composition** : présent sur le mélange, absent de chaque groupe.
- Réflexe systématique : refaire nuage et coefficient **par sous-groupe** (magasin, segment, période) avant de conclure.
- Annoncer toujours le périmètre : « $r = 0{,}28$ sur les deux magasins réunis » est une information complète ; « $r = 0{,}28$ » seul prête à confusion.

PARTIE C — LA RÉGRESSION LINÉAIRE SIMPLE

4.9 Résumer un nuage par une droite : les moindres carrés

Le coefficient de corrélation dit *à quel point* le nuage s'organise en droite. Il ne dit pas *quelle* droite. Pourtant, dans la pratique, c'est souvent la droite elle-même qui intéresse le métier : « si un client a 50 ans, quel montant puis-je attendre en moyenne ? ». La régression linéaire simple répond à cette question : elle choisit, parmi toutes les droites possibles, celle qui résume le mieux le nuage.

« Le mieux » demande un critère. Celui qui s'est imposé consiste à regarder, pour chaque point, son **écart vertical** à la droite — la différence entre sa valeur réelle et la valeur que la droite pronostique à la même abscisse —, à élever chacun de ces écarts au carré (pour qu'ils soient tous positifs et que les grands comptent davantage), puis à tout additionner. La droite retenue est celle qui rend cette somme la plus petite possible.

Définition — la régression linéaire simple

La **régression linéaire simple** (*simple linear regression*) estime une variable quantitative Y (dite *expliquée* ou *cible*) par une fonction affine d'une variable quantitative X (dite *explicative*) : $\hat{y} = ax + b$. La méthode des **moindres carrés** (*least squares*) choisit les coefficients a et b qui minimisent la somme des carrés des écarts verticaux entre valeurs observées et valeurs prédites. Le chapeau sur $\hat{y}$ (« y chapeau ») signale une valeur *prédite par la droite*, par opposition à la valeur *observée* y.

$$\min_{a,\,b} \sum_{i=1}^{n} \left(y_i - (a\,x_i + b)\right)^2$$

x_i, y_i : valeurs observées de X et Y pour l'observation i
a : pente de la droite ; b : ordonnée à l'origine
$y_i - (ax_i + b)$: écart vertical entre la valeur observée et la valeur prédite
n : nombre d'observations

L'écriture se lit ainsi : « chercher les coefficients a et b qui rendent minimale la somme des carrés des écarts verticaux ». Pourquoi des carrés ? Parce que les écarts positifs et négatifs s'annuleraient en simple addition, et parce que le carré pénalise fortement les grosses erreurs : la droite préfère beaucoup de petites erreurs à quelques énormes. Ce critère a l'immense avantage d'avoir une solution unique, calculable par des formules directes (section 4.10).

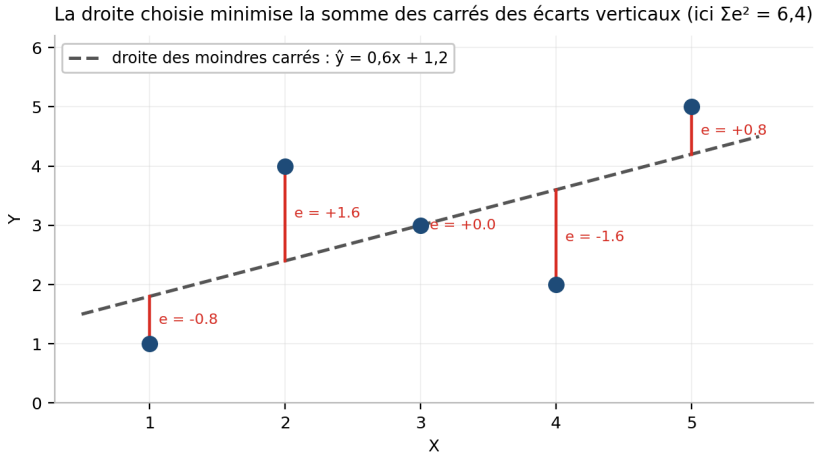


Figure 9 : les cinq semaines, leur droite des moindres carrés et les cinq écarts verticaux (segments rouges). Aucune autre droite ne donne une somme de carrés inférieure à 6,4.

Analogie

Choisir la droite des moindres carrés, c'est comme poser une règle sur le nuage et la faire pivoter jusqu'à ce que l'ensemble des ficelles verticales reliant chaque point à la règle occupe le moins de place possible — sauf que l'on mesure la place en carrés, pas en longueurs : les longues ficelles coûtent très cher.

Exemple guidé — pourquoi cette droite et pas une autre

Étape 1 — La droite retenue. Sur les cinq semaines, les moindres carrés donnent $\hat{y} = 0{,}6x + 1{,}2$ (nous calculerons ces coefficients à la section 4.10). Les écarts verticaux valent $-0{,}8$; $+1{,}6$; 0 ; $-1{,}6$; $+0{,}8$ — leur somme des carrés vaut 6,4.

Étape 2 — Une droite concurrente. Essayez $\hat{y} = 0{,}5x + 1{,}5$, qui semble raisonnable. Prédictions : 2 ; 2,5 ; 3 ; 3,5 ; 4. Écarts : -1 ; $+1{,}5$; 0 ; $-1{,}5$; $+1$. Somme des carrés : $1 + 2{,}25 + 0 + 2{,}25 + 1 = 6{,}5$.

Étape 3 — Comparer. 6,5 > 6,4 : la concurrente perd. Vous pouvez essayer toutes les droites imaginables : aucune ne descendra sous 6,4. C'est exactement ce que garantit la méthode : la solution est le **minimum global**, pas un essai heureux.

Étape 4 — Garder la mesure en tête. 6,4, en « unités de Y au carré », réapparaîtra à la section 4.12 : c'est la quantité d'erreur que la droite laisse subsister — et le point de départ du calcul de R^2.

À retenir

- La régression linéaire simple résume le nuage par une droite $\hat{y} = ax + b$.
- Critère des **moindres carrés** : minimiser la somme des carrés des écarts *verticaux* — les grosses erreurs coûtent cher.
- La solution est unique et calculable directement : ce n'est pas une approximation au hasard.

4.10 Pente et ordonnée à l'origine : calcul et lecture

Les coefficients de la droite des moindres carrés ne tombent pas du ciel : ils se déduisent de quantités que vous connaissez déjà. La pente naît de la covariance rapportée à la variance de X — le sens de la co-variation, ramené à l'échelle de X. L'ordonnée à l'origine n'est ensuite qu'un ajustement de position : elle garantit que la droite passe par le point des moyennes $(\bar{x}, \bar{y})$.

Définition — pente et ordonnée à l'origine

La **pente** (*slope*) a est la variation moyenne prédite de Y quand X augmente d'une unité — dans l'unité de Y par unité de X (ici, des euros par an). L'**ordonnée à l'origine** (*intercept*) b est la valeur prédite de Y quand X vaut 0 : elle positionne la droite, mais n'a de sens descriptif que si $x = 0$ appartient à la plage observée — ce qui n'est presque jamais le cas en pratique.

$$a = \frac{\mathrm{Cov}(X,Y)}{\mathrm{Var}(X)} = r\,\frac{s_Y}{s_X} \qquad\qquad b = \bar{y} - a\,\bar{x}$$

a : pente, en unités de Y par unité de X ; b : ordonnée à l'origine, en unités de Y
$\mathrm{Cov}(X,Y)$: covariance ; $\mathrm{Var}(X)$: variance de X
r : corrélation de Pearson ; s_X, s_Y : écarts-types de X et Y
$\bar{x}$, $\bar{y}$: moyennes de X et Y

La première formule réconcilie les deux mondes : la covariance donne le sens et l'impulsion, la variance de X convertit le tout en « Y par unité de X ». La seconde écriture, $a = r \times s_Y / s_X$, montre le lien direct avec la corrélation : r fixe la *qualité* de la tendance, et le rapport des écarts-types la convertit en *pente*. La formule de b, enfin, n'est qu'une conséquence d'une propriété remarquable : la droite des moindres carrés **passe toujours par le point des moyennes** — connaître a et ce point suffit à la tracer entièrement.

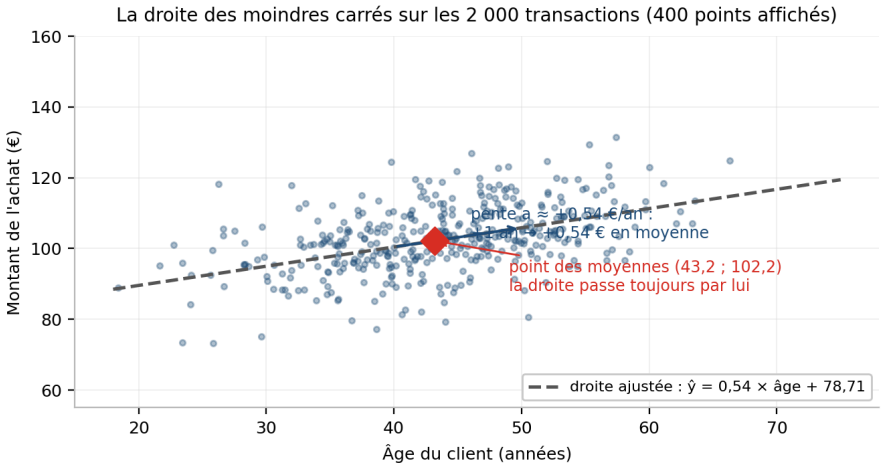


Figure 10 : la droite des moindres carrés du fil rouge (400 transactions affichées sur 2 000). Elle passe par le point des moyennes (43,2 ans ; 102,2 €) — propriété universelle, vraie même si aucun point observé ne s'y trouve.

Exemple guidé — deux calculs de bout en bout

Sur les cinq semaines. $\mathrm{Cov} = 1{,}5$ et $\mathrm{Var}(X) = 2{,}5$ (section 4.2) : $a = 1{,}5/2{,}5 = 0{,}6$. Puis $b = \bar{y} - a\bar{x} = 3 - 0{,}6 \times 3 = 1{,}2$. Droite : $\hat{y} = 0{,}6x + 1{,}2$. Vérification : $\hat{y}(3) = 3 = \bar{y}$: le point des moyennes est bien sur la droite.

Sur le fil rouge. $\mathrm{Cov}(\text{âge}, \text{montant}) = 43{,}10$ an·€ et $\mathrm{Var}(\text{âge}) = 79{,}32$ ans² : $a = 43{,}10/79{,}32 \approx 0{,}54$ €/an. Moyennes : $\bar{x} = 43{,}2$ ans, $\bar{y} = 102{,}2$ €, d'où $b = 102{,}18 - 0{,}5434 \times 43{,}2 \approx 78{,}7$ €.

Lecture métier. « Sur ces transactions, un an d'âge supplémentaire va avec **+0,54 €** de montant moyen » — une description de l'échantillon, dans sa plage. Prédiction à 50 ans : $\hat{y} = 0{,}54 \times 50 + 78{,}7 \approx 105{,}9$ € — une moyenne attendue pour les visites de clients de 50 ans, pas un montant garanti.

Lecture de b. 78,7 € serait le montant prédit « à 0 an » : un client nouveau-né n'existe pas dans les données (âges observés : 18 à 73 ans). b positionne la droite ; l'interpréter comme un vrai montant serait une extrapolation — interdite (section 4.13).

Reste une précaution d'usage : ces coefficients sont des **estimations**, soumises à la variation d'échantillonnage comme toute statistique (cours 2). La figure 11 le montre : on simule 600 échantillons de 40 clients issus d'une même règle (+0,50 €/an programmé) ; les pentes estimées s'étalent de 0,43 à 0,62 €/an selon les tirages. Sur vos 2 000 transactions, la pente 0,54 €/an est beaucoup plus stable, mais elle reste une estimation — à commenter avec la même prudence qu'une moyenne.

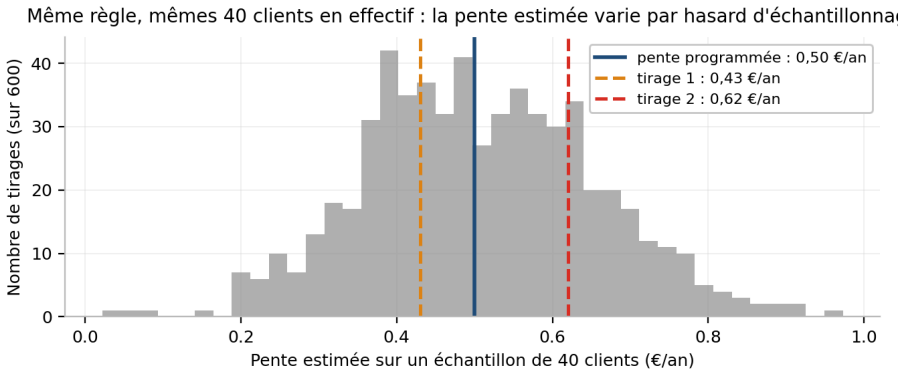


Figure 11 : 600 échantillons de 40 clients, même règle génératrice (+0,50 €/an) : les pentes estimées varient d'un tirage à l'autre. L'effet de la taille d'échantillon est le même que pour la moyenne (cours 2).

En pratique dans le code

```
a, b = np.polyfit(df["age"], df["montant"], 1)   # pente, puis ordonnée
stats.linregress(df["age"], df["montant"])        # a, b, r, valeur p, erreur-type
```

À retenir

- $a = \mathrm{Cov}(X,Y)/\mathrm{Var}(X) = r \times s_Y/s_X$: la pente s'exprime en unités de Y par unité de X.
- La droite des moindres carrés **passe toujours par** $(\bar{x}, \bar{y})$; d'où $b = \bar{y} - a\bar{x}$.
- a et b sont des estimations : elles fluctuent d'un échantillon à l'autre, surtout sur petit effectif.

4.11 Le résidu : ce que la droite n'explique pas

La droite prédit ; la réalité fait ce qu'elle veut. Pour chaque observation, il reste un écart entre le montant réellement payé et le montant pronostiqué par la droite à cet âge. Cet écart signé — observé moins prédit — est le **résidu**. Il est positif quand l'observation dépasse la prédiction, négatif quand elle est en dessous. Les résidus ne sont pas des « erreurs » au sens de fautes : ce sont les parcelles de réalité que la droite, par construction, ne capture pas.

Définition — le résidu

Le **résidu** (*residual*) d'une observation est l'écart vertical signé entre sa valeur observée et la valeur prédite par la droite : $e_i = y_i - \hat{y}_i$. Il s'exprime dans l'unité de Y. Un résidu mêle toujours deux ingrédients impossibles à séparer sur un point isolé : les **facteurs absents** du modèle (la distance, la composition du panier, une promotion…) et la **variation aléatoire** propre à chaque visite.

$$e_i = y_i - \hat{y}_i$$

e_i : résidu de l'observation i, dans l'unité de Y
y_i : valeur observée ; $\hat{y}_i = ax_i + b$: valeur prédite par la droite

La soustraction se fait toujours dans ce sens : observé *moins* prédit. Un résidu de +12 € signifie « 12 € de plus que la prédiction » ; −12 €, « 12 € de moins ». Sur l'ensemble des points, les moindres carrés garantissent que la somme des résidus vaut 0 : la droite ne surestime ni ne sous-estime *en moyenne* — ce qui n'empêche pas chaque point d'être loin de la droite.

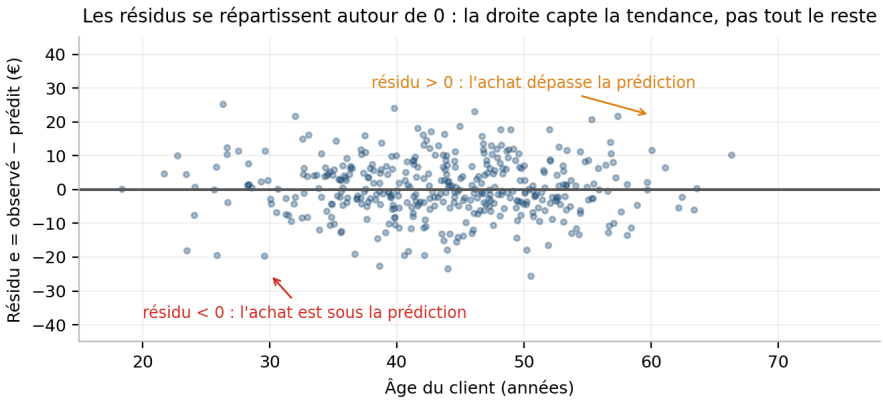


Figure 12 : les résidus du fil rouge (400 transactions affichées) en fonction de l'âge. Ils se répartissent autour de 0, sans structure visible : la droite a capté la tendance ; le reste relève d'autres facteurs et du hasard.

Analogie

Le résidu est l'écart entre la note moyenne annoncée par un professeur (« avec ce travail, tu devrais obtenir 12 ») et la note réelle d'une copie (14,5). Cet écart n'est ni une faute du barème ni un exploit isolé : il mélange tout ce que la moyenne ne voit pas — l'inspiration du jour, le soin, le sujet tombé.

Exemple guidé — lire deux résidus

Sur les cinq semaines. Semaine 4 : $x = 4$, $y = 2$. La droite prédit $\hat{y} = 0{,}6 \times 4 + 1{,}2 = 3{,}6$. Résidu : $e = 2 - 3{,}6 = -1{,}6$: cette semaine compte 1,6 unité de moins que la prédiction. C'est le plus grand écart négatif du jeu — visible sur la figure 9.

Sur le fil rouge. Une visite d'un client de 41 ans se solde à 113,50 €. Prédiction : $\hat{y} = 0{,}54 \times 41 + 78{,}7 \approx 100{,}9$ €. Résidu : $e \approx 113{,}5 - 100{,}9 = +12{,}6$ € : ce panier dépasse la moyenne attendue de 12,6 €.

Interpréter sans extrapoler. Que vaut ce +12,6 € ? On ne sait pas : promotion utilisée, achat exceptionnel, composition de foyer… Le résidu *signale* un écart à enquêter éventuellement, il ne l'*explique* jamais. Et attention à l'unité d'observation : si le même client revient chaque semaine, ses résidus se ressembleront — les visites répétées d'un même client ne sont pas des informations indépendantes (condition déjà rencontrée au test de corrélation, section 4.4).

En pratique dans le code

```
y_chapeau = a * df["age"] + b          # prédictions de la droite
residus = df["montant"] - y_chapeau    # un résidu par ligne
```

À retenir

- Résidu = **observé − prédit**, signé, dans l'unité de Y ; leur somme vaut 0 sur l'échantillon ajusté.
- Un résidu mêle **facteurs absents** et **hasard** : il signale, il n'explique pas.
- Les résidus sont la matière première du diagnostic — et le point de départ de R^2 (section 4.12) et de l'évaluation des modèles (cours 6).

4.12 Le coefficient de détermination R^2

La droite laisse des résidus : somme toute, prédit-elle bien ou mal ? Pour le dire, il faut un étalon. Le voici : **prédire systématiquement la moyenne** $\bar{y}$, sans tenir aucun compte de X. Cette stratégie minimale commet, sur l'ensemble des points, une erreur totale mesurable : la somme des carrés des écarts à la moyenne. La droite des moindres carrés, elle, laisse la somme des carrés des résidus. Le coefficient de détermination compare les deux : **de quelle fraction la droite réduit-elle l'erreur de la stratégie « toujours la moyenne » ?**

Définition — le coefficient de détermination

Le **coefficient de détermination** (*coefficient of determination*), noté R^2, mesure la fraction de la somme des carrés totale (dispersion de Y autour de sa moyenne) que la droite **élimine** par rapport à la prédiction constante $\bar{y}$. En régression linéaire simple ajustée par moindres carrés, il vaut exactement r^2 et se lit entre 0 et 1 : $R^2 = 0{,}28$ signifie que la droite réduit de 28 % la somme des erreurs au carré de la stratégie « toujours la moyenne ».

$$R^2 = 1 - \frac{SSE}{SST} \qquad \text{avec} \quad SSE = \sum_{i=1}^{n} e_i^2 \quad \text{et} \quad SST = \sum_{i=1}^{n} (y_i - \bar{y})^2$$

R^2 : coefficient de détermination, sans unité
SSE : somme des carrés des résidus de la droite (*sum of squared errors*)
SST : somme totale des carrés des écarts à la moyenne (*total sum of squares*)
e_i : résidu de l'observation i ; $\bar{y}$: moyenne de Y

Le dénominateur SST est l'erreur de la stratégie de référence : prédire $\bar{y}$ pour tout le monde. Le numérateur SSE est l'erreur qui subsiste avec la droite. Le rapport SSE/SST dit quelle part de l'erreur *reste* ; $R^2 = 1 - SSE/SST$ dit quelle part a été *éliminée*. Si la droite n'apporte rien, $SSE = SST$ et $R^2 = 0$; si elle passe par tous les points, $SSE = 0$ et $R^2 = 1$.

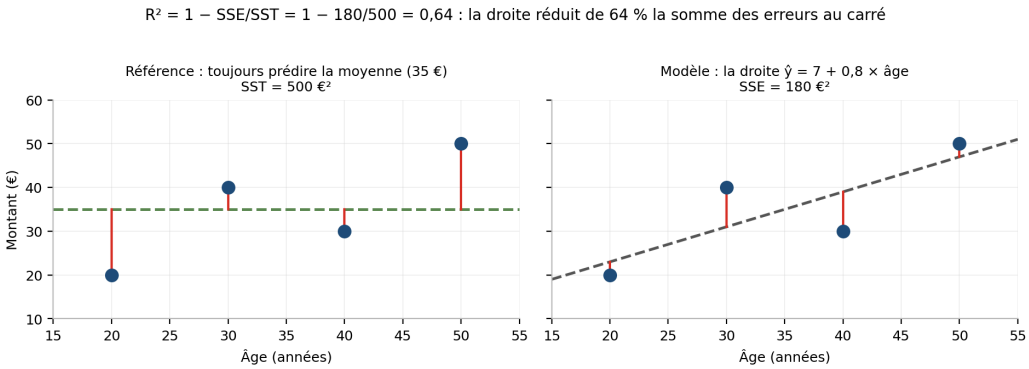


Figure 13 : quatre montants observés selon l'âge. À gauche, la référence « toujours la moyenne » (erreur totale 500) ; à droite, la droite des moindres carrés (erreur 180). $R^2 = 1 - 180/500 = 0{,}64$: la droite a éliminé 64 % de l'erreur au carré de la référence.

Exemple guidé — trois lectures de R²

Calcul complet (figure 13). Moyenne des quatre montants : 35 €. Écarts à la moyenne : −15, +5, −5, +15, de carrés 225, 25, 25, 225 : $SST = 500$. La droite $\hat{y} = 7 + 0{,}8 \times$ âge laisse les résidus −3, +9, −9, +3 : $SSE = 180$. Donc $R^2 = 1 - 180/500 = 0{,}64$.

Sur le fil rouge. $SST = 177\,991$ €² et $SSE = 131\,172$ €² : $R^2 \approx 0{,}26$. Et surprise cohérente : $r^2 = 0{,}51^2 \approx 0{,}26$; en régression simple, les deux coïncident toujours. Lecture : « l'âge, via une droite, réduit d'environ un quart l'erreur de prédiction au carré » — les trois quarts restants tiennent à tout ce que la droite ignore.

Ce que R² n'est pas. Ni « 64 % de prédictions exactes » (R² ne dit rien des prédictions individuelles), ni « 64 % de preuve d'une cause » (R² mesure un ajustement sur *ces* données, jamais un mécanisme). Retenez la phrase exacte : **une réduction de la somme des erreurs au carré, relativement à la moyenne**.

Deux cas limites à connaître. R² peut devenir **négatif** quand on évalue une prédiction *hors ajustement* : prédire 65 € pour tout le monde sur les quatre points donne $SSE = 4\,100 > SST$, soit $R^2 = -7{,}2$ — pire que la moyenne, ce qui arrive quand un modèle appris ailleurs dévisse sur de nouvelles données (le cours 6 y reviendra). Et si $SST = 0$ (Y constant), R² est indéfini : il n'y a rien à réduire.

En pratique dans le code

```
sse = (residus ** 2).sum()                          # somme des carrés des résidus
sst = ((df["montant"] - df["montant"].mean()) ** 2).sum()
r2 = 1 - sse / sst                                  # = r ** 2 en régression simple
```

À retenir

- $R^2 = 1 - SSE/SST$: fraction de l'erreur au carré de la stratégie « toujours la moyenne » éliminée par la droite.
- En régression linéaire **simple** ajustée par moindres carrés : $R^2 = r^2$.
- R^2 ne dit ni précision individuelle, ni causalité ; il peut être négatif hors ajustement, indéfini si $SST = 0$.

4.13 Comprendre ou prédire : deux ambitions différentes

Une même droite peut servir deux projets très différents, et les confondre est une source inépuisable de mauvaises décisions. **Prédire** : estimer le montant attendu d'une visite *ressemblant* à celles observées, pour dimensionner un stock ou une campagne. **Comprendre** : affirmer quelque chose sur le mécanisme — « vieillir fait dépenser ». La première ambition est légitime avec nos outils actuels, à condition de rester dans la plage observée ; la seconde exige bien davantage qu'une pente.

Définition — interpolation et extrapolation

Prédire à l'intérieur de la plage de X réellement observée est une **interpolation** : la prédiction s'appuie sur des données encadrantes. Prédire en dehors est une **extrapolation** (*extrapolation*) : elle suppose que la tendance se poursuit au-delà des données — hypothèse invérifiable sur l'échantillon, et souvent fausse (plafonds, seuils, effets d'âge ou de seuil de prix).

	Prédire	**Comprendre**
Question	« Quel montant attendre pour une visite de ce type ? »	« Pourquoi le montant varie-t-il ? »
Ce qu'on utilise	La droite, dans la plage observée (interpolation)	Le plan de collecte, les variables de contrôle, la causalité (section 4.15)
Ce qu'on peut dire	« En moyenne, pour des visites semblables… »	Rien sur la foi du seul coefficient : association ≠ mécanisme
Risque majeur	Extrapoler hors de la plage (âge 0, 100 ans)	Lire la pente comme « l'effet » de X (confusion, composition)

Tableau 4 : deux ambitions, deux disciplines. La droite sert la première ; la seconde exige un raisonnement causal.

Exemple guidé — trois phrases à juger

Phrase 1. « Pour un client de 50 ans, la visite moyenne attendue est d'environ 106 €. » *Recevable* : interpolation (50 ans est dans la plage 18–73), formulée comme une moyenne sur des visites semblables.

Phrase 2. « À la naissance, le montant prédit est de 78,7 € ; à 100 ans, il atteint 133 €. » *Extrapolations interdites* : aucun client n'a moins de 18 ni plus de 73 ans ; b positionne la droite, il ne décrit aucun client réel — et rien ne garantit que la tendance continue au-delà des données.

Phrase 3. « Chaque année de vieillissement fait dépenser 0,54 € de plus au client. » *Non démontrée* : la pente compare des clients *différents* (les plus âgés ne sont pas les plus jeunes ayant vieilli — ils ont peut-être des revenus, des besoins, des quartiers différents). Pour mesurer « l'effet de vieillir », il faudrait suivre les mêmes personnes dans le temps… et vieillir n'est pas une intervention qu'on peut attribuer au hasard. La pente observe une association ; elle ne mesure pas un effet.

Dernier contrôle — l'unité d'observation. Nos 2 000 lignes sont des *transactions* : un client fidèle y apparaît plusieurs fois et pèse plusieurs fois dans la pente. Pour une prédiction « nouveau client », on regroupera d'abord par client (un point = un client) ; sinon, les habitués dominent l'estimation — c'est la **pseudo-réplication**, déjà signalée pour le test de corrélation.

À retenir

- Prédire : interpolation seule, dans la plage observée, exprimée comme une **moyenne attendue**.
- Comprendre : la pente n'est pas un « effet » ; l'explication causale demande un autre dispositif (section 4.15).
- *b* positionne la droite ; l'interpréter hors de la plage est une extrapolation interdite.
- Vérifier l'unité d'observation : transactions répétées d'un même client = pseudo-réplication.

PARTIE D — DE L'ASSOCIATION À LA CAUSALITÉ

4.14 Variables de confusion et paradoxe de Simpson

Revenons à l'écart du fil rouge : le panier moyen du magasin B dépasse celui de A de 5,95 €. Un « effet magasin » ? Pas si vite. Les clients de B sont aussi *plus âgés* en moyenne (47,9 ans contre 40,1), et nous savons que l'âge va avec des paniers plus élevés. Une partie de l'écart pourrait donc venir de la **composition** des clientèles, et non des magasins eux-mêmes. C'est exactement le schéma de la section 4.8, vu sous un autre angle : une troisième variable — l'âge — est liée aux deux autres et brouille leur relation.

Définition — la variable de confusion

Une **variable de confusion** (*confounding variable* ou *confounder*) est une troisième variable liée à la fois à X et à Y, qui crée, gonfle, masque ou inverse l'association observée entre X et Y. Tant qu'elle n'est pas prise en compte, l'association brute mélange deux ingrédients indiscernables : le lien propre entre X et Y, et l'effet de composition dû à la variable de confusion.

Quand la confusion est prise en compte, il arrive que la conclusion **s'inverse complètement**. Ce retournement porte un nom : le **paradoxe de Simpson** (*Simpson's paradox*). La figure 14 en donne un exemple commercial : deux campagnes promotionnelles, e-mail contre SMS, mesurées par leur taux de conversion (proportion de clients qui achètent).

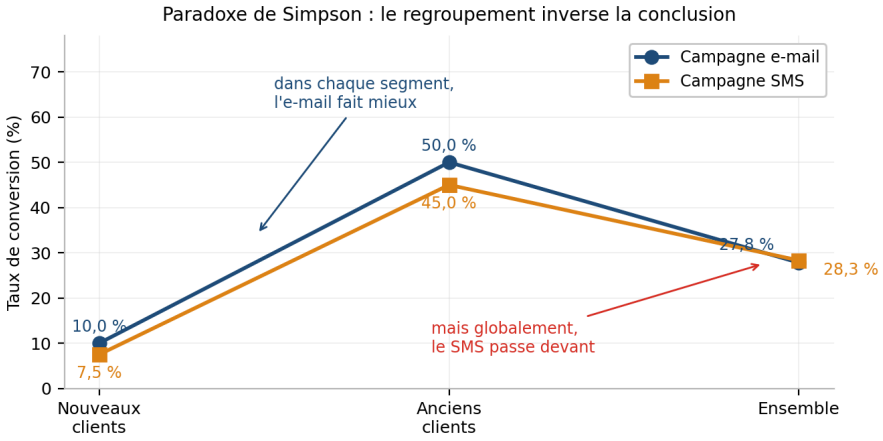


Figure 14 : paradoxe de Simpson. Dans chaque segment (nouveaux clients, anciens clients), l'e-mail convertit mieux que le SMS ; sur l'ensemble, le SMS semble l'emporter — uniquement parce que sa clientèle compte plus d'anciens clients, qui convertissent naturellement mieux.

Exemple guidé — vérifier le paradoxe à la main

Étape 1 — Poser les comptes. Chaque campagne a touché 900 clients. E-mail : 500 nouveaux (10 % convertis, soit 50 achats) et 400 anciens (50 %, soit 200). SMS : 400 nouveaux (7,5 %, soit 30) et 500 anciens (45 %, soit 225).

	Nouveaux clients	Anciens clients	Ensemble
E-mail	50 / 500 = 10,0 %	200 / 400 = 50,0 %	250 / 900 = 27,8 %
SMS	30 / 400 = 7,5 %	225 / 500 = 45,0 %	255 / 900 = 28,3 %

Tableau 5 : les mêmes données, deux conclusions opposées selon le niveau de lecture — segment par segment, ou tous segments confondus.

Étape 2 — Constater l'inversion. Segment par segment, l'e-mail gagne partout (10,0 > 7,5 ; 50,0 > 45,0). Ensemble, il perd (27,8 < 28,3). Aucune donnée n'a changé : seul le regroupement inverse le classement.

Étape 3 — Identifier la confusion. Le segment est la variable de confusion : il est lié à la conversion (les anciens convertissent beaucoup plus) *et* à la campagne (le SMS a été envoyé à 55,6 % d'anciens, l'e-mail à 44,4 %). Le taux global compare donc deux clientèles différentes autant que deux campagnes.

Étape 4 — Conclure correctement. À composition comparable, l'e-mail fait mieux : c'est la lecture segmentée qui informe la décision. La leçon générale : **toute moyenne globale sur des groupes mélangés est suspecte** — le reflexe « découper par sous-groupe » de la section 4.8 est votre protection.

Le même raisonnement permet de **décomposer l'écart** entre les deux magasins du fil rouge, puisque nous connaissons ici le mécanisme des données. L'écart d'âge moyen est de 7,74 ans ; à 0,50 € par année d'âge, la composition d'âge « explique » $0{,}50 \times 7{,}74 \approx 3{,}87$ € des 5,95 € d'écart brut. Le reste — 2,00 € — est l'écart propre de B à âge égal, et 0,08 € de reliquat tient au bruit et aux arrondis. La figure 15 visualise cette décomposition.

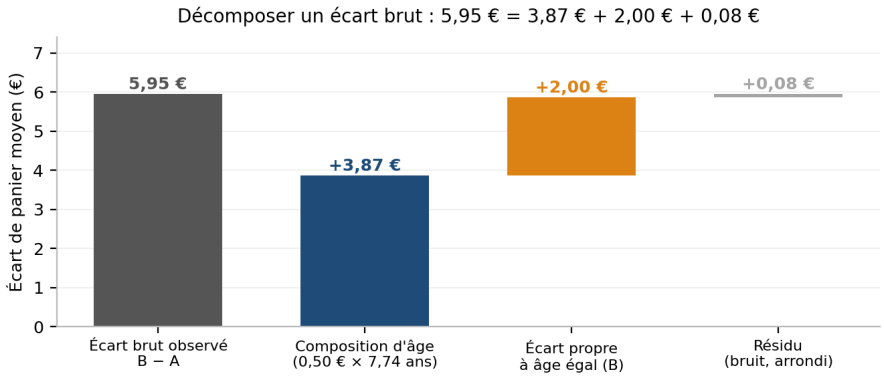


Figure 15 : décomposition de l'écart brut B − A : 5,95 € = 3,87 € (composition d'âge) + 2,00 € (écart propre à âge égal) + 0,08 € (résidu). Sans cette décomposition, les 3,87 € de composition auraient pu être attribués à tort au magasin.

À retenir

- Une **variable de confusion** est liée à X *et* à Y : elle brouille leur association brute.
- **Paradoxe de Simpson** : le regroupement des groupes peut *inverser* la conclusion — toujours analyser par sous-groupe avant de décider.
- Décomposer un écart brut (composition + écart propre + résidu) évite d'attribuer à un facteur ce qui revient à la composition des groupes.

4.15 Tester une cause : observation, intervention, plan croisé

Tout ce cours vous a armé pour mesurer des associations. Mais la question qui tente toujours un décideur est causale : « est-ce *grâce à* la promotion que les clients dépensent plus ? ». Entre l'association et la causalité, il y a un fossé qu'aucun coefficient ne franchit. Ce qui le franchit, c'est la façon dont les données sont produites :

Observer, c'est enregistrer ce que les clients font d'eux-mêmes. Ceux qui utilisent la promotion se sont *choisis* : ils avaient peut-être déjà un budget plus élevé, des besoins plus fréquents, un œil plus attentif aux offres. Leur surconsommation mélange l'effet de la promotion et leurs caractéristiques propres : c'est le **biais de sélection** (*selection bias*), une confusion au moment même de la collecte. Aucun calcul après coup ne le dissipe entièrement.

Intervenir, c'est décider à la place du hasard du client : *vous* attribuez la promotion. Pour raisonner proprement, il faut comparer chaque client à ce qu'il aurait été *sans* la promotion — son **contrefactuel** (*counterfactual*) : la même personne, au même moment, dans l'autre condition. Ce contrefactuel est par définition inobservable ; toute la stratégie consiste à l'approcher par un groupe comparable.

Définitions — le vocabulaire de la causalité

- La **causalité** (*causality*) : la relation entre une intervention et son effet — « X modifie Y » ; plus exigeante que l'association « X et Y varient ensemble ».
- La **randomisation** (*randomization*) : attribution au hasard des unités entre les conditions (promotion ou non). Elle rend les groupes comparables *en moyenne*, sur toutes les caractéristiques — mesurées ou non.
- Le **groupe témoin** (*control group*) : le groupe qui ne reçoit pas l'intervention et joue le rôle de contrefactuel collectif du groupe traité.
- L'**intention de traiter** (*intention to treat*) : comparer les groupes *entiers tels qu'ils ont été constitués par le tirage au sort*, y compris les clients assignés à la promotion qui ne l'ont finalement pas utilisée — les retirer recréerait un biais de sélection.
- Le **plan croisé** (*crossover design*) : les *mêmes* individus vivent les deux conditions à des moments différents, dans un ordre tiré au hasard ; chacun devient son propre témoin.

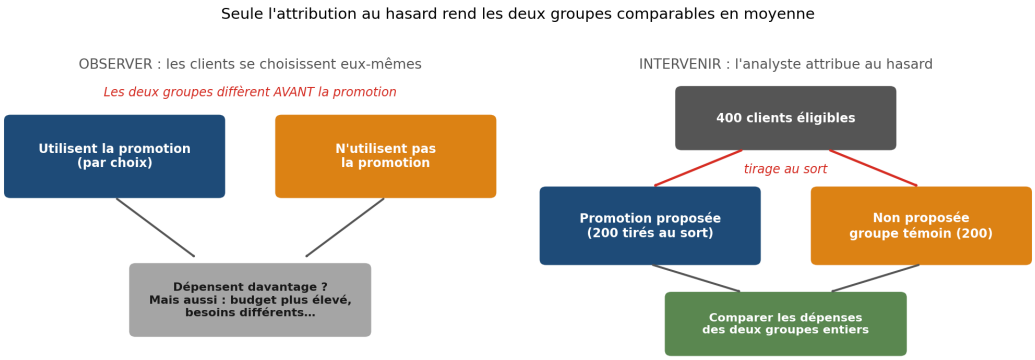


Figure 16 : observer contre intervenir. À gauche, les clients se choisissent : les deux groupes diffèrent avant la promotion. À droite, le tirage au sort crée deux groupes comparables en moyenne : l'écart observé devient attribuable à l'intervention.

Analogie

Tester une promotion en observant les volontaires, c'est comme évaluer un médicament uniquement sur les malades qui ont choisi de le prendre : sont-ils guéris grâce au médicament, ou étaient-ils déjà les plus motivés pour guérir ? C'est pour trancher cette question que les essais cliniques attribuent le traitement au hasard — et comparent aux groupes entiers, témoin inclus.

Quand chaque client peut vivre les deux conditions, le **plan croisé** offre une alternative élégante : les mêmes clients visitent le magasin plusieurs fois, la promotion étant activée ou non selon une séquence tirée au hasard. On compare alors, *client par client*, son panier moyen « avec » à son panier moyen « sans », avant de moyenner ces écarts. Chaque client étant son propre témoin, les différences de budget ou d'habitudes s'annulent d'elles-mêmes.

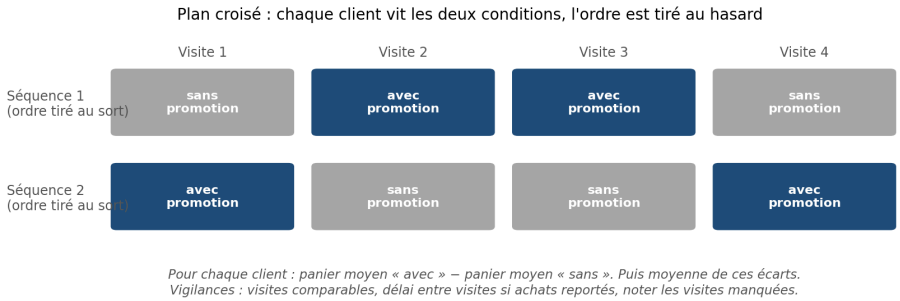


Figure 17 : le plan croisé. L'ordre des conditions est tiré au hasard pour chaque client (deux séquences illustrées). Vigilances : visites comparables, délai suffisant entre visites si les achats peuvent être reportés, suivi des visites manquées.

Exemple guidé — monter l'essai de la promotion

Étape 1 — Nommer la question causale. « La promotion modifie-t-elle le panier avant remise ? » — préciser l'intervention (activer la promotion) et la mesure (panier avant déduction).

Étape 2 — Constituer les groupes par randomisation. 400 clients éligibles, 200 tirés au sort pour recevoir la promotion, 200 en groupe témoin. Pas de choix, pas d'inscription volontaire : c'est le tirage qui décide, sinon le biais de sélection revient par la porte.

Étape 3 — Mesurer en intention de traiter. Certains assignés « promotion » ne l'utiliseront pas : ils *restent* dans leur groupe pour la comparaison. Les exclure comparerait « motivés » contre « tout le monde » et ruinerait la randomisation.

Étape 4 — Conclure avec ses limites. L'écart moyen entre les deux groupes entiers estime l'effet *de la proposition* de la promotion, sur cette clientèle, à cette période. Généraliser à d'autres clients, d'autres promotions ou d'autres saisons reste une hypothèse à argumenter.

Variante plan croisé — et ses pièges. Si les mêmes clients passent plusieurs fois, l'ordre « avec/sans » tiré au sort neutralise leurs habitudes. Mais attention : un client peut reporter un achat prévu sur la visite « avec promotion » (**effet persistant** ou de report), la période peut différer (soldes entre-temps), et les visites manquées déséquilibrent les séquences. Ces limites se déclarent dans la conclusion.

À retenir

- Association ≠ causalité ; le **biais de sélection** naît quand les unités se choisissent elles-mêmes.
- Le raisonnement causal vise le **contrefactuel**, approché par un **groupe témoin** constitué par **randomisation**, analysé en **intention de traiter**.
- Le **plan croisé** rend chaque individu témoin de lui-même — au prix de vigilances (report d'achat, période, visites manquées).
- Aucun coefficient de corrélation, aussi fort soit-il, ne remplace le dispositif de collecte.

5. Erreurs fréquentes et pièges

Piège 1 — « r ≈ 0, donc il n'y a pas de relation »

Pourquoi c'est faux : Pearson ne mesure que la tendance linéaire. Une relation en U parfaite donne $r \approx 0$ (figure 5).

Réflexe correct : regarder le nuage avant de conclure ; nommer la forme ; envisager Spearman (relation monotone) ou un découpage par plages.

Piège 2 — « La corrélation est forte, donc X cause Y »

Pourquoi c'est faux : r ne dit ni le sens de la causalité (Y cause X ?), ni l'absence d'une troisième variable (confusion, composition — sections 4.8 et 4.14). Même le test de corrélation ne teste qu'une liaison, jamais un mécanisme.

Réflexe correct : formuler « association », chercher les confondeurs, et réserver « effet » aux données issues d'une intervention (randomisation, groupe témoin — section 4.15).

Piège 3 — « Je calcule r et la droite sur les visites, alors que l'unité est le client »

Pourquoi c'est faux : les visites répétées d'un même client ne sont pas indépendantes ; le client fidèle pèse autant de fois qu'il est passé. C'est la pseudo-réplication : elle gonfle artificiellement n et fausse à la fois le test et la pente pour toute question posée au niveau du client.

Réflexe correct : fixer l'unité d'observation avant tout calcul (cours 1) ; regrouper par client si la question porte sur les clients.

Piège 4 — « b = 78,7 € : un client de 0 an dépense 78,7 € »

Pourquoi c'est faux : b positionne la droite ; $x = 0$ est hors de la plage observée (18–73 ans). Interpréter b hors plage est une extrapolation.

Réflexe correct : ne commenter que des prédictions *dans* la plage, formulées comme des moyennes attendues.

Piège 5 — « R^2 = 0,64 : 64 % des prédictions sont exactes (et ça prouve la cause) »

Pourquoi c'est faux : R^2 mesure la réduction de la somme des erreurs *au carré* par rapport à « toujours la moyenne » — rien sur les prédictions individuelles, et jamais de causalité : un R^2 élevé peut refléter une pure confusion.

Réflexe correct : énoncer la définition exacte, rappeler que $R^2 = r^2$ en régression simple, et juger le mécanisme par le dispositif de collecte, pas par l'ajustement.

6. Exercices

Faites ces exercices sans relire le cours — c'est en forçant votre mémoire à récupérer les notions que vous les ancrez durablement. Le corrigé détaillé se trouve en section 9, en fin de document : ne le consultez qu'après avoir produit vos propres réponses.

6.1 Auto-évaluation

Q1 (QCM). Autour du point des moyennes $(\bar{x}, \bar{y})$, quels quadrants contiennent les points dont la contribution à la covariance est *positive* ?

A. Haut-droite et bas-gauche · B. Haut-gauche et bas-droite · C. Les quatre quadrants · D. Cela dépend des unités

Q2 (Vrai/Faux). « La valeur p du test de corrélation est la probabilité que ρ vaille 0 dans la population, sachant les données observées. »

Q3 (QCM). Un nuage montre une croissance nette qui plafonne progressivement (courbe monotone). Quel coefficient résume le mieux la force de cette relation ?

A. Le coefficient de Pearson · B. Le coefficient de Spearman · C. La covariance · D. R^2

Q4 (Vrai/Faux). « $R^2 = 0{,}64$ signifie que 64 % des prédictions de la droite sont exactes. »

Q5 (Réponse courte). Montrez, à partir de $b = \bar{y} - a\bar{x}$, que la droite des moindres carrés passe toujours par le point des moyennes $(\bar{x}, \bar{y})$.

Q6 (QCM). On observe une corrélation positive entre le nombre de sapeurs-pompiers dépêchés sur un incendie et le montant des dégâts. Quelle variable de confusion explique cette association ?

A. La vitesse du vent · B. La taille de l'incendie · C. Le prix des camions · D. La distance de la caserne

Q7 (Vrai/Faux). « Le plan croisé supprime tout biais possible dans la mesure de l'effet d'une promotion. »

Q8 (Réponse courte). Expliquez la différence entre *randomisation* et *groupe témoin*, et pourquoi les deux sont nécessaires à une comparaison causale.

6.2 Application guidée — Température et ventes de boissons chaudes

Un café enregistre pendant 6 semaines la température moyenne extérieure (°C) et ses ventes hebdomadaires de boissons chaudes (unités) :

Semaine	**1**	**2**	**3**	**4**	**5**	**6**
Température (°C)	4	8	12	16	20	24
Ventes (unités)	47	39	34	27	23	15

Tableau 6 : six semaines d'observation — une ligne par semaine.

Travail à faire, en suivant les étapes :

1. Calculez les moyennes $\bar{x}$ et $\bar{y}$.
2. Calculez la covariance (somme des contributions $\div\, n-1$) ; vérifiez que la somme des contributions vaut -430.
3. Sachant que $\mathrm{Var}(X) = 56$ et $\mathrm{Var}(Y) \approx 133$, calculez r et commentez-le en trois questions (sens, force, périmètre).
4. Calculez la pente a et l'ordonnée b ; écrivez l'équation de la droite.
5. Prédisez les ventes pour une semaine à 10 °C. Cette prédiction est-elle une interpolation ou une extrapolation ?
6. Calculez les six résidus, puis SSE ; sachant $SST = 664{,}8$, calculez R^2 et énoncez sa signification exacte.
7. La gérante conclut : « la chaleur fait baisser les ventes ». Que répondez-vous ?

6.3 Application autonome

Exercice 1 — Livraisons des entrepôts Nord et Sud (entrelacé : cours 3, 4 et 5)

Vous auditez la table `livraisons` d'un distributeur : 1 200 livraisons attendues, une ligne par livraison, colonnes `date`, `entrepot` (Nord/Sud), `delai_min`, `note_client` (1 à 5). Vos contrôles relèvent : 1 200 lignes (annonce respectée) ; une date au 30/02/2026 ; un délai de -12 min ; 3 doublons exacts ; aucune autre anomalie.

1. **Qualité (cours 3).** Classez chaque anomalie (bloquante ou alerte), proposez la conduite à tenir pour chacune, et rappelez la règle d'or sur la traçabilité.
2. **Comparer les délais (cours 4).** Après corrections, Nord : $n = 610$, moyenne 34,2 min, écart-type 9,1 ; Sud : $n = 590$, moyenne 31,8 min, écart-type 8,7. Quel test choisissez-vous et pourquoi ? On vous donne $t \approx 4{,}7$, $p < 0{,}001$, IC à 95 % de l'écart : [1,4 ; 3,4] min. Rédigez la conclusion (estimation, significativité, importance).
3. **Délai et satisfaction (cours 5).** Sur les mêmes livraisons, la corrélation délai–note vaut $-0{,}34$ sur l'ensemble, mais $-0{,}05$ dans Nord et $-0{,}07$ dans Sud. Décrivez ce que vous observez, nommez le phénomène, et proposez une explication (on sait que la note moyenne est de 4,1 chez Nord et 4,4 chez Sud).
4. **Choisir le coefficient.** La note client est ordinale (1 à 5) et très concentrée sur 4 et 5. Quel coefficient privilégiez-vous pour résumer le lien délai–note, et pourquoi ?
5. **Synthèse.** Rédigez en 4–5 lignes la conclusion que vous présenteriez au directeur logistique.

Exercice 2 — La promotion en libre-service fait-elle vendre ?

Dans une enseigne, les clients peuvent activer eux-mêmes une promotion sur une borne en caisse. Sur le mois écoulé, ceux qui l'ont utilisée ont dépensé en moyenne **+6,40 €** de plus que les autres (panier avant remise).

1. La direction affirme : « la promotion augmente le panier de 6,40 € ». Pourquoi cette conclusion est-elle prématurée ? Nommez le biais et proposez deux explications alternatives à l'écart observé.
2. Concevez un essai permettant de trancher : précisez l'intervention, la constitution des groupes, le rôle du tirage au sort, la mesure retenue, et la règle d'analyse (que fait-on des clients assignés « promotion » qui ne l'ont pas utilisée ?).
3. Proposez une variante en plan croisé pour les clients réguliers et nommez deux limites spécifiques à surveiller.
4. Un collègue ajuste par ailleurs la droite `panier ~ ancienneté` et annonce $R^2 = 0{,}52$. Énoncez sa signification exacte, puis deux choses que ce R² ne permet *pas* de dire.

7. Fiche récapitulative

Notion	Définition courte	Formule / repère
Nuage de points (*scatter plot*)	Deux variables quantitatives, un point par observation	Lecture : direction, force, forme — avant tout calcul
Covariance	Moyenne des produits d'écarts signés ; signe lisible, grandeur non comparable	$\mathrm{Cov}(X,Y) = \frac{1}{n-1}\sum(x_i-\bar{x})(y_i-\bar{y})$; unité = unité(X) × unité(Y)
Corrélation de Pearson r	Covariance standardisée ; force et sens de la tendance **linéaire**	$r = \frac{\mathrm{Cov}(X,Y)}{s_X s_Y}$, dans $[-1\,;\,1]$, sans unité, invariant au changement d'unité
Test de corrélation	$H_0 : \rho = 0$ (population) contre $H_1 : \rho \neq 0$	$t = r\sqrt{(n-2)/(1-r^2)}$, $n-2$ ddl ; conditions : linéaire, indépendant, sans point dominant, périmètre nommé
Corrélation de Spearman ρ_s	Pearson sur les **rangs** ; mesure la relation **monotone**	$\rho_s = 1 - \frac{6\sum d_i^2}{n(n^2-1)}$ (sans ex æquo) ; robuste aux points extrêmes
Limites de r	Non-linéarité ($r \approx 0$ ≠pas de relation) ; point influent ; effet de composition (périmètre)	Réflexes : nuage toujours ; recalcul sans le point ; analyse par sous-groupe
Régression linéaire simple	Droite $\hat{y} = ax + b$ minimisant la somme des carrés des écarts verticaux	$a = \frac{\mathrm{Cov}(X,Y)}{\mathrm{Var}(X)} = r\frac{s_Y}{s_X}$; $b = \bar{y} - a\bar{x}$; passe par $(\bar{x},\bar{y})$
Résidu	Écart signé observé − prédit ; mêle facteurs absents et hasard	$e_i = y_i - \hat{y}_i$; $\sum e_i = 0$; il signale, n'explique pas
Coefficient de détermination R^2	Fraction de l'erreur au carré (vs « toujours la moyenne ») éliminée par la droite	$R^2 = 1 - SSE/SST$; $= r^2$ en régression simple ; négatif possible hors ajustement
Prédire vs comprendre	Prédire = interpolation dans la plage, moyenne attendue ; comprendre = causalité, autre dispositif	Extrapolation interdite ; b positionne la droite ; attention à la pseudo-réplication
Confusion & Simpson	Troisième variable liée à X et Y ; le regroupement peut inverser la conclusion	Décomposer l'écart : composition + écart propre + résidu
Causalité	Observer (biais de sélection) vs intervenir (contrefactuel approché)	Randomisation + groupe témoin + intention de traiter ; plan croisé = chacun son propre témoin

Tableau 7 : l'essentiel du cours 5 en une page — à revoir régulièrement, sans le cours sous les yeux.

Besoin	Fonction
Nuage de points	`plt.scatter(x, y, s=8, alpha=0.4)`
Covariance	`df.cov(numeric_only=True)` ; `np.cov(..., ddof=1)`
Corrélation de Pearson / sa matrice	`df["x"].corr(df["y"])` ; `df.corr(numeric_only=True)`
Test de corrélation	`stats.pearsonr(x, y)`
Corrélation de Spearman	`stats.spearmanr(x, y)` ; `df.corr(method="spearman")`
Droite des moindres carrés	`np.polyfit(x, y, 1)` ; `stats.linregress(x, y)`
Résidus et R^2	`residus = y - (a*x + b)` ; `1 - (residus**2).sum() / ((y - y.mean())**2).sum()`

Tableau 8 : les fonctions du cours — le concept d'abord, l'outil ensuite.

8. Pour aller plus loin (optionnel)

- **Le quartet d'Anscombe.** Quatre jeux de données avec les mêmes moyennes, variances, r, droite et R^2 — et des nuages radicalement différents. La démonstration historique que « le nuage d'abord » n'est pas un conseil de confort mais une nécessité (F. Anscombe, 1973).
- **La corrélation partielle.** Mesurer le lien entre X et Y « à troisième variable fixée » : la version continue du réflexe « analyser par sous-groupe » face aux confusions.
- **La régression multiple.** Plusieurs variables explicites à la fois ($\hat{y} = a_1x_1 + a_2x_2 + b$) : la logique des moindres carrés se généralise, et chaque pente se lit « toutes choses égales par ailleurs ». Vous retrouverez sa cousine pour les cibles binaires, la régression logistique, au cours 7.
- **Les tests A/B en entreprise.** La randomisation de la section 4.15 industrialisée : deux versions d'une page web attribuées au hasard, un indicateur, une décision. Mêmes principes, mêmes pièges (biais de sélection, intention de traiter), à l'échelle de millions d'utilisateurs.

9. Corrigé des exercices

Ne lisez cette section qu'après avoir cherché vos propres réponses — comparer votre production au corrigé fait partie de l'apprentissage.

9.1 Auto-évaluation

Q1 — A. Haut-droite ($x > \bar{x}$ et $y > \bar{y}$: produit de deux écarts positifs) et bas-gauche (produit de deux écarts négatifs, donc positif). Les deux autres quadrants produisent des contributions négatives. Les unités changent la grandeur des contributions, jamais leur signe.

Q2 — Faux. La valeur p est la probabilité, *sous H_0*, d'obtenir un $|r|$ au moins aussi grand que celui observé. Elle n'est ni $P(H_0 \text{ vraie})$, ni une taille d'effet (rappel du cours 4 : toute lecture de p commence par « sous H_0… »).

Q3 — B. La relation est monotone (croissante) mais courbe : Spearman, qui travaille sur les rangs, en mesure la force ; Pearson la sous-estimerait. La covariance n'est pas comparable entre jeux de données, et R^2 juge une droite déjà ajustée.

Q4 — Faux. $R^2 = 0{,}64$ signifie que la droite *élimine 64 % de la somme des erreurs au carré* de la stratégie « toujours la moyenne », sur les données d'ajustement. Il ne dit rien de la proportion de prédictions exactes — une droite peut n'atteindre exactement aucun point avec un R^2 élevé.

Q5. On évalue la droite en $x = \bar{x}$: $\hat{y}(\bar{x}) = a\bar{x} + b = a\bar{x} + (\bar{y} - a\bar{x}) = \bar{y}$. La prédiction au point $\bar{x}$ vaut donc $\bar{y}$: le point des moyennes $(\bar{x}, \bar{y})$ appartient toujours à la droite des moindres carrés — que des données s'y trouvent ou non.

Q6 — B. La taille de l'incendie est liée aux deux variables : les gros incendies mobilisent plus de pompiers *et* causent plus de dégâts. Conclure « les pompiers aggravent les dégâts » serait lire la confusion comme une cause.

Q7 — Faux. Le plan croisé neutralise les différences *stables* entre clients (chacun est son propre témoin) et l'ordre est tiré au hasard, mais il reste exposé au report d'achats entre visites (effet persistant), aux différences de période (soldes, paie) et aux visites manquées. Ces limites se déclarent dans la conclusion.

Q8. La **randomisation** est la *procédure* : attribuer au hasard les unités entre les conditions, ce qui rend les groupes comparables en moyenne sur toutes leurs caractéristiques. Le **groupe témoin** est le *résultat utile* de cette procédure : le groupe sans intervention, qui approche le contrefactuel collectif. Sans randomisation, les groupes diffèrent avant même l'intervention (biais de sélection) ; sans groupe témoin, rien ne sert de point de comparaison.

9.2 Application guidée — corrigé pas à pas

1. Moyennes. $\bar{x} = (4 + 8 + 12 + 16 + 20 + 24)/6 = 84/6 = 14$ °C ; $\bar{y} = 185/6 \approx 30{,}83$ unités.

2. Covariance. Écarts en X : -10, -6, -2, $+2$, $+6$, $+10$; écarts en Y : +16,17, +8,17, +3,17, −3,83, −7,83, −15,83. Contributions : −161,7, −49,0, −6,3, −7,7, −47,0, −158,3 ; somme = −430. $\mathrm{Cov} = -430/5 = -86$ °C·unité. On divise par $n - 1 = 5$ car il s'agit d'un échantillon (convention du cours 1).

3. Corrélation. $s_X s_Y = \sqrt{56 \times 133} \approx 86{,}3$; $r = -86/86{,}3 \approx -0{,}997$. Lecture en trois questions : *sens* — décroissant ; *force* — quasi alignement parfait ; *périmètre* — six semaines, un seul café : joli sur ces données, fragile à généraliser.

4. Droite. $a = -86/56 \approx -1{,}54$ unité par degré ; $b = 30{,}83 - (-1{,}54) \times 14 \approx 52{,}3$ unités. $\hat{y} = -1{,}54x + 52{,}3$. Vérification : $\hat{y}(14) = 30{,}8 \approx \bar{y}$ — le point des moyennes est sur la droite.

5. Prédiction à 10 °C. $\hat{y}(10) \approx -15{,}4 + 52{,}3 \approx 37$ unités. C'est une **interpolation** (10 °C est dans la plage 4–24 °C) : formulation correcte : « une semaine à 10 °C donnerait, sur ces données, environ 37 ventes en moyenne ».

6. Résidus et R^2. Prédictions : 46,2 ; 40,0 ; 33,9 ; 27,8 ; 21,6 ; 15,5. Résidus : +0,8 ; −1,0 ; +0,1 ; −0,8 ; +1,4 ; −0,5 (somme ≈ 0 — bon signe). $SSE \approx 4{,}5$; $R^2 = 1 - 4{,}5/664{,}8 \approx 0{,}993$. Signification exacte : la droite élimine 99,3 % de la somme des erreurs au carré de la stratégie « toujours la moyenne », *sur ces six semaines*.

7. « La chaleur fait baisser les ventes » ? L'association est très forte mais reste une association : rien n'a été attribué au hasard, la température varie avec la saison (qui change aussi les habitudes), et $n = 6$ rend la pente instable d'un échantillon à l'autre. Formulation professionnelle : « sur ces six semaines, ventes et température évoluent en sens opposé de façon quasi linéaire ; pour affirmer un effet de la température, il faudrait plus de semaines et un contrôle des autres variables saisonnières ».

9.3 Application autonome — corrigés

Exercice 1 — Livraisons Nord/Sud

1. Qualité (cours 3). Date au 30/02/2026 : valeur impossible, format non corrigeable sans connaître la bonne date → **bloquante pour la ligne**, renvoi à la source après marquage « à vérifier ». Délai de −12 min : violation de domaine (un délai est positif) → **bloquante pour la ligne**, même conduite. Trois doublons exacts : **alerte** — probable double enregistrement ; exclusion des copies après vérification auprès de la source, en comptant les exclusions par entrepôt. Règle d'or : original intact, journal des corrections (règle appliquée, lignes concernées, justification), revalidation après chaque vague de corrections.

2. Comparaison des délais (cours 4). Deux groupes indépendants, non appariés, variances manifestement proches mais non garanties égales → **test t de Welch** (le choix par défaut, sans hypothèse de variances égales), bilatéral puisqu'aucune direction n'était annoncée. H_0 : $\mu_{\text{Sud}} - \mu_{\text{Nord}} = 0$. Résultats : $t \approx 4{,}7$, $p < 0{,}001$ → écart *statistiquement significatif*. Conclusion complète : « Sud livre en moyenne **2,4 min plus vite** que Nord, IC à 95 % [1,4 ; 3,4] — un écart établi sous les hypothèses du test, dont l'importance pratique (≈ 7 % du délai moyen) reste à arbitrer avec le métier ».

3. Délai et satisfaction. Observation : tendance négative nette sur l'ensemble ($r = -0{,}34$), quasi nulle dans chaque entrepôt ($-0{,}05$ et $-0{,}07$). C'est un **effet de composition** : Nord cumule délais longs *et* notes basses (4,1), Sud délais courts et notes hautes (4,4) ; le mélange dessine une pente que ni l'un ni l'autre ne possède. Explication : les deux entrepôts servent des clientèles ou des zones différentes ; l'écart global reflète surtout cette différence de composition, pas un effet du délai sur la note. Conclusion : pas de preuve, ici, que réduire le délai améliorerait la note *au sein d'un entrepôt*.

4. Choix du coefficient. La note est **ordinale** (1 à 5) et concentrée sur 4 et 5 : distribution très asymétrique, loin des conditions de Pearson. On privilégie **Spearman** (rangs, robuste, adapté aux échelles ordinales) — calculé *par entrepôt*, conformément au point 3.

5. Synthèse attendue. « Sud livre significativement plus vite que Nord (2,4 min d'écart moyen [1,4 ; 3,4] ; l'importance est à juger métier). L'écart de satisfaction entre les deux entrepôts ne s'explique *pas* par les délais : le lien délai–note est nul dans chaque entrepôt — l'apparence de lien global vient de la composition. Piste : enquêter sur les causes propres de l'écart de notes (clientèle, organisation, collecte des notes), en gardant l'analyse par entrepôt comme réflexe. »

Exercice 2 — Promotion en libre-service

1. Conclusion prématurée. Les utilisateurs de la borne se sont *choisis* : **biais de sélection**. Explications alternatives : (a) ce sont des clients plus dépensiers ou plus engagés *avant* la promotion (confusion par l'engagement) ; (b) un gros achat prévu motive l'usage de la borne — la relation s'inverse ; (c) la promotion s'active sur des produits déjà dans le panier — l'écart mesure alors le choix des produits éligibles, pas un effet sur le panier. Les +6,40 € mélangent tous ces ingrédients.

2. Essai randomisé. *Intervention* : proposer la promotion à la borne (vs non). *Groupes* : clients éligibles répartis par **tirage au sort** — par exemple 200 « promotion proposée » / 200 « témoin » sur 400 clients ; le hasard seul rend les groupes comparables en moyenne, y compris sur les caractéristiques non mesurées. *Mesure* : panier avant remise, identique pour tous. *Analyse* : en **intention de traiter** — les clients assignés « promotion » qui ne l'ont pas activée *restent* dans leur groupe ; les retirer recréerait un biais de sélection. La comparaison des deux groupes entiers estime l'effet *de la proposition*, à déclarer avec son périmètre (enseigne, période, clientèle).

3. Variante plan croisé. Pour les clients réguliers : chaque client vit des visites « avec » et « sans » promotion selon une séquence tirée au hasard ; on compare, client par client, le panier moyen « avec » au panier moyen « sans ». Chacun est son propre témoin — les différences de budget s'annulent. *Limites à surveiller* : report d'achats sur les visites « avec » (effet persistant), périodes non comparables (soldes, paie, météo), visites manquées déséquilibrant les séquences, apprentissage du dispositif par les clients.

4. R^2 = 0,52. Signification exacte : la droite « panier en fonction de l'ancienneté » élimine **52 % de la somme des erreurs au carré** de la stratégie « toujours prédire le panier moyen », *sur les données d'ajustement*. Ce qu'il ne permet pas de dire : (a) que l'ancienneté *cause* le panier — un R^2 élevé peut refléter une pure confusion (revenu, fidélité) ; (b) que 52 % des paniers sont bien prédits individuellement ; (c) que le modèle prédira aussi bien de *nouveaux* clients — c'est l'objet du cours 6.