Bloc II — Raisonnement statistique

Cours 6
Évaluer un modèle prédictif : jeux de données, erreurs et surapprentissage

À l'issue de ce cours, vous saurez évaluer un modèle de prédiction sur des données qu'il n'a jamais vues, choisir entre plusieurs candidats sans vous tromper de critère, et reconnaître le surapprentissage.

Formation Data Analyst — Novembre 2026

Sommaire

1. Objectifs d'apprentissage

2. Prérequis et rappels

3. Pourquoi c'est important

4. Corps du cours

PARTIE A — PRÉDIRE : UNE AMBITION À PART

4.1 Décrire, expliquer, prédire : trois ambitions différentes
4.2 Le modèle et l'ajustement : la famille des polynômes
4.3 Du résidu à la MAE : mesurer la taille des erreurs

PARTIE B — LE PROTOCOLE DES TROIS JEUX

4.4 Les trois jeux de données : ajuster, choisir, évaluer
4.5 Une même mesure, deux usages : la comparaison des candidats

PARTIE C — COMPRENDRE LE SURAPPRENTISSAGE

4.6 Le surapprentissage : suivre les points, perdre ailleurs
4.7 Le compromis biais–variance
4.8 La validation croisée : ne plus dépendre d'un seul découpage

PARTIE D — CHOISIR SES REPÈRES

4.9 Choisir sa mesure d'erreur : MAE, RMSE, erreur médiane
4.10 Le modèle de référence : le minimum à battre

PARTIE E — LES LIMITES DE L'ÉVALUATION

4.11 La fuite de données : la séparation par groupe
4.12 Règle connue contre coefficients estimés
4.13 Le périmètre de validité du modèle

5. Erreurs fréquentes et pièges

6. Exercices

6.1 Auto-évaluation
6.2 Application guidée
6.3 Applications autonomes

7. Fiche récapitulative

8. Pour aller plus loin

9. Corrigé des exercices

1. Objectifs d'apprentissage

À l'issue de ce cours, vous saurez :

- **expliquer** pourquoi la qualité d'une prédiction se juge sur des observations qui n'ont pas servi à construire le modèle ;
- **attribuer** le bon rôle à chaque jeu de données — entraînement, validation, test — et respecter l'usage unique du test final ;
- **mesurer** l'erreur d'un modèle (MAE, RMSE) et **comparer** plusieurs modèles candidats sans se tromper de critère ;
- **reconnaître** le surapprentissage dans un tableau de résultats et le **relier** au compromis biais–variance ;
- **prévenir** la fuite de données en séparant les observations par groupe, et **définir** le périmètre de validité d'un modèle.

2. Prérequis et rappels

Prérequis. Cours 5 (association, régression linéaire et causalité) : vous savez ajuster une droite par moindres carrés, calculer un résidu et lire un R^2. Les notions des cours 1 (moyenne, écart absolu) et 2 (variation d'échantillonnage, simulation) seront aussi mobilisées.

Rappels utiles pour ce cours.

- La **droite des moindres carrés** (cours 5) est le modèle qui minimise la somme des carrés des écarts verticaux entre points observés et prédictions.
- Le **résidu** (cours 5) est l'écart signé entre la valeur observée et la valeur prédite : $e_i = y_i - \hat{y}_i$. La somme des résidus d'une droite ajustée vaut zéro.
- Le **R^2** (cours 5) compare la droite à la stratégie « toujours prédire la moyenne » — nous retrouverons cette référence en section 4.10.
- Deux échantillons d'une même population diffèrent par pur hasard : c'est la **variation d'échantillonnage** (cours 2). En simulation, une graine fixée rend les tirages reproductibles.

3. Pourquoi c'est important

Vous êtes analyste dans un entrepôt de préparation de commandes. Pour planifier les équipes de demain, votre direction vous demande un modèle qui prévoit la **durée de préparation** d'une commande à partir de son **nombre d'articles**. Vous ajustez une courbe sur les commandes de la semaine : elle passe presque par tous les points. Vous annoncez fièrement une erreur moyenne d'une minute. Trois jours plus tard, en production, le modèle se trompe en moyenne de six minutes et la planification s'effondre. Que s'est-il passé ? Vous avez mesuré la performance du modèle sur les mêmes commandes qui ont servi à le construire.

Cette mésaventure est l'une des plus fréquentes — et des plus coûteuses — du métier. Un modèle peut être brillant sur les données qu'il connaît et médiocre sur toutes les autres. Inversement, un modèle plus simple, moins flatteur sur le papier, peut être le seul à tenir ses promesses face à de nouvelles commandes. Savoir distinguer ces deux situations n'est pas un raffinement : c'est ce qui sépare une analyse crédible d'une promesse en l'air.

Ce cours vous donne le protocole complet : séparer les données en trois jeux aux rôles distincts, mesurer l'erreur avec une métrique choisie à l'avance, comparer les modèles sur le bon jeu, reconnaître le surapprentissage, et annoncer le périmètre dans lequel l'évaluation vaut. Ces réflexes serviront dans tous les cours suivants — séries temporelles, classification, projets — chaque fois qu'un modèle prétendra prédire.

4. Corps du cours

PARTIE A — PRÉDIRE : UNE AMBITION À PART

4.1 Décrire, expliquer, prédire : trois ambitions différentes

Depuis le cours 1, vous décrivez des données et vous testez des liens entre variables. Avec ce cours, une troisième ambition apparaît : **prédire**. Ces trois ambitions se ressemblent — elles utilisent les mêmes tableaux et parfois les mêmes formules — mais elles ne se jugent pas de la même façon.

- **Décrire** : résumer les données que vous avez. « La durée médiane de préparation cette semaine est de 11 minutes. » La qualité se juge à la fidélité du résumé.
- **Expliquer** : comprendre un mécanisme, identifier une cause. « La durée augmente avec le nombre d'articles *parce que* chaque article ajoute un trajet en rayon. » La qualité se juge par un dispositif de collecte adapté (cours 5, de l'association à la causalité).
- **Prédire** : annoncer la valeur d'une observation *que vous n'avez pas*. « Cette commande de 12 articles prendra environ 14 minutes. » La qualité se juge sur des observations *autres* que celles qui ont servi à construire le modèle.

C'est ce troisième point qui change tout. Un modèle prédictif ne sert que s'il reste bon sur des cas nouveaux : la commande de demain, le client de la semaine prochaine. Le juger sur les données déjà utilisées pour le construire, c'est comme interroger un élève avec les exercices qu'il vient de corriger en classe.

> **Définition.** Un **modèle prédictif** (*predictive model*) est une règle de calcul qui associe à des variables d'entrée une valeur prédite pour une variable cible, dans le but d'être appliqué à des observations nouvelles. Sa qualité se mesure par l'erreur commise sur des observations qui n'ont servi ni à le construire ni à le choisir.

> **Analogie.** Un professeur qui veut savoir si ses élèves ont compris ne leur repose pas les exercices déjà corrigés ensemble : il leur donne des exercices *inédits*. Réussir les exercices corrigés prouve qu'on les a mémorisés ; réussir des exercices nouveaux suggère qu'on a compris. Pour un modèle, c'est pareil : la réussite sur les données d'apprentissage prouve qu'il les a « mémorisées », pas qu'il prédit bien.

Voici la situation qui servira de fil rouge à tout le cours. Un entrepôt a enregistré 344 commandes : pour chacune, le nombre d'articles et la durée de préparation en minutes. L'objectif : prévoir la durée de préparation des *prochaines* commandes, pour planifier les équipes.

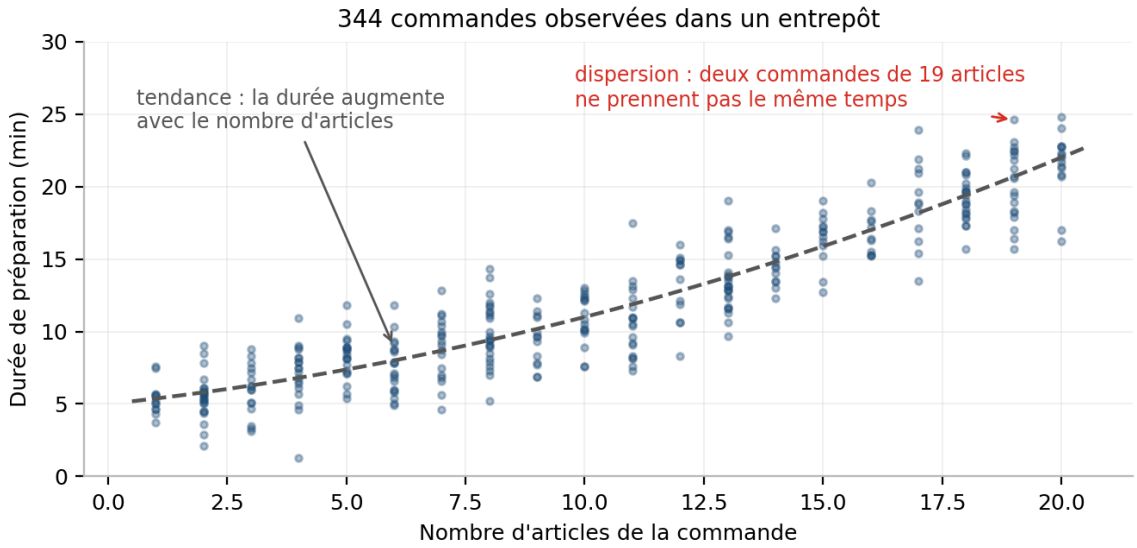


Figure 1 : les 344 commandes du fil rouge. Chaque point est une commande. La durée augmente avec le nombre d'articles (tendance), mais deux commandes identiques en articles ne prennent jamais exactement le même temps (dispersion).

Exemple guidé — Classer trois questions de l'entrepôt.
Le responsable logistique pose trois questions. Classons-les par ambition.

1. « Quelle a été la durée moyenne de préparation le mois dernier ? » → **décrire** : la question porte sur des données déjà connues, la réponse est un résumé.
2. « Les commandes du matin sont-elles préparées plus vite *parce que* les équipes sont reposées ? » → **expliquer** : il faut un dispositif qui isole la cause (cours 5) ; un simple lien observé ne suffit pas.
3. « Combien de temps prendra la commande de 15 articles qui vient d'arriver ? » → **prédire** : la commande n'a pas encore été préparée ; la réponse se vérifiera sur du nouveau.

La question 3 est celle du fil rouge. Elle appelle un modèle — et une évaluation à la hauteur de son ambition.

À retenir

- Décrire, expliquer et prédire sont trois ambitions différentes, qui se jugent différemment.
- Un modèle prédictif se juge sur des observations **nouvelles**, jamais sur celles qui ont servi à le construire.
- Fil rouge du cours : prédire la durée de préparation d'une commande (en minutes) à partir de son nombre d'articles.

4.2 Le modèle et l'ajustement : la famille des polynômes

Au cours 5, vous avez résumé un nuage de points par une droite : c'était déjà un modèle, avec deux coefficients (la pente et l'ordonnée à l'origine) calculés sur les données. Ici, nous élargissons la famille : au lieu d'une droite, on autorise des **courbes** de plus en plus souples — les **polynômes**.

Un polynôme ajoute des termes en puissances de x : terme en x^2 pour une courbure simple, termes jusqu'en x^{12} pour une courbe très souple. La plus haute puissance s'appelle le **degré**. Plus le degré est élevé, plus la courbe peut onduler pour passer près des points.

Définition. **Ajuster** un modèle (*model fitting*) consiste à calculer ses coefficients à partir des observations d'entraînement, en minimisant une mesure d'écart — pour les polynômes de ce cours, la somme des carrés des résidus (moindres carrés, cours 5). Le **degré** (*degree*) d'un polynôme est la plus haute puissance de la variable d'entrée qu'il contient ; il règle sa **souplesse** (*flexibility*).

$$\hat{y} = a_0 + a_1 x + a_2 x^2 + \cdots + a_d x^d$$

$\hat{y}$: durée prédite de la commande (min) ;
x : nombre d'articles de la commande ;
$a_0, a_1, \ldots, a_d$: coefficients, calculés lors de l'ajustement ;
d : degré du polynôme, choisi par l'analyste.

Comment lire cette formule. Chaque terme ajoute une façon de plier la courbe : a_0 fixe la hauteur, $a_1 x$ la pente, $a_2 x^2$ une courbure, et les termes suivants des ondulations de plus en plus fines. Le degré 0 (aucun terme en x) prédit une constante : « toujours la moyenne ». Le degré 1 est la droite du cours 5. Le degré d se choisit *avant* l'ajustement ; les coefficients se calculent *pendant*. C'est le degré que ce cours va apprendre à choisir.

Analogie. Un polynôme de haut degré est comme un costume ajusté au millimètre sur une personne précise : il lui va parfaitement, et à personne d'autre. Un costume trop simple (un poncho) va à tout le monde mais ne va à personne. Entre les deux se trouve la coupe qui convient à la morphologie « en général » — c'est elle que l'on cherche.

Pour le fil rouge, nous annonçons **quatre candidats** — annoncer les candidats *avant* de les comparer est une discipline à conserver, elle évite de bricoler la comparaison après coup :

- **degré 0 — la constante** : prédit toujours la durée moyenne des commandes d'entraînement ;
- **degré 1 — la droite** : une augmentation constante de durée par article ;
- **degré 2 — la courbe simple** : une courbure, grâce au terme en x^2 ;
- **degré 12 — la courbe très souple** : des termes jusqu'en x^{12}, capable d'épouser presque chaque point.

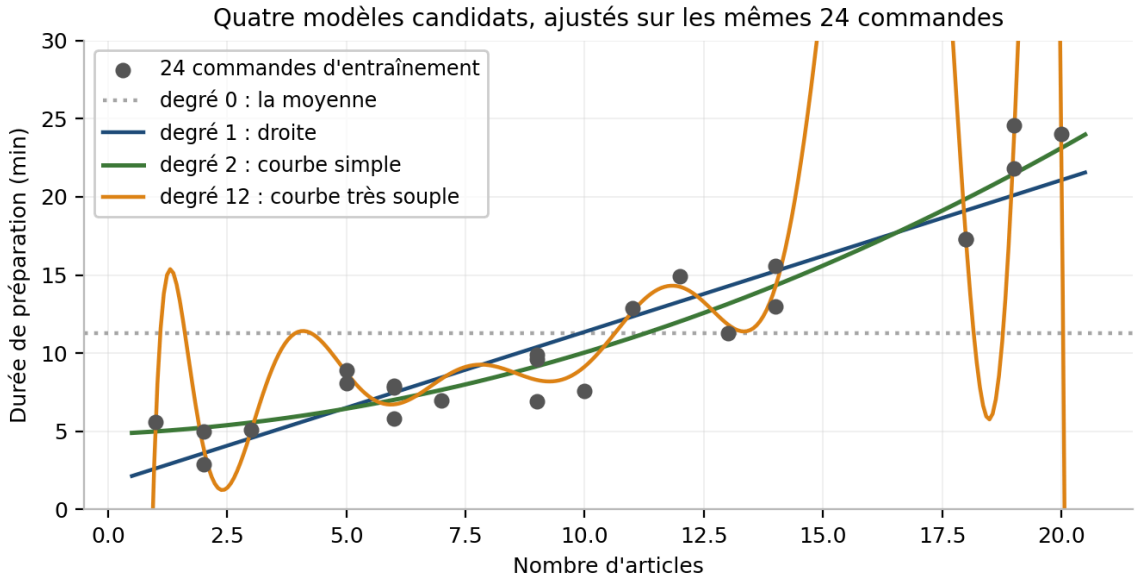


Figure 2 : les quatre candidats ajustés sur les mêmes 24 commandes d'entraînement. La courbe de degré 12 (orange clair) ondule pour passer au plus près des points ; la droite et la courbe simple restent régulières.

Exemple guidé — Lire la figure avant de mesurer.
Avant tout calcul, examinons la figure 2 et formulons une prévision (se forcer à prédire avant de voir le résultat est un excellent entraînement).

1. **Quelle courbe est la plus proche des 24 points ?** La courbe de degré 12 : elle ondule pour frôler presque chaque point. Sur ces commandes-là, elle fera la plus petite erreur.
2. **Où la courbe de degré 12 fait-elle des écarts étranges ?** Aux bords et entre les points : elle plonge et remonte brutalement (par exemple vers 2 et vers 18–20 articles), là où aucune commande ne la retient.
3. **Prévision.** Sur de *nouvelles* commandes, les zigzags du degré 12 tomberont probablement à côté. La droite et la courbe simple, plus régulières, devraient mieux s'en sortir. Nous vérifierons cette prévision chiffre à l'appui en section 4.5.

En pratique dans le code. Pour ajuster un polynôme de degré `d` sur les données d'entraînement : `model = Polynomial.fit(x_train, y_train, deg=d)` (module `numpy.polynomial`). La prédiction sur de nouvelles lignes s'écrit `model(x_nouveau)` — les coefficients ne changent pas. `np.polyfit(x, y, d)` (cours 5) fait le même travail.

À retenir

- Ajuster = calculer les coefficients du modèle sur les données d'entraînement (moindres carrés ici).
- Le degré règle la souplesse : degré 0 = constante, degré 1 = droite, degrés élevés = courbes très souples.
- On annonce les candidats et le critère de choix **avant** de comparer les résultats.

4.3 Du résidu à la MAE : mesurer la taille des erreurs

Pour comparer nos quatre candidats, il faut un chiffre qui résume « à quel point un modèle se trompe ». Le résidu (cours 5) donne l'erreur *commande par commande* : écart signé entre la durée observée et la durée prédite. Un résidu de +3 minutes signifie que la commande a pris trois minutes de plus que prévu ; −2 minutes, deux minutes de moins.

Pour résumer un ensemble de résidus en un seul nombre, une idée naïve serait d'en faire la moyenne. Elle échoue : les signes s'annulent — un modèle qui se trompe de +10 puis −10 minutes afficherait une erreur moyenne de zéro. On neutralise les signes en prenant la **valeur absolue** de chaque résidu, puis on fait la moyenne. C'est la MAE.

Définition. L'**erreur absolue moyenne**, notée **MAE** (*mean absolute error*), est la moyenne des valeurs absolues des résidus sur un jeu d'observations. Elle s'exprime dans l'unité de la variable prédite : une MAE de 2 minutes signifie que le modèle se trompe en moyenne d'environ 2 minutes sur ce jeu.

$$\text{MAE} = \frac{1}{n}\sum_{i=1}^{n} |y_i - \hat{y}_i|$$

n : nombre d'observations évaluées ;
y_i : valeur observée de la i-ème observation (min) ;
$\hat{y}_i$: valeur prédite par le modèle pour cette observation (min) ;
$|y_i - \hat{y}_i|$: valeur absolue du résidu (min).

Comment lire cette formule. Pour chaque observation, on calcule le résidu, on retire son signe (la valeur absolue), puis on fait la moyenne de toutes ces erreurs positives. La valeur absolue empêche les erreurs de signes opposés de se compenser : la MAE ne vaut zéro que si *toutes* les prédictions sont exactes. Plus elle est petite, mieux le modèle prédit — *sur le jeu évalué*, précision qui deviendra centrale à la section suivante.

Analogie. Pour juger la ponctualité d'un transporteur, ce qui compte c'est la *taille* des retards et des avances, pas leur direction : arriver 3 minutes en avance puis 3 minutes en retard ne fait pas une journée « à l'heure ». La MAE raisonne pareil : elle compte la taille de chaque écart, sans jamais laisser une avance effacer un retard.

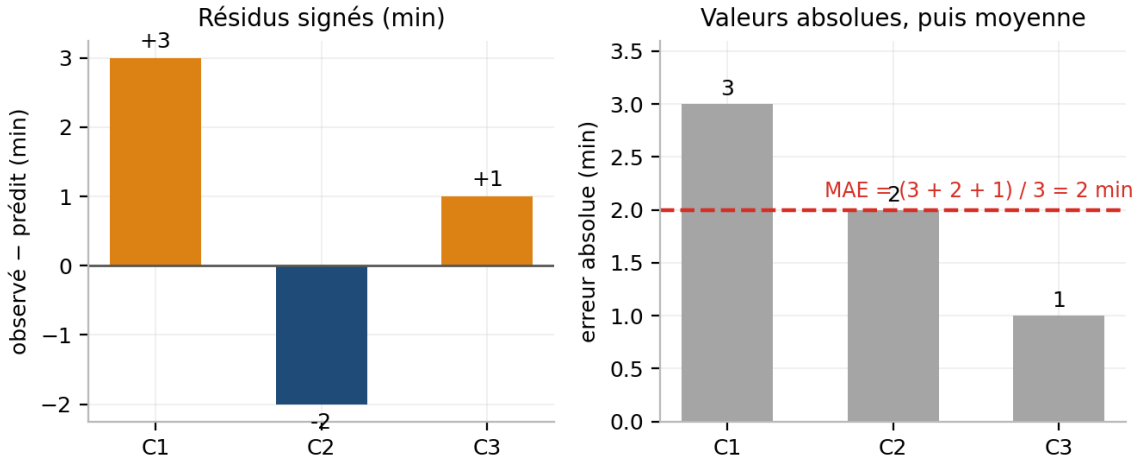


Figure 3 : de trois résidus signés (+3, −2, +1 minute) à la MAE. À gauche, les signes s'annuleraient dans une moyenne simple ; à droite, on moyenne les valeurs absolues : MAE = 2 minutes.

Exemple guidé — Calculer une MAE à la main.
Trois commandes de validation ; le modèle (déjà ajusté, coefficients inchangés) a prédit leurs durées. Les résidus valent +3, −2 et +1 minute. On calcule la MAE en trois temps :

1. **Écrire les résidus signés** : +3 ; −2 ; +1. Le signe dit le sens de l'erreur — la commande C1 a pris plus de temps que prévu — mais pas sa gravité.
2. **Prendre les valeurs absolues** : 3 ; 2 ; 1. Les signes ne peuvent plus s'annuler.
3. **Faire la moyenne** : (3 + 2 + 1) / 3 = 6 / 3 = **2 minutes**. En moyenne, le modèle se trompe de 2 minutes sur ces trois commandes.

On a fait X parce que… : la valeur absolue avant la moyenne, sinon +3 et −3 se neutralisent et masquent deux erreurs réelles.

En pratique dans le code. `np.mean(np.abs(y - y_chapeau))` calcule la MAE avec numpy ; `mean_absolute_error(y, y_chapeau)` fait la même chose avec scikit-learn.

À retenir

- La MAE = moyenne des valeurs absolues des résidus ; elle s'exprime dans l'unité de la variable prédite.
- La valeur absolue empêche les erreurs positives et négatives de s'annuler.
- Une MAE se lit toujours avec le nom du jeu évalué : « MAE de 2 minutes *sur ces trois commandes* ».

PARTIE B — LE PROTOCOLE DES TROIS JEUX

4.4 Trois jeux, trois rôles : entraînement, validation, test

Revenons à la mésaventure de la section 3 : le modèle était bon sur les commandes qu'il connaissait, mauvais sur les suivantes. La leçon : on ne peut pas se servir des mêmes données pour *construire* un modèle et pour *juger* ses prédictions. La solution standard consiste à tirer au hasard trois sous-ensembles — trois **jeux de données** — chacun avec un rôle précis et exclusif.

- Le **jeu d'entraînement** sert à ajuster les modèles : c'est sur lui seul que les coefficients sont calculés.
- Le **jeu de validation** sert à *comparer* les candidats ajustés : c'est sur lui que l'on choisit le meilleur.
- Le **jeu de test** sert une seule fois, à la toute fin, pour *estimer* l'erreur du modèle retenu sur des données vraiment neuves.

Dans notre fil rouge : les 344 commandes sont mélangées au hasard (graine fixée, tirage reproductible, cours 2), puis réparties en **24 commandes d'entraînement, 160 de validation et 160 de test**. L'entraînement est volontairement petit — c'est une situation fréquente, et elle rendra les contrastes plus nets ; validation et test, plus grands, donnent des mesures d'erreur plus stables.

> **Définition.** Un **jeu d'entraînement** (*training set*) est le sous-ensemble des données utilisé pour ajuster les modèles. Un **jeu de validation** (*validation set*) est un sous-ensemble distinct, utilisé pour comparer les candidats et choisir entre eux. Un **jeu de test** (*test set*) est un sous-ensemble distinct des deux précédents, utilisé **une seule fois** pour estimer l'erreur du modèle retenu. Le découpage s'appelle la **répartition entraînement–validation–test** (*train/validation/test split*).

> **Analogie.** Un athlète s'entraîne sur ses parcours habituels (entraînement), dispute des courses de sélection pour décrocher sa place en finale (validation), puis court la finale — une seule fois — sur un parcours découvert le jour J (test). Utiliser les temps d'entraînement pour pronostiquer la finale serait tricher ; courir plusieurs « finales » pour garder le meilleur temps aussi.

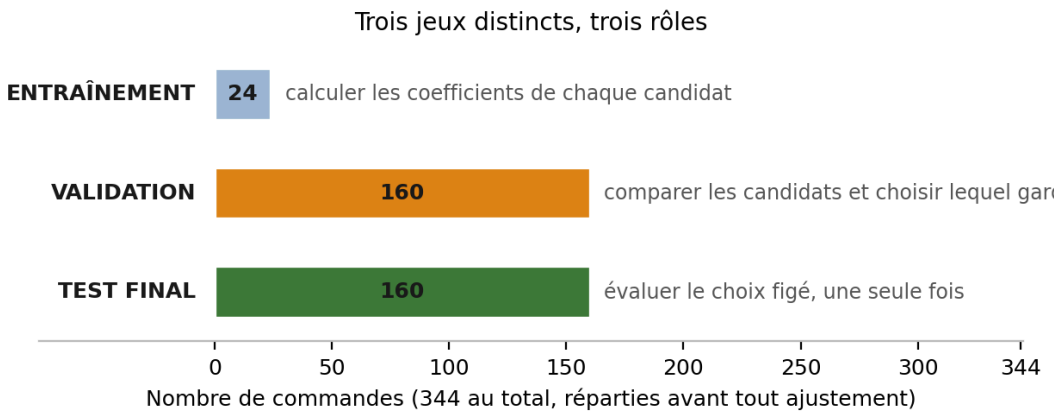


Figure 4 : répartition des 344 commandes en trois jeux disjoints. Le jeu de test (rouge) reste scellé jusqu'au choix final du modèle.

Deux règles disciplinaires découlent de cette répartition :

- **Les coefficients ne viennent que de l'entraînement.** Ni la validation ni le test ne servent jamais à ajuster un coefficient — sinon ils cessent d'être des juges neutres.
- **Le test ne s'utilise qu'une fois.** Si l'on regarde le test, que l'on change de candidat et que l'on regarde à nouveau, le test devient de la validation déguisée : on a choisi un modèle *parce qu'il* réussit sur lui. Son verdict n'est alors plus une estimation honnête de la performance future.

Exemple guidé — Attribuer chaque action au bon jeu.
Pour chaque action du projet fil rouge, indiquons sur quel jeu elle s'appuie et pourquoi.

1. **Calculer les coefficients des quatre polynômes.** → jeu d'*entraînement* (24 commandes) : c'est l'ajustement ; les coefficients ne doivent rien savoir des autres jeux.
2. **Comparer les MAE des quatre candidats pour en choisir un.** → jeu de *validation* (160 commandes) : comparer, c'est choisir ; le choix se fait hors de l'entraînement, mais sans toucher au test.
3. **Annoncer à la direction « le modèle retenu se trompera d'environ X minutes ».** → jeu de *test* (160 commandes), une seule fois, après le choix : seul un jeu jamais utilisé donne une estimation honnête.
4. **Tracer la figure 2 (les quatre courbes sur les points d'entraînement).** → entraînement : une figure pédagogique n'ajuste rien, mais par discipline on n'y montre que l'entraînement, pour ne pas laisser l'œil « choisir » sur la validation.

En pratique dans le code. `np.random.default_rng(graine).permutation(n)` mélange les indices de façon reproductible ; on découpe ensuite les tranches `[:24]`, `[24:184]`, `[184:]`. La fonction `train_test_split` de scikit-learn automatise ce découpage.

À retenir

- Entraînement = ajuster ; validation = choisir ; test = estimer une seule fois.
- Fil rouge : 24 commandes d'entraînement, 160 de validation, 160 de test, tirées au hasard.
- Réutiliser le test pour choisir un modèle le transforme en validation : son verdict n'est plus honnête.

4.5 Comparer les candidats sur la validation — et le test, une seule fois

Tout est en place : quatre candidats ajustés sur les 24 commandes d'entraînement, un critère annoncé (la MAE), deux jeux intacts. On calcule maintenant la MAE de chaque candidat, d'abord sur l'entraînement, puis sur la validation. Les deux colonnes racontent des histoires très différentes.

Candidat	MAE entraînement (min)	MAE validation (min)
Degré 0 — constante	4,99	4,21
Degré 1 — droite	1,77	1,78
Degré 2 — courbe simple	**1,50**	**1,61 ← minimum**
Degré 12 — courbe très souple	0,84	6,02

Tableau 1 : MAE des quatre candidats, calculées sur les commandes d'entraînement puis sur celles de validation. Le candidat retenu est celui qui minimise la MAE de validation.

La lecture du tableau est l'acte central du cours :

- Sur l'**entraînement**, les MAE diminuent toujours avec le degré : 4,99 → 1,77 → 1,50 → 0,84. C'est mécanique : un polynôme plus souple peut toujours se plier davantage vers les points qui ont servi à l'ajuster. Cette colonne ne dit rien sur la capacité à prédire.
- Sur la **validation**, la MAE descend puis explose : le degré 12, champion de l'entraînement (0,84), devient le pire sur du nouveau (6,02). Le **degré 2** présente la plus petite MAE de validation (1,61) : c'est lui que l'on retient.

Le choix est fait, le test peut être descellé — **une seule fois**. Sur les 160 commandes de test, le degré 2 obtient une MAE de **1,79 minute**. C'est ce chiffre, et lui seul, que l'on annonce à la direction : « le modèle retenu se trompe en moyenne d'environ 1,8 minute sur des commandes comparables à celles-ci ». Le test étant un échantillon comme un autre, sa MAE diffère un peu de celle de la validation (1,61) : c'est la variation d'échantillonnage du cours 2, pas un mystère.

Définition. La **capacité de généralisation** (*generalization*) d'un modèle est sa capacité à bien prédire sur des observations nouvelles, issues de la même population que les données d'entraînement. Elle s'estime par l'erreur mesurée sur le jeu de test, une fois le modèle choisi.

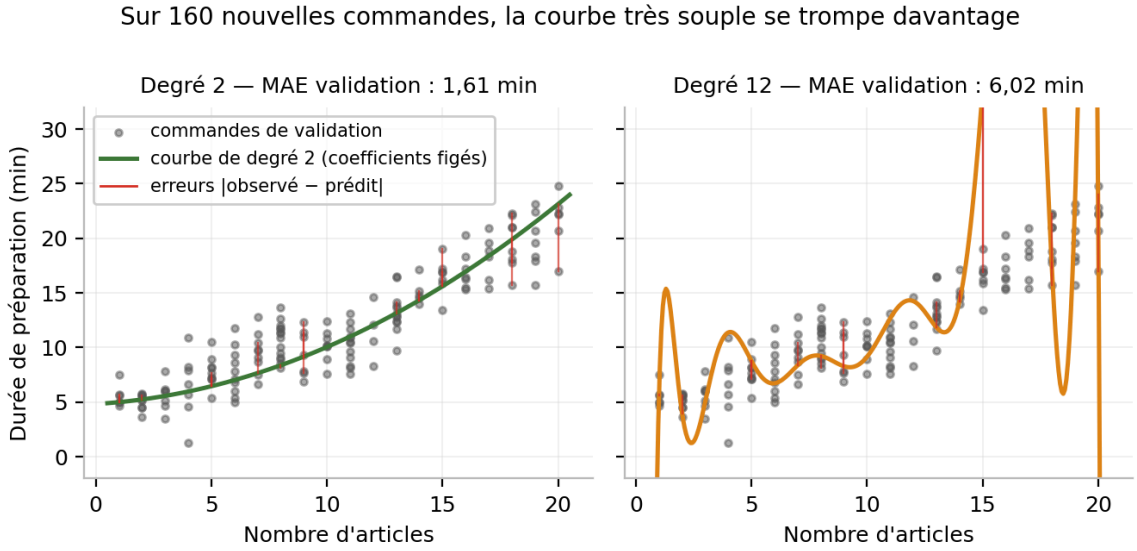


Figure 5 : MAE des quatre candidats sur l'entraînement (bleu) et sur la validation (orange). L'écart béant du degré 12 est la signature du surapprentissage, étudié en 4.6.

Analogie. La colonne « entraînement » est le bulletin de notes sur les exercices corrigés en classe ; la colonne « validation », celui des devoirs surveillés blancs. Un élève peut avoir 20/20 en classe et 8/20 au devoir blanc : c'est le devoir blanc qui prédit l'examen. Et l'examen — le test — ne se passe qu'une fois.

Exemple guidé — Conduire la comparaison de bout en bout.
Reprenons le protocole dans l'ordre, comme dans le projet réel.

1. **Avant tout calcul**, on a annoncé : quatre candidats (degrés 0, 1, 2, 12), critère de choix = MAE de validation la plus petite, verdict final = MAE de test du retenu.
2. **Ajuster** les quatre candidats sur les 24 commandes d'entraînement — aucune autre donnée ne touche les coefficients.
3. **Évaluer** chaque candidat sur la validation (tableau 1) : le degré 2 gagne avec 1,61 min.
4. **Figé le choix** : à partir d'ici, plus aucune comparaison de candidats — le rôle de la validation est terminé.
5. **Ouvrir le test une seule fois** : MAE de 1,79 min pour le degré 2. On annonce ≈ 1,8 minute d'erreur moyenne, en précisant le périmètre (commandes de 1 à 20 articles, voir 4.13).
6. **Ne pas revenir en arrière** : si le test avait déçu, la bonne réponse aurait été de documenter l'échec — pas de choisir un autre candidat « qui marche mieux sur le test ».

On a fait X parce que… : chaque étape consomme un jeu et un seul ; mélanger les rôles rend tous les chiffres invérifiables.

À retenir

- Sur l'entraînement, l'erreur baisse toujours avec la souplesse : cette colonne ne sert pas à choisir.
- Le choix du candidat se fait sur la validation ; le verdict final sur le test, une seule fois.
- Fil rouge : degré 2 retenu (validation 1,61 min ; test 1,79 min) ; le degré 12 s'effondre sur du nouveau.

4.6 Surapprentissage et sous-apprentissage

Le tableau 1 a révélé un phénomène qui porte un nom : le degré 12 **surapprend**. Sa courbe épouse si bien les 24 commandes d'entraînement qu'elle en mémorise le détail — y compris la part de hasard qui ne se reproduira pas. Face à des commandes nouvelles, ce détail appris par cœur devient un handicap.

Pour comprendre ce que le degré 12 mémorise, rappelons la structure des données (cours 2 et 5) : chaque durée observée combine une **tendance** — la même pour toutes les commandes — et une **dispersion** — l'écart aléatoire de chaque commande autour de la tendance. Un bon modèle doit capter la tendance et *ignorer* la dispersion. Le degré 12 fait l'inverse : il ajuste ses zigzags à la dispersion particulière de ses 24 points.

> **Définition.** Il y a **surapprentissage** (*overfitting*) lorsqu'un modèle s'ajuste non seulement à la tendance des données d'entraînement, mais aussi à leur dispersion aléatoire : son erreur sur l'entraînement devient artificiellement basse tandis que son erreur sur des données nouvelles se dégrade. À l'inverse, il y a **sous-apprentissage** (*underfitting*) lorsque le modèle est trop simple pour capter la tendance elle-même : son erreur reste élevée sur tous les jeux.

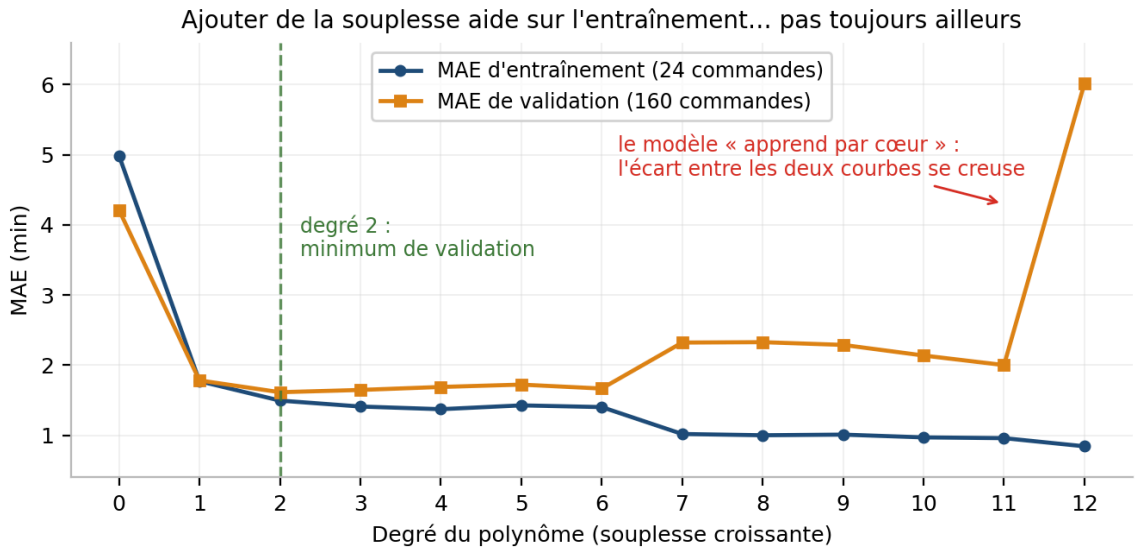


Figure 6 : MAE d'entraînement (bleu) et de validation (orange) en fonction du degré. L'entraînement ne cesse de s'améliorer ; la validation s'améliore puis se dégrade : son minimum marque la bonne souplesse.

La figure 6 donne la carte du problème. À gauche, le degré 0 **sous-apprend** : une constante ne peut pas suivre une tendance croissante — erreur élevée partout (environ 5 et 4 minutes). Au centre, le degré 2 capte la tendance sans épouser la dispersion : c'est le creux de la courbe orange. À droite, les degrés élevés **surapprennent** : la courbe bleue s'écrase vers zéro pendant que l'orange remonte en flèche. L'écart qui se creuse entre les deux courbes est la signature visuelle du surapprentissage.

> **Analogie.** Un élève qui récite sa leçon mot à mot sans la comprendre sera déstabilisé par la moindre question reformulée ; un élève qui n'a pas du tout révisé ne peut répondre à aucune question. Entre les deux, celui qui a compris les idées générales répond même aux questions inédites. Sous-apprentissage, surapprentissage, généralisation : le modèle est cet élève.

Exemple guidé — Diagnostiquer à partir d'un tableau de MAE.
Trois modèles évalués sur les mêmes données : A (entraînement 0,9 min, validation 5,8 min), B (entraînement 4,8 min, validation 4,9 min), C (entraînement 1,6 min, validation 1,7 min). Diagnostiquons chacun.

1. **A** : écart énorme entre les deux colonnes (0,9 contre 5,8) → **surapprentissage** : il a mémorisé l'entraînement, dispersion comprise.
2. **B** : les deux erreurs sont proches mais élevées → **sous-apprentissage** : il est trop simple pour la tendance.
3. **C** : erreurs proches et faibles → modèle **bien réglé** : la bonne souplesse pour ces données.

Le réflexe à acquérir : ne jamais lire la colonne « entraînement » seule ; c'est l'*écart* entre les deux colonnes qui diagnostique.

À retenir

- Surapprentissage : erreur d'entraînement très basse, erreur de validation dégradée → le modèle a mémorisé la dispersion.
- Sous-apprentissage : erreurs élevées sur les deux jeux → le modèle est trop simple pour la tendance.
- Le diagnostic se fait sur l'écart entre les deux colonnes, jamais sur l'entraînement seul.

4.7 Le compromis biais–variance

Pourquoi le degré 2 gagne-t-il, plutôt qu'un degré voisin ? Parce que l'erreur sur des données nouvelles a deux sources antagonistes, et qu'il faut les payer toutes les deux.

- La première source est l'erreur due à la **rigidité** du modèle — son **biais** au sens statistique : une constante ou une droite supposent une forme du monde, et si la vraie tendance est courbe, elles se tromperont *systématiquement*, de la même façon, sur tous les jeux.
- La seconde source est la **sensibilité au tirage** — la **variance** : un polynôme de degré 12 ajusté sur 24 commandes aurait donné des courbes très différentes sur 24 autres commandes ; il amplifie la variation d'échantillonnage du cours 2.

Augmenter la souplesse réduit le biais mais augmente la variance ; la réduire fait l'inverse. La bonne souplesse est un **compromis** : le point où la somme des deux contributions est la plus faible.

Définition. Le **biais** (*bias*) d'un modèle est l'erreur systématique due à sa rigidité : même avec d'énormes données, un modèle trop simple rate la vraie tendance. La **variance** (*variance*) d'un modèle est sa sensibilité au tirage de l'échantillon d'entraînement : plus le modèle est souple et les données rares, plus ses coefficients changent d'un échantillon à l'autre. Le **compromis biais–variance** (*bias-variance tradeoff*) est le fait que l'erreur sur données nouvelles résulte de ces deux contributions, que la souplesse déplace en sens inverse.

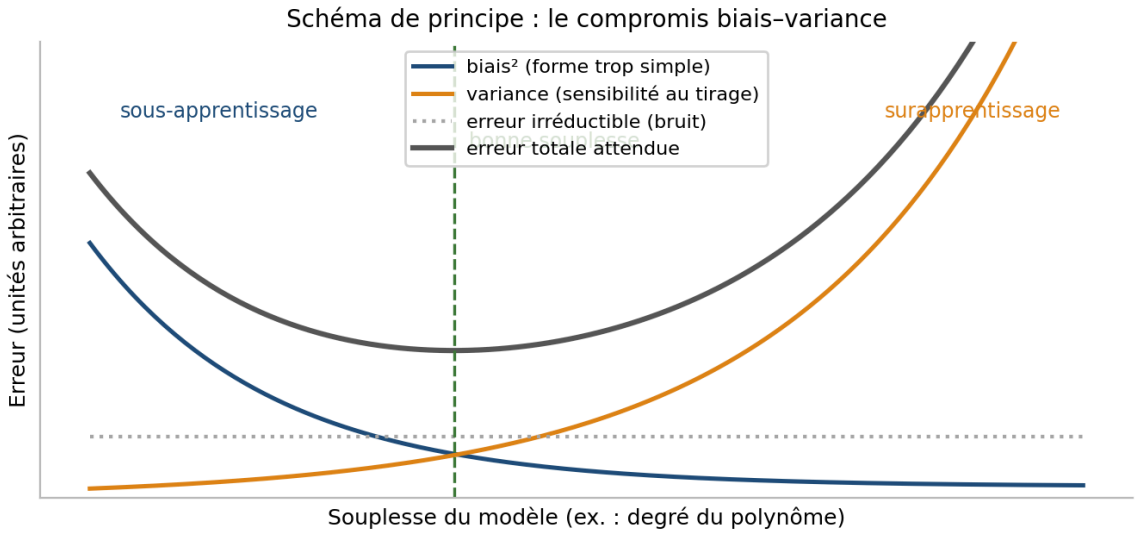


Figure 7 : le compromis biais–variance. Quand la souplesse augmente, l'erreur de biais (gris) diminue mais l'erreur de variance (bleu) augmente ; l'erreur totale (orange) passe par un minimum — ici autour du degré 2, cohérent avec le tableau 1.

Analogie. Viser une cible avec un fusil mal réglé produit des impacts groupés mais décalés du centre : erreur systématique = biais. Viser avec un fusil instable produit des impacts centrés en moyenne mais très dispersés : variance. Un bon tireur cherche une arme à la fois bien réglée *et* stable — pas l'une au détriment de l'autre.

Exemple guidé — Attribuer chaque erreur à sa source.
Sur le fil rouge, attribuons les erreurs observées à leur source dominante.

1. **Le degré 0 se trompe de ≈ 4–5 minutes partout.** Son erreur vient du biais : dire « toujours 11,3 minutes » ignore la tendance croissante ; aucun échantillon ne réparera cela.
2. **Le degré 12 passe de 0,84 (entraînement) à 6,02 (validation).** Son erreur nouvelle vient de la variance : ses 13 coefficients ont été calibrés sur la dispersion de 24 commandes précises ; d'autres 24 auraient donné une autre courbe tout aussi « parfaite ».
3. **Le degré 2 gagne avec 1,61.** Ni rigidité excessive (le terme en x^2 suit la courbure) ni sensibilité excessive (3 coefficients seulement à calibrer sur 24 points) : le compromis est bon.

Retenez le vocabulaire : un modèle « à fort biais » est rigide ; un modèle « à forte variance » est nerveux. Le choix du degré — ou, en 4.8, la validation croisée — sert à trouver l'équilibre.

À retenir

- Biais = erreur systématique de rigidité ; variance = sensibilité au tirage de l'échantillon.
- Plus de souplesse : moins de biais, plus de variance — l'erreur totale passe par un minimum.
- Sur le fil rouge, le minimum se situe au degré 2 : ni rigide, ni nerveux.

4.8 La validation croisée en k plis

Notre protocole a un point faible : le verdict dépend d'*un* découpage particulier. Avec 24 commandes d'entraînement et 160 de validation tirées au hasard, un autre tirage aurait donné d'autres MAE — peut-être assez différentes pour changer le candidat gagnant. La **validation croisée** répond à cette fragilité en faisant tourner les rôles.

Le principe : réunir entraînement et validation en un seul bloc, le découper en **k plis** de même taille, puis répéter k fois l'opération suivante — ajuster le candidat sur k−1 plis et l'évaluer sur le pli restant, chaque pli servant de validation *à son tour*. On obtient k mesures d'erreur ; leur **moyenne** est le score du candidat. Chaque observation a servi une fois de juge et k−1 fois de matière d'apprentissage : plus aucun découpage chanceux ne peut fausser la comparaison.

> **Définition.** La **validation croisée en k plis** (*k-fold cross-validation*) consiste à découper les données d'apprentissage en k sous-ensembles (les **plis**, *folds*), à ajuster le modèle k fois en laissant chaque fois un pli différent de côté pour l'évaluation, puis à moyenner les k erreurs obtenues. Le **jeu de test reste à part** et ne participe jamais à la rotation.

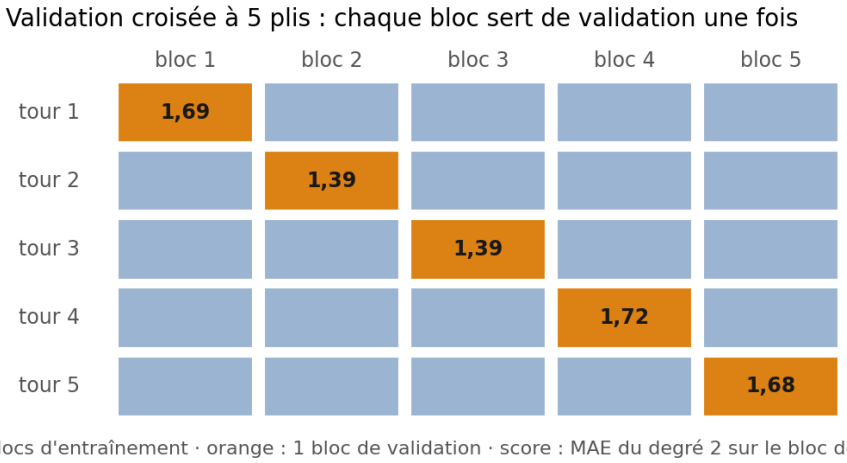


Figure 8 : validation croisée en 5 plis pour le candidat « degré 2 » (184 commandes). Chaque ligne est un tour : le pli orange sert de validation, les quatre bleus d'entraînement. Les MAE des 5 tours (1,69 ; 1,39 ; 1,39 ; 1,72 ; 1,68) donnent le score moyen : 1,57 minute.

Appliquée à nos 184 commandes d'apprentissage (24 + 160) avec k = 5, la procédure confirme le choix du degré 2 :

Candidat	Score moyen en validation croisée (min)
Degré 0 — constante	4,42
Degré 1 — droite	1,71
Degré 2 — courbe simple	**1,57 ← minimum**
Degré 12 — courbe très souple	1,65

Tableau 2 : scores moyens de la validation croisée en 5 plis. Le degré 2 l'emporte à nouveau ; avec davantage de données par ajustement (147 au lieu de 24), le degré 12 n'explose plus mais reste derrière.

Notez un enseignement secondaire : avec 147 commandes par ajustement au lieu de 24, le degré 12 cesse de s'effondrer (1,65 au lieu de 6,02). Plus de données calment la variance des modèles souples — mais le degré 2 reste devant. La validation croisée ne remplace ni le test (qui reste scellé pour le verdict final) ni le bon sens sur la souplesse ; elle rend la *comparaison* plus fiable.

> **Analogie.** Juger un élève sur une seule interrogation, c'est risquer de tomber sur son mauvais jour. La validation croisée, c'est lui faire passer cinq petites épreuves sur cinq chapitres différents et moyenner : chaque chapitre a été tour à tour « question d'examen » et « matière de révision ». Le jugement ne dépend plus du hasard du calendrier.

Exemple guidé — Interpréter les cinq scores d'un même candidat.
Le degré 2 obtient, tour par tour : 1,69 ; 1,39 ; 1,39 ; 1,72 ; 1,68 minute. Que faire de ces cinq nombres ?

1. **Ne pas chercher « le » bon chiffre.** Aucun des cinq n'est la vérité : chacun évalue le candidat sur un pli différent, avec la variation d'échantillonnage qui l'accompagne.
2. **Regarder la dispersion** : de 1,39 à 1,72, les scores restent resserrés → le candidat est *stable*, peu sensible au découpage. C'est la signature d'une variance faible (4.7).
3. **Moyenner pour comparer** : (1,69 + 1,39 + 1,39 + 1,72 + 1,68) / 5 ≈ 1,57 minute. C'est ce score moyen que l'on compare aux autres candidats (tableau 2).

On a fait X parce que… : moyenner des mesures prises sur des plis différents lisse la part de hasard de chaque découpage — le même réflexe que la moyenne de tirages au cours 2.

En pratique dans le code. `cross_val_score(modele, X, y, cv=5, scoring="neg_mean_absolute_error")` (scikit-learn) renvoie les 5 scores, en négatif par convention d'optimisation : on prend l'opposé de leur moyenne. La classe `KFold(n_splits=5, shuffle=True, random_state=graine)` permet de contrôler le découpage.

À retenir

- k plis → k ajustements, chaque pli servant de validation une fois ; le score du candidat est la moyenne des k erreurs.
- La validation croisée rend la comparaison insensible au hasard d'un découpage unique.
- Le test reste hors de la rotation, scellé jusqu'au verdict final.

PARTIE D — CHOISIR SES REPÈRES

4.9 MAE, RMSE, médiane des erreurs : trois mesures, trois sensibilités

Jusqu'ici, toutes nos comparaisons utilisent la MAE. Ce n'est pas la seule métrique possible, et le choix n'est pas neutre : chaque métrique « pardonne » différemment les grosses erreurs. Considérons un modèle dont cinq erreurs absolues valent 1, 1, 2, 1 et 20 minutes — quatre commandes bien prédites, une catastrophique.

- La **MAE** traite toutes les erreurs également : (1+1+2+1+20)/5 = **5,0 minutes**. La grosse erreur pèse proportionnellement à sa taille.
- La **RMSE** élève chaque erreur au carré avant de moyenner, puis prend la racine : $\sqrt{(1+1+4+1+400)/5} = \sqrt{81{,}4} \approx$ **9,0 minutes**. Le carré amplifie la grosse erreur : la RMSE la punit sévèrement.
- La **médiane des erreurs absolues** trie les valeurs (1, 1, 1, 2, 20) et prend le centre : **1 minute**. Elle décrit la commande « typique » et ignore la catastrophe.

Définition. La **racine de l'erreur quadratique moyenne**, notée **RMSE** (*root mean squared error*), est la racine carrée de la moyenne des carrés des résidus. La **médiane des erreurs absolues** (*median absolute error*) est la valeur centrale des erreurs absolues triées. Toutes deux s'expriment dans l'unité de la variable prédite.

$$\mathrm{RMSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}\left(y_i - \hat{y}_i\right)^2}$$

n : nombre d'observations évaluées ;
y_i : valeur observée de la i-ème observation (min) ;
$\hat{y}_i$: valeur prédite par le modèle (min) ;
la racine carrée ramène le résultat dans l'unité d'origine.

Comment lire cette formule. On reconnaît la famille de la MAE : mêmes résidus, même moyenne. Deux différences : les erreurs sont *carrées* avant la moyenne — une erreur de 20 devient 400, elle domine la somme — puis la racine carrée ramène le tout en minutes. Conséquence : la RMSE est toujours supérieure ou égale à la MAE, et l'écart entre les deux grandit avec la taille des plus grosses erreurs. Comparer MAE et RMSE d'un même modèle renseigne donc sur la présence d'erreurs exceptionnelles.

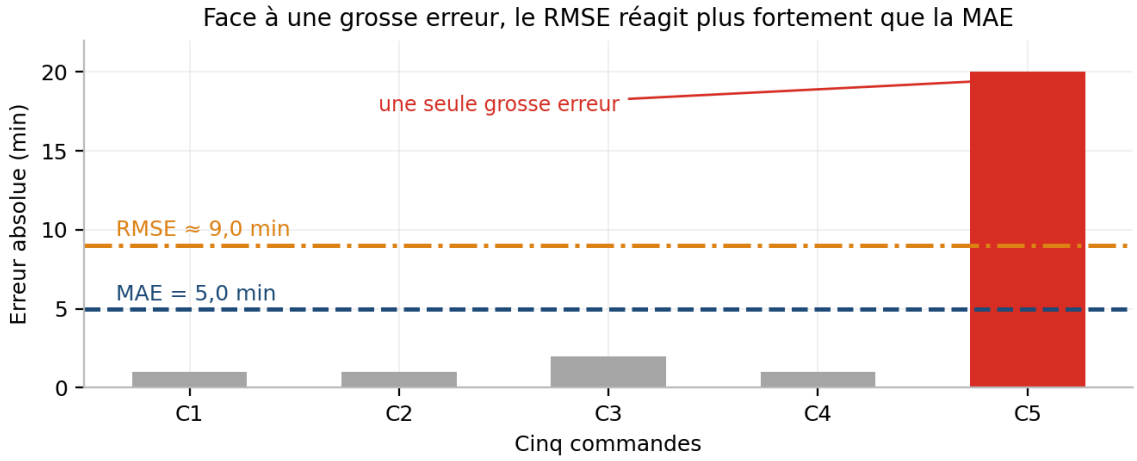


Figure 9 : les mêmes cinq erreurs absolues (1, 1, 2, 1, 20 minutes) vues par trois métriques. La médiane ignore la catastrophe ; la MAE la compte proportionnellement ; la RMSE la punit.

Quelle métrique choisir ? C'est une décision *métier*, à prendre **avant** de regarder les résultats (sinon on choisit après coup celle qui arrange son modèle préféré) :

- si une erreur de 20 minutes coûte *beaucoup plus* que vingt erreurs d'1 minute (crise de livraison, client perdu) → **RMSE**, qui refuse de les pardonner ;
- si chaque minute d'erreur coûte pareil (planification de capacité en moyenne) → **MAE**, lisible et proportionnelle ;
- si l'on veut décrire la commande *typique* sans se laisser définir par les catastrophes (communication grand public) → **médiane des erreurs absolues**.

Analogie. Pour juger la régularité d'un transporteur : la médiane décrit le trajet d'un jour ordinaire ; la MAE, le temps perdu en moyenne par trajet ; la RMSE répond à la question du directeur des risques — « les gros retards, même rares, coûtent-ils cher ? ». Même réalité, trois questions, trois chiffres.

Exemple guidé — Choisir une métrique pour l'entrepôt.
Trois scénarios d'usage du modèle fil rouge. Pour chacun, choisissons la métrique et justifions.

1. **Planifier les effectifs semaine par semaine.** Les erreurs se compensent en moyenne sur des centaines de commandes → **MAE** : chaque minute compte pareil, et la lecture « 1,8 minute d'erreur moyenne » parle à tous.
2. **Garantir un délai « prêt sous X minutes » à des clients grands comptes.** Une seule commande en très gros retard déclenche des pénalités → **RMSE** : elle punit les dérapages rares mais coûteux ; un modèle qui s'en dispense sera préféré.
3. **Afficher au magasin « votre commande est typiquement prête en X minutes ».** On décrit l'expérience de la commande médiane, sans promettre sur les cas extrêmes → **médiane des erreurs absolues**.

Dans tous les cas : la métrique est annoncée *avant* la comparaison des candidats, comme nous l'avons fait avec la MAE en 4.5.

À retenir

- MAE = moyenne des erreurs absolues ; RMSE = racine de la moyenne des carrés ; médiane = centre des erreurs absolues.
- La RMSE punit les grosses erreurs ; la médiane les ignore ; la MAE les compte proportionnellement.
- Le choix de la métrique est une décision métier, prise **avant** toute comparaison de modèles.

4.10 Le modèle de référence : à battre pour mériter d'exister

« MAE de 1,79 minute » — est-ce *bien* ? Un chiffre d'erreur, seul, ne dit rien : il faut un point de comparaison. Le plus exigeant des points de comparaison simples est le **modèle de référence** : le modèle le plus bête qui soit, celui qui n'utilise *aucune* variable d'entrée et prédit toujours la même valeur — la moyenne de la durée d'entraînement. C'était notre candidat « degré 0 ».

Sur le fil rouge, la référence prédit 11,3 minutes pour toute commande et se trompe en moyenne de 4,21 minutes en validation. Le modèle retenu (degré 2) fait 1,61 minute : il divise l'erreur par ≈ 2,6. Voilà une phrase qui parle à un décideur : « notre modèle se trompe 2,6 fois moins que le fait de prévoir toujours la durée moyenne ».

Définition. Un **modèle de référence** (*baseline model*) est un modèle simple, sans variables d'entrée ou presque, que tout modèle candidat doit battre pour justifier sa complexité. En prédiction d'une variable numérique, la référence canonique prédit toujours la moyenne de la variable cible calculée sur l'entraînement. Un modèle qui ne bat pas la référence n'apporte rien.

Vous avez déjà rencontré cette idée : le R^2 du cours 5 comparait la droite à la stratégie « toujours prédire la moyenne ». Le modèle de référence généralise ce réflexe à toutes les métriques et tous les modèles : avant de célébrer une erreur faible, on vérifie que la méthode triviale ne fait pas aussi bien — ou mieux.

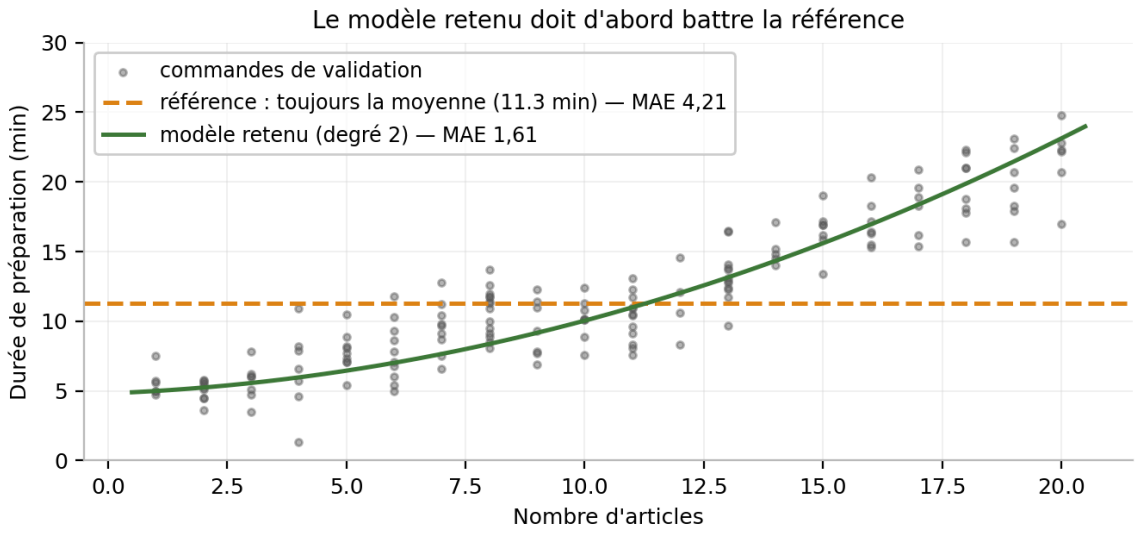


Figure 10 : MAE de validation de la référence (gris, 4,21 min) et des trois candidats à variables. Un modèle à droite de la ligne grise n'a pas mérité sa complexité.

Analogie. Avant d'acheter un GPS sophistiqué, on vérifie qu'il fait mieux que la stratégie « suivre tout droit la route principale ». Sinon, la sophistication est du décorum. En data, la référence est ce « tout droit » : gratuite, incassable, et étonnamment difficile à battre quand le signal est faible.

Exemple guidé — Tester un modèle contre la référence.
Un prestataire propose à l'entrepôt un modèle à 12 variables (jour, heure, météo, opérateur…) et annonce une MAE de validation de 3,9 minutes. Faut-il l'acheter ?

1. **Identifier la référence pertinente** : prédire toujours la durée moyenne d'entraînement → MAE de validation 4,21 minutes, déjà connue, gratuite.
2. **Comparer sur le même jeu et la même métrique** : 3,9 contre 4,21 — le modèle gagne, mais de 7 % seulement.
3. **Comparer avec l'existant** : notre degré 2 à une seule variable fait 1,61 minute. Le modèle du prestataire est à la fois plus complexe et bien moins bon que l'existant : il ne survit pas au test de la référence « enrichie » — le meilleur modèle simple déjà en place.

La discipline : tout nouveau modèle doit battre la référence triviale *et* le meilleur modèle simple disponible, sur le même jeu et la même métrique.

À retenir

- La référence canonique prédit toujours la moyenne d'entraînement ; ici elle se trompe de 4,21 minutes en validation.
- Un modèle qui ne bat pas la référence n'apporte rien, quelle que soit sa sophistication.
- Le R^2 du cours 5 est un cas particulier de ce réflexe : comparer au « toujours prédire la moyenne ».

PARTIE E — LES LIMITES DE L'ÉVALUATION

4.11 La fuite de données : quand les jeux ne sont pas vraiment séparés

Le protocole des trois jeux repose sur un pilier silencieux : les jeux doivent être **vraiment indépendants**. Tirer les lignes au hasard ne suffit pas toujours. Imaginez qu'un même client passe cinq commandes dans la semaine, et que le hasard en mette trois à l'entraînement et deux au test. Le modèle peut alors « apprendre le client » — ses habitudes de commande, sa zone de livraison — plutôt que la relation générale articles → durée. Au test, il retrouve un client qu'il connaît déjà : l'erreur mesurée sera flatteuse, car les données ont *fuité* d'un jeu à l'autre.

Définition. Il y a **fuite de données** (*data leakage*) lorsqu'une information issue des observations d'évaluation influence, directement ou indirectement, la construction ou le choix du modèle — par exemple lorsque des lignes liées (même client, même magasin, même journée) sont réparties entre entraînement et évaluation. La parade : la **séparation par groupes** (*group split*), qui affecte chaque groupe tout entier à un seul jeu.

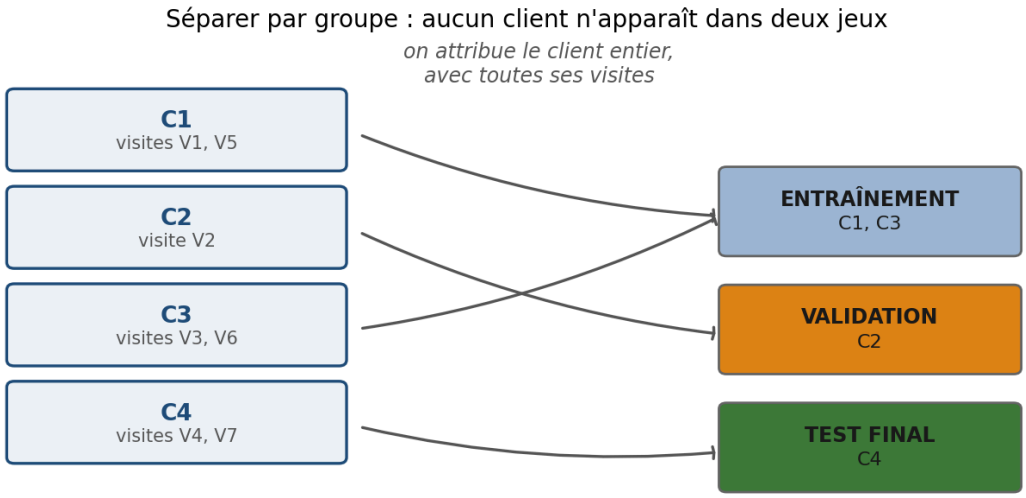


Figure 11 : à gauche, un tirage ligne par ligne éparpille les cinq commandes d'un même client (pastilles de même couleur) entre les jeux — fuite. À droite, la séparation par groupes garde chaque client dans un seul jeu.

Analogie. Pour savoir si un correcteur notationne équitablement, on ne lui fait pas corriger deux copies du même élève dans deux lots différents : s'il reconnaît l'écriture au second lot, sa note n'est plus neutre. Toutes les copies d'un même élève doivent rester dans le même lot — c'est la séparation par groupes.

D'autres fuites sont plus subtiles : calculer la durée moyenne de référence sur *toutes* les commandes avant de découper (la moyenne contient alors l'information du test), ou utiliser comme variable d'entrée une information qui ne sera pas connue au moment de la prédiction (le nombre d'articles *réellement préparés*, par exemple, connu seulement après coup). La question réflexe : « cette information était-elle disponible, sous cette forme, avant la prédiction, et sans toucher aux données d'évaluation ? »

Exemple guidé — Débusquer trois fuites.
Trois procédures d'évaluation proposées à l'entrepôt. Lesquelles fuient, et comment les réparer ?

1. **« On mélange les 344 lignes au hasard, sans se soucier des clients. »** → fuite possible si des clients ont plusieurs commandes. *Réparation* : identifier le client de chaque ligne et découper par client, pas par ligne.
2. **« On calcule la durée moyenne des 344 commandes, on recentre les durées, puis on découpe. »** → fuite : la moyenne utilisée pour transformer les durées contient l'information des jeux d'évaluation. *Réparation* : ne calculer ce genre de statistique que sur l'entraînement, puis l'appliquer tel quel aux autres jeux.
3. **« On découpe par client ; tous les clients de l'entraînement sont absents de la validation et du test. »** → pas de fuite : chaque groupe est tout entier dans un seul jeu, et aucune statistique globale n'a été calculée avant le découpage.

À retenir

- Fuite de données : l'évaluation touche, même indirectement, à des informations liées à l'entraînement.
- Parade : séparer par **groupes** (client, magasin, journée) — un groupe tout entier dans un seul jeu.
- Question réflexe : « cette information était-elle disponible avant la prédiction, sans toucher aux données d'évaluation ? »

4.12 Règle vraie et coefficients estimés : ne pas confondre prédire et expliquer

Le modèle retenu a pour équation estimée $\hat{y} = 4{,}83 + 0{,}13\,x + 0{,}039\,x^2$. Or nous savons — parce que ce fil rouge est une simulation dont nous contrôlons la mécanique — que la tendance qui a engendré les durées est $5 + 0{,}35\,x + 0{,}025\,x^2$. Les deux courbes donnent des prédictions proches (pour 15 articles : 15,6 minutes prédites contre 15,9 « vraies »), mais leurs coefficients diffèrent nettement : 0,13 contre 0,35 pour le terme en x.

Ce décalage n'est ni un bug ni un échec : il est la conséquence de la variation d'échantillonnage (cours 2) sur 24 commandes d'entraînement, amplifiée par le fait que les termes x et x^2 se ressemblent beaucoup sur la plage observée — le modèle répartit l'effet entre les deux de façon un peu arbitraire. La leçon est double :

- **Un modèle peut bien prédire avec des coefficients « faux ».** Si votre objectif est de prédire la durée, l'écart des coefficients importe peu tant que l'erreur de test est bonne.
- **Réciproquement, on ne peut pas lire une histoire causale dans des coefficients estimés.** Dire « chaque article ajoute 0,13 minute » serait une sur-interprétation : un autre échantillon donnerait une autre répartition entre x et x^2. Prédire et expliquer restent deux ambitions distinctes (4.1).

> **Définition.** Les **coefficients estimés** (*estimated coefficients*) sont les valeurs calculées sur un échantillon particulier ; ils diffèrent en général des coefficients de la règle qui engendre les données, du fait de la variation d'échantillonnage. Prédire correctement ne garantit donc pas que les coefficients estimés racontent fidèlement le mécanisme sous-jacent.

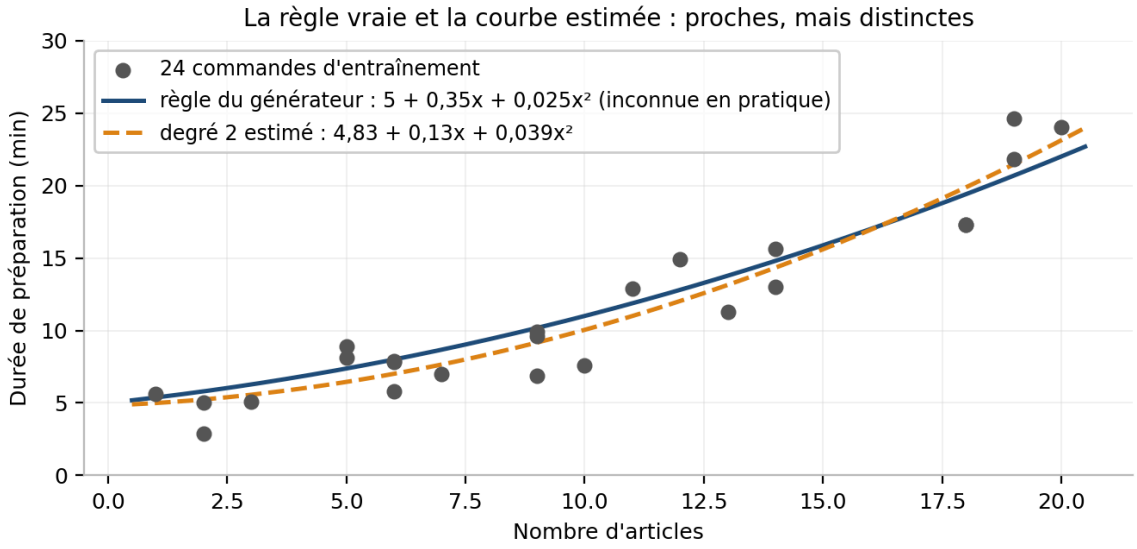


Figure 12 : la règle qui a engendré les durées (gris, connue ici parce que les données sont simulées) et la courbe estimée sur 24 commandes (bleu). Prédictions proches sur la plage observée, coefficients pourtant différents.

> **Analogie.** Un imitateur peut reproduire à s'y méprendre le *résultat* du discours d'un orateur sans en partager les *raisons*. Écouter l'imitation ne vous apprend rien sur les convictions de l'orateur. De même, des coefficients estimés imitent la règle vraie assez bien pour prédire — pas assez pour l'expliquer.

Exemple guidé — Répondre à une question d'interprétation.
Le directeur de l'entrepôt lit l'équation estimée et déclare : « chaque article ajoute 0,13 minute ; à 20 articles, le terme au carré ajoute 15,6 minutes — il faut donc surtout réduire les grosses commandes. » Deux erreurs se cachent dans sa phrase. Trouvons-les.

1. **Sur-interprétation des coefficients.** Les 0,13 et 0,039 sont des estimations instables : la règle vraie (0,35 et 0,025) répartit autrement l'effet entre les deux termes. Sur un autre échantillon, l'estimation pourrait donner 0,30 et 0,028. Conclure sur « l'effet d'un article » à partir de ces nombres est abusif.
2. **Confusion entre prédire et expliquer.** Même bien prédire ne dit pas *pourquoi* la durée augmente (trajets en rayon ? emballage ?), ni si réduire les articles par commande réduirait la durée — c'est une question causale, qui demande un dispositif adapté (cours 5).

La réponse honnête au directeur : « le modèle prédit bien la durée dans le périmètre observé — c'est validé par le test. Ce que ses coefficients racontent du fonctionnement de l'entrepôt, en revanche, ne peut pas être affirmé avec ces seules données. »

À retenir

- Coefficients estimés ≠ règle vraie : la variation d'échantillonnage déplace les valeurs, surtout quand des termes se ressemblent.
- Bien prédire ne donne aucun droit d'expliquer ; expliquer demande un dispositif dédié (cours 5).
- La bonne question à se poser : « mon objectif est-il de prédire ou de comprendre ? » — la réponse change ce que l'on peut conclure.

4.13 Le périmètre de validité : là où le modèle n'a jamais rien vu

Dernière limite, et non la moindre. Nos 344 commandes comptent entre 1 et 20 articles. Que vaut la prédiction pour une commande de 40 articles ? Personne ne le sait : aucune donnée ne couvre cette zone. La courbe de degré 2, si raisonnable entre 1 et 20, part en flèche au-delà — prolonger la courbe en dehors de la plage observée s'appelle **extrapoler**, et c'est le pari le plus risqué du métier.

Définition. Le **périmètre de validité** (*validity domain*) d'un modèle est la zone des valeurs d'entrée couverte par les données d'entraînement et d'évaluation. Prédire en dehors de cette zone s'appelle l'**extrapolation** (*extrapolation*) : l'erreur estimée sur le test ne dit rien de ce qui s'y passe, et l'évaluation doit être refaite dès que de nouvelles données la couvrent.

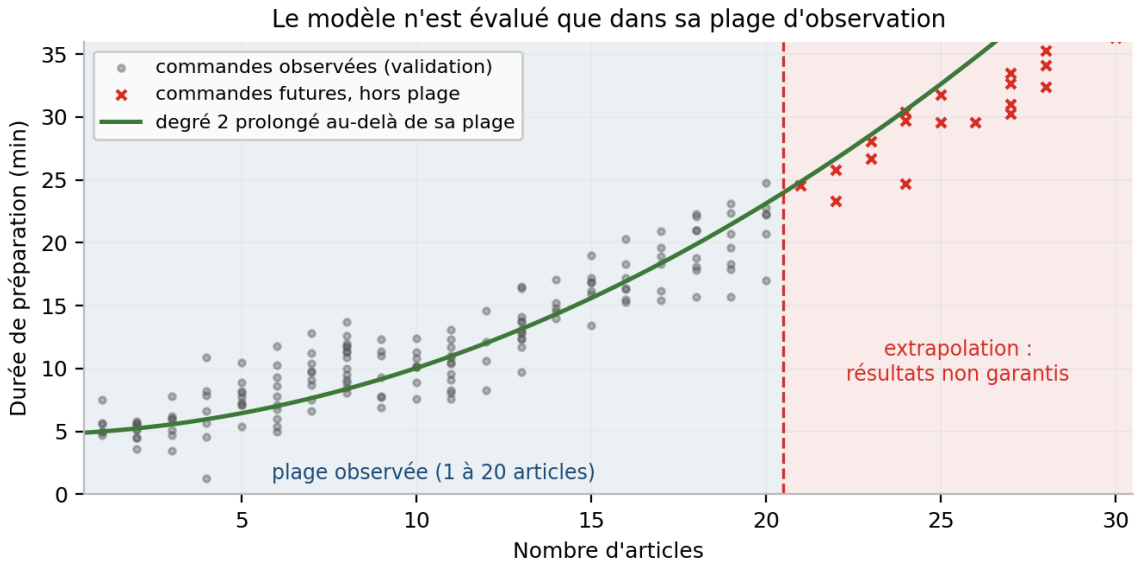


Figure 13 : le modèle de degré 2 prolongé au-delà de la plage observée (1–20 articles). Dans la plage, la MAE de test (1,79 min) est un repère solide ; en dehors (fond rouge), la courbe monte en flèche et rien ne garantit ses prédictions.

Analogie. Une carte routière fiable entre Paris et Lyon ne dit rien des pistes au-delà de Marseille : prolonger les routes « dans la même direction », c'est dessiner sur la mer. Un modèle est une carte : précise là où elle a été levée, muette au-delà.

Le périmètre ne concerne pas que la variable d'entrée : il couvre aussi le *contexte*. Le modèle a été évalué sur des commandes d'un entrepôt donné, avec ses rayonnages, ses équipes, sa saison. Un autre entrepôt, une réorganisation, les semaines de soldes : autant de changements qui sortent du périmètre — l'erreur annoncée ne s'y applique plus, il faut réévaluer.

Exemple guidé — Annoncer honnêtement une prévision.
La direction demande trois prévisions. Rédigeons pour chacune une réponse qui respecte le périmètre.

1. **« Commande de 12 articles demain. »** → dans la plage (1–20), contexte inchangé : « environ 14 minutes, avec une erreur moyenne d'environ 1,8 minute mesurée sur le test. »
2. **« Commande exceptionnelle de 45 articles pour un événement. »** → hors périmètre : « notre modèle n'a jamais vu de commande au-delà de 20 articles ; sa prédiction (environ 28 minutes) est une extrapolation non validée. Pour cette commande, mieux vaut une estimation manuelle, et il faudra enregistrer la durée réelle pour enrichir les données. »
3. **« Semaine des soldes, volumes doublés, intérimaires en renfort. »** → contexte changé : « l'erreur de 1,8 minute a été mesurée en fonctionnement habituel ; avec des intérimaires et des volumes inédits, elle ne vaut plus. On surveillera les erreurs de la semaine pour réévaluer. »

Le réflexe professionnel : toute prévision livrée avec son périmètre — « valable pour des commandes de 1 à 20 articles, dans cet entrepôt, en période normale ».

À retenir

- Le modèle n'est validé que là où les données l'ont couvert : entrées *et* contexte.
- Extrapoler = prédire hors du périmètre : l'erreur de test ne dit rien de ces zones.
- Toute prévision s'annonce avec son périmètre de validité.

5. Erreurs fréquentes

Erreur 1 — Évaluer un modèle sur ses données d'entraînement.
C'est l'erreur inaugurale de ce cours : l'erreur d'entraînement baisse mécaniquement avec la souplesse (tableau 1 : 0,84 minute pour le degré 12 !) et ne dit rien sur la capacité à prédire. **Réflexe** : toute MAE citée porte le nom de son jeu — entraînement, validation ou test.

Erreur 2 — Consulter le test plusieurs fois.
Regarder le test, changer de candidat, regarder à nouveau : le test devient de la validation déguisée, et le verdict final est optimiste. **Réflexe** : le test ne s'ouvre qu'une fois le choix figé ; si le verdict déçoit, on le documente au lieu de tricher.

Erreur 3 — Découper ligne par ligne quand les lignes sont liées.
Cinq commandes d'un même client réparties entre les jeux, et le modèle « reconnaît » le client au lieu d'apprendre la relation générale : fuite de données. **Réflexe** : identifier le groupe de chaque ligne (client, magasin, journée) et découper par groupes entiers.

Erreur 4 — Choisir la métrique après avoir vu les résultats.
« La RMSE est mauvaise ? Prenons la médiane, elle est meilleure. » Choisir après coup la métrique qui arrange son modèle, c'est truquer le juge. **Réflexe** : la métrique est une décision métier (4.9), annoncée avec les candidats *avant* toute comparaison.

Erreur 5 — Prédire hors du périmètre sans le dire.
Le modèle validé sur 1–20 articles ne sait rien des commandes de 45 articles, ni de la semaine des soldes. **Réflexe** : toute prévision est livrée avec son périmètre de validité ; hors périmètre, on le dit et on prévoit une réévaluation.

6. Exercices

6.1 Auto-évaluation

Q1 (QCM). Quel jeu sert à choisir entre plusieurs modèles candidats ?
a) le jeu d'entraînement b) le jeu de validation c) le jeu de test d) les trois ensemble

Q2 (calcul). Sur quatre commandes de validation, les résidus d'un modèle valent +2, −5, +1 et −2 minutes. Calculez la MAE.

Q3 (vrai/faux). « Une fois le test consulté, si le résultat déçoit, on peut reprendre la validation pour choisir un autre modèle et réévaluer sur le même test. »

Q4 (QCM). Un modèle affiche une MAE de 0,7 minute en entraînement et de 5,4 minutes en validation. Le diagnostic le plus probable :
a) sous-apprentissage b) surapprentissage c) bon compromis biais–variance d) fuite de données

Q5 (vrai/faux). « La validation croisée en 5 plis rend le jeu de test inutile : on peut le supprimer du protocole. »

Q6 (réponse courte). Un même client apparaît dans 12 commandes du fichier. Pourquoi faut-il les garder ensemble dans le découpage ?

Q7 (QCM). Votre direction craint surtout les commandes en très gros retard, même rares. Quelle métrique privilégier ?
a) la MAE b) la médiane des erreurs absolues c) la RMSE d) le R^2

Q8 (réponse courte). Que doit vérifier un nouveau modèle sophistiqué avant d'être considéré comme « performant » ?

6.2 Application guidée — Choisir un modèle pour les frais de livraison

Le service livraison veut prédire les frais d'un colis (en €) à partir de son poids. Cinq polynômes candidats ont été ajustés sur l'entraînement, puis évalués (MAE, en €) :

Candidat	MAE entraînement (€)	MAE validation (€)
Référence : toujours la moyenne	14,9	15,2
Degré 1	8,2	8,6
Degré 2	6,1	6,0
Degré 3	5,4	6,4
Degré 5	4,0	7,9
Degré 9	2,7	11,3

Étape 1. La référence est-elle battue par tous les candidats ? Que peut-on déjà affirmer ?

Étape 2. Quel candidat retenez-vous, et sur quelle colonne fondez-vous le choix ?

Étape 3. Que diagnostiquez-vous pour les degrés 5 et 9 ?

Étape 4. Le candidat retenu obtient une MAE de 6,5 € sur le test. Rédigez la phrase d'annonce à la direction (un seul chiffre d'erreur, une comparaison, un périmètre si besoin).

6.3 Applications autonomes

Exercice A — Speedy Drive (révisions cours 2, 5 et 6). L'auto-école Speedy Drive veut prédire le temps de trajet domicile–centre d'examen (en minutes) à partir de la distance (en km). Une droite a été ajustée par moindres carrés sur les trajets d'entraînement : $\hat{y} = 1{,}5\,x + 4$.

Cinq trajets de *validation* (non utilisés pour l'ajustement) :

Distance x (km)	2	4	5	8	10
Durée observée y (min)	6,8	10,5	11,0	15,5	19,7

A1. Calculez la prédiction de la droite pour chaque trajet, puis la MAE de validation.

A2. La durée moyenne des trajets d'*entraînement* était de 12,7 minutes. Calculez la MAE de validation du modèle de référence (« toujours 12,7 minutes »). La droite mérite-t-elle d'exister ?

A3. Deux collègues refont le découpage entraînement/validation. Découpage A : la droite obtient 2,9 min de MAE de validation, une courbe de degré 3 obtient 2,7 min. Découpage B : la droite obtient 2,8 min, la courbe 3,0 min. Lequel des deux modèles choisir, et quelle procédure du cours faut-il appliquer pour trancher proprement ?

Exercice B — La note MarketPredict. La start-up MarketPredict vous présente un modèle qui « prédit le panier moyen des clients avec une erreur de 2 € ». En lisant sa documentation, vous découvrez que : (1) les visites d'un même client ont été réparties au hasard entre l'entraînement et l'évaluation ; (2) l'« erreur de 2 € » a été mesurée sur le jeu de test, qui a servi « une vingtaine de fois pour calibrer les réglages » ; (3) le modèle a été évalué sur les visites de 2025 et doit prédire celles de 2027.

Rédigez une note de dix lignes maximum à votre responsable : identifiez les trois problèmes, expliquez pourquoi chacun fausse l'erreur annoncée, et proposez le protocole correct.

7. Fiche récapitulative

Notion	L'essentiel
Trois ambitions	Décrire (fidélité du résumé), expliquer (dispositif causal), prédire (erreur sur du **nouveau**). Trois juges différents.
Modèle, degré	Ajuster = calculer les coefficients sur l'entraînement. Le degré règle la souplesse ; on annonce candidats et critère *avant* de comparer.
MAE	Moyenne des |résidus|, dans l'unité de la variable. Se cite toujours avec son jeu : « MAE de test : 1,79 min ».
RMSE, médiane	RMSE : punit les grosses erreurs. Médiane : les ignore. La métrique est une décision métier, prise avant les résultats.
Trois jeux	Entraînement = ajuster ; validation = choisir ; test = estimer **une seule fois**. Réutiliser le test = validation déguisée.
Surapprentissage	Entraînement très bas / validation dégradée : le modèle a mémorisé la dispersion. Sous-apprentissage : élevé partout. Diagnostic sur l'écart des colonnes.
Biais–variance	Biais = rigidité (erreur systématique) ; variance = nervosité (sensible au tirage). La bonne souplesse minimise la somme.
Validation croisée	k plis, chacun juge une fois ; le score est la moyenne des k erreurs. Rend la comparaison insensible au découpage ; le test reste scellé à part.
Référence	« Toujours prédire la moyenne » : tout modèle doit la battre pour exister (généralisation du réflexe R^2).
Fuite de données	Lignes liées réparties entre les jeux, ou statistiques calculées avant le découpage. Parade : découper par groupes entiers.
Coefficients estimés	≠ règle vraie (variation d'échantillonnage). Bien prédire ≠ pouvoir expliquer.
Périmètre	Validé seulement là où les données couvrent (entrées *et* contexte). Extrapolation = prévision non garantie, à annoncer comme telle.

8. Pour aller plus loin

- **Régularisation** (Ridge, Lasso) : au lieu de choisir le degré, on pénalise les coefficients trop grands dans l'ajustement lui-même — une autre façon de dompter la variance. Vous la rencontrerez dans les suites de modèles à plusieurs variables.
- **Courbes d'apprentissage** : tracer l'erreur en fonction de la taille de l'entraînement dit si collecter plus de données réduira la variance — ou si seule une autre famille de modèles fera progresser.
- **Découpage temporel** : pour prédire le futur, on ne tire pas au hasard — l'entraînement est passé, le test est futur. Ce sera le protocole du cours 13 (séries temporelles).
- **Évaluer un classifieur** : quand la cible est une catégorie (malade / sain), MAE et RMSE ne s'appliquent plus ; d'autres métriques prennent le relais au cours 7.

9. Corrigé des exercices

Corrigé de l'auto-évaluation

> **Q1 — b).** La validation sert à comparer et choisir. L'entraînement sert à ajuster ; le test, à estimer une seule fois après le choix.
>
> **Q2.** Valeurs absolues : 2, 5, 1, 2. MAE = (2 + 5 + 1 + 2) / 4 = 10 / 4 = **2,5 minutes**.
>
> **Q3 — Faux.** Après consultation, le test a influencé le choix : il est devenu de la validation déguisée. Une réévaluation honnête exigerait un jeu de test nouveau.

Q4 — b). L'écart 0,7 / 5,4 est la signature du surapprentissage : le modèle a mémorisé la dispersion de l'entraînement.

Q5 — Faux. La validation croisée sert à *comparer* les candidats de façon robuste ; le test reste nécessaire pour *estimer* l'erreur finale du modèle retenu, une seule fois, sur des données jamais impliquées.

Q6. Si ses commandes sont réparties entre les jeux, le modèle peut mémoriser les spécificités du client à l'entraînement et le « reconnaître » à l'évaluation : fuite de données. On découpe par groupes (clients) entiers.

Q7 — c). La RMSE punit sévèrement les grosses erreurs : elle est alignée avec une crainte des dérapages rares mais coûteux.

Q8. Qu'il bat le modèle de référence (« toujours prédire la moyenne ») — et le meilleur modèle simple disponible — sur le même jeu et la même métrique.

Corrigé de l'application guidée (6.2)

Étape 1. Oui : toutes les MAE de validation des candidats (6,0 à 11,3 €) sont inférieures aux 15,2 € de la référence. Chaque candidat apporte donc quelque chose par rapport à « toujours prédire la moyenne ».

Étape 2. Le **degré 2**, fondé sur la colonne **validation** : c'est elle qui mesure la capacité à prédire (6,0 €, minimum). La colonne entraînement, qui préférerait le degré 9 (2,7 €), ne sert pas à choisir.

Étape 3. Surapprentissage : leurs erreurs d'entraînement chutent (4,0 et 2,7 €) pendant que la validation se dégrade (7,9 et 11,3 €) — ils mémorisent la dispersion de l'entraînement.

Étape 4. « Le modèle retenu se trompe en moyenne d'environ 6,5 € par colis (mesure sur test, une seule fois), contre 15,2 € pour la simple moyenne — une erreur 2,3 fois plus faible, valable pour des colis dans la plage de poids observée. »

Corrigé des applications autonomes (6.3)

Exercice A.

A1. Prédictions $\hat{y} = 1{,}5x + 4$: x = 2 → 7,0 ; x = 4 → 10,0 ; x = 5 → 11,5 ; x = 8 → 16,0 ; x = 10 → 19,0. Erreurs absolues : |6,8 − 7,0| = 0,2 ; |10,5 − 10,0| = 0,5 ; |11,0 − 11,5| = 0,5 ; |15,5 − 16,0| = 0,5 ; |19,7 − 19,0| = 0,7. MAE = (0,2 + 0,5 + 0,5 + 0,5 + 0,7) / 5 = 2,4 / 5 = **0,48 minute**.

A2. Référence : prédire toujours 12,7 min. Erreurs absolues : |6,8 − 12,7| = 5,9 ; |10,5 − 12,7| = 2,2 ; |11,0 − 12,7| = 1,7 ; |15,5 − 12,7| = 2,8 ; |19,7 − 12,7| = 7,0. MAE = (5,9 + 2,2 + 1,7 + 2,8 + 7,0) / 5 = 19,6 / 5 = **3,92 minutes**. La droite (0,48 min) divise l'erreur par ≈ 8 : elle bat largement la référence, elle mérite d'exister.

A3. Les deux découpages ne désignent pas le même vainqueur (la courbe gagne en A, la droite en B) : le choix dépend du hasard du tirage. Il faut une **validation croisée en k plis** : chaque candidat est évalué sur plusieurs plis successifs et l'on compare les scores *moyens*, ce qui neutralise la sensibilité au découpage. Le test reste scellé jusqu'au choix final.

Exercice B (éléments de note).

1. **Fuite par groupes** : des visites d'un même client sont à la fois à l'entraînement et à l'évaluation — le modèle « reconnaît » les clients au lieu d'apprendre une relation générale. Correction : découper par clients entiers.
2. **Test réutilisé ≈ 20 fois** : il a servi à calibrer les réglages, donc à *choisir* — c'est de la validation déguisée ; les « 2 € » sont optimistes. Correction : un test neuf, consulté une seule fois après le choix figé.
3. **Hors périmètre temporel** : évalué sur 2025, rien ne garantit 2027 (comportements, prix, catalogue évoluent). Correction : évaluer sur une période postérieure à l'entraînement (découpage temporel, amorce du cours 13) et prévoir une réévaluation régulière.