Compte rendu — Bibliothèque de cours de data analyse

Classification par thème des fichiers de cours (parties exercices et ateliers ignorées)

Méthodologie : chacun des 17 fichiers fournis (16 présentations PowerPoint et 1 document PDF) a été intégralement lu. Seul le contenu explicatif des cours a été retenu ; les sections « exercice », « atelier », « pause » et « travail étudiant » ont été écartées conformément à la demande. Les résumés ci-dessous décrivent le contenu pédagogique de chaque fichier.

Vue d'ensemble

Thème	Fichiers
Introduction à l'intelligence artificielle	2025-11_Introduction_à_l'IA_final.pptx
Statistiques descriptives et exploration de données	diapositives-3-1.pdf 2026-09-18_review_and_two_gaussians.pptx
Comparaison de groupes et tests d'hypothèses	2026-09-29_gaussian_project_and_distribution_comparison.pptx 2026-10-01_age_purchase_association.pptx
Corrélation, régression linéaire et causalité	2026-10-06_correlation.pptx
Python : programmation, architecture et performance	2026-09-22_python_architecture_packages_parallelism.pptx 2026-09-24_python_tools_parallelism_course.pptx 2026-09-25_python_architecture_et_sql.pptx
Git et travail collaboratif	2026-10-08_git_et_evaluation_modeles.pptx 2026-10-09_collaboration_et_simulation.pptx
Évaluation de modèles prédictifs	2026-10-08_git_et_evaluation_modeles.pptx 2026-10-09_collaboration_et_simulation.pptx
Business Intelligence : Power BI, Power Query et DAX	Cours_PowerBI_Desktop_PowerQuery.pptx ModuleBI_Modelisation_DAX.pptx
Pilotage de la performance : indicateurs, KPI et tableaux de bord	Indicateurs-cours 02.pptx Graphiques-KPI-cours.pptx Pilotage-de-la-performance-Dashboards-et-TB.pptx
Fichier d'exercices (annexe)	2026-09-22_afternoon_exercise_choices.pptx

Thème 1 — Introduction à l'intelligence artificielle

• 2025-11_Introduction_à_l'IA_final.pptx

Présentation générale de l'IA : définition de l'intelligence, rappels historiques (Aristote, Sénèque), fonctionnement d'un réseau de neurones (neurone, poids, seuil, entraînement), comparaison cerveau humain / usines d'entraînement (Colossus, GPUs), place des LLM (GPT, transformers), limites de l'IA « boîte noire » (biais, erreurs, opacité), taux de réussite des projets d'IA, impact industriel (ex. Amazon) et

perspectives (AGI, singularité, IA quantique, jumeaux numériques).

Thème 2 — Statistiques descriptives et exploration de données

• *diapositives-3-1.pdf*

Fondamentaux de lecture d'une distribution : centre, dispersion, forme (Où ? Combien ? Quelle forme ?). Choix des bins d'un histogramme, distinction effectif / fréquence / densité, lecture des silhouettes et familles de modèles (normale, lognormale, exponentielle). Effet de la taille d'échantillon (n) et de la graine (seed) sur la stabilité des résumés. Notions de pipeline de données vérifiable (générer → préparer → décrire → visualiser) et de gestion des valeurs inhabituelles (garder, corriger ou exclure, avec condition).

• *2026-09-18_review_and_two_gaussians.pptx*

Revue d'analyse défendable (quatre traces : population, décisions QC, preuves, conclusions). Journal de contrôle qualité (doublons, durées négatives), résumés par groupe (moyenne, médiane, écart-type, quartiles), histogrammes et boxplots. Modèles générateurs simulés (normale, lognormale, exponentielle décalée), distinction entre échantillon observé et modèle. Introduction au problème de la comparaison de deux groupes gaussiens et aux hypothèses H■ / H■ en préparation du test formel.

Thème 3 — Comparaison de groupes et tests d'hypothèses

• *2026-09-29_gaussian_project_and_distribution_comparison.pptx*

Du projet gaussien au test de Welch : lecture du projet de référence (architecture, preuves d'exécution), description des distributions (centre, dispersion, forme), notation probabiliste ($X \sim N(\mu, \sigma^2)$), population vs échantillon. Hypothèses H■ / H■ portant sur les populations, variation d'échantillonnage, simulation sous H■, p-value, statistique t de Welch et intervalle de confiance. Interprétation correcte (significatif ≠ important), limites d'application, distances globales (Wasserstein-2) et choix d'une stratégie de comparaison.

• *2026-10-01_age_purchase_association.pptx*

Rappel du test de Welch appliqué à un écart de montant d'achat A/B, convergence des estimateurs avec la taille d'échantillon. Exploitation d'un nouveau CSV (âge, attente, distance, montant) via nuages de points, puis introduction à la covariance et à la corrélation de Pearson. Ouverture du générateur de données pour distinguer lien direct, fluctuation d'échantillonnage et effet de composition (le groupe B étant plus âgé, la distance semble liée au montant par simple mécanisme simulé).

Thème 4 — Corrélation, régression linéaire et causalité

• *2026-10-06_correlation.pptx*

Cours approfondi sur la corrélation et la régression : covariance (unités, signe), corrélation de Pearson r entre –1 et 1, sensibilité aux points atypiques. Régression linéaire $y = ax + b$: calcul de la pente et de l'ordonnée à l'origine, propriété du point des moyennes, résidus, coefficient de détermination R^2. Distinction comprendre / prédire, variable de confusion (âge–distance), et introduction à la causalité : plan croisé (cross-over) pour tester un effet causal, de l'observation à l'essai.

Thème 5 — Python : programmation, architecture et performance

• *2026-09-22_python_architecture_packages_parallelism.pptx*

Programmation orientée objet (fonction, classe, attributs, méthodes, self, instances), architecture d'un projet Python (scripts vs notebooks, environnement virtuel .venv, requirements.txt, paquets avec

__init__.py). Exécution et performance : compilation vs interprétation, vectorisation NumPy, threads CPU, GIL, GPU et coût des transferts mémoire, lecture critique de l'indice TIOBE.

• *2026-09-24_python_tools_parallelism_course.pptx*

Boîte à outils Python : prédire avant d'exécuter, vérifier l'environnement (terminal vs notebook), diagnostic des imports, utilisation de VS Code (Pylance, débogage avec points d'arrêt, tests unittest). Assistance par IA : formuler une demande vérifiable, personnalisation des consignes, gestion du contexte partagé. Performance : vectorisation, benchmark et protocole de mesure, threads vs processus, GIL, GPU. Lecture de données : CSV avec pandas (types, valeurs manquantes, NaN), lambda, fiche de référence de fonctions.

• *2026-09-25_python_architecture_et_sql.pptx*

Conception d'un projet de simulation gaussienne (exigences : simuler deux groupes, produire un dataframe, organiser le calcul avec une classe, scripts d'opérations). Seconde partie : lecture de CSV et utilisation de SQL depuis Python (SQLite), avec rappels pandas (StringIO, types de colonnes, valeurs manquantes, positions et étiquettes NumPy vs pandas, lambda).

Thème 6 — Git et travail collaboratif

• *2026-10-08_git_et_evaluation_modeles.pptx*

Prise en main de Git : commits, branches, fusion, lecture de l'historique dans VS Code, dépôt local puis collaboration via GitHub (clone, add/commit/push, récupération des versions). Trois situations sur main : avance rapide (fast-forward), divergence puis fusion, conflit et résolution (KDiff3 ou VS Code), diagnostic des erreurs courantes.

• *2026-10-09_collaboration_et_simulation.pptx*

Approfondissement du travail collaboratif sur Git : deux copies d'un même dépôt, simulation de deux contributeurs, publication et récupération sur main, gestion des divergences et des conflits (choix du contenu, outils de résolution). Le fichier reprend également la partie évaluation des modèles (voir Thème 7).

Thème 7 — Évaluation de modèles prédictifs

• *2026-10-08_git_et_evaluation_modeles.pptx (partie 2)*

Évaluation d'une prédiction : pourquoi séparer les données (entraînement / validation / test final), quand utiliser le jeu de test. Quatre modèles candidats pour prédire un temps de préparation, erreur MAE, comparaison des erreurs d'entraînement et de validation, reconnaissance du surapprentissage, périmètre de validité (plage observée, stabilité des coefficients estimés).

• *2026-10-09_collaboration_et_simulation.pptx (partie 2)*

Reprise intégrale de la séquence d'évaluation des modèles (données séparées, MAE, surapprentissage, test final), avec application guidée en notebook et bilan de compréhension individuel.

Thème 8 — Business Intelligence : Power BI, Power Query et DAX

• *Cours_PowerBI_Desktop_PowerQuery.pptx*

Prise en main de Power BI Desktop : écosystème Power BI, cycle de vie d'un projet, interface (rubans, volets, trois vues), visuels (axes, valeurs, légendes). Import et préparation des données (sources, import vs connexion), Power Query : requêtes, transformations essentielles, types de données, pivot / dépivotage, ajout et fusion, paramètres reproductibles. Introduction au langage M (let / in) et cas

pratique de synthèse.

• *ModuleBI_Modelisation_DAX.pptx*

Modélisation des données dans Power BI : modèle en étoile vs flocon, tables de faits et dimensions, relations, cardinalités (1:N, N:N), direction du filtre, bonnes pratiques. Langage DAX : colonnes calculées vs mesures, fonctions d'agrégation, contexte de ligne et de filtre, CALCULATE, variables (VAR / RETURN), Time Intelligence (comparaison N-1, TOTALYTD), erreurs fréquentes à éviter.

Thème 9 — Pilotage de la performance : indicateurs, KPI et tableaux de bord

• *Indicateurs-cours 02.pptx*

Construction d'indicateurs statistiques : distinction mesure / indicateur, chaîne Données → Information → Intelligence → Décision, rappels de statistique descriptive (types de variables, moyenne vs médiane, dispersion, proportion). Types d'indicateurs selon le besoin, dangers (décider sans mesurer, mesurer la mauvaise chose), contextualisation (paradoxe de Simpson, absolu vs relatif), méthode pas à pas (quatre questions, définition Olist, seuil d'action, fiche indicateur, quatre piliers d'un bon indicateur).

• *Graphiques-KPI-cours.pptx*

Choix de la visualisation adaptée à la question : barres, courbes, camembert, barres empilées, nuage de points, histogramme, avec les pièges à éviter (troncature d'axe, double axe, 3D). Désignation des KPI : indicateur vs KPI, critères d'un bon KPI (aligné sur un objectif, spécifique, actionnable), les quatre niveaux de lecture, risque de multiplication des indicateurs.

• *Pilotage-de-la-performance-Dashboards-et-TB.pptx*

Dashboards et tableaux de bord : définition et rôles, typologie (stratégique, tactique, opérationnel), déclinaison de la stratégie (Balanced Scorecard, chaîne d'objectifs), méthodologies (Kaplan & Norton, GIMSI, OVAR), construction pas à pas, choix du support technique (outils BI type Power BI / Tableau, R Shiny, code), bonnes pratiques de livraison (définitions, sources, tableau vivant).

Annexe — Fichier d'exercices (hors périmètre)

• *2026-09-22_afternoon_exercise_choices.pptx*

Fiche d'atelier individuel : quatre options d'exercices Python (fonctions, classe + module, tests unitaires, boucle vs NumPy). Fichier à vocation d'exercices — hors périmètre du compte rendu.