

Statistiques descriptives

- Nous aide à simplifier et organiser de grandes quantités de données. Ça nous permet de décrire et résumer des données de grande taille (ex : moyenne, médiane).
- Ex : "La moyenne des notes est de 12/20."

Statistiques inférentielles

- Faire des prédictions ou généraliser à partir d'un échantillon (ex : tests d'hypothèses, intervalles de confiance).
- Ex : "Avec 95 % de confiance, la moyenne des notes de la population est entre 11,5 et 12,5."

Types de données

Variables qualitatives

Données généralement non numériques, qui décrivent des qualités, caractéristiques, ou attributs. Ces données sont surtout utilisées pour comprendre les opinions, comportements, expériences, et catégories.

- Nominale : Données utilisées pour labelliser, nommer ou classer des variables sans ordre particulier (ex : couleur des yeux, genre).
- Ordinale : Données qui ont un ordre naturel. La différence exacte entre les catégories ne peut pas être mesurée (ex : niveau de satisfaction : faible, moyen, élevé).

Variables quantitatives

- Discrètes : Valeurs qu'on compte, valeurs entières (ex : nombre d'enfants, résultat d'un dé).
- Continues : Valeurs qu'on mesure, valeurs décimales (on peut mettre une infinité de valeurs entre 2 valeurs)(ex : taille, poids).

Population VS échantillon

Mesures de tendance centrale

- **Moyenne :**
 - Moyenne d'un groupe
 - est calculée en faisant la somme de tous les éléments qu'on a, et le divisant ensuite par le nombre d'éléments.
 - formule : $(\sum x)/N$
- **Médiane :**
 - Valeur qui partage une série de données ordonnées en deux parties contenant chacune 50 % des observations
 - Est calculée en trouvant la valeur centrale pour un nombre impair d'observation, ou en faisant la moyenne des deux valeurs centrales pour un nombre pair d'observation.

Mesures de tendance centrale

- **Mode :**
 - Valeur la plus fréquente.
 - Peut ne pas exister (si aucune valeur se répète). Solution peut être uni-modale, bimodale, tri-modale, multimodale.
- **Classe modale :**

- Mode pour des données groupées.
- Un groupe ou une intervalle de valeurs la plus fréquente.
- La valeur du mode approximative (mode interpolé) peut parfois être calculée

$$\text{Mode} = L + \left(\frac{f_1 - f_0}{2f_1 - f_0 - f_2} \right) \times h$$

- formule :
- L = borne inférieure de la classe modale
- h = largeur de la classe modale
- f1 = fréquence de la classe modale
- f0 = fréquence de la classe précédente
- f2 = fréquence de la classe suivante
- Attention : si la classe précédente ou suivante n'existe pas on ne peut pas faire le calcul!
- Peut être estimé de la façon suivante : 3 fois la médiane- 2 fois la moyenne

Mesures de dispersion

- **Étendue :**
 - L'étendue est la différence entre la valeur maximale et minimale de nos données
 - formule : $\max(X) - \min(X)$
- **Variance**
 - La variance calcule à quel point les valeurs s'éloignent de la moyenne, c'est-à-dire la dispersion autour de la moyenne.

$$\sigma^2 = \frac{\sum (X - \mu)^2}{n}$$

- formule :
 - μ = moyenne
 - n = nombre de données
- **Écart-type**
 - L'écart-type est la racine carrée de la variance. Elle nous permet de nous remettre aux mêmes unités que les données originales.

$$\sigma = \sqrt{(\sigma^2)} = \sqrt{\left(\frac{\sum (X - \mu)^2}{n} \right)}$$

- formule :
- La règle du 68-95-99.7 : environ 68% des valeurs se situe à un écart-type de la moyenne, environ 95% se situe à deux écart-types, et 99.7% se situent à trois écart-types.

Différentes formules pour une population et un échantillon.

Ecart-type population :

$$\sigma = \sqrt{\frac{1}{N} \sum_{i=1}^N (x_i - \mu)^2}$$

Division par N

Ecart-type échantillon :

$$s = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2}$$

Division par N-1

Pourquoi cette différence?

- On utilise déjà les données pour calculer la moyenne
- Cela a pour effet de rendre les écarts à la moyenne un peu plus petits en moyenne que ceux qu'on aurait obtenu avec la vraie moyenne de la population
- En divisant par n , on sous-estime systématiquement l'écart-type de la population.
- La plupart des logiciels statistiques utilisent $n - 1$ par défaut lorsqu'on calcule l'écart-type d'un échantillon

Écart interquartile

- L'écart interquartile représente la distribution des 50% de données autour de la médiane.
- Il n'est pas sensible aux données extrêmes et nous permet donc de mieux représenter la distribution des données.
- L'écart interquartile représente l'écart entre le premier quartile $Q1$ et le troisième quartile $Q3$.
- formule : **$Q3 - Q1$**
 - formule $Q1$: médiane de la moitié basse des données
 - formule $Q3$: médiane de la moitié haute des données
 - Le deuxième quartile $Q2$ est la médiane.

Écart absolu moyen

L'écart absolu moyen (MAD) est la moyenne des écarts absolus entre les données et leur moyenne.

$$\frac{\sum_{i=1}^n |X_i - \mu|}{n}$$

formule :

Ce n'est pas la même chose que l'écart-type!

Indicateurs statistiques : Forme, Dispersion & Relations

Mesures de dispersion complémentaires

- MAD (Median Absolute Deviation) : Écart absolu à la médiane. Mesure de dispersion robuste, insensible aux valeurs aberrantes (outliers).
 $MAD = \text{médiane}(|X_i - \text{médiane}(X)|)$
- Coefficient de variation : Mesure la dispersion relative par rapport à la moyenne. Permet de comparer la variabilité de séries ayant des unités ou des ordres de grandeur différents.

$$CV = \left(\frac{\sigma}{\mu} \right) \times 100$$

(écart type / moyenne) x 100

Coefficients d'asymétrie (skewness)

- Évaluer si les données sont réparties de manière symétrique ou étalées vers la droite / la gauche.
- 1^{er} coefficient d'asymétrie de Pearson (basé sur le Mode) : Évaluer si les données sont réparties de manière symétrique ou étalées vers la droite / la gauche.

$$Sk_1 = \frac{\bar{x} - \text{Mode}}{s}$$

- (Moyenne – mode) / écart type
- 2^e coefficient d'asymétrie de Pearson (basé sur la Médiane) :

$$Sk_2 = \frac{3(\bar{x} - \text{Médiane})}{s}$$

- 3x (moyenne – médiane)/écart type
- Interprétation des coefficients d'asymétrie :
 - $Sk > 0$: Asymétrie positive (étalée vers la droite / majorité des données à gauche).
 - $Sk = 0$: Distribution symétrique.
 - $Sk < 0$: Asymétrie négative (étalée vers la gauche / majorité des données à droite).

Relation entre 2 variables X et Y

- Covariance (Cov(X,Y))
 - Mesure comment deux variables quantitatives évoluent conjointement.

$$\text{Cov}_p(X, Y) = \frac{1}{N} \sum_{i=1}^N (X_i - \mu_X)(Y_i - \mu_Y)$$

- $\text{Cov}_p(X, Y) = (1/n) \times \text{somme } N \times (X_i - \mu_X)(Y_i - \mu_Y)$
 - X_i : ième valeur de X
 - Y_i : ième valeur de Y
 - μ_X : Moyenne de X
 - μ_Y : Moyenne de Y
 - N : nombre d'observations
 - Coefficient de Corrélation de Pearson
 - Covariance normalisée comprise dans l'intervalle [-1 ; 1]
- $$\rho(X, Y) = \frac{\text{Cov}(X, Y)}{\sigma_X \cdot \sigma_Y}$$
- $\rho(X, Y) = \text{cov}(X, Y) / (\text{écart type de X} \times \text{écart-type de y})$
 - $\rho = 1$: Relation linéaire positive parfaite (quand X augmente, Y augmente proportionnellement).
 - $\rho = 0$: Absence de relation linéaire.
 - $\rho = -1$: Relation linéaire négative parfaite (quand X augmente, Y diminue proportionnellement).